

Régression logistique et classification **un-contre-tous**

Modélisation, estimation, calcul numérique et évaluation

Sylvain Maitre

15 juillet 2026

Résumé

Ce document répond à une question précise : comment apprendre, à partir d'observations étiquetées, une règle qui attribue l'une de plusieurs classes à une nouvelle observation ? Il établit d'abord le modèle logistique binaire depuis les log-cotes et une loi de Bernoulli, puis dérive la log-vraisemblance, le gradient et les conditions de l'optimisation. Le cas des quatre maisons est traité par quatre modèles « une classe contre le reste » : la décision OvR est le maximum de leurs scores, sans recours nécessaire à softmax. La préparation des données, la régularisation et l'évaluation sont développées comme des parties du modèle statistique, avec des exemples numériques et les contrôles nécessaires pour distinguer convergence sur l'apprentissage et performance hors échantillon.

Table des matières

1	Problème statistique et chaîne de traitement	1
2	Données, préparation et protocole expérimental	4
2.1	Matrice de design	4
2.2	Valeurs manquantes et standardisation	5
2.3	Partition et déséquilibre des classes	8
3	Modèle logistique binaire	10
3.1	Interprétation par les log-cotes	10
3.2	Frontière de décision	12
4	Estimation par maximum de vraisemblance	14
4.1	Gradient et correction des coefficients	17
4.2	Convexité, unicité et séparabilité	17
4.3	Régularisation facultative	19
5	Optimisation et calcul numérique	22
5.1	Formules numériquement stables	25
6	Extension multi-classes un-contre-tous	27
7	Évaluation et expérience reproductible	31
7.1	Matrice de confusion et mesures	31
7.2	Protocole minimal d'évaluation	33
7.3	Validation croisée : plis et répétitions	34

8	Notations et lecture des formules	37
8.1	Indices, effectifs et ensembles	37
8.2	Une observation et ses caractéristiques	39
8.3	Classes observées, cibles binaires et prédictions	39
8.4	Paramètres, score et probabilité binaire	40
8.5	Vraisemblance, perte et optimisation	40
8.6	Probabilités et opérateurs	43
9	Guide de lecture et ressources ouvertes	44
9.1	Premiers repères statistiques	44
9.2	Probabilités et calcul	44
9.3	Approfondir le formalisme	45
	Conclusion	46
A	Dérivations mathématiques	47
A.1	Inversion du logit	47
A.2	Gradient de la log-perte	47
A.3	Convexité de la log-perte	48
A.4	Direction de descente	48

Chapitre 1

Problème statistique et chaîne de traitement

Le fichier fournit des élèves dont la maison est connue. Le modèle cherche des régularités reliant leurs notes à leur maison, puis applique ces régularités à un élève absent du fichier d'apprentissage. Toute l'analyse porte sur l'écart entre réussir sur les élèves déjà vus et réussir sur de nouveaux élèves.

On observe m élèves. L'élève d'indice i est décrit par n variables numériques $\mathbf{x}_i \in \mathbb{R}^n$ et par une maison c_i appartenant à

$$\mathcal{C} = \{\text{Gryffindor, Hufflepuff, Ravenclaw, Slytherin}\}, \quad K = |\mathcal{C}| = 4.$$

L'objectif n'est pas d'expliquer parfaitement l'échantillon observé, mais de construire une règle $f : \mathbb{R}^n \rightarrow \mathcal{C}$ dont l'erreur reste faible sur des élèves nouveaux, issus du même mécanisme de génération des données.

Le terme *régression* décrit ici la modélisation d'un log-rapport de chances par une fonction affine. La variable réponse demeure qualitative : il s'agit donc bien d'un problème de classification [1, chap. 4].

Un échantillon d'apprentissage peut être représenté comme dans la table 1.1. Les valeurs numériques ne sont pas encore les entrées du modèle : elles devront être imputées si nécessaire, puis standardisées. La colonne House, au contraire, est la réponse à prédire.




FIGURE 1.1 – Chaîne de traitement. Les statistiques de préparation sont estimées exclusivement sur l'ensemble d'apprentissage, puis réutilisées sans les recalculer sur les données de test.

élève	Astronomy	Herbology	Charms	Flying	House
1	-487,9	5,7	-232,8	-26,9	Ravenclaw
2	-552,1	-6,0	-252,2	-113,5	Slytherin
3	-366,1	7,7	-227,3	30,4	Ravenclaw
4	697,7	-6,5	-256,8	200,6	Gryffindor

TABLE 1.1 – Extrait schématique du jeu d’entraînement. Chaque ligne représente une observation ; les quatre colonnes numériques illustrent un sous-ensemble des caractéristiques disponibles.

Ordre global : apprentissage, sélection et évaluation

1. **Partitionner.** Construire les indices d’apprentissage et de test, puis mettre le test à l’écart.
2. **Préparer.** Estimer imputation, moyennes et écarts-types sur l’apprentissage ; transformer les données avec ces valeurs.
3. **Organiser la sélection.** Réserver une validation ou construire des plis à l’intérieur des données disponibles pour l’apprentissage.
4. **Former les cibles OvR.** Pour chaque classe k , construire le vecteur binaire $\mathbf{y}_k$.
5. **Ajuster une configuration.** Pour chaque classe, initialiser θ_k , puis répéter scores, probabilités, gradient et mise à jour jusqu’au critère d’arrêt.
6. **Comparer les configurations.** Utiliser uniquement la validation pour choisir α , λ , le seuil ou tout autre hyperparamètre.
7. **Figurer le modèle.** Conserver la préparation, l’ordre des caractéristiques, les K vecteurs θ_k et l’ordre des classes.
8. **Prédire le test.** Appliquer la préparation conservée, calculer les K scores de chaque ligne et retenir leur maximum.
9. **Évaluer une fois.** Comparer prédictions et classes réelles du test ; produire matrice de confusion et mesures par classe.
10. **Archiver l’expérience.** Conserver graine, indices, hyperparamètres, historiques de convergence et résultats finaux.

Les cadres intitulés « sous-procédure » détaillent une opération appelée par cet ordre global. Ils ne forment pas une seconde séquence à exécuter de haut en bas : certains décrivent un calcul interne, d’autres un contrôle ou une méthode de sélection.

Risque de généralisation

La quantité pertinente est le risque de généralisation $R(f) = \mathbb{P}(f(X) \neq C)$. Comme la loi jointe de (X, C) est inconnue, on estime ce risque sur un ensemble de test qui n’a participé ni au choix des variables, ni à l’estimation des transformations, ni à l’ajustement des paramètres.

Concrètement, si un test indépendant contient 200 élèves et que 160 sont correctement classés, l’erreur test observée vaut $40/200 = 0,20$. Elle sert d’estimation du risque de généralisation : on estime qu’environ 20 % des futurs élèves comparables seraient mal classés. Ce nombre n’est ni la valeur exacte de $R(f)$ ni une garantie individuelle ; un autre échantillon de 200 élèves

donnerait vraisemblablement un résultat légèrement différent.

Décision et calibration probabiliste. Attribuer une maison à un nouvel élève est une tâche de *décision*. Estimer une probabilité d'appartenance bien calibrée est une tâche plus exigeante : parmi les élèves auxquels on attribue une probabilité proche de 0,8, environ 80 % devraient effectivement appartenir à la classe. OvR répond directement à la première question ; la seconde exige les précautions discutées au chapitre 6.

Par exemple, supposons que le modèle attribue une probabilité comprise entre 0,75 et 0,85 à Ravenclaw pour 50 élèves. Si 39 d'entre eux sont réellement Ravenclaw, la fréquence observée vaut $39/50 = 0,78$, proche des probabilités annoncées. Si seulement 20 le sont, la fréquence vaut 0,40 : le modèle peut encore classer correctement certains élèves par maximum des scores, mais ses nombres ne doivent pas être interprétés comme des probabilités bien calibrées.

Objets définis par le problème

Le jeu étiqueté fournit une matrice de caractéristiques et un vecteur de maisons. L'apprentissage produira des paramètres ; la prédiction transformera une nouvelle ligne de caractéristiques en une maison ; l'évaluation comparera le vecteur des maisons prédites au vecteur des maisons réelles. Ces objets restent distincts pendant toute la chaîne de traitement.

Chapitre 2

Données, préparation et protocole expérimental

2.1 Matrice de design

Une matrice de design est le tableau numérique effectivement reçu par le modèle. Chaque ligne décrit un élève ; chaque colonne décrit une caractéristique. Une colonne supplémentaire remplie de 1 permet d'ajouter le même terme constant au score de tous les élèves.

Après préparation, on ajoute une coordonnée constante à chaque observation :


$$\tilde{\mathbf{x}}_i = (1, x_{i1}, \dots, x_{in})^\top \in \mathbb{R}^{n+1}.$$

La matrice de design empile les observations par lignes,

$$\mathbf{X} = \begin{bmatrix} \tilde{\mathbf{x}}_1^\top \\ \vdots \\ \tilde{\mathbf{x}}_m^\top \end{bmatrix} \in \mathbb{R}^{m \times (n+1)}.$$

Cette convention fixe toutes les dimensions ultérieures : les paramètres sont des vecteurs colonnes de $\mathbb{R}^{n+1}$ et $\mathbf{X}\boldsymbol{\theta} \in \mathbb{R}^m$.

Sur trois élèves décrits par deux notes standardisées, la construction devient par exemple



une ligne = une observation ; une colonne = une caractéristique
la première colonne, constante, est associée à θ_0

$$\underbrace{\begin{bmatrix} 1 & -1,2 & 0,4 \\ 1 & 0,3 & -0,8 \\ 1 & 1,1 & 0,6 \end{bmatrix}}_{\mathbf{X} \ (3 \times 3)} \underbrace{\begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix}}_{\boldsymbol{\theta} \ (3 \times 1)} = \underbrace{\begin{bmatrix} \theta_0 - 1,2\theta_1 + 0,4\theta_2 \\ \theta_0 + 0,3\theta_1 - 0,8\theta_2 \\ \theta_0 + 1,1\theta_1 + 0,6\theta_2 \end{bmatrix}}_{\mathbf{X}\boldsymbol{\theta} = (z_1, z_2, z_3)^\top \ (3 \times 1)}$$

FIGURE 2.1 – Construction concrète d’une matrice de design. La colonne de 1 multiplie θ_0 dans chaque score et encode ainsi le terme constant. Ici $\mathbf{X} \in \mathbb{R}^{3 \times 3}$, $\boldsymbol{\theta} \in \mathbb{R}^3$ et $\mathbf{X}\boldsymbol{\theta} \in \mathbb{R}^3$.

Sous-procédure – Former la matrice de design

Entrée : m observations déjà préparées, chacune décrite par les mêmes n caractéristiques dans un ordre fixé. **Sortie :** une matrice $\mathbf{X} \in \mathbb{R}^{m \times (n+1)}$.

1. écrire les n valeurs de l’observation i sur la ligne i ;
2. ajouter à gauche une colonne de 1, associée au biais θ_0 ;
3. enregistrer l’ordre des colonnes, par exemple (1, Astronomy, Herbology, ...) ;
4. vérifier que chaque ligne contient $n + 1$ nombres et que $\mathbf{X}\boldsymbol{\theta}$ produit exactement m scores.

Avec deux caractéristiques, le rôle de la constante apparaît dans l’équation de la frontière. Sans première coordonnée égale à 1, le score serait $\theta_1 x_1 + \theta_2 x_2$ et la frontière passerait nécessairement par l’origine. Avec θ_0 , elle devient $\theta_0 + \theta_1 x_1 + \theta_2 x_2 = 0$ et peut se déplacer parallèlement à elle-même. Le biais est un paramètre du modèle qui règle cette translation de la frontière.

2.2 Valeurs manquantes et standardisation

Le calcul exige un nombre dans chaque case et des échelles comparables. Imputer consiste à définir la valeur utilisée lorsqu’une mesure manque. Standardiser consiste à exprimer ensuite chaque mesure par rapport à la moyenne et à l’écart-type calculés sur l’apprentissage.

Une régression logistique ne définit aucune opération sur une valeur manquante. Il faut donc choisir explicitement une règle, par exemple l’imputation médiane, et conserver pour chaque variable la valeur d’imputation utilisée. Une ligne ne doit être supprimée que si ce choix est justifié et documenté.




FIGURE 2.2 – Effet du biais pour des poids θ_1 et θ_2 fixés. Modifier θ_0 translate la frontière parallèlement à elle-même ; sans biais, elle est contrainte de passer par l’origine.

Exemple : les valeurs d’apprentissage d’un cours sont $\{4, 7, 9, 12, 100\}$. La médiane vaut 9 ; une note manquante est donc remplacée par 9. La moyenne vaudrait 26,4 et serait fortement déplacée par la valeur 100. Ce calcul explique l’intérêt possible de la médiane, mais ne démontre pas qu’elle est toujours optimale : l’imputation réduit artificiellement la dispersion et peut masquer un mécanisme de données manquantes informatif.

valeur observée		valeur préparée
4		4
7		7
manquante	médiane = 9 →	9
12		12
100		100

FIGURE 2.3 – Imputation médiane sur une variable. La valeur ajoutée est mise en évidence : elle n’a pas été observée et ne doit pas être confondue avec une mesure réelle. La médiane est calculée sur l’apprentissage seulement.

Pour une note brute r_j , on estime sur l’apprentissage

$$\mu_j = \frac{1}{m_{\text{tr}}} \sum_{i \in \mathcal{I}_{\text{tr}}} r_{ij}, \quad s_j = \sqrt{\frac{1}{m_{\text{tr}}} \sum_{i \in \mathcal{I}_{\text{tr}}} (r_{ij} - \mu_j)^2}, \quad x_j = \frac{r_j - \mu_j}{s_j}.$$

Le choix du diviseur (m_{tr} ou $m_{\text{tr}} - 1$) a peu d’effet ici, mais doit rester identique entre entraînement et prédiction. Si $s_j = 0$, la variable est constante sur l’apprentissage et doit être retirée.

La standardisation ne modifie pas la famille des frontières linéaires : elle reparamètre le modèle. Elle améliore en revanche le conditionnement numérique de l’optimisation et rend une éventuelle pénalisation comparable entre variables [1, sec. 4.6.3].

Le *conditionnement* décrit ici la sensibilité du calcul aux différentes directions de l'espace des paramètres. Si une variable varie autour de 10^3 et une autre autour de 10^{-2} , un même déplacement numérique de leurs coefficients ne modifie pas le score dans des proportions comparables. Les courbes de niveau du coût deviennent très allongées : la descente zigzague ou nécessite un petit pas. La figure 5.2 en donne la représentation géométrique ; la standardisation rapproche les échelles sans modifier l'information portée par l'ordre des observations.

Exemple de standardisation

Supposons que la note Astronomy ait, sur l'apprentissage, une moyenne $\mu = 20$ et un écart-type $s = 100$. Les notes brutes -180 , 20 et 170 deviennent respectivement -2 , 0 et $1,5$. La transformation conserve leur ordre et leurs positions relatives, mais fixe une origine et une échelle communes. Une valeur standardisée de $1,5$ signifie « un écart-type et demi au-dessus de la moyenne d'apprentissage » ; elle ne signifie ni 150% ni une probabilité de $1,5$.




FIGURE 2.4 – Correspondance complète entre l'axe des notes brutes et l'axe standardisé. Chaque flèche verticale relie deux écritures de la même observation : $-180 \leftrightarrow -2$, $20 \leftrightarrow 0$ et $170 \leftrightarrow 1,5$.

Fuite de données

Calculer μ_j , s_j , une médiane d'imputation ou choisir des variables à partir de l'ensemble complet transmet de l'information du test vers l'apprentissage. L'évaluation devient alors optimiste. La partition doit précéder toute transformation apprise des données.

Sous-procédure — Préparer une caractéristique numérique

Entrée : les valeurs brutes r_{ij} de la caractéristique j sur les lignes d'apprentissage. **Sortie** : la valeur d'imputation, μ_j , s_j et les valeurs transformées x_{ij} .

1. calculer la médiane des valeurs présentes et l'utiliser pour remplacer les valeurs manquantes ;
2. calculer ensuite μ_j et s_j sur cette colonne d'apprentissage complétée ;
3. transformer chaque valeur par $x_{ij} = (r_{ij} - \mu_j)/s_j$; par exemple, $r = 170$, $\mu = 20$, $s = 100$ donnent $x = 1,5$;
4. conserver médiane, μ_j et s_j , puis les réutiliser sans les recalculer ;
5. si $s_j = 0$, signaler une colonne constante et la retirer du calcul.

2.3 Partition et déséquilibre des classes

La partition produit deux listes d'indices disjointes : les indices d'apprentissage $\mathcal{I}_{\text{tr}}$ et les indices de test $\mathcal{I}_{\text{te}}$. Une ligne appartient à une seule liste. Toutes les transformations et tous les coefficients sont estimés depuis la première ; la seconde reste intacte jusqu'à l'évaluation finale.

Les deux listes vérifient

$$\mathcal{I}_{\text{tr}} \cap \mathcal{I}_{\text{te}} = \emptyset, \quad \mathcal{I}_{\text{tr}} \cup \mathcal{I}_{\text{te}} = \{1, \dots, m\}.$$

Pour construire une partition stratifiée, on regroupe d'abord les indices par classe. Dans chaque groupe, on mélange les indices avec une graine fixée, puis on affecte la proportion prévue à l'apprentissage et le reste au test. Les morceaux obtenus sont enfin réunis dans les deux listes. Les données numériques restent inchangées : seuls leurs indices sont répartis.

Les objets à conserver sont donc la graine et les deux listes d'indices. Les moyennes, écarts-types et valeurs d'imputation sont ensuite calculés uniquement sur les lignes désignées par $\mathcal{I}_{\text{tr}}$. Au moment du test, ces mêmes statistiques sont appliquées aux lignes de $\mathcal{I}_{\text{te}}$ sans nouvelle estimation.

Préservation des effectifs par classe. Avec 1 000 élèves, dont 900 majoritaires et 100 dans la classe étudiée, une répartition 80 %/20 % affecte séparément 80 % de chaque classe à l'apprentissage. On obtient ainsi $720 + 80 = 800$ lignes d'apprentissage et $180 + 20 = 200$ lignes de test. La stratification ne modifie pas le déséquilibre 90 %/10 % ; elle le reproduit dans les deux sous-ensembles.

classe	ensemble disponible	apprentissage (80 %)	test (20 %)
majoritaire	900	720	180
classe étudiée	100	80	20
total	1 000	800	200

$$900 = 720 + 180 \qquad 100 = 80 + 20$$

FIGURE 2.5 – Effectifs produits par une partition stratifiée 80 %/20 %.

Un *hyperparamètre* est fixé par le protocole et non estimé directement par le gradient. Par exemple, les coefficients θ sont des paramètres appris ; le taux α et la pénalisation λ sont des hyperparamètres. Si trois valeurs de λ donnent sur validation des exactitudes 0,78, 0,83 et 0,80, on retient la deuxième avant d'évaluer une seule fois le modèle sur le test. La validation croisée, construite explicitement au chapitre 7, généralise ce principe lorsque l'on ne souhaite pas réserver un unique ensemble de validation.

Quantités fixées après la préparation

La préparation produit les listes d'indices d'apprentissage et de test, une valeur d'imputation par caractéristique, une moyenne et un écart-type par caractéristique, puis les matrices numériques transformées. Ces quantités sont estimées une fois sur l'apprentissage et réutilisées sans modification pour la validation, le test et toute observation future.

Sous-procédure — Construire une partition stratifiée

Entrées : les numéros de lignes $1, \dots, m$, leur classe c_i , une proportion d'apprentissage et une *graine*. La graine est un entier qui initialise le générateur pseudo-aléatoire : reprendre le même entier reproduit le même mélange. **Sorties :** deux listes d'indices $\mathcal{I}_{tr}$ et $\mathcal{I}_{te}$.

1. former une liste de numéros de lignes par classe ; par exemple, une liste contient les 100 indices de la classe étudiée ;
2. mélanger chaque liste après initialisation avec la graine enregistrée ;
3. pour une proportion 80 %, placer les 80 premiers indices de cette liste dans $\mathcal{I}_{tr}$ et les 20 autres dans $\mathcal{I}_{te}$; répéter pour chaque classe ;
4. concaténer les morceaux obtenus : dans l'exemple complet, les deux listes contiennent respectivement 800 et 200 indices ;
5. vérifier qu'aucun indice n'apparaît deux fois, qu'aucun ne manque et que les effectifs par classe correspondent à la table 2.5 ;
6. enregistrer définitivement graine et listes avant de calculer médianes, moyennes ou écarts-types.

Chapitre 3

Modèle logistique binaire

Le cas binaire pose une question à deux réponses, par exemple « Ravenclaw ou non-Ravenclaw ? ». Les caractéristiques produisent d'abord un score réel, qui peut être négatif ou positif. La sigmoïde convertit ce score en un nombre entre 0 et 1 interprété comme une probabilité conditionnelle.

Considérons provisoirement des étiquettes $y_i \in \{0, 1\}$. On pose

$$z_{\theta}(\mathbf{x}) = \boldsymbol{\theta}^{\top} \tilde{\mathbf{x}}, \quad \sigma(z) = \frac{1}{1 + e^{-z}}, \quad p_{\theta}(\mathbf{x}) = \sigma(z_{\theta}(\mathbf{x})).$$

Cette paramétrisation définit la régression logistique binaire [1, 2, sec. 4.4].

Pour un ensemble de m observations, le même calcul est effectué simultanément : $\mathbf{X}\boldsymbol{\theta}$ produit un vecteur de m scores, puis la sigmoïde appliquée composante par composante produit un vecteur de m probabilités. Le vecteur $\boldsymbol{\theta}$ contient les seules quantités ajustées par l'apprentissage ; $\mathbf{X}$ reste fixé pendant les itérations.

3.1 Interprétation par les log-cotes

Les cotes comparent la probabilité de l'événement à celle de son contraire. Une probabilité de 0,75 correspond à des cotes $0,75/0,25 = 3$: l'événement est trois fois plus probable que son contraire. Le logarithme transforme les multiplications de cotes en additions, compatibles avec un score linéaire.

La fonction logistique est équivalente au modèle linéaire

$$\log \frac{\mathbb{P}(Y = 1 \mid X = \mathbf{x})}{\mathbb{P}(Y = 0 \mid X = \mathbf{x})} = \boldsymbol{\theta}^{\top} \tilde{\mathbf{x}}.$$

Cette égalité est précisément la formulation en log-cotes du modèle logistique [1, équations 4.17–4.18].

Le modèle suppose que les log-cotes sont une fonction affine des caractéristiques. La transformation inverse est

$$p = \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Le calcul reçoit donc un score réel $z = \boldsymbol{\theta}^\top \tilde{\mathbf{x}}$ et produit une probabilité comprise entre 0 et 1. Les étapes algébriques de l'inversion sont données à l'annexe A.1. Ainsi, à caractéristiques égales par ailleurs, augmenter x_j d'une unité multiplie les *cotes* de la classe positive par e^{θ_j} . Après standardisation, cette unité correspond à un écart-type de la variable brute. Cette interprétation porte sur les cotes conditionnelles, non sur une variation constante de probabilité.

Par exemple, $\theta_j = \log 2 \approx 0,693$ signifie qu'une augmentation d'une unité de x_j double les cotes, puisque $e^{\theta_j} = 2$. Si la probabilité initiale vaut 0,20, les cotes valent $0,20/0,80 = 0,25$; après doublement, elles valent 0,50, soit une probabilité $0,50/(1 + 0,50) = 1/3$. La probabilité n'a donc pas doublé : c'est bien le rapport de chances qui a été multiplié par deux.




FIGURE 3.1 – Passage entre probabilité, cotes et log-cotes. Ajouter $\log 2$ au score double les cotes, mais transforme ici la probabilité de 0,20 en $1/3$, pas en 0,40.




FIGURE 3.2 – La logistique est strictement croissante, vérifie $\sigma(-z) = 1 - \sigma(z)$ et $\sigma'(z) = \sigma(z)(1 - \sigma(z))$. Le seuil de probabilité $1/2$ correspond donc au score nul.




FIGURE 3.3 – La probabilité et la décision ne sont pas le même objet. La sigmoïde exprime une transition continue et conserve le degré de confiance ; le seuil produit seulement une étiquette binaire discontinue.

Sous-procédure — Calculer une sortie binaire

Entrées : une ligne $\tilde{\mathbf{x}} \in \mathbb{R}^{n+1}$ et les paramètres $\boldsymbol{\theta} \in \mathbb{R}^{n+1}$. **Sorties :** un score réel z et une probabilité p .

1. vérifier que $\tilde{\mathbf{x}}$ et $\boldsymbol{\theta}$ ont la même longueur et le même ordre de colonnes ;
2. calculer $z = \theta_0 + \theta_1 x_1 + \cdots + \theta_n x_n$;
3. calculer $p = 1/(1 + e^{-z})$ avec la forme stable du chapitre 5 ;
4. vérifier $0 < p < 1$ et conserver z séparément de p : OvR compare les scores.

3.2 Frontière de décision

La probabilité varie continûment, mais la décision exige une classe. Avec un seuil de 0,5, la frontière réunit les observations pour lesquelles le modèle hésite exactement entre les deux réponses. Dans deux dimensions, cette frontière est une droite ; dans davantage de dimensions, c'est un hyperplan.

Avec des coûts d'erreur symétriques, la règle de Bayes estimée est

$$\hat{y}(\mathbf{x}) = \mathbf{1}[p_{\boldsymbol{\theta}}(\mathbf{x}) \geq 1/2] = \mathbf{1}[\boldsymbol{\theta}^\top \tilde{\mathbf{x}} \geq 0].$$

La règle générale consiste à choisir la classe de probabilité conditionnelle maximale ; le seuil $1/2$ en est le cas binaire à coûts symétriques [1, sec. 2.4]. La frontière $\{\mathbf{x} : \boldsymbol{\theta}^\top \tilde{\mathbf{x}} = 0\}$ est un hyperplan. La transformation logistique rend la sortie bornée, mais n'introduit aucune non-linéarité dans la géométrie de la frontière exprimée dans les variables fournies au modèle.




FIGURE 3.4 – Exemple à deux caractéristiques. La droite pleine est la frontière $p = 0,5$; les droites pointillées sont des lignes d'égale probabilité. Elles sont parallèles parce que le score est affine. Les points sont illustratifs et ne représentent pas les données complètes du projet.

Sous-procédure — Appliquer une décision binaire

Entrée : une probabilité p et un seuil τ fixé avant le test. **Sortie :** une étiquette $\hat{y} \in \{0, 1\}$.

1. avec des coûts symétriques, choisir $\tau = 0,5$;
2. produire $\hat{y} = 1$ si $p \geq \tau$, sinon $\hat{y} = 0$;
3. exemple : $p = 0,71$ donne 1, tandis que $p = 0,23$ donne 0;
4. si un autre seuil est nécessaire, le sélectionner sur validation et enregistrer sa valeur avant l'évaluation du test.

Quantités produites par un modèle binaire

Une ligne préparée $\tilde{\mathbf{x}}$ et un vecteur de paramètres $\boldsymbol{\theta}$ produisent d'abord un score $z = \boldsymbol{\theta}^\top \tilde{\mathbf{x}}$, puis une probabilité $p = \sigma(z)$, puis une décision binaire après comparaison au seuil. L'apprentissage modifie $\boldsymbol{\theta}$; la prédiction utilise ensuite ce vecteur sans le réestimer.

Chapitre 4

Estimation par maximum de vraisemblance

L'apprentissage compare les probabilités annoncées aux réponses observées. Un paramétrage reçoit une vraisemblance élevée lorsqu'il attribue une forte probabilité aux étiquettes effectivement présentes dans le fichier. La log-perte est la même comparaison écrite sous la forme d'un coût à minimiser.

On suppose les observations indépendantes conditionnellement à leurs variables explicatives et

$$Y_i \mid X_i = \mathbf{x}_i \sim \text{Bernoulli}(p_i), \quad p_i = \sigma(\boldsymbol{\theta}^\top \tilde{\mathbf{x}}_i).$$

Ce modèle de Bernoulli conditionnel et son estimation par maximum de vraisemblance sont la construction standard de la régression logistique [1, 2, sec. 4.4.1].

À une valeur donnée de $\boldsymbol{\theta}$ correspondent donc trois objets successifs : le vecteur des scores $\mathbf{X}\boldsymbol{\theta}$, le vecteur des probabilités $\mathbf{p}$ et un coût scalaire $J(\boldsymbol{\theta})$ qui résume l'accord avec toutes les cibles. L'apprentissage réévalue ces objets après chaque modification de $\boldsymbol{\theta}$; les observations et leurs cibles restent fixes.

La masse de probabilité d'une Bernoulli peut s'écrire sous une forme unique pour les deux valeurs possibles de y_i :

$$\mathbb{P}(Y_i = y_i \mid X_i = \mathbf{x}_i; \boldsymbol{\theta}) = p_i^{y_i} (1 - p_i)^{1-y_i}.$$

Si $y_i = 1$, cette expression devient p_i ; si $y_i = 0$, elle devient $1 - p_i$. Sous l'hypothèse d'indépendance conditionnelle des observations, la probabilité jointe des réponses observées est le produit de ces contributions. C'est ce passage — et non une analogie avec les moindres carrés — qui produit la vraisemblance suivante.

Cette indépendance concerne les élèves une fois leurs caractéristiques fixées. Elle permet d'écrire, pour deux observations,

$$\begin{aligned} \mathbb{P}(Y_1 = y_1, Y_2 = y_2 \mid X_1 = \mathbf{x}_1, X_2 = \mathbf{x}_2; \boldsymbol{\theta}) \\ = \mathbb{P}(Y_1 = y_1 \mid X_1 = \mathbf{x}_1; \boldsymbol{\theta}) \mathbb{P}(Y_2 = y_2 \mid X_2 = \mathbf{x}_2; \boldsymbol{\theta}). \end{aligned}$$

Elle serait douteuse si plusieurs lignes correspondaient au même élève ou à des jumeaux dont les réponses restent liées après prise en compte des variables. Le produit de vraisemblance n'est donc pas une identité universelle : il traduit une hypothèse sur la manière dont les données ont été recueillies. La vraisemblance et sa log-vraisemblance sont

$$L(\boldsymbol{\theta}) = \prod_{i=1}^m p_i^{y_i} (1 - p_i)^{1-y_i},$$

$$\log L(\boldsymbol{\theta}) = \sum_{i=1}^m [y_i \log p_i + (1 - y_i) \log(1 - p_i)].$$

Maximiser L équivaut à minimiser la log-perte moyenne

$$J(\boldsymbol{\theta}) = -\frac{1}{m} \log L(\boldsymbol{\theta}) = -\frac{1}{m} \sum_{i=1}^m [y_i \log p_i + (1 - y_i) \log(1 - p_i)]. \quad (1)$$

L'équation (1) est l'opposé de la log-vraisemblance binomiale, également appelée log-perte ou entropie croisée binaire [1, équations 4.19–4.20]. Cette quantité est l'opposé du logarithme de la probabilité attribuée par le modèle aux étiquettes observées.

i	y_i	p_i	probabilité attribuée au résultat observé	ℓ_i
1	1	0,90	0,90	$-\log(0,90) = 0,105$
2	0	0,20	$1 - 0,20 = 0,80$	$-\log(0,80) = 0,223$
3	1	0,10	0,10	$-\log(0,10) = 2,303$
perte moyenne J				0,877

TABLE 4.1 – Calcul de la log-perte sur trois observations. La troisième prédiction, fausse et assurée, domine la moyenne ; c'est le comportement recherché par le maximum de vraisemblance.

Sous-procédure – Évaluer la log-perte

Entrées : m probabilités p_i et m cibles $y_i \in \{0, 1\}$. **Sortie :** un nombre $J(\boldsymbol{\theta})$; une valeur plus faible indique un meilleur accord avec les étiquettes observées.

1. calculer les scores z_i , puis les probabilités p_i ;
2. pour chaque ligne, prendre $a_i = p_i$ si $y_i = 1$, sinon $a_i = 1 - p_i$;
3. calculer $\ell_i = -\log(a_i)$; par exemple, $a_i = 0,9$ donne $\ell_i \approx 0,105$ et $a_i = 0,1$ donne $\ell_i \approx 2,303$;
4. calculer $J = m^{-1} \sum_i \ell_i$ et vérifier qu'il reste fini.




FIGURE 4.1 – Une prédiction correcte et assurée coûte presque zéro ; une prédiction erronée et assurée reçoit une pénalité non bornée.




FIGURE 4.2 – Comparaison pour $y = 1$. Les deux pertes sont minimales en $p = 1$, mais la log-perte pénalise beaucoup plus fortement une probabilité presque nulle attribuée à l'événement réellement observé. Elle découle en outre directement de la vraisemblance de Bernoulli.

4.1 Gradient et correction des coefficients

Le gradient indique comment une petite modification de chaque coefficient ferait varier le coût. Chaque observation contribue selon son erreur $p_i - y_i$ et selon ses caractéristiques. La somme de ces contributions fournit la correction de tous les coefficients en une opération matricielle.

Pour chaque observation, le programme calcule d'abord l'écart $p_i - y_i$ entre la probabilité produite et la cible binaire. Il pondère ensuite cet écart par les caractéristiques de l'observation, puis additionne les contributions. Le calcul complet s'écrit

$$\nabla J(\boldsymbol{\theta}) = \frac{1}{m} \mathbf{X}^\top (\sigma(\mathbf{X}\boldsymbol{\theta}) - \mathbf{y}). \quad (2)$$

Cette expression est le score de vraisemblance sous forme matricielle [1, équation 4.21]. Sa dérivation par la règle de chaîne figure à l'annexe A.2. Le gradient a bien la dimension $n + 1$: $\mathbf{X}^\top$ est de taille $(n + 1) \times m$ et le vecteur des résidus probabilistes est de taille m .

Le terme $(p_i - y_i)\tilde{\mathbf{x}}_i$ permet une lecture locale. Pour un positif $y_i = 1$ sous-estimé à $p_i = 0,1$, le résidu vaut $-0,9$: l'observation exerce une correction importante. Pour un positif déjà estimé à $0,99$, le résidu vaut seulement $-0,01$. Le gradient agrège ces corrections en tenant compte de la direction $\tilde{\mathbf{x}}_i$ de chaque observation.

Sous-procédure — Calculer le gradient

Entrées : $\mathbf{X} \in \mathbb{R}^{m \times (n+1)}$, $\mathbf{y} \in \{0, 1\}^m$ et $\boldsymbol{\theta} \in \mathbb{R}^{n+1}$. **Sortie :** $\mathbf{g} \in \mathbb{R}^{n+1}$, dont chaque composante indique la correction associée à un coefficient.

1. calculer $\mathbf{z} = \mathbf{X}\boldsymbol{\theta}$, de longueur m , puis $\mathbf{p} = \sigma(\mathbf{z})$;
2. calculer $\mathbf{r} = \mathbf{p} - \mathbf{y}$; un positif prédit à $0,1$ contribue par un écart $-0,9$;
3. calculer $\mathbf{g} = \mathbf{X}^\top \mathbf{r} / m$;
4. vérifier que $\mathbf{g}$ et $\boldsymbol{\theta}$ ont tous deux $n + 1$ composantes;
5. avant l'entraînement complet, comparer quelques composantes à la différence finie de la figure 5.5.

4.2 Convexité, unicité et séparabilité

Une fonction convexe a la géométrie générale d'une cuvette : descendre localement ne conduit pas vers un faux minimum isolé. Une cuvette peut toutefois posséder un fond plat, donc plusieurs paramètres équivalents. Avec des classes parfaitement séparées, le minimum non pénalisé peut même être repoussé à l'infini.

En notant $\mathbf{W} = \text{diag}(p_i(1 - p_i))$, la Hessienne vaut

$$\nabla^2 J(\boldsymbol{\theta}) = \frac{1}{m} \mathbf{X}^\top \mathbf{W} \mathbf{X}.$$

Cette Hessienne est la matrice d'information observée, à un facteur de normalisation près [1, équations 4.22–4.25]. Les coefficients diagonaux $p_i(1 - p_i)$ sont positifs ou nuls ; la Hessienne est donc positive semi-définie et J est convexe. Tout minimum local est global. La preuve matricielle est donnée à l'annexe A.3. La stricte convexité, et donc l'unicité du minimiseur, exige toutefois des conditions de rang et l'absence de directions dégénérées.

La distinction entre convexité et stricte convexité est importante. Une fonction convexe ne possède pas de minimum local trompeur, mais elle peut présenter un fond plat contenant plusieurs minimiseurs. Si deux colonnes de $\mathbf{X}$ sont identiques, par exemple, certains changements opposés de leurs coefficients laissent les scores inchangés. La prédiction peut alors être unique tandis que le vecteur de paramètres ne l'est pas.

En une dimension, $J(\theta) = (\theta - 1)^2$ est strictement convexe : sa courbure $J''(\theta) = 2$ est positive et son unique minimum est $\theta = 1$. La fonction $J(\theta_1, \theta_2) = (\theta_1 + \theta_2 - 1)^2$ est seulement convexe : tous les couples vérifiant $\theta_1 + \theta_2 = 1$ minimisent le coût. Cette seconde situation reproduit ce qui se passe lorsque deux colonnes de la matrice de design apportent exactement la même information.

Séparation complète

Si un hyperplan sépare parfaitement les deux classes, la vraisemblance non pénalisée peut croître lorsque $\|\boldsymbol{\theta}\| \rightarrow \infty$ sans atteindre de maximiseur fini. La convexité seule n'assure donc pas l'existence d'un minimiseur fini. Une pénalisation L^2 , ou une autre méthode adaptée, rétablit en général un problème bien posé [3].

Exemple : sur une caractéristique x , supposons que tous les négatifs vérifient $x < 0$ et tous les positifs $x > 0$. Le score $z = 10x$ classe déjà les observations avec assurance ; $z = 100x$ rend les probabilités encore plus proches de 0 ou de 1 et augmente encore la vraisemblance. Aucun coefficient fini n'est désigné comme optimum : le modèle pousse le coefficient vers $+\infty$. La pénalisation ajoute un coût croissant avec ce coefficient et empêche cette fuite.




FIGURE 4.3 – Séparation complète sur une unique caractéristique x . Tous les points appartiennent au même axe : les cercles ($y = 0$) sont à gauche du seuil et les triangles ($y = 1$) à droite. Multiplier le coefficient conserve le seuil mais rend les probabilités toujours plus extrêmes.

Sous-procédure — Diagnostiquer l'existence d'une solution finie

Entrées : la matrice $\mathbf{X}$, les cibles $\mathbf{y}$ et l'historique des paramètres. **Sortie :** un diagnostic : ajustement ordinaire, redondance des colonnes ou séparation complète.

1. repérer deux colonnes identiques ou proportionnelles : leurs coefficients ne peuvent pas être identifiés séparément ;
2. vérifier si une frontière classe toutes les observations sans erreur ;
3. pendant l'ajustement, suivre $\|\boldsymbol{\theta}\|_2$ en plus de J : une norme qui croît continuellement tandis que J baisse signale une séparation probable ;
4. dans ce cas, activer une pénalisation L^2 et documenter le diagnostic.

4.3 Régularisation facultative

La régularisation compare deux objectifs : bien reproduire les observations et éviter des coefficients excessivement grands. Le paramètre λ fixe le poids du second objectif. Une valeur nulle conserve le modèle initial ; une valeur croissante contracte progressivement les coefficients vers zéro.

Une pénalisation quadratique donne

$$J_\lambda(\boldsymbol{\theta}) = J(\boldsymbol{\theta}) + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2, \quad \nabla J_\lambda = \nabla J + \frac{\lambda}{m} (0, \theta_1, \dots, \theta_n)^\top.$$

Cette forme correspond à la régression logistique pénalisée par une norme quadratique [1, sec. 4.4.4]. Le symbole

$$\|\mathbf{w}\|_2^2 = \theta_1^2 + \dots + \theta_n^2$$

est le carré de la norme euclidienne des coefficients hors biais. Ajouter cette quantité au coût signifie qu'un ajustement n'est plus jugé uniquement sur son accord aux données : entre deux solutions de log-pertes voisines, on préfère celle dont les coefficients sont moins grands.

Le paramètre λ règle le compromis. Lorsque $\lambda = 0$, on retrouve le maximum de vraisemblance non pénalisé. Quand λ augmente, les coefficients sont progressivement ramenés vers zéro. À la limite, le modèle dépend de moins en moins des caractéristiques et tend vers une prédiction principalement gouvernée par le biais. Le biais n'est conventionnellement pas pénalisé : même si toutes les caractéristiques deviennent sans effet, le modèle doit encore pouvoir représenter la fréquence moyenne de la classe positive.

La réduction de variance signifie ici que de petites modifications de l'échantillon d'apprentissage provoquent généralement de moins grandes modifications des coefficients et des prédictions. Cette stabilité est achetée au prix d'un biais statistique supplémentaire : le modèle pénalisé n'essaie volontairement pas d'ajuster aussi étroitement les données observées. Le meilleur compromis n'est pas connu à l'avance.




FIGURE 4.4 – Chemins de coefficients sous pénalisation L^2 : leur amplitude décroît lorsque λ augmente.

On compare donc plusieurs valeurs de λ sur un ensemble de validation ou par validation croisée. Choisir λ sur le test reviendrait à adapter le modèle aux réponses du test ; celui-ci ne fournirait alors plus une évaluation indépendante. La figure 4.5 résume cette logique.




FIGURE 4.5 – Sélection de λ par minimisation de la log-perte de validation ; le test final reste exclu de cette sélection.

Sous-procédure — Sélectionner la pénalisation

Entrées : une grille explicite, par exemple $\lambda \in \{0, 10^{-2}, 10^{-1}, 1, 10\}$, et une partition de validation commune. **Sortie :** une valeur de λ choisie avant le test.

1. réinitialiser et ajuster un modèle pour chaque λ sur les mêmes lignes d'apprentissage ;
2. calculer pour chacun la log-perte sur les mêmes lignes de validation ;
3. construire le tableau $(\lambda, J_{\text{val}})$ et choisir la plus petite perte, avec une règle de départage fixée en cas d'égalité ;
4. enregistrer λ et les autres hyperparamètres retenus ;
5. appliquer ensuite le protocole final et consulter le test une seule fois.

Quantités recalculées pendant l'ajustement

À chaque itération, les paramètres courants produisent les scores, les probabilités, la log-perte moyenne et le gradient. La log-perte mesure l'état de l'ajustement ; le gradient produit la correction suivante. La régularisation ajoute sa contribution au coût et au gradient avant cette correction.

Chapitre 5

Optimisation et calcul numérique

La fonction de coût associe un nombre à chaque choix des coefficients. Optimiser consiste à déplacer progressivement ces coefficients vers une zone où ce nombre est plus faible. Le gradient donne la direction de plus forte hausse ; la descente suit donc la direction opposée, avec une longueur de pas réglée par α .

La descente de gradient simultanée produit la suite

$$\boldsymbol{\theta}^{[t+1]} = \boldsymbol{\theta}^{[t]} - \alpha \nabla J(\boldsymbol{\theta}^{[t]}), \quad \alpha > 0.$$

Cette itération est la descente de gradient par lot appliquée à la log-vraisemblance négative [4, chap. 8].

Le gradient indique la direction locale de hausse du coût ; son opposé indique donc une direction locale de baisse. Cette propriété résulte du développement au premier ordre présenté à l'annexe A.4. Elle reste locale : un pas trop grand peut dépasser la zone où cette approximation décrit correctement la fonction. Le mot *simultanée* est important : toutes les composantes du nouveau vecteur sont calculées à partir du même ancien vecteur. Un taux trop grand peut faire augmenter le coût ou provoquer une divergence ; un taux très petit rend la convergence inutilement lente.

Un arrêt robuste combine un nombre maximal d'itérations avec, par exemple,

$$\frac{|J^{(t+1)} - J^{(t)}|}{\max(1, |J^{(t)}|)} < \varepsilon \quad \text{ou} \quad \|\nabla J(\boldsymbol{\theta}^{[t]})\|_2 < \varepsilon.$$

Un simple nombre fixe d'itérations ne démontre pas la convergence.

Il faut distinguer trois diagnostics. Une baisse du coût indique que l'algorithme avance ; une petite norme du gradient indique qu'il approche un point stationnaire ; une bonne performance de validation indique que ce point produit un modèle utile hors échantillon. Aucun de ces faits n'implique automatiquement les deux autres.

Un *point stationnaire* est un point où le gradient est nul. Pour $J(\theta) = \theta^2$, le point 0 est stationnaire et constitue le minimum. Pour $J(\theta) = \theta^3$, le point 0 est aussi stationnaire, mais la fonction




FIGURE 5.1 – Diagnostic typique du coût : décroissance stable (trait plein) et oscillations dues à un pas trop agressif (pointillé). Cette figure est schématique ; le tracé du coût réel doit être conservé avec l'expérience.




FIGURE 5.2 – Courbes de niveau schématiques de $J(\theta_0, \theta_1)$ et trajectoire de descente. L'allongement des ellipses traduit un mauvais conditionnement : un même taux d'apprentissage progresse vite dans une direction et lentement dans l'autre. Les points successifs aboutissent ici au centre des courbes, le minimum. La standardisation tend à réduire cet effet d'allongement.

continue de décroître à gauche et de croître à droite : ce n'est pas un minimum. Dans le problème logistique convexe, un point stationnaire fini est un minimum global ; c'est la convexité établie au chapitre précédent qui autorise cette conclusion, pas la seule égalité $\nabla J = 0$.

Influence du taux d'apprentissage dans le cas scalaire. La fonction $J(\theta) = (\theta - 2)^2$ mesure ici la distance quadratique au minimum situé en $\theta = 2$. À chaque tour, le programme évalue la pente $J'(\theta) = 2(\theta - 2)$, la multiplie par α , puis soustrait cette correction à la valeur courante. Depuis $\theta^{[0]} = -2$, le pas $\alpha = 0,25$ rapproche successivement le paramètre du minimum, tandis que $\alpha = 1$ le fait passer alternativement d'un côté à l'autre sans réduire l'écart.




FIGURE 5.3 – Valeur du paramètre après chaque mise à jour. Les segments relient deux itérations successives ; ils représentent l'ordre des calculs, pas une grandeur supplémentaire.

Dans le modèle complet, la même séquence s'applique à un vecteur : calculer les scores, les probabilités, le gradient, puis mettre à jour simultanément tous les coefficients. Le suivi de J permet de détecter une décroissance, une oscillation ou une divergence.




FIGURE 5.4 – Cycle de calcul d'une itération de descente de gradient par lot. Chaque flèche correspond à une transformation nécessaire ; aucun réajustement des données préparées n'intervient dans cette boucle.

Sous-procédure — Exécuter une itération d'ajustement

Entrées : $\mathbf{X}$, $\mathbf{y}$, les paramètres courants $\boldsymbol{\theta}^{[t]}$ et le taux α . **Sorties :** $\boldsymbol{\theta}^{[t+1]}$, le coût $J^{[t]}$ et la norme du gradient $\|\mathbf{g}^{[t]}\|_2$.

1. calculer $\mathbf{z} = \mathbf{X}\boldsymbol{\theta}^{[t]}$, $\mathbf{p} = \sigma(\mathbf{z})$, $J^{[t]}$ et $\mathbf{g}^{[t]} = \mathbf{X}^\top(\mathbf{p} - \mathbf{y})/m$;
2. calculer toutes les composantes de $\boldsymbol{\theta}^{[t+1]} = \boldsymbol{\theta}^{[t]} - \alpha\mathbf{g}^{[t]}$ depuis le même ancien vecteur;
3. ajouter $J^{[t]}$ et $\|\mathbf{g}^{[t]}\|_2$ aux historiques;
4. arrêter si la tolérance ou le nombre maximal d'itérations est atteint;
5. sinon remplacer t par $t + 1$; si J augmente durablement ou devient non fini, interrompre et revoir α ou la stabilité des calculs.

5.1 Formules numériquement stables

Deux formules mathématiquement égales peuvent se comporter différemment sur un ordinateur, dont les nombres ont une taille et une précision finies. Les formes stables évitent de calculer des exponentielles immenses, puis de soustraire ou de logarithmer des valeurs arrondies à 0 ou 1.

Évaluer e^{-z} sans précaution peut déborder pour un score très négatif. Une sigmoïde stable utilise deux branches :

$$\sigma(z) = \begin{cases} 1/(1 + e^{-z}), & z \geq 0, \\ e^z/(1 + e^z), & z < 0. \end{cases}$$

Il est préférable de calculer directement la perte à partir du score,

$$\ell(y, z) = \log(1 + e^z) - yz = \text{softplus}(z) - yz,$$

L'identité résulte directement du remplacement $p = \sigma(z)$ dans la log-perte et constitue la forme usuelle de la perte logistique [7, sec. 7.1]. avec une primitive stable de type $\log(1 + e^z)$, plutôt que de calculer $\log(\sigma(z))$ après arrondi de la probabilité à 0 ou 1.

Contrôle du gradient

Avant tout entraînement, comparer le gradient analytique à une différence finie centrée sur un cas test de faible dimension :

$$\frac{\partial J}{\partial \theta_j} \approx \frac{J(\boldsymbol{\theta} + h\mathbf{e}_j) - J(\boldsymbol{\theta} - h\mathbf{e}_j)}{2h}.$$

Ce test détecte efficacement un signe inversé, un facteur $1/m$ oublié ou un problème d'orientation des matrices. Il valide la dérivation, pas l'ensemble du modèle.




FIGURE 5.5 – Exemple numérique cohérent avec $J(u) = (u - 0,7)^2 + 0,45$, $\theta_j = 0,2$ et $h = 0,5$. Les deux points de la corde appartiennent à la courbe. Sa pente vaut -1 , exactement comme $J'(0,2) = 2(0,2 - 0,7) = -1$ dans cet exemple quadratique.

Sous-procédure — Évaluer les formules sans instabilité numérique

Entrée : un score réel z , éventuellement de grande amplitude. **Sorties :** une probabilité et une perte finies, calculées sans dépassement de capacité.

1. si $z \geq 0$, utiliser $1/(1 + e^{-z})$; sinon utiliser $e^z/(1 + e^z)$, afin que l'exponentielle porte sur un nombre négatif ;
2. calculer la perte depuis z avec une primitive stable de softplus ;
3. tester des scores extrêmes, par exemple $z = -1000, 0, 1000$, et vérifier l'absence de valeur infinie ou indéfinie ;
4. sur un cas de faible dimension, comparer gradient analytique et différence finie avec une tolérance fixée avant l'entraînement complet.

Chapitre 6

Extension multi-classes un-contre-tous

OvR transforme le problème à quatre maisons en quatre questions binaires : « Gryffindor contre les autres », puis Hufflepuff, Ravenclaw et Slytherin. Pour un nouvel élève, les quatre modèles produisent quatre scores ; la maison associée au score maximal devient la prédiction.

Pour chaque classe $k \in \{1, \dots, K\}$, on construit la cible binaire

$$y_{ik} = \mathbf{1}[c_i = k]$$

. Cette réduction est la stratégie one-vs-rest : un classifieur binaire par classe, la classe considérée étant positive et toutes les autres négatives [5, sec. 4.1]. On ajuste ensuite indépendamment un paramètre θ_k pour chacun de ces problèmes. On obtient les scores $z_k(\mathbf{x}) = \theta_k^\top \tilde{\mathbf{x}}$ et les sorties binaires $q_k(\mathbf{x}) = \sigma(z_k(\mathbf{x}))$. La règle de décision est

$$\hat{c}(\mathbf{x}) = \arg \max_{k \in \{1, \dots, K\}} q_k(\mathbf{x}) = \arg \max_{k \in \{1, \dots, K\}} z_k(\mathbf{x}), \quad (3)$$

car σ est strictement croissante et commune aux K modèles. La décision par maximum des réponses binaires est la règle OvR usuelle [5].

L'apprentissage produit ainsi K vecteurs de paramètres $\theta_1, \dots, \theta_K$. Pour quatre maisons, une même matrice $\mathbf{X}$ est associée successivement à quatre vecteurs cibles $\mathbf{y}_1, \dots, \mathbf{y}_4$. À la prédiction, une observation préparée est multipliée par chacun des quatre vecteurs de paramètres ; les quatre scores obtenus sont comparés, et l'indice du maximum fournit la maison.

classe k	score z_k	sortie $q_k = \sigma(z_k)$	rang
Gryffindor	-1,99	0,12	3
Hufflepuff	-2,31	0,09	4
Ravenclaw	0,90	0,71	1
Slytherin	-1,21	0,23	2

TABLE 6.1 – Décision OvR sur une observation. Ravenclaw maximise à la fois z_k et q_k , car la même fonction strictement croissante σ est appliquée aux quatre scores. La somme des sorties vaut ici 1,15, non 1.




FIGURE 6.1 – Comparaison sur les scores de la table 6.1. OvR applique une sigmoïde séparée à chaque score ; softmax normalise conjointement les exponentielles des scores. Les deux méthodes choisissent ici Ravenclaw, mais leurs valeurs n'ont pas la même signification probabiliste.




FIGURE 6.2 – Architecture OvR complète pour les quatre maisons. La même observation traverse les quatre modèles binaires ; les quatre scores sont effectivement calculés, puis comparés. Aucun classifieur n'est caché derrière des points de suspension.

Sous-procédure — Ajuster et utiliser un modèle OvR

Entrées d'apprentissage : $\mathbf{X} \in \mathbb{R}^{m \times (n+1)}$ et les classes c_i . **État produit :** K vecteurs θ_k associés à K libellés. **Sortie de prédiction :** un libellé de classe.

1. pour la classe k , construire $y_{ik} = 1$ si $c_i = k$, sinon 0;
2. ajuster θ_k avec $\mathbf{X}$ et ce vecteur cible, puis répéter pour les K classes;
3. stocker les paramètres dans un ordre explicite, par exemple G, H, R, S, et conserver cet ordre avec le modèle;
4. pour une nouvelle ligne $\tilde{\mathbf{x}}$, calculer $(z_G, z_H, z_R, z_S) = (\theta_G^\top \tilde{\mathbf{x}}, \dots, \theta_S^\top \tilde{\mathbf{x}})$;
5. prendre la position de la plus grande valeur; par exemple $(-1,99, -2,31, 0,90, -1,21)$ renvoie la troisième position, donc Ravenclaw;
6. vérifier que quatre scores ont été produits et qu'aucun n'est non fini.

Scores, probabilités binaires et probabilités multiclassées

q_k estime la probabilité de la cible binaire « classe k contre le reste » dans le modèle k . Les K modèles étant ajustés séparément, le vecteur $(q_1, \dots, q_K)$ n'est pas construit comme une loi catégorielle et sa somme n'est pas contrainte à valoir 1. Ces nombres conviennent au classement de l'équation (3), mais ne doivent pas être présentés sans réserve comme un unique vecteur de probabilités multiclassées calibrées [6]. Une régression logistique multinomiale à fonction softmax est l'alternative cohérente si cet objectif probabiliste est central [1].

Règle de décision OvR

Pour classifier avec OvR, on calcule les quatre scores z_k et on retient directement $\arg \max_k z_k$. Il ne faut ni appliquer softmax à ces scores, ni normaliser les quatre sigmoïdes pour prendre cette décision. La section suivante présente softmax uniquement comme un autre modèle probabiliste multiclassées, pas comme une étape supplémentaire d'OvR.

Pour être explicite, la fonction softmax mentionnée dans la comparaison est

$$\mathbb{P}(C = k \mid \mathbf{x}) = \frac{e^{z_k}}{\sum_{r=1}^K e^{z_r}}.$$

Son dénominateur couple les K classes et impose une somme égale à 1. Dans OvR, au contraire, le dénominateur de $q_k = 1/(1 + e^{-z_k})$ ne contient aucun des autres scores. Cette différence algébrique explique la différence conceptuelle; elle ne signifie pas que softmax domine systématiquement OvR en exactitude.

Les négatifs d'un problème OvR sont généralement plus nombreux et plus hétérogènes que les positifs. L'exactitude binaire de chaque sous-modèle peut donc être trompeuse; il faut juger en priorité la décision multiclassées finale et examiner les performances par maison.

Deux situations méritent d'être distinguées. Si tous les scores sont négatifs, le modèle choisit tout de même le moins négatif: il ne possède pas spontanément de classe « inconnue ». Si plusieurs scores sont fortement positifs, il choisit également le maximum, sans signaler explicitement le conflit. Une politique de rejet éventuelle doit donc être définie et validée séparément; elle ne découle pas de la règle OvR.




FIGURE 6.3 – Régions de décision OvR schématiques dans un espace à deux caractéristiques. Chaque point est attribué à la région où un score est le plus grand. Les frontières entre deux régions satisfont $z_k(\mathbf{x}) = z_r(\mathbf{x})$; elles sont linéaires lorsque les scores le sont.

Exemple de rejet : on pourrait décider de ne produire aucune maison si le meilleur score est inférieur à -2 , ou si l'écart entre les deux meilleurs scores est inférieur à $0,1$. Ces seuils ne sont pas fournis par la régression logistique. Ils créent une nouvelle décision avec ses propres erreurs : davantage de rejets peut réduire les mauvaises attributions, mais laisse davantage d'élèves sans réponse. Les seuils doivent donc être choisis sur validation en fonction du coût réel d'un rejet et d'une erreur, puis évalués sur test.

État conservé par le modèle OvR

Avec K classes, l'apprentissage conserve K vecteurs de paramètres et l'ordre qui associe chaque vecteur à son libellé de classe. Une prédiction produit un vecteur de K scores dans ce même ordre. L'indice du score maximal est ensuite converti en libellé; cette correspondance fait partie du modèle entraîné.

Chapitre 7

Évaluation et expérience reproductible

7.1 Matrice de confusion et mesures

L'exactitude compte la proportion totale de décisions correctes. La matrice de confusion conserve davantage d'information : ses lignes indiquent les maisons réelles et ses colonnes les maisons prédites. Elle montre ainsi quelles classes sont bien reconnues et lesquelles sont confondues.

Pour un test de taille m_{te} , l'exactitude est

$$\text{accuracy} = \frac{1}{m_{te}} \sum_{i \in \mathcal{I}_{te}} \mathbf{1}[\hat{c}_i = c_i].$$

Cette quantité est l'estimateur empirique de la probabilité de classification correcte sur un échantillon test indépendant [1, chap. 7]. En français statistique, *exactitude* évite la confusion avec la *précision* au sens anglophone de $\text{precision} = TP / (TP + FP)$.

L'évaluation reçoit deux vecteurs de même longueur : les classes réelles (c_i) et les classes prédites ($\hat{c}_i$) du test. Chaque paire $(c_i, \hat{c}_i)$ incrémente une case d'une matrice $K \times K$. L'exactitude est calculée depuis la diagonale ; les mesures par classe utilisent ensuite les sommes des lignes et des colonnes. Aucun réentraînement n'intervient dans ces comptages.

La matrice de confusion M , définie par $M_{ab} = \#\{i : c_i = a, \hat{c}_i = b\}$, révèle quelles maisons sont confondues. Pour chaque classe, on complète par rappel, précision et score F_1 . La moyenne macro donne le même poids à chaque maison ; la moyenne pondérée tient compte de leurs effectifs. Une valeur unique ne remplace pas ces diagnostics.

Le score F_1 d'une classe est la moyenne harmonique de sa précision P et de son rappel R :

$$F_1 = \frac{2PR}{P + R}.$$

Il n'est élevé que si les deux quantités le sont. Avec $P = 0,80$ et $R = 0,50$, on obtient $F_1 \approx 0,615$, et non leur moyenne arithmétique 0,65.

Supposons ensuite deux classes : la première contient 900 observations et a un F_1 de 0,95 ; la seconde en contient 100 et a un F_1 de 0,40. La moyenne macro vaut $(0,95 + 0,40)/2 = 0,675$. La moyenne pondérée vaut $(900 \times 0,95 + 100 \times 0,40)/1000 = 0,895$. Le second nombre paraît bien meilleur parce que la classe majoritaire domine le calcul. Rapporter les deux indique si l'on privilégie la performance par individu ou l'équilibre entre classes.

réelle \ prédite	G	H	R	S	total
G	42	3	2	3	50
H	4	35	6	5	50
R	1	4	43	2	50
S	5	2	3	40	50
total prédit	52	44	54	50	200

TABLE 7.1 – Matrice de confusion fictive. Les bonnes décisions occupent la diagonale. L'exactitude vaut $(42 + 35 + 43 + 40)/200 = 0,80$, mais la ligne Hufflepuff révèle un rappel inférieur aux autres classes.

Dans cet exemple, le rappel de Hufflepuff vaut $35/50 = 0,70$, tandis que sa précision vaut $35/44 \approx 0,80$. La première quantité répond à « quelle part des vrais Hufflepuff est retrouvée ? » ; la seconde à « parmi les élèves prédits Hufflepuff, quelle part l'est réellement ? ». Ces dénominateurs différents expliquent pourquoi les deux mesures ne sont pas interchangeables.




FIGURE 7.1 – Rappel et précision par classe calculés à partir de la table 7.1. Une exactitude globale de 80 % masque notamment le rappel plus faible de Hufflepuff.

Sous-procédure — Construire les mesures de classification

Entrées : m_{te} classes réelles et autant de classes prédites, codées dans le même ordre de K libellés. **Sorties :** une matrice de confusion M , l'exactitude et les mesures par classe.

1. initialiser $M \in \mathbb{N}^{K \times K}$ à zéro ; les lignes représentent le réel et les colonnes la prédiction ;
2. pour chaque paire $(c_i, \widehat{c}_i)$, incrémenter $M_{c_i, \widehat{c}_i}$;
3. vérifier que la somme de toutes les cases vaut m_{te} ;
4. calculer l'exactitude comme somme diagonale divisée par m_{te} ;
5. pour la classe k , calculer rappel = diagonale/somme de la ligne et précision = diagonale/somme de la colonne, puis F_1 ;
6. signaler tout dénominateur nul et rapporter les valeurs par classe.

7.2 Protocole minimal d'évaluation

Un score isolé est impossible à interpréter sans connaître la manière dont il a été obtenu. Le protocole enregistre les données utilisées, leur préparation, les paramètres d'entraînement et les mesures finales afin que la même expérience puisse être reproduite et contrôlée.

Une expérience exploitable doit conserver :

1. les variables retenues et la politique de valeurs manquantes ;
2. la partition, sa stratification et sa graine ;
3. les statistiques de préparation apprises sur le train ;
4. α , ε , le nombre maximal d'itérations et, le cas échéant, λ ;
5. pour chaque classe, le coût initial, le coût final, le nombre d'itérations et la norme finale du gradient ;
6. sur le test : matrice de confusion, exactitude et mesures par classe.

Deux contrôles simples donnent du sens au résultat. Le modèle doit dépasser une référence majoritaire qui prédit toujours la maison la plus fréquente. Puis une permutation aléatoire des étiquettes doit ramener la performance vers le hasard ; une performance anormalement élevée après permutation signale souvent une fuite de données ou une erreur de protocole.

Exemple : si Gryffindor représente 35 % du test, prédire Gryffindor pour tout le monde donne déjà 35 % d'exactitude. Un modèle obtenant 38 % ne doit donc pas être comparé seulement au hasard uniforme de 25 %, mais aussi à cette référence majoritaire. Pour le contrôle par permutation, on mélange les maisons entre les lignes avant l'entraînement tout en conservant les notes. Le lien entre caractéristiques et réponse est alors détruit. Sur quatre classes équilibrées, une exactitude proche de 25 % est attendue ; obtenir encore 80 % indiquerait presque certainement que la réponse ou une information qui la révèle s'est introduite dans les variables ou dans la préparation.

Sous-procédure — Exécuter une évaluation contrôlée

Entrées : modèle figé, statistiques de préparation, indices de test et classes réelles. **Sortie :** un compte rendu reproductible, sans modification du modèle.

1. sélectionner les lignes désignées par $\mathcal{I}_{te}$ et leur appliquer les statistiques d'apprentissage déjà conservées;
2. produire exactement une prédiction par ligne, sans mise à jour des paramètres;
3. vérifier l'égalité des longueurs entre prédictions et classes réelles;
4. construire matrice de confusion, exactitude et mesures par classe;
5. comparer l'exactitude à celle de la classe majoritaire et exécuter séparément le contrôle par permutation sur une expérience d'apprentissage;
6. enregistrer résultats, paramètres, hyperparamètres, graine et indices.

7.3 Validation croisée : plis et répétitions

Une seule partition peut avantager ou désavantager un modèle par hasard. La validation croisée fait tourner le rôle de validation entre plusieurs blocs : chaque observation est évaluée une fois tout en restant hors de l'apprentissage correspondant. Répéter l'ensemble du découpage mesure la sensibilité à cette répartition aléatoire.

Un *pli* désigne un bloc d'observations. Dans une validation croisée à cinq plis, on découpe les données disponibles pour la sélection du modèle en cinq blocs disjoints $B_1, \dots, B_5$. On entraîne cinq fois le modèle : à chaque fois, quatre blocs servent à l'ajustement et le bloc restant sert à la validation.

	B_1	B_2	B_3	B_4	B_5
validation sur B_1	V	A	A	A	A
validation sur B_2	A	V	A	A	A
validation sur B_3	A	A	V	A	A
validation sur B_4	A	A	A	V	A
validation sur B_5	A	A	A	A	V

A : apprentissage V : validation

FIGURE 7.2 – Validation croisée à cinq plis. Chaque observation sert quatre fois à l'apprentissage et exactement une fois à la validation. Le test final reste à l'écart de l'ensemble de ce mécanisme.

Supposons que les exactitudes de validation des cinq tours soient 0,79, 0,82, 0,77, 0,81 et 0,80. Leur moyenne vaut 0,798. Leur dispersion montre aussi que le résultat dépend quelque peu des observations placées dans le bloc de validation; annoncer seulement « environ 0,80 » masque cette information.

Une *répétition* consiste à refaire tout le découpage en cinq blocs avec une autre permutation

aléatoire, puis à recommencer les cinq entraînements. Les observations ne changent pas ; seule leur affectation aux blocs change. Deux répétitions produisent ici dix mesures :

	pli 1	pli 2	pli 3	pli 4	pli 5	moyenne
répétition 1	0,79	0,82	0,77	0,81	0,80	0,798
répétition 2	0,81	0,78	0,80	0,76	0,83	0,796
moyenne des dix validations						0,797

TABLE 7.2 – Exemple fictif de validation croisée répétée. Les dix nombres ne sont pas dix évaluations finales indépendantes : les ensembles d'apprentissage se recouvrent fortement. Ils décrivent néanmoins la sensibilité au découpage.

Sous-procédure — Comparer des configurations par validation croisée

Entrées : les données d'apprentissage, une liste de configurations et un nombre de plis q . Un pli est une liste d'indices utilisée une fois pour la validation. **Sortie** : une configuration choisie sans consulter le test.

1. répartir les indices en q blocs disjoints et enregistrer ces blocs ;
2. pour une configuration donnée et un bloc B_r , ajuster sur tous les indices hors de B_r , puis mesurer sur B_r ;
3. répéter pour $r = 1, \dots, q$: chaque ligne sert ainsi une fois à la validation ;
4. calculer la moyenne et la dispersion des q mesures ;
5. recommencer avec exactement les mêmes blocs pour chaque configuration ;
6. choisir selon une règle fixée, puis seulement exécuter le protocole final et le test.

Pour comparer deux modèles A et B, on utilise exactement les mêmes blocs pour les deux. Si, sur un pli donné, A obtient 0,81 et B 0,79, la différence est +0,02. Répéter ce calcul pli par pli sépare mieux l'effet du modèle de la difficulté particulière d'un bloc. Employer des découpages différents ajouterait inutilement la variation des données à la comparaison.

Incertitude de l'évaluation

Une exactitude test est elle-même une estimation soumise à la variabilité d'échantillonnage. Sur 200 observations, une différence de deux bonnes prédictions ne représente qu'un point de pourcentage et ne suffit généralement pas à conclure qu'un modèle est réellement supérieur. La comparaison de modèles doit conserver les mêmes partitions. Les plis et répétitions de la section précédente mesurent la sensibilité pendant la sélection ; ils ne transforment pas le test final en certitude.

Par exemple, A classe correctement 162 élèves sur 200 et B en classe 160. L'écart d'exactitude vaut 0,01, mais il faut regarder les décisions appariées. Si A corrige deux erreurs de B sans introduire aucune nouvelle erreur, l'écart est cohérent sur ces deux cas. Si A et B se trompent chacun sur vingt élèves presque tous différents, le même total cache des comportements très différents. La matrice de confusion et la liste des désaccords sont alors plus informatives que le seul écart d'un point.

Résultats produits par l'évaluation

L'évaluation finale produit le vecteur des classes prédites, la matrice de confusion, l'exactitude globale et les mesures par classe. Les historiques de coût et de norme du gradient décrivent la convergence de l'entraînement ; ils ne remplacent pas les mesures calculées sur le test.

Chapitre 8

Notations et lecture des formules

Une formule se lit d'abord comme une phrase : quels objets entrent dans le calcul, quelle opération les relie et quel objet en sort ? Les tableaux de ce chapitre donnent pour chaque symbole sa nature, sa lecture orale professionnelle et son rôle dans le modèle.

Ce chapitre fixe non seulement le sens des symboles, mais aussi la manière de les nommer à l'oral. Une notation ne peut être comprise indépendamment de sa nature : un scalaire, un vecteur, une matrice, une fonction et un ensemble ne se manipulent pas de la même façon. Les vecteurs sont écrits en gras, les ensembles en lettres calligraphiques et les paramètres grecs en gras lorsqu'ils forment un vecteur.

Le document adopte la convention statistique suivante : l'indice d'observation est placé en bas. Ainsi, $\mathbf{x}_i$ est le vecteur de l'élève i , x_{ij} sa caractéristique j et c_i sa classe. Certains cours de machine learning écrivent $\mathbf{x}^{(i)}$ afin de distinguer le numéro d'exemple d'une puissance ; cette convention est légitime, mais elle est moins naturelle à l'oral et entre en conflit avec l'usage matriciel x_{ij} . Elle n'est donc pas retenue ici. Les crochets en exposant, comme $\theta^{[t]}$, sont réservés au numéro d'itération et ne désignent jamais une puissance.




FIGURE 8.1 – Nature des objets successifs. Ce schéma empêche notamment de confondre une caractéristique, un score, une sortie logistique et une classe.

8.1 Indices, effectifs et ensembles

L'écriture $i \in \mathcal{I}_{\text{tr}}$ se lit « i appartient à l'ensemble des indices d'apprentissage ». L'écriture $k \in \{1, \dots, K\}$ se lit « k varie de un à K ».

symbole	lecture orale	signification exacte
i	« indice i » lorsqu'il est attaché à un symbole	indice d'une observation : ici, un élève. Il varie de 1 à m .
j	« indice j » lorsqu'il est attaché à un symbole	indice d'une caractéristique : ici, un cours ou une note. Il varie de 1 à n .
k	« indice k » lorsqu'il est attaché à un symbole	indice d'une classe : ici, une maison. Il varie de 1 à K .
t	« itération t »	indice d'une itération de l'algorithme d'optimisation.
m	« m »	nombre total d'observations dans l'ensemble considéré.
n	« n »	nombre de caractéristiques utilisées par le modèle, avant ajout du biais.
K	« K »	nombre de classes ; dans ce problème, $K = 4$.
$\mathcal{C}$	« l'ensemble des classes C »	ensemble des classes possibles, et non une classe particulière. On précise « C calligraphique » seulement si l'on doit dicter la graphie.
$\mathbb{R}$	« R » ou « l'ensemble des réels »	ensemble dans lequel prennent leurs valeurs les scores, paramètres et caractéristiques numériques.
$\mathcal{I}_{\text{tr}}$	« I indice apprentissage »	ensemble des indices appartenant à l'échantillon d'apprentissage.
$\mathcal{I}_{\text{te}}$	« I indice test »	ensemble des indices appartenant à l'échantillon de test.

TABLE 8.1 – Indices, tailles et ensembles. Un même indice conserve le même rôle dans tout le document.

8.2 Une observation et ses caractéristiques

symbole	lecture orale	signification exacte
r_{ij}	« r indice i j »	valeur brute de la caractéristique j pour l'élève i , avant standardisation. Le premier indice repère la ligne, le second la variable.
μ_j	« mu indice j »	moyenne de la caractéristique j , estimée uniquement sur l'apprentissage.
s_j	« s indice j »	écart-type de la caractéristique j , estimé uniquement sur l'apprentissage.
x_{ij}	« x indice i j »	caractéristique j standardisée de l'observation i ; c'est un scalaire.
$\mathbf{x}_i$	« x indice i »	vecteur colonne des n caractéristiques standardisées de l'observation i ; $\mathbf{x}_i \in \mathbb{R}^n$. Le caractère gras est généralement implicite à l'oral.
$\tilde{\mathbf{x}}_i$	« x tilde indice i » ou « x i augmenté »	vecteur $\mathbf{x}_i$ précédé d'une coordonnée égale à 1 pour intégrer le biais; $\tilde{\mathbf{x}}_i \in \mathbb{R}^{n+1}$.
$\mathbf{X}$	« la matrice X » ou « la matrice de design »	matrice qui empile les vecteurs augmentés en lignes; $\mathbf{X} \in \mathbb{R}^{m \times (n+1)}$.
X_i	« la variable aléatoire X indice i »	vecteur aléatoire représentant les caractéristiques de l'observation i avant leur réalisation. Il se distingue de la valeur observée $\mathbf{x}_i$ et de la matrice $\mathbf{X}$.

TABLE 8.2 – Les minuscules désignent une observation ou une composante; la majuscule grasse $\mathbf{X}$ désigne l'ensemble des observations sous forme matricielle.

La formule

$$x_{ij} = \frac{r_{ij} - \mu_j}{s_j}$$

se lit : « x indice i j égale r indice i j moins mu indice j, sur s indice j ». Elle exprime la valeur de la note en nombre d'écarts-types au-dessus ou au-dessous de la moyenne d'apprentissage.

8.3 Classes observées, cibles binaires et prédictions

L'écriture $y_{ik} = \mathbf{1}[c_i = k]$ se lit : « y indice i k est l'indicatrice de l'événement c indice i égale k »; en contexte, on dira plus naturellement : « la cible de l'observation i pour la classe k vaut un si sa classe est k ».

symbole	lecture orale	signification exacte
C_i	« la variable aléatoire C indice i »	maison de l'élève i avant observation; C_i prend ses valeurs dans $\mathcal{C}$.
c_i	« c indice i »	maison effectivement observée pour l'élève i ; $c_i \in \mathcal{C}$. La minuscule désigne ici une réalisation de C_i .
y_{ik}	« y indice i k »	cible binaire du classifieur k pour l'observation i : 1 si $c_i = k$, sinon 0.
$\mathbf{y}_k$	« le vecteur y indice k »	vecteur colonne réunissant les m cibles du problème « classe k contre le reste »; $\mathbf{y}_k \in \{0, 1\}^m$.
$\hat{y}_i$	« y chapeau indice i »	classe binaire prédite pour l'observation i , égale à 0 ou 1. Le chapeau marque une valeur estimée.
$\hat{c}(\mathbf{x})$	« c chapeau évalué en $\mathbf{x}$ » ou « la classe prédite en $\mathbf{x}$ »	règle de classification multiclassées évaluée pour les caractéristiques $\mathbf{x}$.
$1[A]$	« l'indicatrice de l'événement A »	vaut 1 lorsque la proposition A est vraie et 0 sinon.

TABLE 8.3 – Une classe observée c_i ne doit pas être confondue avec la cible binaire y_{ik} fabriquée pour le sous-problème OvR numéro k .

8.4 Paramètres, score et probabilité binaire

Le produit $\boldsymbol{\theta}^\top \tilde{\mathbf{x}}$ se lit « thêta transposé x tilde », ou « le produit scalaire de thêta et x tilde ». Le symbole $\top$ indique la transposition : il transforme ici le vecteur colonne $\boldsymbol{\theta}$ en vecteur ligne afin que le produit scalaire soit défini. Développé, ce produit vaut

$$\boldsymbol{\theta}^\top \tilde{\mathbf{x}} = \theta_0 + \theta_1 x_1 + \cdots + \theta_n x_n.$$

8.5 Vraisemblance, perte et optimisation

La formule

$$\nabla J(\boldsymbol{\theta}) = \frac{1}{m} \mathbf{X}^\top (\sigma(\mathbf{X}\boldsymbol{\theta}) - \mathbf{y})$$

se lit : « le gradient de J en thêta vaut un sur m , X transposé, multiplié par le vecteur sigma de X thêta moins y ». Le vecteur entre parenthèses contient les écarts entre probabilités prédites et étiquettes observées.

La mise à jour

$$\boldsymbol{\theta}^{[t+1]} = \boldsymbol{\theta}^{[t]} - \alpha \nabla J(\boldsymbol{\theta}^{[t]})$$

se lit : « à l'itération t plus un, thêta vaut sa valeur à l'itération t moins alpha fois le gradient évalué en cette valeur ». Les crochets $[t]$ repèrent une itération; ils ne désignent pas une puissance.

symbole	lecture orale	signification exacte
θ_j	« thème indice j »	coefficient scalaire associé à la caractéristique j . Son signe indique le sens de son effet sur les log-cotes, toutes choses égales par ailleurs.
θ_0	« thème zéro »	biais ou constante du modèle ; il multiplie la coordonnée ajoutée $x_0 = 1$.
θ	« thème » ou « le vecteur des paramètres thème »	vecteur colonne de tous les paramètres $(\theta_0, \dots, \theta_n)^\top \in \mathbb{R}^{n+1}$. On ne dit « vecteur » que lorsque sa nature doit être soulignée.
θ_k	« thème indice k »	vecteur des paramètres du classifieur binaire « classe k contre le reste ».
$z_\theta(\mathbf{x})$	« le score z , paramétré par thème, évalué en $\mathbf{x}$ » ; souvent « le score en $\mathbf{x}$ »	score linéaire réel $\theta^\top \tilde{\mathbf{x}}$. Il n'est ni une classe ni une probabilité.
σ	« sigma »	fonction logistique $z \mapsto (1 + e^{-z})^{-1}$, qui transforme un score réel en nombre strictement compris entre 0 et 1.
$p_\theta(\mathbf{x})$	« p paramétré par thème, évalué en $\mathbf{x}$ » ; souvent « la probabilité prédite en $\mathbf{x}$ »	probabilité conditionnelle modélisée de la classe binaire positive : $\mathbb{P}(Y = 1 \mid X = \mathbf{x})$.
$q_k(\mathbf{x})$	« q indice k évalué en $\mathbf{x}$ »	sortie du classifieur binaire k , égale à $\sigma(\theta_k^\top \tilde{\mathbf{x}})$. Les q_k OvR ne sont pas contraints de sommer à 1.
Θ	« thème majuscule » ou « la matrice des paramètres »	matrice regroupant les K vecteurs de paramètres, un par classifieur OvR.

TABLE 8.4 – Le score z , la probabilité binaire p et la décision $\hat{y}$ sont trois objets distincts produits successivement par le modèle.

symbole	lecture orale	signification exacte
$L(\theta)$	« la vraisemblance évaluée en θ »	vraisemblance : probabilité des étiquettes observées, considérée comme fonction des paramètres.
$\log L(\theta)$	« la log-vraisemblance en θ »	logarithme de la vraisemblance ; il remplace les produits par des sommes sans changer le maximiseur.
$\ell_i(\theta)$	« ℓ indice i évaluée en θ » ou « la perte de l'observation i »	opposé de la contribution de l'observation i à la log-vraisemblance.
$J(\theta)$	« J évaluée en θ » ou « le coût en θ »	fonction objectif : moyenne des pertes sur l'échantillon d'apprentissage.
$\nabla J(\theta)$	« le gradient de J en θ »	vecteur des $n + 1$ dérivées partielles de J ; il pointe dans la direction locale de plus forte augmentation. « Nabla J » sert surtout à dicter la formule.
$\nabla^2 J(\theta)$	« la Hessienne de J en θ »	matrice des dérivées secondes ; elle décrit la courbure locale de la fonction objectif. « Nabla carré J » décrit la notation, moins bien l'objet.
W	« la matrice W »	matrice diagonale dont le terme i vaut $p_i(1 - p_i)$; elle intervient dans la Hessienne.
α	« alpha »	taux d'apprentissage, c'est-à-dire longueur multiplicative du pas de descente de gradient.
λ	« lambda »	intensité de la pénalisation quadratique ; $\lambda = 0$ signifie absence de régularisation.
ε	« epsilon »	tolérance numérique utilisée dans le critère d'arrêt.

TABLE 8.5 – Objets employés pour estimer les paramètres. La vraisemblance est maximisée ; son opposé logarithmique J est minimisé.

8.6 Probabilités et opérateurs

symbole	lecture orale	signification exacte
$\mathbb{P}(A)$	« probabilité de l'événement A »	probabilité de l'événement A .
$\mathbb{P}(A \mid B)$	« probabilité de A conditionnellement à B » ; couramment « A sachant B »	probabilité conditionnelle de A lorsque l'information B est connue.
$Y \mid X = \mathbf{x}$	« la loi de Y conditionnellement à X égal $\mathbf{x}$ »	loi conditionnelle de la réponse pour une observation dont les caractéristiques valent $\mathbf{x}$.
$\sum_{i=1}^m$	« somme sur i , de un à m »	addition de l'expression située à droite pour toutes les observations.
$\prod_{i=1}^m$	« produit sur i , de un à m »	multiplication de l'expression située à droite pour toutes les observations.
$\arg \max_k a_k$	« l'argument du maximum sur k de a indice k »	valeur de l'indice k pour laquelle a_k est maximal ; le résultat est un indice, pas la valeur maximale elle-même. Dans l'usage, « $\arg \max$ » est également courant.
$\ v\ _2$	« norme euclidienne de v » ou « norme deux de v »	longueur euclidienne du vecteur v .
$\text{diag}(a_i)$	« la matrice diagonale de termes a indice i »	matrice dont la diagonale contient les a_i et dont les autres termes sont nuls.
$\partial J / \partial \theta_j$	« dérivée partielle de J par rapport à θ indice j »	variation locale de J lorsque seul θ_j varie, les autres paramètres étant maintenus fixes.

TABLE 8.6 – Opérateurs qui apparaissent dans les dérivations et les règles de décision.

Enfin,

$$\hat{c}(\mathbf{x}) = \arg \max_{k \in \{1, \dots, K\}} \boldsymbol{\theta}_k^\top \tilde{\mathbf{x}}$$

se lit : « la classe prédite en $\mathbf{x}$ est l'argument qui maximise, sur les classes k , le score θ indice k transposé $\mathbf{x}$ tilde ». Cette formule renvoie le nom de la classe gagnante après conversion de l'indice vers le libellé correspondant.

Chapitre 9

Guide de lecture et ressources ouvertes

Une bibliographie brute ne dit pas par où commencer. Les ressources ci-dessous sont donc ordonnées par objectif et par niveau mathématique. Tous les intitulés en couleur sont des liens cliquables vers une version ouverte ou vers la page officielle de la ressource.

9.1 Premiers repères statistiques

[Introduction to Modern Statistics — chapitre 9](#)

Ressource libre de Çetinkaya-Rundel et Hardin [8]. Le chapitre sur la régression logistique part de données, explique les cotes et l'interprétation des coefficients avant de développer l'inférence. C'est le meilleur point d'entrée de cette liste si les probabilités conditionnelles et les log-cotes ne sont pas encore familières.

[An Introduction to Statistical Learning](#)

Ouvrage de James, Witten, Hastie, Tibshirani et Taylor [9], disponible gratuitement en versions R et Python. Le traitement est moins technique que *The Elements of Statistical Learning*, avec des exemples, des figures et des laboratoires. Lire le chapitre Classification, puis les chapitres Resampling Methods et Linear Model Selection and Regularization pour comprendre validation croisée et pénalisation.

9.2 Probabilités et calcul

[Stanford CS109 — Logistic Regression](#)

Cours court accompagné de diapositives et de code [10]. Il est utile pour revoir maximum de vraisemblance et régression logistique dans une progression de probabilités appliquées, sans entrer immédiatement dans un traité de statistique mathématique.

[Stanford Engineering Everywhere — CS229](#)

Le cours historique fournit vidéos, transcriptions, exercices et notes. Les notes 1 couvrent classification et régression logistique ; les notes 5 couvrent régularisation et sélection de modèle [11]. La densité mathématique est supérieure aux deux ressources précédentes, mais les dérivations sont directement utilisables.

Penn State STAT 504 — Analysis of Discrete Data

Notes de cours ouvertes du département de statistique de Penn State [12]. Les leçons 6 à 8 traitent successivement régression logistique binaire, diagnostics et régression multinomiale. Cette ressource est particulièrement utile pour approfondir rapports de cotes, qualité d'ajustement et interprétation statistique.

9.3 Approfondir le formalisme

The Elements of Statistical Learning

Référence de Hastie, Tibshirani et Friedman [1]. Le chapitre 4 contient les équations citées dans ce document. Il est concis et exigeant : mieux vaut l'utiliser après une première lecture d'ISL ou d'OpenIntro, puis vérifier une à une vraisemblance, gradient, Hessienne et régularisation.

Probabilistic Machine Learning: An Introduction

Ouvrage de Murphy [7]. Il replace la régression logistique dans un cadre probabiliste plus large et développe optimisation, calibration et modèles multiclassés. À consulter lorsque les objets du présent cours sont déjà maîtrisés séparément.

Convex Optimization

Ouvrage ouvert de Boyd et Vandenberghe [4]. Les chapitres sur la convexité et les méthodes de descente donnent le cadre général derrière la Hessienne positive et le choix d'une direction de descente. Cette référence traite l'optimisation mathématique générale ; son étude suppose donc déjà le contexte statistique de la classification.

Parcours conseillé

Pour une première étude : OpenIntro, puis ISL, puis les notes CS229. Pour vérifier le formalisme du présent document : ESL chapitre 4 et Boyd chapitre 9. Pour aller au-delà d'OvR vers une modélisation probabiliste multiclassés : Penn State leçon 8, puis Murphy. Cette progression évite de demander à une même source d'être à la fois introduction, manuel de calcul et référence théorique.

Conclusion

La régression logistique repose sur une chaîne cohérente : modèle linéaire des log-cotes, loi de Bernoulli conditionnelle, maximum de vraisemblance, log-perte convexe et optimisation numérique contrôlée. OvR réutilise exactement ce problème binaire K fois et fournit une règle multiclass simple par maximum des scores. Sa simplicité a une contrepartie précise : la somme des sorties indépendantes est libre, alors qu'une distribution catégorielle exige une somme égale à 1. La validité du résultat dépend enfin autant du protocole expérimental — absence de fuite, test indépendant, diagnostics par classe — que de la correction des équations.

Enchaînement des opérations

Le modèle reçoit des caractéristiques préparées, calcule quatre combinaisons linéaires, transforme éventuellement leurs scores par la fonction logistique et retient le score maximal. Son apprentissage consiste à choisir chaque vecteur de paramètres de façon à maximiser la vraisemblance de la cible binaire associée. Sa validation consiste à vérifier séparément la convergence numérique, la généralisation et les erreurs propres à chaque maison. Ces trois niveaux ne doivent jamais être confondus.

Annexe A

Dérivations mathématiques

Cette annexe rassemble les justifications algébriques des formules utilisées dans le corps du document. Les chapitres principaux conservent les expressions nécessaires au calcul et leur interprétation opérationnelle.

A.1 Inversion du logit

En posant $p = \mathbb{P}(Y = 1 \mid X = \mathbf{x})$ et $z = \boldsymbol{\theta}^\top \tilde{\mathbf{x}}$,

$$\begin{aligned} \log \frac{p}{1-p} = z &\iff \frac{p}{1-p} = e^z \iff p = e^z(1-p) \\ &\iff p(1+e^z) = e^z \iff p = \frac{e^z}{1+e^z} = \frac{1}{1+e^{-z}}. \end{aligned}$$

A.2 Gradient de la log-perte

Pour une observation, $\ell_i = -y_i \log p_i - (1 - y_i) \log(1 - p_i)$ et $\partial p_i / \partial z_i = p_i(1 - p_i)$. La règle de chaîne donne

$$\begin{aligned} \frac{\partial \ell_i}{\partial z_i} &= -\frac{y_i}{p_i} p_i(1 - p_i) + \frac{1 - y_i}{1 - p_i} p_i(1 - p_i) \\ &= p_i - y_i. \end{aligned}$$

Comme $\nabla_{\boldsymbol{\theta}} z_i = \tilde{\mathbf{x}}_i$, la moyenne des contributions vaut

$$\nabla J(\boldsymbol{\theta}) = \frac{1}{m} \sum_{i=1}^m (p_i - y_i) \tilde{\mathbf{x}}_i = \frac{1}{m} \mathbf{X}^\top (\sigma(\mathbf{X}\boldsymbol{\theta}) - \mathbf{y}).$$

A.3 Convexité de la log-perte

Avec $W = \text{diag}(p_i(1 - p_i))$,

$$\nabla^2 J(\boldsymbol{\theta}) = \frac{1}{m} \mathbf{X}^\top W \mathbf{X}.$$

Pour tout $v \in \mathbb{R}^{n+1}$,

$$v^\top \nabla^2 J(\boldsymbol{\theta}) v = \frac{1}{m} (\mathbf{X}v)^\top W (\mathbf{X}v) = \frac{1}{m} \sum_{i=1}^m p_i(1 - p_i) (\tilde{\mathbf{x}}_i^\top v)^2 \geq 0.$$

La Hessienne est donc positive semi-définie et J est convexe.

A.4 Direction de descente

Pour un déplacement suffisamment petit $\Delta\boldsymbol{\theta}$,

$$J(\boldsymbol{\theta} + \Delta\boldsymbol{\theta}) = J(\boldsymbol{\theta}) + \nabla J(\boldsymbol{\theta})^\top \Delta\boldsymbol{\theta} + o(\|\Delta\boldsymbol{\theta}\|).$$

Avec $\Delta\boldsymbol{\theta} = -\alpha \nabla J(\boldsymbol{\theta})$,

$$J(\boldsymbol{\theta} + \Delta\boldsymbol{\theta}) = J(\boldsymbol{\theta}) - \alpha \|\nabla J(\boldsymbol{\theta})\|_2^2 + o(\alpha \|\nabla J(\boldsymbol{\theta})\|).$$

Le terme principal est négatif pour $\alpha > 0$ lorsque le gradient est non nul.

Références citées

- [1] Trevor HASTIE, Robert TIBSHIRANI et Jerome FRIEDMAN. *The Elements of Statistical Learning : Data Mining, Inference, and Prediction*. 2^e éd. New York : Springer, 2009. DOI : [10 . 1007 / 978 - 0 - 387 - 84858 - 7](https://doi.org/10.1007/978-0-387-84858-7). URL : [https : // hastie . su . domains / ElemStatLearn/](https://hastie.su.domains/ElemStatLearn/) (visité le 15/07/2026).
- [2] David R. COX. « The Regression Analysis of Binary Sequences ». In : *Journal of the Royal Statistical Society : Series B* 20.2 (1958), p. 215-242. DOI : [10 . 1111 / j . 2517 - 6161 . 1958 . tb00292 . x](https://doi.org/10.1111/j.2517-6161.1958.tb00292.x).
- [3] Adelin ALBERT et John A. ANDERSON. « On the Existence of Maximum Likelihood Estimates in Logistic Regression Models ». In : *Biometrika* 71.1 (1984), p. 1-10. DOI : [10 . 1093 / biomet / 71 . 1 . 1](https://doi.org/10.1093/biomet/71.1.1).
- [4] Stephen BOYD et Lieven VANDENBERGHE. *Convex Optimization*. Cambridge University Press, 2004. URL : [https : // web . stanford . edu / ~ boyd / cvxbook/](https://web.stanford.edu/~boyd/cvxbook/) (visité le 15/07/2026).
- [5] Ryan RIFKIN et Aldebaro KLAUTAU. « In Defense of One-Vs-All Classification ». In : *Journal of Machine Learning Research* 5 (2004), p. 101-141. URL : [https : // www . jmlr . org / papers / v5 / rifkin04a . html](https://www.jmlr.org/papers/v5/rifkin04a.html) (visité le 15/07/2026).
- [6] Bianca ZADROZNY et Charles ELKAN. « Transforming Classifier Scores into Accurate Multiclass Probability Estimates ». In : *Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2002, p. 694-699. DOI : [10 . 1145 / 775047 . 775151](https://doi.org/10.1145/775047.775151).

Lectures complémentaires

- [7] Kevin P. MURPHY. *Probabilistic Machine Learning : An Introduction*. MIT Press, 2022. URL : <https://probml.github.io/pml-book/book1.html> (visit  le 15/07/2026).
- [8] Mine  ETINKAYA-RUNDEL et Johanna HARDIN. *Introduction to Modern Statistics*. 2024. URL : <https://openintrostat.github.io/ims/> (visit  le 15/07/2026).
- [9] Gareth JAMES et al. *An Introduction to Statistical Learning : with Applications in Python*. Springer, 2023. DOI : 10.1007/978-3-031-38747-0. URL : <https://www.statlearning.com/> (visit  le 15/07/2026).
- [10] STANFORD UNIVERSITY. *CS109 : Logistic Regression*. Department of Computer Science. 2026. URL : <https://web.stanford.edu/class/archive/cs/cs109/cs109.1264/lectures/20-LogisticRegression/> (visit  le 15/07/2026).
- [11] Andrew NG. *CS229 Lecture Notes : Supervised Learning*. Stanford University, 2018. URL : https://cs229.stanford.edu/main_notes.pdf (visit  le 15/07/2026).
- [12] PENNSYLVANIA STATE UNIVERSITY. *STAT 504 : Analysis of Discrete Data*. Department of Statistics. URL : <https://online.stat.psu.edu/stat504/> (visit  le 15/07/2026).
- [13] Christopher M. BISHOP. *Pattern Recognition and Machine Learning*. New York : Springer, 2006. ISBN : 978-0-387-31073-2.
- [14] Ian GOODFELLOW, Yoshua BENGIO et Aaron COURVILLE. *Deep Learning*. MIT Press, 2016. URL : <https://www.deeplearningbook.org/> (visit  le 15/07/2026).