

Régression logistique

Ce qu'elle fait, et pourquoi elle le fait

Sylvain Maitre

1^{er} août 2026

Résumé

Une droite sépare deux groupes de points. Elle rend une réponse binaire, alors qu'une probabilité est nécessaire : cet élève est Gryffindor à quatre-vingt-dix pour cent. La régression logistique construit ce passage, et le reste en découle — la mesure de l'erreur, sa dérivée, et le déplacement de la droite jusqu'à sa position optimale.

La première partie suit ce parcours sur un cas réel : mille six cents élèves, deux notes chacun, quatre maisons à reconnaître. Les formules y sont données et employées, jamais démontrées. La deuxième construit le programme qui exécute tout cela, du fichier brut à la maison prédite, sans bibliothèque de calcul. La troisième démontre chaque formule ligne à ligne, en rappelant les règles de calcul à l'endroit où elles servent.

Les figures proviennent d'une descente réellement exécutée sur le fichier des élèves.

Ce texte a été rédigé avec GPT et Claude selon mes instructions et éléments fournis. Le résultat n'est pas formidable mais il est lisible et peut apporter des éléments de compréhension. Il est mis à disposition sous licence CC-BY-SA 4.0.

Table des matières

I	Voir	1
1	Notes brutes et standardisation	2
1.1	Fichier d'entraînement	2
1.2	Notes absentes	2
1.3	Différence d'échelle entre les colonnes	3
1.4	Application à un élève	5
2	Nuage de points et frontière de décision	6
2.1	Séparation par une note	6
2.2	Équation de la frontière	7
2.3	Score	9
2.4	Variable cible	10
2.5	Du signe à une quantité continue	11
2.6	Au-delà de deux matières	12
3	Du score à la probabilité	14
3.1	Fonction logistique	14
3.2	Calcul de la probabilité	15
3.3	Règle de décision	17
4	Coût, mesure de l'erreur	21
4.1	Coût d'un élève	21
4.2	Coût moyen sur le fichier	22
4.3	Répartition du coût	24

4.4	Comptage et coût	25
5	Descente de gradient	27
5.1	Correction à appliquer	27
5.2	Premier pas de la descente	28
5.3	Coût au fil des itérations	29
5.4	Déplacement de la frontière	30
5.5	Niveau 0,5 de la sigmoïde	34
5.6	Surface du coût	35
5.7	Longueur du pas	38
6	Modèle obtenu	41
6.1	Interprétation des coefficients	41
6.2	Paramètres appris et paramètres fixés	43
6.3	Classement d'un nouvel élève	43
6.4	Extension à dix notes et quatre maisons	45
7	Classification à quatre maisons	46
7.1	Un modèle par maison	46
7.2	Règle du score maximal	47
7.3	Des quatre frontières aux quatre régions	49
7.4	Contenu du classifieur	50
7.5	Somme des quatre probabilités	51
II	Construire	52
8	Du score au coût	53
8.1	Étape 1 : le score d'un élève	53
8.2	Étape 2 : du score à la probabilité	54
8.3	Étape 3 : le coût d'une prédiction	55
8.4	Étape 4 : le coût moyen	55

9	Recherche de meilleurs coefficients	58
9.1	Étape 5 : la pente et sa vérification	58
9.2	Étape 6 : un pas	59
9.3	Étape 7 : itération jusqu'à stabilisation	61
10	Quatre maisons et mesure de l'exactitude	63
10.1	Étape 8 : la même descente, quatre fois	63
10.2	Étape 9 : mesure sur des élèves inconnus	64
10.3	Compléments pour un programme livrable	66
III	Démontrer	68
11	Construction de la fonction logistique	69
11.1	Première transformation : la cote	69
11.2	Seconde transformation : le logarithme	70
11.3	Expression de p en fonction de z	70
11.4	Vérification numérique	71
12	Propriétés de la fonction logistique	74
12.1	Symétrie	74
12.2	Dérivée	75
12.3	Variation de la probabilité avec le score	75
13	Construction du coût par vraisemblance	77
13.1	Probabilité d'une réponse observée	77
13.2	Vraisemblance du fichier	77
13.3	Passage au logarithme	78
13.4	Du maximum à un minimum	78
13.5	Coût d'un élève	79
14	Calcul du gradient	80
14.1	Composition à dériver	80

14.2	Première dérivée : le coût d'un élève par rapport au score	81
14.3	Seconde dérivée : le score par rapport à un coefficient	81
14.4	Assemblage	82
14.5	Facteurs du gradient	82
15	Unicité du minimum	84
15.1	Courbure d'une fonction d'une variable	84
15.2	Courbure du coût logistique	85
15.3	Positivité de la courbure	85
15.4	Directions de courbure nulle	86
16	Réécritures pour la stabilité numérique	87
16.1	Coût exprimé à partir du score	87
16.2	Formes protégées de softplus et de la sigmoïde	88
A	Croissance de la norme des coefficients	90
A.1	Équilibre qui arrête la croissance	90

Première partie

Voir

Chapitre 1

Notes brutes et standardisation

Deux opérations transforment les notes d'examen du fichier en valeurs standardisées : le remplacement des notes absentes, puis le changement d'unité. Les axes gradués en écarts-types en sont le résultat.

1.1 Fichier d'entraînement

`dataset_train.csv` contient 1 600 lignes, une par élève. Les six premières colonnes donnent l'index, la maison, le nom, la date de naissance et la main directrice ; les treize suivantes donnent une note par matière. La maison est renseignée pour les 1 600 élèves : c'est la réponse que le modèle doit retrouver.

Deux d'entre elles servent ici, **Herbology** et **Ancient Runes** : leurs distributions par maison se recouvrent peu, et elles suffisent à isoler les **Gryffindor** (ch. 2). Le modèle complet en retient dix.

matière	absentes	minimum	maximum	médiane	moyenne	écart-type
Herbology	33	−10,30	11,61	3,469	1,189	5,175
Ancient Runes	35	283,87	745,40	463,918	495,052	105,186

TABLE 1.1. Les deux colonnes employées, telles qu'elles figurent dans le fichier. La moyenne et l'écart-type sont calculés après remplacement des notes absentes, donc sur les 1 600 lignes.

1.2 Notes absentes

Certaines cases du fichier sont vides : la note n'a pas été enregistrée pour cet élève dans cette matière. Le calcul qui suit exige une valeur pour chaque terme, puisque le score est une somme de produits ; une case vide arrête donc le traitement de la ligne entière.

Deux voies s'ouvrent. Écarter les élèves incomplets conserve des mesures authentiques, au prix du nombre d'élèves, et suppose que les absents de la colonne ressemblent aux présents — une hypothèse que le fichier ne permet pas de vérifier. Attribuer une valeur à chaque case vide conserve tous les élèves, au prix de valeurs fabriquées. Cette seconde opération s'appelle une *imputation*, et c'est celle qui est retenue ici.

Reste à choisir la valeur attribuée. Une valeur centrale perturbe la colonne au minimum, et deux candidates se présentent : la moyenne et la médiane. La médiane est la valeur qui coupe la colonne en deux moitiés de même effectif ; déplacer la plus haute note du fichier à mille points au-dessus la laisse identique, alors que la moyenne se déplace avec elle. Cette insensibilité aux valeurs extrêmes est la première raison de la préférer. La seconde tient à la suite : la moyenne de la colonne sert au calcul de la section suivante, et remplir les cases vides avec elle reviendrait à la calculer à partir d'elle-même.

CASES VIDES DES DEUX COLONNES

	Herbology	Ancient Runes	
notes absentes	33	35	soit 68 élèves, 4,25 % du fichier
médiane attribuée	3,469	463,918	
moyenne avant	1,141	495,748	sur les notes présentes
moyenne après	1,189	495,052	elle monte d'un côté, baisse de l'autre

Le remplissage déplace chaque moyenne de moins d'un centième d'écart-type : 0,009 pour **Herbology**, 0,007 pour **Ancient Runes**. Les 68 élèves concernés le sont chacun sur une seule des deux colonnes.

Un élève ainsi complété occupe dans le nuage une position que ses résultats scolaires ne justifient pas. La méthode tient parce que les cases vides sont rares ; sur une colonne à moitié vide, elle empilerait la moitié des élèves sur un même point.

L'élève 21, dont la note d'**Ancient Runes** est absente, reçoit 463,918, soit $-0,296$ une fois standardisée.

1.3 Différence d'échelle entre les colonnes

Les deux colonnes mesurent une performance scolaire, mais dans des unités sans rapport entre elles. Le score les additionne pourtant, après avoir multiplié chacune par son coefficient. Une matière dont les notes s'étalent sur une large plage pèse alors davantage qu'une autre, à coefficient égal, pour la seule raison de son échelle de notation. Deux conséquences en découlent : les coefficients cessent d'être comparables entre eux, et la distance entre deux élèves du plan dépend du barème de chaque matière plutôt que de leurs résultats.

Une note d'**Herbology** se lit entre -10 et $+12$, une note d'**Ancient Runes** autour de 500, et les secondes sont vingt fois plus dispersées : dans $w_1x_1 + w_2x_2$, un w_2 de 1 produit donc un effet vingt fois plus grand qu'un w_1 de 1.

Ramener les deux colonnes à une échelle commune supprime cette dépendance.

$$x = \frac{\overbrace{v - \mu}^{\text{écart à la moyenne de la colonne}}}{\underbrace{\sigma}_{\text{écart-type de la colonne}}}$$

Cette transformation porte le nom de *centrage-réduction* ; son résultat s'appelle *cote standard*, ou *z-score* en anglais. Ce document note x la cote standard et réserve la lettre z au score du modèle, introduit au chapitre 2. La soustraction place la moyenne en 0, la division fixe l'écart-type à 1. Une valeur standardisée se lit donc directement : +1 désigne un élève situé un écart-type au-dessus de la moyenne de sa colonne, quelle que soit la matière.




FIGURE 1.1. La transformation est affine : elle déplace l'origine et change l'unité, sans modifier l'ordre des élèves ni les rapports de distances. En rouge, l'élève 3.

Le nuage conserve sa forme, seules ses graduations changent.




FIGURE 1.2. Les mêmes 534 élèves, un sur trois pour la lisibilité. Les deux figures se déduisent l'une de l'autre par changement de graduation. La standardisation rend les deux coefficients comparables entre eux et le score indépendant des unités de notation.

1.4 Application à un élève

L'élève 3 a $-6,497$ en **Herbology** et $523,982$ en **Ancient Runes**.

$$x_1 = \frac{-6,497 - 1,189}{5,175} = -1,485, \quad x_2 = \frac{523,982 - 495,052}{105,186} = +0,275.$$

Ces deux valeurs sont les coordonnées du point qui représente cet élève dans le plan (x_1, x_2) . La première le situe à un écart-type et demi au-dessous de la moyenne en **Herbology**, la seconde à un quart d'écart-type au-dessus en **Ancient Runes**.

Statistiques à conserver

La médiane, la moyenne et l'écart-type sont calculés une fois, sur les élèves d'entraînement, et font partie du modèle au même titre que les coefficients. Un élève inconnu se standardise avec ces trois nombres-là, jamais avec ceux de son propre fichier : recalculer une moyenne sur de nouvelles données placerait les scores dans une autre échelle, et sur un fichier d'un seul élève, l'écart-type serait nul.

Chapitre 2

Nuage de points et frontière de décision

Deux notes par élève définissent un point du plan. Les **Gryffindor** occupent une région, les autres élèves une autre, et une droite sépare approximativement les deux : c'est la *frontière de décision* du modèle, *decision boundary* dans la littérature anglophone [1, 2]. Reste à la déterminer par le calcul, et à en tirer une probabilité plutôt qu'une décision binaire.

2.1 Séparation par une note

Herbology sépare les maisons en deux groupes : **Gryffindor** et **Slytherin** d'un côté, **Hufflepuff** et **Ravenclaw** de l'autre. Sur cette seule note, un **Gryffindor** et un **Slytherin** sont indiscernables. **Ancient Runes** les sépare autrement : **Gryffindor** et **Ravenclaw** d'un côté, **Hufflepuff** et **Slytherin** de l'autre. Là encore, deux maisons restent confondues.




FIGURE 2.1. Répartition des élèves selon leur seule note d'**Herbology**. Les **Gryffindor** se concentrent sous la bosse de gauche — le *mode* de la distribution — que partagent des élèves d'une autre maison : aucun seuil sur cet axe ne sépare les deux populations.

Prises ensemble, les deux notes situent chaque élève dans un plan, où les **Gryffindor** occupent une région que les trois autres maisons laissent vide. La séparation qu'aucune des deux notes ne produit seule résulte de leur combinaison.




FIGURE 2.2. Les mêmes élèves, chacun placé selon ses deux notes. Les **Gryffindor** occupent seuls le quadrant $x_1 < 0, x_2 > 0$ — notes basses en **Herbology**, hautes en **Ancient Runes**; les trois autres maisons se répartissent dans les trois quadrants restants.

2.2 Équation de la frontière

Les deux notes standardisées (x_1, x_2) sont des nombres sans dimension, exprimés dans la même unité — l'écart-type de leur colonne. Le plan qu'elles engendrent peut donc être muni d'un repère orthonormé, et c'est ce qui donne un sens aux notions d'angle, de perpendiculaire et de distance employées plus bas. Sur les notes brutes, où un axe se gradue en points et l'autre en centaines de points, aucune de ces notions ne serait pertinente.

Dans ce repère, une droite admet pour équation cartésienne

$$w_0 + w_1x_1 + w_2x_2 = 0.$$

Trois coefficients y figurent, alors que deux nombres suffisent à désigner une droite du plan — sa pente et son ordonnée à l'origine, par exemple. La raison est que l'équation est définie à un facteur multiplicatif près : w et λw ont exactement les mêmes solutions pour tout $\lambda \neq 0$, et désignent donc la même droite. Ce sont les rapports entre coefficients qui la fixent, jamais leurs valeurs.

Le couple (w_1, w_2) est un *vecteur normal* à la droite : il lui est perpendiculaire et pointe vers la région où $w_0 + w_1x_1 + w_2x_2$ est positif. Sa longueur est la *norme* de w , notée $\|w\|$ et employée

dans tout ce qui suit :

$$\|w\| = \sqrt{w_1^2 + w_2^2}.$$

Le coefficient w_0 , lui, place la droite relativement à l'origine du repère, dont la distance signée à la droite vaut

$$d_0 = -\frac{w_0}{\|w\|}.$$

Il porte le nom de *biais* : c'est la valeur que prend $w_0 + w_1x_1 + w_2x_2$ pour un élève dont les deux notes valent zéro, autrement dit pour un élève moyen dans les deux matières.




FIGURE 2.3. La frontière $-0,4 - 0,6x_1 + x_2 = 0$ sépare le plan en deux demi-plans. Le vecteur normal $(w_1, w_2) = (-0,6; 1)$, tracé à l'échelle depuis le pied de la perpendiculaire issue de l'origine, est orthogonal à la frontière et pointe vers le demi-plan où $z > 0$. Le segment d_O joint l'origine à ce pied et mesure $-w_0/\|w\| = 0,343$. La norme de (w_1, w_2) laisse la frontière en place et fixe la vitesse à laquelle z croît lorsqu'on s'en éloigne.

Les deux panneaux suivants font varier un coefficient à la fois à partir de $w = (0; 0,8; 1)$, les deux autres restant fixés. Deux panneaux couvrent tous les cas : la frontière ne dépend que de la direction de (w_1, w_2) , et faire varier w_1 à w_2 fixé parcourt déjà cette direction tout entière.




FIGURE 2.4. Le trait plein est le même dans les deux panneaux : $w = (0; 0,8; 1)$. À gauche, w_0 translate la droite parallèlement à elle-même. À droite, w_1 la fait pivoter autour de l'origine, qui annule $w_0 + w_1x_1 + w_2x_2$ pour toute valeur de w_1 puisque w_0 est nul.

2.3 Score

Le membre de gauche de cette équation se calcule pour tout élève du plan, sur la frontière ou ailleurs. On l'appelle le *score* :

$$z = \underbrace{w_0}_{\substack{\text{biais} \\ \text{le même pour tous}}} + \underbrace{w_1x_1}_{\substack{\text{apport de la note} \\ \text{d'Herbology}}} + \underbrace{w_2x_2}_{\substack{\text{apport de la note} \\ \text{d'Ancient Runes}}}$$

La frontière de décision est l'ensemble des points où ce nombre s'annule, $\{x : z(x) = 0\}$. Le score est positif d'un côté, négatif de l'autre, et sa valeur absolue croît proportionnellement à la distance à la frontière : $z = \|w\| d$ (ch. 5).

Reste à relier ce score à une probabilité. La régression logistique pose que le score est le logarithme d'une cote.

La *cote* d'un événement est le rapport entre sa probabilité et celle de l'événement contraire :

$$\text{cote}(p) = \frac{\overbrace{p}^{\substack{\text{probabilité} \\ \text{de l'événement}}}}{\underbrace{1-p}_{\substack{\text{probabilité} \\ \text{du contraire}}}}$$

C'est la quantité employée dans les paris. Un élève auquel on accorde $p = 0,8$ d'être **Gryffindor** a ainsi une cote de

$$\frac{0,8}{0,2} = 4,$$

soit quatre fois plus de chances d'en être que de ne pas en être. Une cote de 1 correspond à $p = 0,5$, les deux réponses étant alors également probables. Quand p parcourt $]0, 1[$, la cote

parcourt $]0, +\infty[$: elle tend vers 0 lorsque la probabilité s'annule, et croît sans borne lorsqu'elle approche 1.

Le *logit* est le logarithme de cette cote,

$$\text{logit}(p) = \log \frac{p}{1-p}.$$

Il vaut 0 pour $p = 0,5$, il est négatif en dessous et positif au-dessus, et il parcourt $\mathbb{R}$ tout entier : exactement l'ensemble des valeurs que peut prendre un score. L'hypothèse annoncée s'écrit donc

$$\log \frac{p}{1-p} = z = w_0 + w_1x_1 + w_2x_2,$$

et c'est la seule que fait la régression logistique : le logit de la probabilité cherchée est une fonction *affine* des notes, c'est-à-dire une somme de leurs multiples augmentée d'une constante. L'expression de p en fonction de z s'en déduit (ch. 11).

L'élève 3, dont le score vaut $+1,34$, a une cote de $e^{1,34} = 3,82$ d'être [Gryffindor](#), soit une probabilité de $3,82/4,82 = 0,79$.




FIGURE 2.5. Le trait épais est la frontière, tracée ici pour $w = (-0,4; -0,6; 1)$. Le segment en pointillé joint le point $z = +3,1$ à son projeté orthogonal sur la frontière ; il mesure $d = |z|/\|w\| = 2,66$. À coefficients fixés, le score est proportionnel à la distance à la frontière : le point $z = +0,2$ en est distant de 0,17.

2.4 Variable cible

La frontière de décision sépare le plan en exactement deux régions. Elle peut donc porter une question à deux réponses, et une seule, alors que le fichier en distingue quatre.

La construction traite donc une maison à la fois : **Gryffindor** contre les trois autres réunies. Les trois questions restantes se posent à l'identique et se résolvent séparément (ch. 7).

La réponse à cette question s'appelle la *variable cible*. Sa colonne se déduit ligne à ligne de la colonne `Hogwarts House` du fichier, qui donne la maison de chacun des 1 600 élèves. C'est cette même quantité que le modèle devra produire pour un élève dont on ne connaîtra que les notes. Elle se code par

$$y_i = \begin{cases} 1 & \text{si l'élève } i \text{ appartient à } \text{Gryffindor}, \\ 0 & \text{sinon,} \end{cases}$$

ce qui donne 327 valeurs égales à 1 et 1 273 égales à 0.

Le choix de 1 et 0 procure deux propriétés qui serviront constamment. La moyenne de la colonne y vaut la proportion de **Gryffindor** dans le fichier, $327/1\,600 = 0,2044$. Et le chapitre suivant produira, pour chaque élève, une probabilité comprise entre 0 et 1 ; les deux colonnes seront alors comparables ligne à ligne, et leur différence mesurera l'erreur commise.

Index	Hogwarts House		y
0	Ravenclaw	→	0
1	Slytherin	→	0
2	Ravenclaw	→	0
3	Gryffindor	→	1
4	Gryffindor	→	1
⋮	⋮		⋮

$y_i = 1$ si l'élève i est **Gryffindor**, $y_i = 0$ sinon

FIGURE 2.6. Les cinq premières lignes de `dataset_train.csv`. Les deux colonnes de gauche figurent dans le fichier ; la troisième est construite, et l'est différemment pour chacune des quatre maisons.

2.5 Du signe à une quantité continue

Le signe de z fournit déjà une règle de décision : **Gryffindor** si $z > 0$, autre maison sinon. Deux exigences conduisent à lui préférer une quantité qui varie de façon continue.

La première est de rendre compte de la fiabilité. Deux élèves situés du même côté reçoivent la même réponse, que l'un se tienne loin de la frontière et l'autre tout contre, là où une note manquante ou une erreur de saisie suffit à le faire changer de classe. La valeur du score porte cette différence, que son signe seul laisse tomber.

Les deux élèves marqués sur la figure 2.5 ont pour scores $+3,1$ et $+0,2$.

La seconde est de rendre la frontière corrigeable. Déterminer sa position par le calcul suppose en effet de mesurer de combien elle est mal placée, de la déplacer d'autant, et de recommencer. Une réponse qui vaut juste ou fausse fournit une mesure qui saute d'une valeur à l'autre : elle

garde la même valeur sur tout un intervalle de positions, et le calcul y reçoit partout la même indication. Il faut une quantité qui réponde à un déplacement, si petit soit-il.

Transformation cherchée

Il faut transformer le score z , qui parcourt $\mathbb{R}$, en une probabilité, comprise entre 0 et 1. Cette transformation doit être continue, pour qu'un petit déplacement de la droite produise un petit changement de probabilité, et croissante, pour qu'un score plus élevé signifie une chance plus grande. Une infinité de fonctions remplissent ces deux conditions ; la fonction de répartition de la loi normale en est une, et fonde le modèle *probit*. Celle de la régression logistique s'obtient en posant que le logarithme de la cote est une fonction affine des notes, hypothèse qui conduit aux formules les plus simples (ch. 11).

2.6 Au-delà de deux matières

Le fichier compte treize matières, et le modèle complet en retient dix. La question se pose alors : la frontière reste-t-elle une droite ?

Non, et le mot change à chaque dimension ajoutée. Avec n notes, un élève est un point de $\mathbb{R}^n$ et l'équation devient

$$w_0 + w_1x_1 + \cdots + w_nx_n = 0,$$

soit une équation linéaire à n inconnues. Son ensemble de solutions est un sous-espace affine de dimension $n - 1$: une seule contrainte retire exactement un degré de liberté à l'espace. Cet objet porte le nom d'*hyperplan affine* de $\mathbb{R}^n$ — droite pour $n = 2$, plan pour $n = 3$, et sans représentation graphique au-delà.

matières	espace des élèves	frontière	sa dimension	coefficients
1	$\mathbb{R}$	un point	0	2
2	$\mathbb{R}^2$	une droite	1	3
3	$\mathbb{R}^3$	un plan	2	4
n	$\mathbb{R}^n$	un hyperplan	$n - 1$	$n + 1$
10	$\mathbb{R}^{10}$	un hyperplan	9	11

TABLE 2.1. La frontière occupe toujours une dimension de moins que l'espace où vivent les élèves, et sépare toujours celui-ci en exactement deux régions. Le nombre de coefficients, lui, croît d'une unité par matière ajoutée.




FIGURE 2.7. La frontière pour une, deux et trois matières. Le vecteur normal $(w_1, \dots, w_n)$ garde son rôle dans tous les cas, la distance d'un élève à la frontière vaut toujours $|z|/\|w\|$, et le signe de z désigne toujours l'un des deux demi-espaces. Seule la représentation graphique s'arrête à $n = 3$.

Seule la représentation graphique change. Les formules des chapitres suivants s'écrivent avec un nombre quelconque de notes, le code de la deuxième partie boucle sur les colonnes en lisant leur nombre dans le fichier, et les démonstrations de la troisième valent pour n quelconque. Deux matières servent ici parce qu'elles se dessinent.

Énoncé du problème

Reconnaître les 327 [Gryffindor](#) parmi les 1 600 élèves, à partir des deux notes standardisées du chapitre précédent, en déterminant par le calcul les trois coefficients d'une frontière de décision.

Chapitre 3

Du score à la probabilité

Le score indique de quel côté de la frontière de décision se situe un élève. Il faut en tirer une probabilité. La fonction qui opère ce passage est la fonction logistique (ch. 11).

3.1 Fonction logistique

$$\sigma(z) = \frac{1}{1 + e^{-z}},$$

$\underbrace{z}_{\substack{\text{score} \\ \text{parcourt } \mathbb{R}}} \longmapsto \underbrace{\sigma(z)}_{\substack{\text{probabilité} \\ \text{dans }]0, 1[}}$

Elle prend n'importe quel nombre et rend une valeur strictement comprise entre 0 et 1. Un score très négatif donne une probabilité proche de zéro, un score très positif une probabilité proche de un, et le score nul donne exactement 0,5 : sur la frontière, le modèle ne départage pas les deux réponses.




FIGURE 3.1. Les trois points marqués sont trois élèves réels du fichier, dont les scores sont calculés ci-dessous.

Deux propriétés servent constamment par la suite. La fonction est croissante, donc un score plus grand donne toujours une probabilité plus grande : classer par score ou par probabilité

revient au même. Elle est symétrique autour de 0,5, puisque $\sigma(-z)$ vaut exactement $1 - \sigma(z)$, si bien que les deux réponses jouent des rôles symétriques.

3.2 Calcul de la probabilité

Trois opérations séparent la note brute de la probabilité, et les nombres qu'elles emploient viennent de trois endroits différents.

Standardiser. Chaque note est remplacée dans l'échelle commune du chapitre 1, $(v - \mu)/\sigma$. La moyenne et l'écart-type sont ceux de sa colonne, mesurés une fois sur le fichier d'entraînement.

Calculer le score. Les deux notes standardisées sont combinées en un seul nombre, $z = w_0 + w_1x_1 + w_2x_2$. Les trois coefficients de cette combinaison sont ceux que la descente détermine (ch. 5); ils portent tout ce que le modèle a appris.

Passer par la logistique. Le score parcourt $\mathbb{R}$, la probabilité tient dans $]0, 1[: p = \sigma(z)$ opère ce passage. Cette étape est la même pour tous les modèles et tous les fichiers, σ étant une fonction fixe.

CONSTANTES DU MODÈLE

	Herbology	Ancient Runes	origine
moyenne μ	1,189	495,052	le fichier
écart-type σ	5,175	105,186	le fichier
coefficient w_j	-3,454	+3,469	l'entraînement
biais w_0	-4,745		l'entraînement

Les deux coefficients sont de signes opposés et de tailles voisines : une note basse en **Herbology** et une note haute en **Ancient Runes** poussent toutes deux le score vers le haut.




FIGURE 3.2. Le trajet complet pour l'élève 3. Les deux premières étapes dépendent du fichier, la troisième des coefficients appris, la quatrième est la même fonction pour tous.

élève	maison réelle	Herbo.	x_1	A. Runes	x_2	z	p
3	Gryffindor	-6,497	-1,485	523,982	+0,275	+1,34	0,792
4	Gryffindor	-7,82	-1,741	599,33	+0,991	+4,71	0,991
1	Slytherin	-5,99	-1,387	367,76	-1,210	-4,15	0,016
0	Ravenclaw	+5,73	+0,877	532,48	+0,356	-6,54	0,001

TABLE 3.1. Quatre élèves du fichier, de la note brute à la probabilité d'être Gryffindor.




FIGURE 3.3. Les trois termes du score de l'élève 3, à l'échelle. Le biais tire vers les autres maisons, les deux notes tirent vers Gryffindor, et la somme reste faible : +1,34 pour des contributions individuelles de l'ordre de 5.

Ses notes standardisées valent $x_1 = -1,485$ et $x_2 = +0,275$, d'où

$$z = -4,745 + (-3,454) \times (-1,485) + 3,469 \times 0,275 = +1,34, \quad p = \frac{1}{1 + e^{-1,34}} = 0,792.$$

Chaque terme du score est un produit de deux nombres signés, et son signe fixe le sens de sa contribution : un terme positif rapproche l'élève de Gryffindor, un terme négatif l'en éloigne. Le signe du coefficient est une propriété de la matière, fixée par l'entraînement pour tous les élèves ; celui de la note standardisée dit seulement si cet élève-ci est au-dessus ou en dessous de la moyenne de sa promotion. La règle des signes combine les deux.

	note sous la moyenne $x < 0$	note au-dessus $x > 0$
coefficient négatif $w < 0$	$w x > 0$ contribue vers Gryffindor	$w x < 0$ Herbology contribue vers les autres
coefficient positif $w > 0$	$w x < 0$ contribue vers les autres	$w x > 0$ Ancient Runes contribue vers Gryffindor

FIGURE 3.4. Le sens de la contribution d'une matière, selon le signe de son coefficient et la position de la note. Sur ce modèle, Herbology a un coefficient négatif et Ancient Runes un coefficient positif : la première ligne décrit donc le comportement d'Herbology, la seconde celui d'Ancient Runes.

Le biais entre dans le score tel quel, sans facteur : sa contribution est la même pour tous les élèves, ici vers les autres maisons. Un élève est donc classé **Gryffindor** lorsque les poussées de ses deux notes l'emportent sur celle du biais.

L'élève 3 illustre la première ligne du tableau : sa note d'**Herbology** est basse, le coefficient est négatif, leur produit contribue en faveur de **Gryffindor**. Sa note d'**Ancient Runes**, légèrement au-dessus de la moyenne, contribue dans le même sens par la seconde ligne. Les deux contributions l'emportent de peu sur le biais, d'où un score de +1,34 et une probabilité de 0,79 : l'élève se tient du côté attendu, près de la frontière. L'élève 4 cumule une note d'**Herbology** très basse et une note d'**Ancient Runes** élevée : les mêmes deux lignes jouent, avec des notes plus marquées, et le score atteint +4,71 pour une probabilité de 0,99.

3.3 Règle de décision

La sigmoïde rend une probabilité, et annoncer une maison demande une réponse. Un *seuil* fait la conversion : au-dessus, le modèle annonce **Gryffindor** ; en dessous, une autre maison. On adopte ici $s = 0,5$, ce qui revient à compter les deux erreurs au même prix.

Le seuil se fixe après l'entraînement, qui détermine les coefficients et avec eux les probabilités. Or les mêmes probabilités, lues avec deux seuils, donnent deux classements.

Sur 0,5, la comparaison se ramène au signe du score,

$$p \geq 0,5 \iff z \geq 0 \iff \text{l'élève est du côté } \textbf{Gryffindor} \text{ de la frontière,}$$

les trois formulations étant équivalentes puisque σ est croissante et vaut 0,5 en zéro. Le programme peut donc s'en tenir aux scores lorsque seule la maison intéresse, et calculer les probabilités uniquement pour les afficher.

Déplacer le seuil échange une erreur contre l'autre, car les deux erreurs possibles portent sur des élèves distincts. Un **Gryffindor** dont la probabilité tombe sous le seuil est manqué. Un élève d'une autre maison dont la probabilité le dépasse est désigné à tort. Monter le seuil rend la désignation plus exigeante : les élèves désignés à tort se raréfient, les **Gryffindor** manqués se multiplient. Le descendre produit l'effet inverse. Toute position en laisse des deux sortes, et choisir un seuil revient à choisir laquelle des deux on préfère commettre.




FIGURE 3.5. Les deux panneaux partagent le même axe horizontal, si bien qu'une position de seuil se lit sur l'un et sur l'autre. En haut, les probabilités rendues par le modèle, séparées selon la maison réelle ; l'échelle verticale est logarithmique, les deux groupes étant de tailles très inégales, et les barres hachurées sont les élèves qu'un seuil de 0,5 classe mal. En bas, ce que devient chaque erreur quand le seuil se déplace : les deux courbes vont en sens contraire et leur somme passe par un minimum, marqué d'un cercle.

Un seuil s quelconque revient de même à comparer le score au logit de s , donc à tracer la droite $z = \text{logit}(s)$, parallèle à celle de 0,5. Changer le seuil translate la frontière sans la faire pivoter, ce qui revient à déplacer le seul biais w_0 (ch. 2).




FIGURE 3.6. Les mêmes élèves qu’au chapitre 1, avec les trois droites correspondant aux seuils 0,3, 0,5 et 0,7. Elles ont la même direction et se suivent de près : l’agrandissement montre les quelques élèves qui changent de réponse d’une droite à l’autre.

Les trois seuils reviennent aux biais $-3,898$, $-4,745$ et $-5,593$, soit des droites distantes de 0,17 écart-type.

seuil	Gryffindor manqués	désignés à tort	total	
0,30	22	33	55	
0,50	24	12	36	seuil retenu
0,58	24	7	31	minimum sur ce fichier
0,70	27	4	31	

Le minimum tombe un peu au-dessus de 0,5 parce que les deux groupes sont de tailles inégales : 327 **Gryffindor** contre 1 273 autres élèves. Une même proportion du grand groupe qui franchit le seuil fournit davantage d'erreurs que la même proportion du petit, si bien qu'un seuil un peu plus exigeant réduit le total. Le programme garde 0,5. Cette valeur vient d'une décision, la même pour tout fichier ; 0,58 est mesuré sur celui-ci et changerait avec lui.

Un seuil franchement différent se justifie lorsque les deux erreurs coûtent des prix différents. Recenser tous les **Gryffindor** quitte à en désigner quelques-uns de trop conduit à l'abaisser ; ne désigner que des cas sûrs conduit à l'élever. Ce choix relève de l'usage fait des prédictions, que les données seules laissent ouvert.

Un seuil tranche entre deux réponses. Le classifieur à quatre maisons compare quatre scores et retient le plus grand, l'ordre suffisant à trancher (ch. 7). La valeur 0,5 garde en revanche partout son autre rôle, celui de la probabilité que rend σ en zéro, qui situe la frontière et donne le coût de départ.

Apport de la probabilité

Deux élèves rangés dans la même maison peuvent l'être avec des assurances très différentes. La probabilité chiffre cette assurance là où la décision les confond, et c'est cette quantité continue qui permettra, au chapitre suivant, de mesurer de combien la frontière est mal placée.

Chapitre 4

Coût, mesure de l'erreur

Déplacer la frontière par le calcul suppose de savoir si elle est mal placée, et de combien. Un seul nombre doit résumer les mille six cents prédictions. Ce nombre est le coût, et il ne dépend que d'une quantité : la probabilité que le modèle accordait à la réponse observée.

4.1 Coût d'un élève

Le fichier donne l'élève 3 pour [Gryffindor](#), et le modèle lui accordait 0,79. Cette probabilité est la quantité à évaluer : plus elle est proche de 1, plus la prédiction est correcte.

L'élève 1 est [Slytherin](#), et le modèle annonçait 0,016 de probabilité d'être [Gryffindor](#), donc 0,984 de ne pas l'être. C'est cette seconde valeur qui entre dans le calcul.

Le coût d'un élève est l'opposé du logarithme de cette probabilité. La fonction ainsi obtenue s'appelle l'*entropie croisée binaire* : elle croise deux distributions sur les deux réponses possibles, celle qu'observe le fichier et celle qu'annonce le modèle, et mesure ce que la seconde coûte lorsque la première est vraie. Son autre nom, log-vraisemblance négative, vient de sa construction (ch. 13).

$$\ell = -\log(\text{probabilité accordée à la bonne réponse}).$$

Le logarithme transforme un produit en somme, ce qui est nécessaire pour agréger mille six cents élèves : le produit d'autant de facteurs inférieurs à 1 passe sous le plus petit flottant représentable.

Une prédiction correcte assortie d'une probabilité élevée coûte presque zéro. Une prédiction fausse assortie de la même probabilité coûte d'autant plus que celle-ci est élevée, et sans borne supérieure : le modèle ne peut donc pas maintenir une prédiction fausse avec une forte probabilité.

élève	maison réelle	p (Gryffindor)	prob. de la vérité	coût
3	Gryffindor	0,792	0,792	0,233
4	Gryffindor	0,991	0,991	0,009
1	Slytherin	0,016	0,984	0,016
0	Ravenclaw	0,001	0,999	0,001

TABLE 4.1. Les quatre élèves du chapitre précédent. Aucun n'est mal classé, donc tous les coûts sont faibles ; le plus élevé est celui de l'élève 3, le cas limite.




FIGURE 4.1. Le coût d'un seul élève. Il vaut $\log 2$ en 0,5, tend vers zéro à droite et croît sans borne à gauche.

4.2 Coût moyen sur le fichier

Le coût précédent juge une prédiction. Placer la frontière demande de juger un modèle, c'est-à-dire les mille six cents prédictions qu'il produit, et de le comparer à un autre modèle. Mille six cents coûts individuels ne se comparent pas : déplacer la frontière améliore en effet les uns et dégrade les autres, et deux modèles se retrouvent meilleurs chacun sur une partie du fichier. Le calcul a besoin d'une quantité unique, qui tranche.

élève	y_i	p_i	coût ℓ_i	
3	1	0,792	0,233	} $J = \frac{1}{m} \sum_{i=1}^m \ell_i = 0,108$
4	1	0,991	0,009	
1	0	0,016	0,016	
0	0	0,001	0,001	
$\vdots$			$\vdots$	
1 600 lignes				

FIGURE 4.2. Les quatre élèves du tableau 4.1, suivis des mille cinq cent quatre-vingt-seize autres. Chacun reçoit son propre coût, et la moyenne les réduit à un seul nombre : celui que la descente fait baisser, et le seul qui permette de comparer deux jeux de coefficients.

La moyenne remplit cet office, et le fait mieux que la somme : celle-ci croît avec le nombre d'élèves, si bien que le même modèle afficherait un coût dix fois plus grand sur un fichier dix fois

plus long. Divisée par m , la valeur reste comparable d'un fichier à l'autre — entre l'entraînement et le test, notamment — et la longueur du pas de la descente conserve le même sens quel que soit le nombre d'élèves.

En notant y_i la réponse, valant 1 pour un **Gryffindor** et 0 sinon, et p_i la probabilité annoncée :

$$J = - \underbrace{\frac{1}{m} \sum_{i=1}^m}_{\text{moyenne sur les élèves}} \left[\underbrace{y_i \log p_i}_{\substack{\text{seul terme retenu} \\ \text{si } y_i = 1}} + \underbrace{(1 - y_i) \log(1 - p_i)}_{\substack{\text{seul terme retenu} \\ \text{si } y_i = 0}} \right]$$

Un seul des deux termes agit pour chaque élève. Pour un **Gryffindor**, $y_i = 1$: le second s'annule et il reste $-\log p_i$. Pour un élève d'une autre maison, $y_i = 0$: le premier s'annule et il reste $-\log(1 - p_i)$. Le facteur y_i joue ainsi le rôle d'un interrupteur, et cette écriture en une seule ligne remplace un branchement, ce qui la rend dérivable d'un bout à l'autre — propriété dont le chapitre suivant a besoin.

Coût au point de départ

Si tous les coefficients valent zéro, tous les scores valent zéro, donc toutes les probabilités valent 0,5. Chaque élève coûte alors $-\log(0,5)$, et la moyenne aussi :

$$J = \log 2 = 0,693147.$$

C'est la première valeur qu'affiche n'importe quel entraînement partant de zéro. Une autre valeur situe l'erreur dans le calcul du score ou dans l'initialisation.

Reste à dire ce qu'on fait de ce nombre. Il dépend des coefficients, seule chose qui varie une fois le fichier fixé : les probabilités p_i viennent des scores, les scores viennent des coefficients. Déplacer la frontière change les mille six cents probabilités, partant les mille six cents coûts, et avec eux leur moyenne. Le coût s'écrit ainsi comme une fonction des trois coefficients, et se note $J(w)$.

Cette dépendance transforme la question de départ. Placer une frontière dans un nuage de points est un problème de géométrie, sans procédé de résolution évident. Chercher les trois nombres qui rendent $J(w)$ le plus petit possible est un problème de minimisation d'une fonction de trois variables, pour lequel il existe des méthodes. Les deux questions ont la même réponse, et c'est la seconde que le programme résout.

Formulation du problème

$$\underbrace{\text{où placer la frontière?}}_{\text{géométrie}} \longrightarrow \underbrace{\text{quel } w \text{ minimise } J(w)?}_{\text{calcul}}$$

La surface que définit $J(w)$ au-dessus des couples de coefficients possibles apparaît à la figure 5.9 ; la méthode consiste à en suivre la pente vers le bas.

Deux questions restent ouvertes sur cette moyenne, et les deux sections suivantes les traitent : ce qu'elle recouvre, mille six cents coûts pouvant se répartir très différemment pour une même valeur, et ce qui la rend préférable au comptage des élèves bien classés.

4.3 Répartition du coût

Le coût moyen final vaut 0,108, et cette valeur agrège mille six cents nombres très inégaux entre eux. L'inégalité tient à la forme du coût individuel. Un élève bien classé et loin de la frontière reçoit une probabilité proche de 1, dont le logarithme est proche de zéro : sa contribution s'éteint. Un élève du mauvais côté reçoit une probabilité d'autant plus petite qu'il en est loin, et $-\log p$ croît alors sans borne. La moyenne se trouve portée par les quelques élèves que le modèle place du mauvais côté avec assurance.




FIGURE 4.3. Chaque élève, coloré par son coût dans le modèle final. La quasi-totalité du nuage est grise, ces élèves contribuant de façon négligeable. Seuls quelques points, tous situés du côté opposé à leur maison, portent une couleur.

CONCENTRATION DU COÛT

part du coût portée par les 2 % les plus coûteux	60,5 %
coût de l'élève le plus coûteux	11,1
coût moyen	0,108

Cet élève est un **Gryffindor** dont la note d'**Herbology** dépasse la moyenne et dont celle d'**Ancient Runes** lui est inférieure : il se tient là où le modèle attend les trois autres maisons.

Conséquence sur l'entraînement

Le coût, et donc la correction qui en découle, dépend principalement d'un petit nombre d'élèves atypiques. Déplacer la frontière pour reclasser ces quelques points fait baisser J davantage qu'augmenter la probabilité accordée aux mille cinq cents autres. De là vient sa sensibilité aux valeurs aberrantes, ce qui impose d'examiner les élèves mal classés et pas seulement la moyenne.

4.4 Comptage et coût

Savoir si une frontière est bien placée admet deux réponses. Compter les élèves du bon côté est la plus directe : le résultat est un nombre entier, qui se lit sans convention. Faire la moyenne des coûts individuels donne un nombre réel, dont la valeur ne s'interprète pas seule. C'est pourtant la seconde qui sert à l'entraînement, et la raison tient à la manière dont chacune réagit lorsque la frontière se déplace.

Le comptage change par sauts. Tant que la frontière se déplace sans que personne ne la traverse, il garde en effet la même valeur, et il saute d'une unité à l'instant où un élève passe de l'autre côté. Sur tout l'intervalle qui sépare deux sauts, il rend la même réponse pour des frontières différentes, et un calcul qui chercherait à l'améliorer recevrait partout la même information.

Le coût répond à tout déplacement. Chaque élève y contribue par la probabilité que le modèle lui accorde, et cette probabilité change dès que la frontière bouge, fût-ce d'un millièmme d'écart-type. La moyenne bouge elle aussi, et le sens dans lequel elle bouge désigne le sens du déplacement à faire.

Trois jeux de coefficients, mesurés sur les mêmes 1 600 élèves, donnent à voir cette différence.

coefficients	frontière	élèves bien classés	coût J
w au 50 ^e tour	—	1 563	0,1438
w au 400 ^e tour	voisine de la précédente	1 564	0,1081
$1,5 w$ au 400 ^e	identique à la précédente	1 564	0,1155

TABLE 4.2. Les deux premières lignes séparent presque les mêmes élèves ; la troisième multiplie les coefficients par 1,5, ce qui laisse la frontière exactement où elle est.

Les deux premières lignes portent des frontières voisines, que le comptage sépare d'une unité et le coût d'un quart de sa valeur : trois cent cinquante tours de travail apparaissent dans une seule des deux mesures. La troisième garde la frontière exactement où elle était, en multipliant les trois coefficients par un même facteur — w et λw s'annulent aux mêmes points. Les mêmes élèves sont du bon côté, le comptage rend le même nombre, et le coût distingue pourtant les deux modèles : l'écartement des probabilités profite peu aux élèves déjà bien classés et pénalise lourdement les trente-six autres.




FIGURE 4.4. Les deux mesures le long d'un déplacement du biais, les deux autres coefficients restant à leur valeur finale. Le nombre de mal classés progresse par paliers — 68 valeurs distinctes sur les 161 positions essayées — et reste plat sur des intervalles entiers : aucune correction ne s'en déduit. Le coût varie à chaque déplacement, ce qui permet d'en tirer une direction. Les deux minima tombent à des endroits différents : le coût est le plus bas en $w_0 = -4,80$, les erreurs les moins nombreuses en $w_0 = -5,68$.

C'est cette sensibilité que le chapitre suivant exploite : une quantité qui répond à tout déplacement, si petit soit-il, se dérive, et sa dérivée indique dans quel sens déplacer les coefficients.

Chapitre 5

Descente de gradient

Le coût dépend des trois coefficients. Reste à déterminer dans quel sens les déplacer. La quantité qui l'indique prend ici une forme simple : l'erreur commise sur un élève, multipliée par sa note. Les valeurs citées proviennent d'une descente exécutée sur les mille six cents élèves.

5.1 Correction à appliquer

Pour chaque coefficient w_j , on calcule

$$\frac{\partial J}{\partial w_j} = \underbrace{\frac{1}{m} \sum_{i=1}^m}_{\text{moyenne sur les } m \text{ élèves}} \underbrace{(p_i - y_i)}_{\text{erreur sur l'élève } i \text{ annoncé moins observé}} \underbrace{x_{ij}}_{\text{sa note dans la matière } j}$$

Cette formule dérive du coût du chapitre précédent (ch. 14).

$p_i - y_i$ est l'erreur commise sur l'élève i : la probabilité annoncée moins la réponse observée. Elle vaut $-0,9$ pour un **Gryffindor** auquel le modèle n'accorde que $0,1$, et $-0,01$ pour un **Gryffindor** déjà reconnu à $0,99$. La correction se trouve négligeable pour un élève correctement classé, maximale pour un élève classé dans l'autre catégorie avec une probabilité élevée.

x_{ij} est sa note dans la matière j . Elle pondère la contribution de l'erreur au coefficient j : un élève aux notes extrêmes contribue fortement, un élève moyen, dont la note standardisée avoisine zéro, presque pas.

Le déplacement se fait en sens inverse, le gradient indiquant la direction dans laquelle le coût augmente :

$$\underbrace{w_j}_{\text{nouvelle valeur}} \leftarrow \underbrace{w_j}_{\text{ancienne valeur}} - \underbrace{\alpha}_{\text{taux d'apprentissage}} \underbrace{\frac{\partial J}{\partial w_j}}_{\text{pente du coût en ce point}} \quad \text{pour tous les } j \text{ à la fois.}$$

Le signe moins constitue l'essentiel de l'algorithme : une pente positive signifie qu'augmenter w_j augmenterait le coût, donc w_j diminue. Le facteur α fixe la longueur du pas : c'est le *taux d'apprentissage*, le seul paramètre de l'algorithme que l'utilisateur fixe lui-même.

Les coefficients sont corrigés simultanément, à partir des mêmes valeurs antérieures. Corriger w_0 puis calculer la correction de w_1 avec le w_0 déjà modifié évaluerait les deux dérivées en deux points distincts.

5.2 Premier pas de la descente

La descente part ici de coefficients nuls. Le point d'arrivée est le même quel que soit le départ, la surface du coût ayant un fond unique (ch. 15) ; partir de zéro rend le premier tour calculable à la main, tous les scores valant alors zéro et toutes les probabilités 0,5. La correction du biais s'écrit alors, puisque x_{i0} vaut 1 pour tout le monde,

$$\frac{\partial J}{\partial w_0} = \frac{1}{m} \sum_{i=1}^m \left(\underbrace{0,5}_{\text{annoncé}} - \underbrace{y_i}_{\text{observé}} \right) = \underbrace{0,5}_{\text{proportion annoncée}} - \underbrace{\frac{327}{1\,600}}_{\text{proportion réelle}} = 0,5 - 0,2044 = 0,2956$$

La descente donne exactement cette valeur, 327 élèves sur 1 600 étant *Gryffindor*. Avec $\alpha = 1$, le biais passe de 0 à $-0,2956$.

Le modèle annonçait 50 % de *Gryffindor* pour une fréquence observée de 20,44 %. Le biais diminue, et continuera de diminuer tant que la moyenne annoncée dépassera cette fréquence.

itération	w_0 (biais)	w_1 (<i>Herbology</i>)	w_2 (<i>Ancient Runes</i>)	coût J
0	0,0000	0,0000	0,0000	0,693147
1	-0,2956	-0,2289	0,1924	0,538507
2	-0,5194	-0,4005	0,3364	0,449297
5	-0,9622	-0,7378	0,6266	0,325975
10	-1,3952	-1,0678	0,9338	0,250029
50	-2,7318	-2,0538	1,9613	0,143846
400	-4,7454	-3,4535	3,4688	0,108113

TABLE 5.1. Descente réelle, $\alpha = 1$, sur les 1 600 élèves. Le coût initial vaut $\log 2$ (ch. 13). Les signes des coefficients se fixent dès le premier tour et ne changent plus : négatif pour *Herbology*, positif pour *Ancient Runes*.

5.3 Coût au fil des itérations

Répéter l'opération précédente quatre cents fois produit une suite de coûts, dont le tracé résume la descente entière. La baisse y est d'abord rapide, puis de plus en plus lente, et cette forme se déduit de la formule de correction.

Au départ, chaque élève contribue autant que les autres : le modèle accorde 0,5 à tout le monde et se trompe ainsi de moitié sur chacun, si bien que les mille six cents erreurs $p_i - y_i$ s'additionnent. À mesure que les probabilités s'ajustent, l'erreur s'éteint pour les élèves que le modèle a placés du bon côté, et la correction ne provient plus que des cas litigieux, qui sont peu nombreux. La somme qui commande le déplacement se vide ainsi de ses termes, tour après tour.




FIGURE 5.1. Les dix premières itérations couvrent les deux tiers de la baisse totale ; les trois cent cinquante dernières n'agissent plus que sur la quatrième décimale.




FIGURE 5.2. La longueur du gradient, en échelle logarithmique. Elle décroît régulièrement : la surface s'aplatit à l'approche du minimum. C'est cette quantité, ou la variation du coût, qui sert de critère d'arrêt.

La seconde figure mesure cet épuisement directement : la longueur du gradient, c'est-à-dire la taille de la correction appliquée à chaque tour. Elle passe de 0,42 à 0,0026 sur les quatre cents itérations, soit une division par cent soixante. C'est de cette décroissance que vient le critère d'arrêt : une correction devenue assez petite laisse les coefficients là où ils sont.

5.4 Déplacement de la frontière

La frontière $w_0 + w_1x_1 + w_2x_2 = 0$ se trace sous sa forme résolue,

$$x_2 = -\frac{w_0 + w_1x_1}{w_2},$$

qui donne l'ordonnée de la frontière pour chaque abscisse. Son déplacement au fil de la descente est trop faible pour être visible à l'échelle du nuage.




FIGURE 5.3. La frontière aux itérations 1, 10 et 400. À l'échelle du nuage, les trois droites se confondent ; le rectangle agrandi les sépare. Elles pivotent autour d'un point situé vers le centre du nuage, d'où un écart nul en ce point et maximal sur les bords. Le déplacement total vaut un tiers d'écart-type.

Trois cent quatre-vingt-dix-neuf itérations pour un tiers d'écart-type : le déplacement de la frontière n'absorbe pas l'essentiel de la descente. Celle-ci agit sur la probabilité, définie en tout point du plan et représentable comme une surface d'altitude p .

itération 1 — transition sur 7,35 écart-type




FIGURE 5.4. Premier tour. La surface est presque plane et traverse le nuage à mi-hauteur : le modèle répond 0,5 ou presque en tout point, et la couleur reste pâle au-dessus des quatre groupes d'élèves. La ligne noire marque les 50 %, le pointillé sa projection dans le plan des notes.

itération 10 — transition sur 1,55 écart-type




FIGURE 5.5. Dixième tour. Les deux plateaux apparaissent, la transition s’est resserrée d’un facteur cinq, et les couleurs se différencient au-dessus des groupes.

itération 400 — transition sur 0,45 écart-type




FIGURE 5.6. Quatre centième tour. Le plateau bleu couvre le groupe des Gryffindor, le plateau brun les trois autres, et la transition tient sur moins d'un demi-écart-type. La couleur indique la maison prédite ; les zones pâles sont celles où la probabilité reste proche de 0,5.

5.5 Niveau 0,5 de la sigmoïde

Cette surface est la sigmoïde (ch. 3) composée avec le score. La frontière tracée jusqu'ici est le lieu où elle vaut exactement 0,5.

Notons d la distance d'un élève à la frontière, comptée perpendiculairement et affectée du signe du côté où il se situe. Alors

$$z = \|w\| d \quad \text{donc} \quad p = \sigma(\|w\| d).$$

Le rapport des coefficients fixe la position de la frontière (ch. 2) et leur norme $\|w\|$ fixe la rapidité avec laquelle la probabilité passe de 0 à 1 de part et d'autre : les deux quantités agissent séparément. Relevée le long de cette perpendiculaire, la probabilité décrit toujours une sigmoïde, d'autant plus comprimée que $\|w\|$ est grand.




FIGURE 5.7. À gauche, le modèle vu de dessus et la direction perpendiculaire à la frontière. À droite, la probabilité relevée le long de cette direction, aux trois itérations. Les trois courbes passent par 0,5 à la même abscisse : la frontière est inchangée. Seule la largeur de la transition varie.

La largeur de cette transition se mesure par la distance qu'il faut parcourir pour que la probabilité passe de 25 % à 75 %, soit $2 \log 3 / \|w\|$: elle est inversement proportionnelle à la norme, et se resserre à mesure que celle-ci grandit.

$\|w\|$ passe de 0,30 à 4,89 entre le premier tour et le quatre centième, et la largeur de transition de 7,35 écarts-types à 0,45 : divisée par seize, comme la norme est multipliée par seize.

La frontière, elle, garde sa place : le tracé de la figure 5.3 le montrait, les deux courbes de la figure 5.8 le mesurent tour par tour.




FIGURE 5.8. La pente de la frontière atteint sa valeur finale en une cinquantaine de tours et n'évolue ensuite que dans la troisième décimale, de 1,047 à 0,996. La norme des coefficients, elle, croît pendant les trois cent cinquante tours suivants, de 2,84 à 4,89. Les trois cent cinquante derniers tours resserrent la sigmoïde autour d'une frontière déjà en place.

Régimes successifs

Quelques itérations suffisent à orienter la frontière. Le reste de la descente augmente la norme des coefficients, ce qui écarte les probabilités de 0,5 en conservant chaque décision. Le coût continue pourtant de décroître, puisqu'il décroît dès que la probabilité accordée à la réponse observée augmente : un critère d'arrêt fondé sur le coût s'arrête donc bien après que le classement s'est stabilisé. Cette croissance de la norme trouve elle-même une limite, que l'annexe A établit.

5.6 Surface du coût

Chaque couple de coefficients produit un coût, calculable sur les mille six cents élèves. Porter ce coût en altitude au-dessus du couple qui le produit définit une surface au-dessus du plan (w_1, w_2) , dont chaque point représente un modèle possible. Le coût dépendant de trois coefficients, sa représentation demanderait quatre dimensions ; fixer le biais à sa valeur finale ramène à deux.

La descente se lit sur cette surface : partant d'un point, elle suit la ligne de plus grande pente et progresse par pas de longueur proportionnelle à α .

Deux propriétés de la surface commandent ce qui précède. Elle admet un minimum unique, propriété que la convexité établit (ch. 15) et dont il résulte que tout point de départ conduit au même modèle. Sa pente décroît par ailleurs à l'approche de ce minimum, ce qui raccourcit les pas successifs et se mesure à la figure 5.2.




FIGURE 5.9. La surface du coût au-dessus du plan (w_1, w_2) , le biais étant figé à sa valeur finale. Chaque point du plan horizontal est un couple de coefficients, et l'altitude au-dessus de lui est le coût que ce couple produit sur les 1 600 élèves. La trajectoire rouge part des coefficients nuls et rejoint le fond. Les courbes tracées au sol sont les lignes de niveau, reprises seules à la figure 5.10, où la trajectoire se lit sans perspective.




FIGURE 5.10. La même surface vue de dessus. Chaque courbe relie les points de coût égal, et la trajectoire les coupe perpendiculairement : c'est la propriété du gradient, qui pointe dans la direction de plus forte pente. Les points marquent une itération sur vingt-cinq, ce qui rend visible le ralentissement : les premiers pas traversent plusieurs niveaux, les derniers se resserrent au fond.

Le coût passe de 0,98 aux coefficients nuls à 0,11 au minimum, le biais étant figé à sa valeur finale.

5.7 Longueur du pas

À chaque tour, le gradient fournit une direction : celle dans laquelle le coût décroît le plus vite depuis le point où l'on se trouve. Il reste muet sur la distance à parcourir dans cette direction, et c'est α qui la fixe, en multipliant le déplacement. Direction et longueur sont deux décisions séparées : la première se calcule, la seconde se règle.

Un pas court avance peu à chaque tour. La correction disponible n'est consommée que par fractions, et il en faut d'autant plus pour parcourir la même distance. Comme un tour demande un passage complet sur les 1 600 élèves, le prix se paie en temps de calcul, pour aboutir à la même frontière.

Un pas long expose au dépassement. Le gradient donne en effet la pente au point de départ, et cette pente ne décrit fidèlement le terrain qu'à son voisinage. Un déplacement assez grand fait sortir de ce voisinage : les coefficients passent de l'autre côté du minimum et remontent la pente opposée, si bien que le coût augmente au lieu de baisser (figure 5.12). Les tours suivants ramènent vers le bas, mais la trajectoire a fait un détour.




FIGURE 5.11. Quarante itérations sur les 1 600 élèves, à partir des mêmes coefficients nuls. Le pas le plus court laisse la courbe très au-dessus des autres : il lui faudrait des centaines de tours pour les rejoindre. Le pas le plus long fait remonter le coût dès le premier déplacement, avant de redescendre.

α	départ	après un tour	après quarante	
0,05	0,693	0,684	0,467	pas trop court
0,3	0,693	0,642	0,238	
1	0,693	0,539	0,153	réglage retenu
100	0,693	0,408	0,112	dépassement au premier pas

Les quatre partent du même coût, $\log 2 = 0,693$, puisque les coefficients nuls donnent 0,5 à tout le monde. À $\alpha = 0,05$, atteindre 0,15 demanderait plusieurs centaines de tours pour la même frontière. À $\alpha = 100$, le premier pas emmène les coefficients au-delà du minimum, et la trajectoire revient ensuite par l'autre versant : quarante tours plus tard, ce réglage a rattrapé son détour et devancé $\alpha = 1$. Ce rattrapage tient à une propriété de ce coût précisément, établie ci-dessous.

α se règle par essais, en lisant la courbe de coût : un bon réglage la fait décroître à chaque tour, vite d'abord puis de moins en moins. On retient ici $\alpha = 1$.

Effet d'un pas excessif

Le déplacement produit par un pas reste borné quel que soit α : la dérivée du coût par rapport au score vaut $p - y$, de valeur absolue inférieure à 1, et la courbure est majorée par $p(1 - p) \leq \frac{1}{4}$. Un α excessif allonge la trajectoire au lieu de faire exploser les valeurs. Sur ces données, $\alpha = 1\,000$ porte le coût à 6,61 au premier tour, puis le fait redescendre tour après tour.




FIGURE 5.12. Le cas général, sur une fonction quadratique d'une seule variable dont le minimum est en 2. À gauche le coefficient s'en approche, à droite il oscille entre deux valeurs sans converger. Ce second comportement suppose une courbure croissant avec la distance ; celle du coût logistique reste majorée par $\frac{1}{4}$.

Critères d'arrêt

Deux critères, employés ensemble. Le premier compare deux coûts successifs : si la baisse relative passe sous ε , la descente a convergé. Le second est un plafond d'itérations, qui borne le temps de calcul lorsque le premier tarde à se déclencher. Sur les 1 600 élèves, la baisse relative passe sous 10^{-6} bien après que la frontière a cessé de se déplacer de façon perceptible : convergence numérique et stabilité des décisions sont deux choses distinctes.

Chapitre 6

Modèle obtenu

La descente s'arrête sur trois nombres, qui constituent le modèle et sont seuls à conserver. Ils s'interprètent directement et suffisent à classer un élève dont on ne connaît que les notes.

6.1 Interprétation des coefficients

$$w_0 = -4,745, \quad w_1 = -3,454 \text{ (Herbology)}, \quad w_2 = +3,469 \text{ (Ancient Runes)}.$$

Le *signe* dit le sens de l'influence. **Herbology** est négatif : plus la note est haute, plus le score baisse, donc moins l'élève est **Gryffindor**. **Ancient Runes** est positif : c'est l'inverse. Le nuage (ch. 2) montre ce croisement, les **Gryffindor** occupant la région en haut à gauche.

La *valeur absolue* mesure le poids de la matière. Les deux valeurs, 3,45 et 3,47, sont presque égales : les deux matières pèsent autant. Cette comparaison n'a de sens que parce que les notes ont été standardisées, donc exprimées dans la même unité. Sur les notes brutes, le coefficient d'**Ancient Runes** serait vingt fois plus petit que celui d'**Herbology**, pour la seule raison que ses valeurs sont vingt fois plus dispersées.

Le *biais* w_0 est le seul des trois à s'appliquer identiquement à tous les élèves. Il reflète la fréquence de base : les **Gryffindor** étant minoritaires, un élève quelconque reçoit un score négatif, et seules des notes suffisamment marquées le ramènent au-dessus de zéro.

Les deux panneaux ci-dessous font varier w_0 puis w_1 autour du modèle obtenu, les autres coefficients restant à leur valeur. Un troisième panneau pour w_2 montrerait un pivotement identique à celui de w_1 : c'est le rapport w_1/w_2 qui fixe la direction de la frontière, et le faire varier par l'un ou par l'autre revient au même.




FIGURE 6.1. À gauche, seul w_0 change : la frontière se translate sans tourner, et la sigmoïde reste identique puisque $\|w\|$ ne dépend que de w_1 et w_2 . À droite, seul w_1 change : la frontière pivote, mais $\|w\|$ change avec elle, donc la pente de la sigmoïde aussi : un coefficient de pondération agit sur deux propriétés à la fois. Le trait épais est le modèle obtenu, les traits pâles deux jeux voisins.

Contenu du modèle enregistré

Trois coefficients, plus les quatre nombres qui ont servi à standardiser — la moyenne et l'écart-type de chaque matière. Ces derniers font partie du modèle : une note brute doit subir exactement la même transformation à la prédiction qu'à l'entraînement, sous peine de produire un score dans une autre échelle.

coefficients ajustés

$w_0 = -4,745$
 $w_1 = -3,454$
 $w_2 = +3,469$

conventions

ordre des matières : **Herbology**, **Ancient Runes**
réponse associée : **Gryffindor** ou non

statistiques d'entraînement

matière	médiane	moyenne	écart-type
Herbology	3,469	1,189	5,175
Ancient Runes	463,918	495,052	105,186

FIGURE 6.2. Un fichier de modèle complet. Appliqués à des notes standardisées avec d'autres statistiques, ou rangées dans un autre ordre, les coefficients produisent des scores parfaitement calculés et des réponses fausses.

6.2 Paramètres appris et paramètres fixés

Les trois coefficients sortent du calcul ; tout le reste a été décidé avant lui, et d'autres décisions auraient donné un autre modèle sur le même fichier.

	valeur ici	ce qui la fixe
déterminé par la descente		
coefficients w	les trois valeurs ci-dessus	les notes et les maisons du fichier
posé avant la descente		
matières retenues	Herbology, Ancient Runes	le choix de deux matières qui se dessinent
remplissage des vides	la médiane	un arbitrage entre deux méthodes (ch. 1)
échelle des notes	centrage-réduction	rendre les coefficients comparables
coefficients de départ	tous nuls	un point de départ quelconque convient
longueur du pas α	1	un essai contrôlé sur la courbe de coût
critère d'arrêt	ε et un plafond	le temps de calcul accordé
seuil de décision	0,5	les deux erreurs comptées au même prix (ch. 3)

TABLE 6.1. Le calcul produit trois nombres ; les sept décisions le précèdent.

Ces décisions restent invisibles dans les trois coefficients enregistrés, et doivent être consignées à côté d'eux pour qu'un tiers puisse refaire le résultat.

6.3 Classement d'un nouvel élève

Le calcul est celui du chapitre 3, la maison n'étant plus connue mais déduite.

1. standardiser les deux notes avec les moyennes et écarts-types d'entraînement ;
2. calculer $z = w_0 + w_1x_1 + w_2x_2$;
3. annoncer Gryffindor si $z \geq 0$.




FIGURE 6.3. La prédiction sur un élève dont la maison est inconnue. Les trois apports du modèle enregistré entrent par le haut et sont repris tels quels sur les nouvelles données. Le signe de z suffit à la décision ; la sigmoïde le convertit en probabilité lorsque celle-ci doit être affichée.

L'étape 3 compare z à zéro, ce qui équivaut à comparer p à 0,5 puisque la sigmoïde est croissante. La sigmoïde sert donc à deux choses : afficher une probabilité, et mesurer l'assurance d'une prédiction pour la comparer à une autre.

Sur les 1 600 élèves du fichier, cette règle en classe correctement 1 564. Les trente-six erreurs relèvent de deux causes, que la distance à la frontière sépare.

La première est le recouvrement des deux groupes. Dans la bande où les *Gryffindor* et les autres élèves occupent la même région du plan, une droite laisse forcément des élèves du mauvais côté, et le choix de sa position ne fait que déplacer lesquels. Ces erreurs se reconnaissent à leur score, faible en valeur absolue, et à la probabilité qui l'accompagne, voisine de 0,5 : le modèle sépare mal ces élèves, et le recouvrement des deux groupes le justifie.

La seconde tient à des élèves dont les notes contredisent leur maison. Ils se trouvent loin dans la région de l'autre groupe, le modèle les classe avec assurance, et il se trompe. Ce sont les élèves atypiques du chapitre 4, dont le coût individuel dépasse cent fois la moyenne. Le plus éloigné se tient à 2,27 écarts-types du mauvais côté.

ERREURS PAR DISTANCE À LA FRONTIÈRE

distance	élèves	
moins de 0,5 écart-type	20	recouvrement des deux groupes
de 0,5 à 1,0	11	
plus de 1,0	5	élèves atypiques, jusqu'à 2,27
total	36	sur 1 600, soit 97,75 % de justes

La distance est comptée perpendiculairement à la frontière, en écarts-types, soit $|z|/\|w\|$.

Mesure faite sur les données d'entraînement

Un taux mesuré sur les élèves qui ont servi à placer la frontière surestime ce que le modèle fera sur des élèves nouveaux : il est toujours meilleur sur les données qu'il a vues. Une mesure valide suppose un ensemble de test mis de côté avant l'entraînement et consulté une seule fois, à la fin (ch. 10).

6.4 Extension à dix notes et quatre maisons

Passer de deux notes à dix ajoute huit coefficients et laisse les formules identiques : la frontière devient l'hyperplan de $\mathbb{R}^{10}$ décrit au chapitre 2. Ce qui change ici est la taille du fichier enregistré.

matières	une maison		quatre maisons	
	coefficients	statistiques	coefficients	statistiques
2	3	6	12	6
10	11	30	44	30
n	$n + 1$	$3n$	$4(n + 1)$	$3n$

TABLE 6.2. Taille du modèle enregistré. Les coefficients se multiplient par le nombre de maisons, les statistiques non : médiane, moyenne et écart-type sont calculés une fois par matière et servent aux quatre modèles.

Le passage à quatre maisons demande une décision de plus. On entraîne quatre modèles comme celui-ci — **Gryffindor** contre le reste, puis **Hufflepuff** contre le reste, et ainsi de suite — ce qui donne quatre scores pour un même élève. La maison retenue est celle du plus grand. Comme la sigmoïde est croissante et commune aux quatre, comparer les scores ou les probabilités revient au même, et la probabilité se calcule seulement pour être affichée.

Chaîne complète

Deux notes situent un élève dans le plan, une frontière linéaire l'y sépare des autres. Le score donne le côté et la distance, la fonction logistique le convertit en probabilité, le coût mesure l'écart aux réponses connues, sa dérivée donne la correction, et l'application répétée de cette correction fixe la frontière.

Chapitre 7

Classification à quatre maisons

Le modèle construit jusqu'ici répond à une seule question : **Gryffindor** ou non. Le problème en compte quatre, et une réponse unique doit en sortir. La construction réutilise les outils déjà en place : le même ajustement est répété pour chaque maison, et les quatre scores obtenus sont comparés.

7.1 Un modèle par maison

Cette stratégie s'appelle *un contre tous*, ou *one-vs-rest*. Pour chaque maison, on reprend le procédé à l'identique, seule la cible changeant :

$$y_i = 1 \text{ si l'élève } i \text{ appartient à la maison traitée,} \quad y_i = 0 \text{ sinon.}$$

Les notes et leur préparation sont inchangées, le tableau **X** est le même pour les quatre modèles ; seule la colonne des réponses change.

maison	$y^{(G)}$	$y^{(H)}$	$y^{(R)}$	$y^{(S)}$
Gryffindor	1	0	0	0
Slytherin	0	0	0	1
Ravenclaw	0	0	1	0
Hufflepuff	0	1	0	0

FIGURE 7.1. Quatre colonnes de réponses construites depuis la même colonne de maisons. Chaque ligne porte exactement un 1 : les quatre modèles sont ajustés séparément, mais leurs cibles restent liées par cette contrainte, qu'aucun d'eux ne connaît.

Quatre descentes indépendantes donnent quatre jeux de coefficients. Sur les deux matières employées ici :

Ces douze nombres se lisent sur le nuage par le procédé du chapitre 6 : le signe de w_1 dit de quel côté en **Herbology** se trouve la maison traitée, celui de w_2 fait de même en **Ancient Runes**.

maison traitée	w_0	w_1 (Herbology)	w_2 (Ancient Runes)
Gryffindor	-4,997	-3,625	+3,655
Hufflepuff	-3,056	+3,889	-4,358
Ravenclaw	-3,729	+4,061	+3,869
Slytherin	-4,545	-3,341	-3,549

TABLE 7.1. Les quatre modèles binaires. Chaque maison correspond à un couple de signes distinct, et les quatre combinaisons possibles sont occupées.

Les quatre maisons occupant chacune un coin du nuage, les quatre couples de signes possibles se trouvent employés, un par maison.

Les quatre biais, eux, sont négatifs pour une raison commune : chaque maison est minoritaire face aux trois autres réunies, si bien qu'un élève pris au hasard reçoit un score négatif dans les quatre modèles.

7.2 Règle du score maximal

Un nouvel élève reçoit quatre scores, un par maison. La règle de décision est le maximum :

$$\text{maison prédite} = \arg \max_k z_k, \quad z_k = w_{k0} + w_{k1}x_1 + w_{k2}x_2.$$

Cette règle prend la place du seuil employé au chapitre 3 : avec quatre réponses possibles, c'est l'ordre des scores qui décide. Comparer les scores ou comparer les probabilités revient d'ailleurs au même, σ étant croissante et identique pour les quatre modèles, donc l'ordre se conserve d'un côté à l'autre. La décision se prend sur les quatre scores, et les probabilités ne se calculent que pour être affichées.

L'élève 3, de notes standardisées $x_1 = -1,485$ et $x_2 = +0,275$, donne

$$\begin{aligned} z_G &= -4,997 - 3,625 \times (-1,485) + 3,655 \times 0,275 = +1,393, \\ z_H &= -3,056 + 3,889 \times (-1,485) - 4,358 \times 0,275 = -10,031, \\ z_R &= -3,729 + 4,061 \times (-1,485) + 3,869 \times 0,275 = -8,697, \\ z_S &= -4,545 - 3,341 \times (-1,485) - 3,549 \times 0,275 = -0,558. \end{aligned}$$

Le maximum est z_G , et la maison prédite est celle de l'élève. L'écart avec le deuxième score vaut près de deux unités, ce qui rend la décision franche.

élève	z_G	z_H	z_R	z_S	prédiction
3	+1,393	-10,031	-8,697	-0,558	Gryffindor , sa maison
571	-6,829	-1,125	-1,046	-6,781	Ravenclaw , alors qu'il est Hufflepuff

TABLE 7.2. Deux élèves passés aux quatre modèles ; le score retenu est en gras. L'élève 571 départage **Ravenclaw** et **Hufflepuff** sur un écart de 0,079, et la règle se trompe. Ses quatre scores sont négatifs, ce qui signifie que les quatre modèles binaires répondent « non » : le maximum reste le moins mauvais des quatre.




FIGURE 7.2. À gauche, les quatre frontières, chacune séparant une maison des trois autres. À droite, le découpage du plan qui en résulte : chaque point reçoit la maison dont le score est le plus élevé. Les limites de ces quatre régions ont leur propre direction, établie à la section suivante.

7.3 Des quatre frontières aux quatre régions

Chacune des quatre droites sépare une maison des trois autres, et la maison attribuée à un point du plan résulte de la comparaison de ses quatre scores. Parcourir un trajet rend cette comparaison visible : le long d'un segment, chaque score est une fonction affine du chemin parcouru, donc une droite.



FIGURE 7.3. Le trajet du panneau de gauche part du groupe des **Gryffindor** et rejoint celui des **Hufflepuff**. À droite, les quatre scores relevés le long de ce trajet. Le maximum des quatre est la ligne brisée en trait épais : elle appartient à **Gryffindor** sur le premier tiers, à **Ravenclaw** ensuite, à **Hufflepuff** pour finir. Les deux points anguleux sont les endroits où deux scores s'égalisent, et ce sont eux qui marquent le passage d'une région à la suivante.

Le maximum de quatre fonctions affines est une ligne brisée dont chaque segment appartient à une maison. Les points anguleux vérifient l'égalité de deux scores, et cette égalité s'écrit comme une équation de droite :

$$z_G = z_R \iff (w_{G0} - w_{R0}) + (w_{G1} - w_{R1})x_1 + (w_{G2} - w_{R2})x_2 = 0.$$

La limite entre deux régions est donc une droite, de vecteur normal $w_G - w_R$ obtenu en soustrayant terme à terme les deux jeux de coefficients. Sur le modèle à deux matières,

$$w_G - w_R = (-4,997 + 3,729; -3,625 - 4,061; +3,655 - 3,869) = (-1,268; -7,686; -0,214),$$

La limite est la droite $-1,268 - 7,686x_1 - 0,214x_2 = 0$, presque verticale puisque son vecteur normal est presque horizontal : elle coupe l'axe des **Herbology** en $x_1 = -0,165$.




FIGURE 7.4. Les deux frontières binaires de **Gryffindor** et de **Ravenclaw**, et la limite qui sépare effectivement leurs deux régions. Cette limite a sa propre direction, portée par le vecteur normal $w_G - w_R$, et passe par le point d'intersection des deux premières : en ce point les deux scores valent 0, donc ils sont égaux.

Quatre maisons forment six paires, donc six droites d'égalité. Chacune ne borde une région que sur la portion où le score commun aux deux maisons dépasse aussi les deux autres : c'est ce qui donne au découpage ses arêtes de longueur finie, visibles sur le panneau de droite de la figure 7.2. Les quatre modèles, ajustés séparément, produisent ainsi un découpage cohérent du plan.

7.4 Contenu du classifieur

Avec dix matières au lieu de deux, chaque modèle a onze coefficients au lieu de trois, sans autre modification. Le classifieur complet se réduit alors à :

	biais	une colonne par matière						
Gryffindor	w_0	w_1	w_2	w_3	...	w_{10}	} $4 \times 11 = 44$ coefficients, plus $3 \times 10 = 30$ statistiques, plus deux listes ordonnées	
Hufflepuff	w_0	w_1	w_2	w_3	...	w_{10}		
Ravenclaw	w_0	w_1	w_2	w_3	...	w_{10}		
Slytherin	w_0	w_1	w_2	w_3	...	w_{10}		

FIGURE 7.5. Le classifieur complet, pour dix matières. Chaque ligne est un modèle binaire indépendant, chaque colonne une matière ; la première colonne ne correspond à aucune note. Les 44 coefficients demandent leur contexte : les trois statistiques par matière et l'ordre des lignes et des colonnes, faute de quoi ils s'appliquent à des quantités inconnues.

— quatre vecteurs de onze coefficients, soit 44 nombres ;

- la liste ordonnée des dix matières, qui dit à quelle note s'applique chaque coefficient ;
- la liste ordonnée des quatre maisons, qui dit quel vecteur correspond à quelle réponse ;
- pour chaque matière, la valeur d'imputation, la moyenne et l'écart-type appris à l'entraînement.

Ordre des colonnes et des maisons

Un vecteur de coefficients s'applique aux notes dans l'ordre où il a été ajusté, et l'indice du maximum ne devient une maison que par la liste des libellés. Perdre l'un ou l'autre de ces ordres donne un classifieur qui calcule des scores justes et rend des maisons fausses : une défaillance qui ne provoque aucune erreur d'exécution.

7.5 Somme des quatre probabilités

Chaque $\sigma(z_k)$ répond à sa propre question binaire : *cet élève est-il un Gryffindor ?*, puis la même pour les trois autres maisons. Quatre expériences séparées, et donc quatre nombres libres les uns des autres, dont la somme prend une valeur quelconque entre 0 et 4.




FIGURE 7.6. Les quatre probabilités de trois élèves du fichier, et leur somme. Le premier reçoit moins de 0,09 des quatre modèles, et sa maison est pourtant correctement prédite : seul l'ordre compte. Le dernier dépasse 0,89 pour deux maisons à la fois. Sur les 1 600 élèves, la somme excède 1 dans 981 cas et lui reste inférieure dans 619.

La décision lit l'ordre de ces quatre nombres, et cet ordre reste valide quelle que soit leur somme. Lire chacun d'eux comme une part d'un tout demanderait en revanche que la somme vaille 1 : c'est à cette condition qu'une phrase telle que « 0,95 de chances d'être Gryffindor » prend son sens, et l'élève 1067 montre où elle conduit ici, avec 0,949 pour Gryffindor et 0,897 pour Ravenclaw. Le modèle qui fournit directement une telle distribution est la régression softmax, qui ajuste les quatre jeux de coefficients ensemble plutôt que séparément.

Classifieur complet

Quatre modèles binaires ajustés indépendamment sur les mêmes notes, et une comparaison de leurs quatre scores. Sur *Herbology* et *Ancient Runes*, cette règle classe correctement 1 540 élèves sur 1 600 ; avec les dix matières du fichier, elle dépasse 98 %.

Deuxième partie

Construire

Chapitre 8

Du score au coût

Le modèle est établi; il reste à l'écrire, en Python et sans bibliothèque de calcul. Quatre étapes mènent du score d'un seul élève au coût moyen sur les mille six cents, chacune vérifiable par un nombre connu d'avance.

Le programme se répartit en neuf fichiers exécutables l'un après l'autre. Chacun importe le précédent, ajoute une fonction, et affiche un nombre qui se contrôle avant de passer au suivant.

le coût	step1_score.py	le score d'un élève
	step2_sigmoid.py	la sigmoïde, écrite pour ne pas déborder
	step3_single_cost.py	le coût d'une prédiction
	step4_total_cost.py	la lecture du fichier, le coût moyen
la descente	step5_gradient.py	la pente, et sa vérification par mesure
	step6_one_step.py	un pas de descente
	step7_loop.py	la boucle et ses deux arrêts
les maisons	step8_four_houses.py	quatre descentes, le plus grand score
	step9_holdout.py	l'exactitude hors des élèves appris

FIGURE 8.1. Les cinq derniers fichiers importent tous `step4`, dont `load` et `total_cost` servent jusqu'à la dernière étape.

8.1 Étape 1 : le score d'un élève

Le score est une somme de trois produits. Les deux notes arrivent déjà standardisées, opération traitée à l'étape 4, et les trois coefficients valent zéro.

```
x = [1.0, -1.485, 0.275] # student 3; the 1.0 carries the bias
weights = [0.0, 0.0, 0.0]

score = weights[0] * x[0] + weights[1] * x[1] + weights[2] * x[2]
print("score:", score)
```

```
score: 0.0
```

Le 1,0 en tête de x vaut 1 pour tous les élèves : c'est la colonne du biais, qui fait entrer $weights[0]$ dans la somme sans le multiplier par une donnée. Sans elle, chaque formule ultérieure devrait traiter $weights[0]$ à part, y compris celle de la pente.

Des coefficients nuls donnent un score nul pour n'importe quel élève. La sortie ne contrôle donc que la mécanique de la somme.

8.2 Étape 2 : du score à la probabilité

Le score parcourt tout $\mathbb{R}$, la probabilité doit tomber entre 0 et 1. La fonction logistique opère ce passage (ch. 11).

```
def sigmoid(z):
    if z >= 0:
        return 1 / (1 + exp(-z))
    return exp(z) / (1 + exp(z)) # exponent stays negative
```

Les deux branches calculent la même valeur et diffèrent par le seul exposant employé. En double précision, e^u dépasse le plus grand flottant représentable dès $u > 709,78$: l'écriture $1/(1 + e^{-z})$ échoue donc pour tout score inférieur à -710 , alors que la valeur cherchée est simplement 0. Multiplier haut et bas par e^z donne $e^z/(1 + e^z)$, dont l'exposant reste négatif de ce côté : e^{-800} passe sous le plus petit flottant, vaut 0 sans lever d'exception, et le quotient rend 0.

```
sigmoid(0)      = 0.5
sigmoid(2)      = 0.8808
sigmoid(-800)   = 0.0
single branch : OverflowError, math range error
```

La dernière ligne exécute l'écriture à une seule branche sur le même nombre. Un score de -800 apparaît dès qu'un coefficient diverge (ch. 15).

Contrôle en zéro

$\sigma(0)$ vaut 0,5 exactement. Une fonction qui rend autre chose en zéro est fausse, et tout ce qui la suit le sera.

8.3 Étape 3 : le coût d'une prédiction

Le modèle annonce une probabilité, le fichier donne la réponse observée. Le coût mesure l'écart entre les deux.

```
def student_cost(score, expected):  
    # expected: 1.0 if the student is in the house, 0.0 otherwise  
    p = sigmoid(score)  
    return -(expected * log(p) + (1 - expected) * log(1 - p))
```

Les deux termes ne servent jamais ensemble : `expected` annule l'un et conserve l'autre.




FIGURE 8.2. Le facteur nul annule son terme avant que le logarithme ne soit évalué ; aucune des deux branches ne calcule $\log 0$ tant que p reste strictement entre 0 et 1, ce que garantit la sigmoïde.

```
no opinion, student inside the house : 0.693147  
no opinion, student outside          : 0.693147  
confident and right                 : 0.002476  
confident and wrong                 : 6.002476  
log(2) = 0.693147
```

Les deux premières lignes correspondent à $z = 0$, donc $p = 0,5$: le coût vaut $\log 2$ quelle que soit la réponse attendue, puisque les deux termes sont alors symétriques. Les deux suivantes correspondent à $z = 6$, donc $p = 0,9975$. Cette probabilité coûte 0,0025 lorsqu'elle porte sur la réponse observée et 6,0025 lorsqu'elle porte sur l'autre : pour une prédiction fausse assortie d'un score élevé, le coût croît comme $|z|$, sans borne supérieure.

8.4 Étape 4 : le coût moyen

Deux traitements précèdent l'emploi des notes brutes.

```
def standardise(marks):  
    known = sorted(v for v in marks if v is not None)  
    median = known[len(known) // 2]  
    filled = [v if v is not None else median for v in marks]  
    mean = sum(filled) / len(filled)  
    sd = (sum((v - mean) ** 2 for v in filled) / len(filled)) ** 0.5  
    return [(v - mean) / sd for v in filled]
```

Herbology compte 33 notes absentes et **Ancient Runes** 35, sur 1 600 lignes. Elles reçoivent la médiane de leur colonne plutôt que la moyenne : quelques notes extrêmes déplacent la seconde et non la première.

Les deux colonnes n'ont ensuite ni le même centre ni la même dispersion. **Herbology** a pour moyenne 1,19 et pour écart-type 5,18, **Ancient Runes** 495,05 et 105,19. Un même coefficient produirait donc dans la seconde un effet vingt fois plus grand que dans la première, pour une raison qui tient à l'unité de la note et non à ce qu'elle dit de l'élève. Après retrait de la moyenne et division par l'écart-type, les deux colonnes ont pour moyenne 0 et pour écart-type 1, et un coefficient de 3 signifie la même chose des deux côtés.

```
def load():
    data = Data(TRAIN)
    columns = [standardise(data.courses[course]) for course in COURSES]
    X = []
    for row in range(len(data.houses)):
        X.append([1.0] + [column[row] for column in columns])
    return X, data.houses
```




FIGURE 8.3. La médiane d'**Ancient Runes**, 463,92, remplace la note absente du troisième élève et donne -0,296 après standardisation. Sa ligne reste exploitable.

Le coût moyen se calcule alors élève par élève, en réutilisant les deux fonctions précédentes.

```
def score_of(weights, x):
    total = 0.0
    for column in range(len(weights)):
        total += weights[column] * x[column]
    return total

def total_cost(weights, X, target):
    total = 0.0
    for x, expected in zip(X, target):
        total += student_cost(score_of(weights, x), expected)
    return total / len(X)
```




FIGURE 8.4. L'élève 3 traversant les trois fonctions, coefficients nuls. Les coefficients n'interviennent qu'au premier passage et la réponse attendue qu'au dernier : entre les deux, le calcul ne dépend plus des données.

```

1600 students, 3 columns (bias included)
cost with zero weights: 0.693147

```

Contrôle de sortie

Sur des coefficients nuls, le programme doit afficher 0,693147 (ch. 4). Cette valeur est la même pour tout fichier, tout choix de matières et tout nombre d'élèves : un écart localise donc l'erreur dans le score, la sigmoïde ou le coût.

Le programme sait maintenant juger un jeu de coefficients. En produire un meilleur est l'objet du chapitre suivant.

Chapitre 9

Recherche de meilleurs coefficients

Le chapitre précédent s'arrête sur une fonction qui évalue un jeu de coefficients. Les trois étapes qui suivent produisent la pente du coût, la contrôlent contre une mesure indépendante, puis l'appliquent en boucle jusqu'à stabilisation.

Après avoir jugé un jeu de coefficients, il reste à savoir dans quel sens les déplacer, et à vérifier que cette direction est la bonne avant d'en tirer une boucle d'entraînement.

9.1 Étape 5 : la pente et sa vérification

La pente du coût par rapport à chaque coefficient s'obtient par une formule démontrée au chapitre 14. Les trois pentes sortent ensemble d'un seul passage sur les élèves.

```
def gradient(weights, X, target):
    slope = [0.0] * len(weights)
    for x, expected in zip(X, target):
        error = sigmoid(score_of(weights, x)) - expected
        for column in range(len(weights)):
            slope[column] += error * x[column]
    return [s / len(X) for s in slope]
```

Une erreur de signe ou un indice décalé produit ici un programme qui s'exécute, converge lentement et reste silencieux. La formule se contrôle sans démonstration, en mesurant ce qu'elle prétend calculer : une pente est un rapport d'accroissements, obtenu en déplaçant un coefficient dans les deux sens et en divisant l'écart de coût par la distance parcourue.

```
def measured_slope(weights, X, target, column, h=1e-5):
    below, above = list(weights), list(weights)
    below[column] -= h
    above[column] += h
    rise = total_cost(above, X, target) - total_cost(below, X, target)
    return rise / (2 * h)
```


Cette seconde fonction ignore tout de la régression logistique. Elle appelle deux fois le coût de l'étape 4 et divise, ce qui représente deux passages complets sur les 1 600 élèves pour un seul coefficient : inutilisable dans une boucle d'entraînement, mais indépendant de la formule qu'elle contrôle.




FIGURE 9.1. Le point d'évaluation est choisi loin de zéro. Plusieurs erreurs classiques — facteur $1/m$ omis, indice décalé — rendent zéro des deux côtés en $(0, 0, 0)$ et passeraient inaperçues.

column	from the formula	measured	gap
0	+0.358202569	+0.358202569	9.04e-11
1	+0.071184453	+0.071184453	3.30e-11
2	-0.098350181	-0.098350181	3.91e-11

L'écart résiduel vient de la mesure, pas de la formule. Une différence centrée sur un pas h commet une erreur en h^2 , soit 10^{-10} pour $h = 10^{-5}$, ce que les trois lignes retrouvent. Un h plus grand mesurerait une corde au lieu d'une tangente ; un h plus petit ferait perdre à la soustraction ses décimales significatives.

Ordre de grandeur de l'écart

Un écart de l'ordre de 10^{-10} valide la formule. Un écart de 10^{-2} désigne un facteur oublié, un signe opposé désigne une soustraction inversée, et une seule colonne fausse désigne l'indice.

9.2 Étape 6 : un pas

Descendre consiste à retrancher la pente, multipliée par la longueur du pas.

```
ALPHA = 1.0
```

```
def one_step(weights, X, target):
    slope = gradient(weights, X, target)
    return [w - ALPHA * g for w, g in zip(weights, slope)]
```

turn 0	cost 0.693147	weights +0.0000	+0.0000	+0.0000
turn 1	cost 0.538507	weights -0.2956	-0.2289	+0.1924
turn 2	cost 0.449297	weights -0.5194	-0.4005	+0.3364
turn 3	cost 0.393020	weights -0.6955	-0.5348	+0.4500

Le premier biais se recalcule à la main, et c'est le contrôle à faire ici. Les coefficients étant nuls, le modèle annonce 0,5 pour les 1 600 élèves. La pente du biais est la moyenne des écarts $\sigma(z) - y$, où y vaut 1 pour les **Gryffindor** et 0 pour les autres.

Gryffindor, 20,44 %



$$\sigma(0) - 1 = -0,5$$

$$\sigma(0) - 0 = +0,5$$

$$\text{moyenne} = \frac{1\,273 \times 0,5 - 327 \times 0,5}{1\,600} = 0,2956$$

FIGURE 9.2. Le pas retranche cette moyenne au biais, d'où $-0,2956$ au premier tour. Le biais se déplace donc vers la valeur qui fait annoncer 20,44 % à tout le monde, ce que peut faire de mieux un modèle réduit à son biais.

ALPHA est le taux d'apprentissage α . À 1 sur des colonnes standardisées, le coût baisse dès le premier tour ; s'il augmentait, la cause serait un pas trop long ou un signe inversé dans la correction.

La nouvelle liste de coefficients est construite, non modifiée en place. Corriger `weights[0]` avant de calculer la correction de `weights[1]` évaluerait les deux pentes en deux points différents, faute qu'une liste neuve rend impossible.

9.3 Étape 7 : itération jusqu'à stabilisation

```
EPSILON, MAX_ITER = 1e-6, 6000

def descend(X, target):
    weights = [0.0] * len(X[0])
    previous = float('inf')
    for iteration in range(1, MAX_ITER + 1):
        cost = total_cost(weights, X, target)
        if abs(previous - cost) / max(1, abs(cost)) < EPSILON:
            return weights, cost, iteration
        previous = cost
        weights = one_step(weights, X, target)
    return weights, cost, MAX_ITER
```




FIGURE 9.3. Le coût est calculé une fois par tour, pour le seul test d'arrêt. Le gradient constitue un second passage sur les 1 600 élèves : une itération en coûte donc deux.

Les deux conditions d'arrêt sont nécessaires l'une comme l'autre. La première compare la baisse du coût à sa valeur, en relatif : sous `EPSILON`, les tours suivants ne déplacent plus la frontière de façon mesurable. La seconde est un plafond, et il est indispensable : dans certaines configurations, la première ne se déclenche jamais parce que les coefficients divergent (annexe A).

```
stopped after 652 iterations, cost 0.107387
weights: -5.0360 -3.6513 +3.6841
```

Le nombre d'itérations se lit en premier. À 652 pour un plafond de 6 000, c'est le critère de stagnation qui a mis fin à la boucle. Une valeur égale au plafond signalerait un pas trop court, ou l'absence de minimum.

Les figures de la première partie s'arrêtent au quatre-centième tour et donnent $-4,745$, $-3,454$, $+3,469$. Les rapports entre coefficients y sont déjà ceux d'ici à trois millièmes près : la frontière est en place bien avant que le coût cesse de baisser, et les 252 derniers tours ne font qu'accentuer la pente de la sigmoïde de part et d'autre.

Fonction d'entraînement

Une fonction qui prend un tableau de notes et une colonne de réponses, et rend trois nombres.
Il reste à l'employer quatre fois.

Chapitre 10

Quatre maisons et mesure de l'exactitude

La descente du chapitre précédent traite une maison. Les deux dernières étapes l'appliquent aux quatre, puis mesurent l'exactitude du résultat sur des élèves que le modèle n'a jamais vus — seule mesure qui prédise quelque chose.

La boucle précédente répond à une seule question : cet élève est-il [Gryffindor](#). Il en faut quatre, et il faut en tirer une réponse unique. L'exactitude obtenue demande ensuite d'être mesurée sur des élèves que le modèle n'a pas vus.

10.1 Étape 8 : la même descente, quatre fois

La descente, le coût et le gradient sont ceux de l'étape précédente, appelés quatre fois de suite. Seule la colonne des réponses est refaite à chaque tour : elle vaut 1 pour la maison traitée et 0 pour les trois autres.

```
def train(X, houses):
    model = {}
    for house in HOUSES:
        target = [1.0 if h == house else 0.0 for h in houses]
        model[house], cost, iterations = descend(X, target)
        print(f" {house:<12} cost {cost:.4f} {iterations:>4} iterations")
    return model

def predict(model, x):
    return max(HOUSES, key=lambda house: score_of(model[house], x))
```

Gryffindor	cost 0.1074	652 iterations
Hufflepuff	cost 0.1369	544 iterations
Ravenclaw	cost 0.1310	565 iterations
Slytherin	cost 0.1354	568 iterations

1540 students out of 1600 get their house, that is 0.9625

Les quatre coûts sont du même ordre et aucune descente n'a touché son plafond : les quatre maisons se séparent aussi bien les unes que les autres sur ces deux matières.

	quatre jeux de coefficients			scores	
Gryffindor	-5,036	- 3,651	+ 3,684	+1,401	→ predict Gryffindor
Hufflepuff	-3,032	+ 3,859	- 4,325	-9,954	
Ravenclaw	-3,710	+ 4,040	+ 3,852	-8,651	
Slytherin	-4,525	- 3,327	- 3,531	-0,555	

FIGURE 10.1. L'élève 3 passé aux quatre modèles. **Slytherin** arrive deuxième avec $-0,555$: ses coefficients ont le même signe que ceux de **Gryffindor** sur **Herbology** et le signe opposé sur **Ancient Runes** : les deux maisons occupent le même côté du nuage et ne se départagent que sur la seconde note.

`predict` retient le plus grand des quatre scores. Comparer les scores ou les probabilités revient au même, la sigmoïde étant croissante et commune aux quatre modèles : elle conserve l'ordre. Son calcul est réservé à l'affichage d'une probabilité.

10.2 Étape 9 : mesure sur des élèves inconnus

96,25 % surestime nettement la performance réelle. Ces 1 600 élèves sont exactement ceux qui ont servi à placer les quatre frontières, et les reclasser ne mesure donc pas la capacité du modèle à traiter un élève inconnu. La mesure correcte scinde le fichier en un *ensemble d'apprentissage*, qui sert à ajuster les coefficients, et un *ensemble de test* mis de côté avant l'entraînement et consulté une seule fois, à la fin.

```
def split(houses, part=0.8, seed=0):
    state, learn, test = seed, [], []
    # drawn house by house, so both sides keep the same proportions
    for house in HOUSES:
        rows = [i for i, h in enumerate(houses) if h == house]
        for k in range(len(rows) - 1, 0, -1):
            state = (state * 1103515245 + 12345) % (1 << 31)
            j = state % (k + 1)
            rows[k], rows[j] = rows[j], rows[k]
        cut = round(part * len(rows))
        learn += rows[:cut]
        test += rows[cut:]
    return learn, test

def accuracy(model, X, houses, rows):
    right = sum(1 for i in rows if predict(model, X[i]) == houses[i])
    return right / len(rows)
```




FIGURE 10.2. Teinte pleine, les 1 280 élèves d'apprentissage ; teinte claire, les 320 mis de côté. Le tirage prend 80 % de chaque maison, non 80 % du fichier. Un tirage global laisserait les quatre proportions varier d'une exécution à l'autre, et **Slytherin**, la plus petite maison, en subirait l'écart le plus large.

Le mélange se fait sur les indices, par un générateur écrit sur place plutôt que par `random.shuffle`. Chaque nombre tiré s'obtient du précédent par

$$\text{état} \leftarrow (a \text{ état} + c) \bmod 2^{31},$$

avec deux constantes éprouvées. Repartir du même état initial — la graine 0 — redonne la même suite, donc le même découpage à chaque exécution, sans quoi deux mesures ne seraient pas comparables.

1280 students to learn from, 320 set aside

Gryffindor	cost 0.1087	657 iterations
Hufflepuff	cost 0.1467	494 iterations
Ravenclaw	cost 0.1309	561 iterations
Slytherin	cost 0.1429	529 iterations

on students already seen : 0.9609
on students never seen : 0.9719
everyone into Hufflepuff : 0.3312




FIGURE 10.3. Le plancher est l'exactitude d'une règle qui attribuerait *Hufflepuff* à tout le monde. L'écart entre apprentissage et test vaut onze millièmes, soit trois ou quatre élèves sur les 320 mis de côté : l'ordre de grandeur de la variation qu'induirait un autre tirage.

Le premier chiffre porte sur les élèves d'apprentissage et reste optimiste par construction. Le deuxième porte sur 320 élèves que le modèle n'a jamais vus : c'est le seul qui prédise quelque chose sur un élève à venir. Le troisième donne le plancher, celui qu'obtient une règle qui met tout le monde dans la maison la plus nombreuse ; un modèle doit le dépasser nettement pour démontrer un apport.

Écart entre apprentissage et test

Ici le second dépasse même le premier, écart qui reste dans la marge d'un échantillon de 320 élèves. Un modèle à 99 % sur l'apprentissage et 85 % sur le test aurait au contraire appris les élèves plutôt que la règle : c'est le *surapprentissage*, et l'écart entre les deux mesures en est le seul révélateur. Trois coefficients par maison n'offrent pas assez de liberté pour cela ; avec les treize matières du fichier, donc quatorze coefficients, la question se pose.

10.3 Compléments pour un programme livrable

Trois ajouts séparent ce qui précède d'un programme utilisable sur un fichier d'élèves inconnus.

Enregistrer le modèle. Les quatre vecteurs, mais aussi les trois statistiques par matière, la liste ordonnée des matières et celle des maisons. Un coefficient s'applique à la note qui occupait sa place pendant l'entraînement, et le plus grand score ne devient une maison que par la liste des libellés. Perdre l'un de ces ordres donne des scores justes et des réponses fausses, sans aucune erreur d'exécution.

Appliquer les statistiques d'entraînement à la prédiction. Un élève inconnu reçoit la médiane, la moyenne et l'écart-type appris sur les élèves d'entraînement, jamais les siens. Recalculer ces trois nombres sur les nouvelles données placerait les scores dans une autre échelle ; sur un fichier d'un seul élève, l'écart-type serait nul et l'opération n'aurait pas de sens.

Lire les erreurs. Le tableau qui croise maison réelle et maison prédite, la *matrice de confusion*, indique quelles maisons sont confondues, là où le taux global les agrège en un seul nombre : ses 16 cases distinguent une maison systématiquement manquée d'erreurs réparties au hasard.

Étapes du programme

Un score, une probabilité, un coût, une pente vérifiée contre une mesure, un pas, une boucle, quatre maisons, un découpage stratifié. Une centaine de lignes de fonctions sans bibliothèque de calcul, deux cent trente avec les imports et les affichages de contrôle, et 97,19 % de réponses justes sur des élèves jamais vus.

Les formules employées ici sont démontrées dans la partie suivante.

Troisième partie

Démontrer

Chapitre 11

Construction de la fonction logistique

Le score z parcourt $\mathbb{R}$, la probabilité est comprise entre 0 et 1. Il faut une fonction qui relie les deux. Plutôt que d'en postuler une, on procède en sens inverse : on transforme la probabilité jusqu'à ce qu'elle parcoure $\mathbb{R}$, et l'inversion de cette transformation donne la fonction logistique.

11.1 Première transformation : la cote

Une probabilité p appartient à $[0, 1]$. Le rapport

$$\frac{p}{1-p}$$

s'appelle la *cote*. C'est le langage des paris : une cote de 3 signifie trois chances contre une. Ce rapport vaut 0 quand $p = 0$, vaut 1 quand $p = 0,5$, et croît sans borne quand p approche 1.

p	$1-p$	cote $p/(1-p)$	log de la cote
0,10	0,90	0,111	-2,197
0,25	0,75	0,333	-1,099
0,50	0,50	1,000	0,000
0,75	0,25	3,000	+1,099
0,90	0,10	9,000	+2,197

TABLE 11.1. La cote transporte $[0, 1]$ vers $[0, +\infty[$, son logarithme vers $\mathbb{R}$ tout entier. La dernière colonne est symétrique autour de $p = 0,5$: c'est la propriété que le score doit posséder.

La cote atteint ainsi toutes les valeurs positives ; restent les négatives.




FIGURE 11.1. Les trois intervalles. La cote étire $[0, 1]$ sur $[0, +\infty[$ en envoyant 0,5 sur 1 ; le logarithme envoie ce demi-axe sur $\mathbb{R}$ tout entier en plaçant 1 à l'origine. La composée est donc une bijection croissante de $]0, 1[$ sur $\mathbb{R}$, ce qui autorise à poser son égalité avec le score.

11.2 Seconde transformation : le logarithme

Le logarithme envoie $]0, +\infty[$ sur $\mathbb{R}$: il vaut $-\infty$ près de zéro, 0 en 1, et croît sans borne. En le composant avec la cote, on obtient la *log-cote*

$$\log \frac{p}{1-p},$$

qui prend toutes les valeurs réelles, exactement comme le score z . Rien n'empêche plus de poser leur égalité :

$$\boxed{\log \frac{p}{1-p} = z = \sum_{j=0}^n w_j x_j} \quad (\star)$$

Cette égalité constitue l'unique hypothèse de la régression logistique : les log-cotes sont supposées être une somme pondérée des notes ; les seize pages qui suivent n'en font que dérouler les conséquences algébriques.

11.3 Expression de p en fonction de z

L'équation $(\star)$ donne z à partir de p , alors que le programme part de z pour obtenir la probabilité. L'inversion consiste à isoler p ; chaque ligne porte à droite l'opération qui la produit.

$$\begin{aligned}
\log \frac{p}{1-p} &= z && \text{on applique } e^{\cdot} \text{ aux deux membres} \\
e^{\log \frac{p}{1-p}} &= e^z && \text{car } e^{\log a} = a \\
\frac{p}{1-p} &= e^z && \\
p &= e^z(1-p) && \text{on multiplie les deux membres par } 1-p \\
p &= e^z - e^z p && \text{on développe} \\
p + e^z p &= e^z && \text{on rassemble les } p \\
p(1 + e^z) &= e^z && \text{on met } p \text{ en facteur} \\
p &= \frac{e^z}{1 + e^z} && \text{on divise par } 1 + e^z, \text{ qui n'est jamais nul} \quad (11.1)
\end{aligned}$$

Cette écriture se met sous une forme plus courante en divisant numérateur et dénominateur par e^z :

$$\begin{aligned}
p &= \frac{e^z}{1 + e^z} = \frac{e^z/e^z}{(1 + e^z)/e^z} && \text{on divise en haut et en bas par } e^z \neq 0 \\
&= \frac{1}{1/e^z + 1} && \text{car } e^z/e^z = 1 \text{ et } e^z/e^z = 1 \\
&= \frac{1}{1 + e^{-z}} && \text{car } 1/e^z = e^{-z} \quad (11.2)
\end{aligned}$$

Fonction logistique

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{e^z}{1 + e^z}.$$

Les deux écritures sont la même fonction, comme le montre le calcul ci-dessus. Elle découle de l'hypothèse (*) écrite dans l'autre sens.

Chacune des deux formes échoue là où l'autre tient. Pour z très négatif, e^{-z} devient gigantesque et $1/(1 + e^{-z})$ déborde la capacité de la machine, tandis que $e^z/(1 + e^z)$ rend 0. Pour z très positif, c'est l'inverse. Le programme utilise donc l'une ou l'autre selon le signe de z (ch. 16).

11.4 Vérification numérique

La table 11.1 se relit dans l'autre sens. Pour $z = 1,099$:

$$e^{-1,099} = 0,3333, \quad \sigma(1,099) = \frac{1}{1 + 0,3333} = \frac{1}{1,3333} = 0,75.$$

On retrouve la ligne $p = 0,75$, dont la log-cote valait $+1,099$. Pour $z = 0$:

$$\sigma(0) = \frac{1}{1 + e^0} = \frac{1}{1 + 1} = 0,5.$$




FIGURE 11.2. La fonction logistique envoie $\mathbb{R}$ dans l'intervalle $]0, 1[$, sans jamais atteindre les bornes, et passe par 0,5 à l'origine.

Un élève situé exactement sur la droite reçoit une probabilité de 0,5 : la frontière (ch. 2) est la ligne de niveau 0,5 du modèle.

Valeurs prises par σ

Pour z fini, $1 + e^{-z}$ reste strictement plus grand que 1, donc $\sigma(z)$ reste strictement compris entre 0 et 1. Toute probabilité annoncée par le modèle appartient donc à l'intervalle ouvert $]0, 1[$. En machine, $\sigma(40)$ vaut pourtant exactement 1 après arrondi : l'écart disparaît à partir d'un score d'environ 37, avec les conséquences que cela entraîne dans un logarithme (ch. 16).

Chapitre 12

Propriétés de la fonction logistique

Deux égalités serviront constamment par la suite. La première dit que la fonction est symétrique : changer le signe du score revient à échanger les deux réponses. La seconde donne sa dérivée, et cette dérivée s'exprime avec la fonction elle-même, ce qui simplifiera tout le calcul du gradient.

12.1 Symétrie

$$\begin{aligned}\sigma(-z) &= \frac{1}{1 + e^{-(-z)}} \\ &= \frac{1}{1 + e^z}\end{aligned}$$

définition, avec $-z$ à la place de z

car $-(-z) = z$

et par ailleurs

$$\begin{aligned}1 - \sigma(z) &= 1 - \frac{1}{1 + e^{-z}} \\ &= \frac{(1 + e^{-z}) - 1}{1 + e^{-z}} \\ &= \frac{e^{-z}}{1 + e^{-z}} \\ &= \frac{e^{-z}}{1 + e^{-z}} \cdot \frac{e^z}{e^z} \\ &= \frac{e^{-z}e^z}{e^z + e^{-z}e^z} \\ &= \frac{1}{e^z + 1}\end{aligned}$$

définition

même dénominateur

on simplifie le numérateur

on multiplie par 1 écrit e^z/e^z

on distribue

car $e^{-z}e^z = e^0 = 1$

(12.1)

Les deux résultats coïncident, donc

$$\sigma(-z) = 1 - \sigma(z)$$

La probabilité accordée à « **Gryffindor** » pour un score z égale donc celle accordée à « pas **Gryffindor** » pour le score $-z$.

$$\sigma(2) = 0,8808 \text{ et } \sigma(-2) = 0,1192, \text{ de somme } 1.$$

12.2 Dérivée

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{1}{u}, \quad u = 1 + e^{-z}$$

$$\begin{aligned} u' &= (1 + e^{-z})' = 0 + e^{-z} \cdot (-1) && \text{dérivée d'une somme, puis chaîne sur } e^{-z} \\ &= -e^{-z} \end{aligned}$$

$$\sigma'(z) = -\frac{u'}{u^2}$$

dérivée d'un inverse : $(1/u)' = -u'/u^2$

$$= -\frac{-e^{-z}}{(1 + e^{-z})^2}$$

on remplace u et u'

$$= \frac{e^{-z}}{(1 + e^{-z})^2}$$

les deux signes moins s'annulent

$$= \frac{1}{1 + e^{-z}} \cdot \frac{e^{-z}}{1 + e^{-z}}$$

on sépare le carré en deux facteurs

$$= \sigma(z) \cdot (1 - \sigma(z))$$

le second facteur est $1 - \sigma(z)$, établi en (12.1)

(12.2)

Dérivée de la sigmoïde

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)).$$

La pente se calcule donc sans nouvelle exponentielle : si l'on connaît déjà $p = \sigma(z)$, la pente vaut $p(1 - p)$.

12.3 Variation de la probabilité avec le score

La quantité $p(1-p)$ atteint son maximum, 0,25, en $p = 0,5$, et décroît vers 0 aux deux extrémités : la probabilité varie fortement avec le score près de la frontière, et très peu lorsqu'elle est déjà proche de 0 ou de 1.




FIGURE 12.1. La dérivée atteint son maximum, 0,25, en $z = 0$, et tend vers zéro dès que la probabilité approche 0 ou 1.

Cette forme en cloche a une conséquence pratique : un élève déjà correctement classé contribue très peu au déplacement de la frontière, tandis qu'un élève proche de celle-ci y contribue au maximum. L'ajustement est donc déterminé par les cas limites.

Chapitre 13

Construction du coût par vraisemblance

Le modèle annonce une probabilité pour chaque élève. Le fichier, lui, donne la réponse. Un bon jeu de coefficients est celui sous lequel les réponses observées étaient les plus probables. Ce critère s'écrit, se transforme en somme, et devient le nombre unique que le programme cherche à faire baisser.

13.1 Probabilité d'une réponse observée

Notons y_i la réponse : 1 si l'élève i est [Gryffindor](#), 0 sinon, et $p_i = \sigma(z_i)$ ce que le modèle annonce. La probabilité que le modèle attribue à la réponse effectivement observée vaut p_i si $y_i = 1$, et $1 - p_i$ si $y_i = 0$. Ces deux cas se rassemblent :

$$\mathbb{P}(y_i) = p_i^{y_i} (1 - p_i)^{1-y_i}.$$

Vérification des deux cas, en se souvenant que $a^0 = 1$ et $a^1 = a$:

$$y_i = 1 : \quad p_i^1(1 - p_i)^0 = p_i \cdot 1 = p_i, \quad y_i = 0 : \quad p_i^0(1 - p_i)^1 = 1 \cdot (1 - p_i) = 1 - p_i.$$

L'exposant nul ramène à 1 le facteur qui ne correspond pas au cas observé.

13.2 Vraisemblance du fichier

Les élèves sont supposés indépendants une fois leurs notes connues. La probabilité d'observer l'ensemble des réponses du fichier est alors le produit des probabilités individuelles :

$$L(\mathbf{w}) = \prod_{i=1}^m p_i^{y_i} (1 - p_i)^{1-y_i}.$$

L s'appelle la *vraisemblance*. Elle dépend des coefficients $\mathbf{w}$, car ce sont eux qui produisent les p_i . Chercher les meilleurs coefficients, c'est chercher ceux qui rendent L maximale.

Sous-dépassement du produit

Le produit compte 1 600 facteurs, tous inférieurs à 1. Même si chacun valait 0,9, il vaudrait $0,9^{1600} \approx 10^{-73}$. En machine, un tel nombre s'arrondit à zéro et toute comparaison devient impossible. Le logarithme rend le critère exploitable.




FIGURE 13.1. Le produit des probabilités individuelles mesure la plausibilité du jeu de coefficients, mais s'annule numériquement dès quelques centaines de facteurs. Le logarithme le convertit en somme sans déplacer l'optimum, puisqu'il est strictement croissant ; le facteur $-1/m$ transforme la maximisation en minimisation et rend la valeur indépendante du nombre d'élèves.

13.3 Passage au logarithme

$$\begin{aligned}
 \log L(\mathbf{w}) &= \log \prod_{i=1}^m p_i^{y_i} (1 - p_i)^{1-y_i} \\
 &= \sum_{i=1}^m \log \left[p_i^{y_i} (1 - p_i)^{1-y_i} \right] && \text{le log d'un produit, sur les } m \text{ facteurs} \\
 &= \sum_{i=1}^m \left[\log p_i^{y_i} + \log (1 - p_i)^{1-y_i} \right] && \text{le log d'un produit, sur deux termes} \\
 &= \sum_{i=1}^m \left[y_i \log p_i + (1 - y_i) \log (1 - p_i) \right] && \log a^b = b \log a \quad (13.1)
 \end{aligned}$$

Le passage au logarithme est légitime pour chercher un maximum : $\log$ est strictement croissante, donc elle conserve l'ordre. Le $\mathbf{w}$ qui maximise L est exactement celui qui maximise $\log L$.

13.4 Du maximum à un minimum

Les algorithmes d'optimisation minimisent par convention. On change donc le signe, et on divise par m pour obtenir une valeur moyenne, indépendante du nombre d'élèves :

$$J(\mathbf{w}) = -\frac{1}{m} \sum_{i=1}^m \left[y_i \log p_i + (1 - y_i) \log (1 - p_i) \right] \quad (\dagger)$$

Maximiser $\log L$ et minimiser J sont la même opération : multiplier par $-1/m$ retourne la fonction et la met à l'échelle, sans déplacer l'argument où l'optimum est atteint. C'est la formule que donne le sujet du projet.

13.5 Coût d'un élève

Le terme d'un seul élève vaut $-\log p_i$ s'il est [Gryffindor](#), et $-\log(1 - p_i)$ sinon : dans les deux cas, l'opposé du logarithme de la probabilité accordée à la bonne réponse.

y_i	p_i	probabilité accordée à la vérité	coût $-\log(\cdot)$
1	0,99	0,99	0,010
1	0,75	0,75	0,288
1	0,50	0,50	0,693
1	0,10	0,10	2,303
1	0,01	0,01	4,605
0	0,10	0,90	0,105
0	0,90	0,10	2,303

TABLE 13.1. Une prédiction correcte assortie d'une probabilité élevée coûte presque zéro. Une prédiction fausse assortie de la même probabilité coûte d'autant plus, sans borne supérieure : le coût diverge quand la probabilité accordée à la réponse observée tend vers zéro.




FIGURE 13.2. Le coût d'un élève en fonction de la probabilité que le modèle accordait à sa maison réelle. Le point 0,693 correspond à un modèle qui annonce 0,5.

La formule rend compte du contrôle employé depuis le chapitre 4 : des coefficients nuls donnent $p_i = \sigma(0) = 0,5$ pour chaque élève, donc un coût moyen de $-\log(0,5) = \log 2$.

Chapitre 14

Calcul du gradient

Le coût est un nombre qui dépend des coefficients. Pour le faire baisser, il faut savoir comment il varie quand chaque coefficient varie : c'est sa dérivée partielle. Le calcul se décompose en deux dérivées enchaînées, et le résultat se réduit à l'erreur commise, multipliée par la note.

14.1 Composition à dériver

Le coefficient w_j n'apparaît pas directement dans J . Il agit par étapes :

$$w_j \longrightarrow z_i = \sum_j w_j x_{ij} \longrightarrow p_i = \sigma(z_i) \longrightarrow \ell_i \longrightarrow J.$$

La règle de dérivation des fonctions composées traverse cette suite : chaque facteur se calcule séparément, puis les facteurs se multiplient.




FIGURE 14.1. Le coefficient n'agit sur le coût que par cette chaîne. Les deux dérivées encadrées se multiplient, et la moyenne sur les élèves donne $\partial J / \partial w_j$. Le passage par p_i disparaît du résultat : la propriété $\sigma' = \sigma(1 - \sigma)$ fait que les deux dérivées intermédiaires se simplifient en un seul facteur $p_i - y_i$.

14.2 Première dérivée : le coût d'un élève par rapport au score

Posons, pour un élève dont on omet l'indice,

$$\ell = -[y \log \sigma(z) + (1 - y) \log(1 - \sigma(z))].$$

$$\begin{aligned} \frac{\partial \ell}{\partial z} &= - \left[y \cdot \frac{1}{\sigma(z)} \cdot \sigma'(z) + (1 - y) \cdot \frac{1}{1 - \sigma(z)} \cdot (-\sigma'(z)) \right] && \text{chaîne sur log} \\ &= - \left[\frac{y \sigma'(z)}{\sigma(z)} - \frac{(1 - y) \sigma'(z)}{1 - \sigma(z)} \right] && \text{on range} \\ &= - \left[\frac{y \sigma(z)(1 - \sigma(z))}{\sigma(z)} - \frac{(1 - y) \sigma(z)(1 - \sigma(z))}{1 - \sigma(z)} \right] && \sigma' = \sigma(1 - \sigma) \\ &= -[y(1 - \sigma(z)) - (1 - y)\sigma(z)] && \text{on simplifie chaque fraction} \\ &= -[y - y\sigma(z) - \sigma(z) + y\sigma(z)] && \text{on développe} \\ &= -[y - \sigma(z)] && \text{les } y\sigma(z) \text{ s'annulent} \\ &= \sigma(z) - y && (14.1) \end{aligned}$$

Le troisième passage repose entièrement sur la propriété $\sigma' = \sigma(1 - \sigma)$ (ch. 12) : c'est elle qui fait disparaître les dénominateurs.

Résidu

$$\frac{\partial \ell}{\partial z} = \sigma(z) - y = p - y.$$

La pente du coût par rapport au score est simplement l'écart entre ce que le modèle annonce et ce qui est observé. Un élève **Gryffindor** ($y = 1$) auquel le modèle accorde 0,1 donne $-0,9$; le même, déjà classé à 0,99, donne $-0,01$. La correction issue d'un élève correctement classé est donc négligeable.

14.3 Seconde dérivée : le score par rapport à un coefficient

$$\begin{aligned} \frac{\partial z_i}{\partial w_j} &= \frac{\partial}{\partial w_j} \sum_{k=0}^n w_k x_{ik} \\ &= \sum_{k=0}^n \frac{\partial (w_k x_{ik})}{\partial w_j} && \text{la dérivée entre dans la somme} \\ &= x_{ij} && \text{dérivée partielle} \end{aligned} \quad (14.2)$$

Dans la somme, un seul terme contient w_j , c'est $w_j x_{ij}$, et sa dérivée par rapport à w_j vaut x_{ij} . Les autres termes $w_k x_{ik}$, avec $k \neq j$, sont des constantes du point de vue de cette dérivée, qui est donc nulle.

14.4 Assemblage

$$\begin{aligned}
 \frac{\partial J}{\partial w_j} &= \frac{\partial}{\partial w_j} \left[\frac{1}{m} \sum_{i=1}^m \ell_i \right] \\
 &= \frac{1}{m} \sum_{i=1}^m \frac{\partial \ell_i}{\partial w_j} && \text{la dérivée entre, } 1/m \text{ sort} \\
 &= \frac{1}{m} \sum_{i=1}^m \frac{\partial \ell_i}{\partial z_i} \cdot \frac{\partial z_i}{\partial w_j} && \text{règle de chaîne} \\
 &= \frac{1}{m} \sum_{i=1}^m (\sigma(z_i) - y_i) x_{ij} && \text{les deux dérivées calculées ci-dessus} \quad (14.3)
 \end{aligned}$$

Gradient

$$\frac{\partial J}{\partial w_j} = \underbrace{\frac{1}{m} \sum_{i=1}^m}_{\text{moyenne}} \underbrace{(p_i - y_i)}_{\text{erreur}} \underbrace{x_{ij}}_{\text{note}}$$

C'est la formule du sujet, $\frac{1}{m} \sum (h_\theta(x^i) - y^i) x_j^i$, obtenue sans hypothèse supplémentaire. Le gradient ∇J est le vecteur de ces $n + 1$ dérivées partielles, une par coefficient.

14.5 Facteurs du gradient

Chaque élève contribue au gradient du coefficient j par le produit de deux facteurs : son erreur $p_i - y_i$, et sa note x_{ij} .

Le premier facteur donne le sens et l'intensité de la correction. Il est négatif quand le modèle sous-estime un **Gryffindor**, positif quand il surestime un autre élève, et proche de zéro dès que la prédiction est correcte.

Le second répartit la correction entre les coefficients. Un élève dont la note d'**Herbology** est extrême pèse fortement sur w_1 , tandis qu'un élève de note moyenne, dont la valeur standardisée est proche de zéro, n'y contribue presque pas.

Cas du biais

Pour $j = 0$, la note x_{i0} vaut 1 pour tout le monde. La formule devient

$$\frac{\partial J}{\partial w_0} = \frac{1}{m} \sum_{i=1}^m (p_i - y_i),$$

soit la moyenne des erreurs. Le biais s'ajuste donc sur la fréquence globale : il se déplace jusqu'à ce que la proportion moyenne annoncée égale la proportion réelle de [Gryffindor](#), ce que la première itération vérifie (ch. 5).

Chapitre 15

Unicité du minimum

La descente de gradient suppose un minimum unique. Sur une surface qui en compte plusieurs, elle s'arrête au premier atteint et le résultat dépend du point de départ. Le coût de la régression logistique n'en admet qu'un, ce qui se démontre en vérifiant que sa courbure ne change jamais de signe.

15.1 Courbure d'une fonction d'une variable

La dérivée seconde mesure la variation de la pente. Si elle reste positive, la pente croît sur tout l'intervalle et la concavité de la courbe reste tournée du même côté. Une telle fonction est dite *convexe* : elle ne peut pas présenter deux minimums séparés par un maximum local, ce qui exigerait que la pente cesse de croître.




FIGURE 15.1. À gauche, un minimum unique, atteint quel que soit le point de départ. À droite, deux minimums locaux : la descente s'arrête dans celui vers lequel le gradient initial la dirige, et ignore l'autre.

15.2 Courbure du coût logistique

Reprenons la dérivée première (ch. 14) :

$$\frac{\partial J}{\partial w_j} = \frac{1}{m} \sum_{i=1}^m (\sigma(z_i) - y_i) x_{ij}.$$

Dérivons une seconde fois, par rapport à un autre coefficient w_k :

$$\begin{aligned} \frac{\partial^2 J}{\partial w_j \partial w_k} &= \frac{1}{m} \sum_{i=1}^m \frac{\partial}{\partial w_k} [(\sigma(z_i) - y_i) x_{ij}] && \text{la dérivée entre dans la somme} \\ &= \frac{1}{m} \sum_{i=1}^m x_{ij} \sigma'(z_i) \frac{\partial z_i}{\partial w_k} && \text{chaîne, et } y_i \text{ est constant} \\ &= \frac{1}{m} \sum_{i=1}^m x_{ij} \sigma(z_i) (1 - \sigma(z_i)) x_{ik} && \text{chapitre 12, et } \partial z_i / \partial w_k = x_{ik} \end{aligned} \quad (15.1)$$

Ces nombres, rangés dans un tableau carré dont la case (j, k) porte $\partial^2 J / \partial w_j \partial w_k$, forment la *Hessienne* de J : la matrice de ses dérivées secondes. Posons $s_i = \sigma(z_i)(1 - \sigma(z_i))$, qui est le facteur commun à chaque terme.

15.3 Positivité de la courbure

Prenons une direction quelconque dans l'espace des coefficients, décrite par un vecteur $\mathbf{v} = (v_0, \dots, v_n)$. La courbure de J le long de cette direction vaut

$$\begin{aligned} \sum_j \sum_k v_j \frac{\partial^2 J}{\partial w_j \partial w_k} v_k &= \frac{1}{m} \sum_{i=1}^m s_i \left(\sum_j v_j x_{ij} \right) \left(\sum_k v_k x_{ik} \right) && \text{on regroupe} \\ &= \frac{1}{m} \sum_{i=1}^m s_i \left(\sum_j v_j x_{ij} \right)^2 && \text{les deux facteurs sont égaux} \\ &\geq 0 && (15.2) \end{aligned}$$

La dernière ligne tient parce que chaque terme de la somme est le produit de deux quantités positives ou nulles : un carré, toujours positif ou nul, et s_i , qui vaut $\sigma(z_i)(1 - \sigma(z_i))$ avec σ strictement comprise entre 0 et 1, donc lui aussi positif.

Unicité du minimum

La courbure de J est positive ou nulle dans toutes les directions, quelle que soit la position des coefficients. Le coût est donc convexe et n'admet pas de minimum local secondaire. Tout point où le gradient s'annule est un minimum global, et la descente y conduit quel que soit son point de départ : partir de zéro relève de la reproductibilité, non de la qualité du résultat.

15.4 Directions de courbure nulle

Positif *ou nul* : la nuance a des conséquences. La courbure s'annule dans une direction $\mathbf{v}$ dès que $\sum_j v_j x_{ij} = 0$ pour tous les élèves, c'est-à-dire lorsqu'une combinaison des notes est identiquement nulle. L'ensemble des minima est alors une droite, ou un sous-espace de dimension supérieure.

C'est exactement ce qui se produit avec deux colonnes proportionnelles. Si Astronomy vaut -100 fois Defense Against the Dark Arts, augmenter un coefficient et diminuer l'autre dans le bon rapport laisse tous les scores inchangés : les prédictions restent identiques, mais les coefficients dérivent sans se stabiliser.

Séparation complète

Un second cas éloigne le minimum à l'infini. Si une droite sépare parfaitement les deux groupes — on dit alors que les données sont *linéairement séparables* — multiplier tous les coefficients par 10 rapproche encore les probabilités de 0 et de 1, et fait donc encore baisser le coût. Chaque jeu de coefficients en admet un meilleur et la suite diverge. La convexité établie ci-dessus reste vraie : elle garantit l'unicité du minimum lorsqu'il existe, et c'est son existence à distance finie que ce cas met en défaut (annexe A).

Chapitre 16

Réécritures pour la stabilité numérique

Les formules démontrées jusqu'ici sont exactes en arithmétique réelle. Sur une machine, les nombres ont une taille finie, et deux expressions mathématiquement égales n'y sont pas équivalentes : l'une rend un résultat, l'autre échoue. Les deux réécritures établies ici conservent chaque valeur et modifient seulement la suite d'opérations qui y conduit.

16.1 Coût exprimé à partir du score

En double précision, $\sigma(z)$ vaut exactement 1 dès que z dépasse environ 37 : e^{-37} est de l'ordre de 10^{-17} , en dessous de ce qu'un flottant distingue de 1 lorsqu'on l'y ajoute. Le coût demande alors $\log(1 - 1)$, qui n'existe pas. Un élève d'une autre maison auquel le modèle attribue une forte probabilité d'être [Gryffindor](#) suffit donc à interrompre le programme, alors que c'est exactement le cas que le coût doit signaler.

Logarithme d'un quotient, logarithme d'une exponentielle

$$\log(a/b) = \log a - \log b, \text{ et } \log(e^b) = b.$$

Reprenons le coût d'un élève et remplaçons p par $\sigma(z)$:

$$\begin{aligned}
\ell &= -[y \log \sigma(z) + (1 - y) \log(1 - \sigma(z))] \\
\log \sigma(z) &= \log \frac{1}{1 + e^{-z}} = \log 1 - \log(1 + e^{-z}) \\
&= -\log(1 + e^{-z}) && \text{car } \log 1 = 0 \\
\log(1 - \sigma(z)) &= \log \frac{e^{-z}}{1 + e^{-z}} = \log e^{-z} - \log(1 + e^{-z}) \\
&= -z - \log(1 + e^{-z}) && \text{car } \log e^{-z} = -z \\
\ell &= -\left[y(-\log(1 + e^{-z})) \right. \\
&\quad \left. + (1 - y)(-z - \log(1 + e^{-z})) \right] \\
&= y \log(1 + e^{-z}) + (1 - y)z + (1 - y) \log(1 + e^{-z}) && \text{on distribue} \\
&= \log(1 + e^{-z}) + (1 - y)z && \text{les logs se regroupent} \\
&= \underbrace{\log(1 + e^{-z}) + z}_{= \log(1 + e^z)} - yz \\
&= \log(1 + e^z) - yz && (16.1)
\end{aligned}$$

Le regroupement souligné s'établit ainsi :

$$\log(1 + e^{-z}) + z = \log(1 + e^{-z}) + \log e^z = \log(e^z(1 + e^{-z})) = \log(e^z + 1),$$

en remontant z sous forme de $\log e^z$, en regroupant les deux logarithmes en celui d'un produit, puis en développant : $e^z \cdot e^{-z} = e^0 = 1$.

Forme employée par le programme

$$\ell(y, z) = \text{softplus}(z) - yz, \quad \text{softplus}(z) = \log(1 + e^z).$$

Cette forme se calcule à partir du score seul, hors d'atteinte des arrondis qui produisent $\log 0$.

Pour $y = 1$ et $z = 6$, la forme directe donne $-\log(0,997527) = 0,002476$ et celle-ci $\text{softplus}(6) - 6 = 6,002476 - 6 = 0,002476$.

16.2 Formes protégées de softplus et de la sigmoïde

softplus contient encore e^z , qui déborde pour z grand. On l'écrit donc

$$\text{softplus}(z) = \max(z, 0) + \log(1 + e^{-|z|}),$$

dont l'exposant est toujours négatif ou nul. La vérification porte sur deux cas. Pour $z \geq 0$, $\max(z, 0) = z$ et l'expression vaut $z + \log(1 + e^{-z}) = \log(e^z + 1)$, par le même regroupement que ci-dessus. Pour $z < 0$, $\max(z, 0) = 0$ et $|z| = -z$, il reste $\log(1 + e^z)$, qui est la définition.

La sigmoïde reçoit le même traitement, avec ses deux écritures (ch. 11) :

$$\sigma(z) = \begin{cases} 1/(1 + e^{-z}), & z \geq 0, \\ e^z/(1 + e^z), & z < 0. \end{cases}$$

Dans les deux branches, l'exponentielle porte sur un nombre négatif ou nul. Un exposant très négatif s'arrondit à zéro sans dommage ; un exposant très positif, lui, dépasse la capacité du format et provoque une erreur.




FIGURE 16.1. Les trois régimes du calcul en double précision. La zone centrale seule tolère l'écriture directe ; les formes protégées rendent des valeurs finies sur tout l'axe. Un score de ± 800 apparaît dès que les coefficients divergent (ch. 15).

z	écriture directe	écriture protégée
-800	e^{800} déborde	0,0
+800	$\log(1 + e^{800})$ déborde	800,0
+40	$\log(1 - \sigma(40)) = \log 0$	0,0

TABLE 16.1. En double précision, l'exponentielle déborde au-delà de $|z| \approx 710$ et la sigmoïde s'arrondit à 1 dès $z \approx 37$. Les formes protégées rendent des valeurs finies dans les trois cas.

Contrôles numériques

Le premier coût vaut $\log 2 = 0,693147$ quand les coefficients partent de zéro. Toute autre valeur signale une erreur dans le score ou l'initialisation.

Le gradient calculé par la formule, comparé à $(J(\mathbf{w} + h\mathbf{e}_j) - J(\mathbf{w} - h\mathbf{e}_j))/2h$ sur un cas de petite taille, doit coïncider à 10^{-6} près. Ce test détecte un signe inversé, un facteur $1/m$ oublié, un indice décalé.

La sigmoïde et le coût, évalués en $z = \pm 1000$, doivent rendre des nombres finis.

Annexe A

Croissance de la norme des coefficients

Le plafond d'itérations du chapitre 9 paraît arbitraire tant qu'on ignore le cas qu'il traite. La norme des coefficients cesse de croître par un équilibre entre deux effets, et cet équilibre disparaît lorsque les deux groupes sont parfaitement séparables.

A.1 Équilibre qui arrête la croissance

Les coefficients grandissent à chaque tour : leur norme passe de 0,30 au premier tour à 4,89 au quatre centième, alors que la frontière est en place depuis longtemps et que plus aucune décision ne change. Pourquoi ne grandissent-ils pas indéfiniment ?

La réponse commande un morceau du programme. Tant qu'il reste des élèves mal classés, la croissance s'arrête d'elle-même et le critère de stagnation termine la boucle. Lorsque tous sont bien classés, elle se poursuit indéfiniment et seul le plafond d'itérations arrête la descente : c'est la raison pour laquelle le code de la deuxième partie porte ces deux conditions d'arrêt plutôt qu'une seule.

Agrandir les coefficients raidit la sigmoïde autour de la frontière, sans déplacer celle-ci. Les probabilités s'écartent donc de 0,5, ce qui produit deux effets opposés : les 1 564 élèves bien classés voient la leur tendre vers 1 et leur coût vers 0 ; les 36 autres voient la leur tendre vers 0 et leur coût vers l'infini.




FIGURE A.1. Le coût de deux élèves lorsque la norme des coefficients est multipliée par 1, 2 puis 3, la frontière restant fixe. À gauche, un élève du bon côté : son coût se rapproche de zéro et ne peut pas descendre plus bas, si bien que tout le gain possible tient dans les 0,233 de départ. À droite, un élève du mauvais côté : le sien augmente à chaque fois, et rien ne le borne. Multiplier encore par dix porterait le premier à 0,000 et le second à 2,99.




FIGURE A.2. Les deux parts du coût lorsque les coefficients sont agrandis, la frontière restant fixe. Celle des élèves bien classés décroît vers zéro sans jamais passer dessous ; celle des 36 autres croît sans borne, puisque $-\log p$ diverge quand leur probabilité tend vers 0. La somme atteint son minimum en $\|w\| = 5,38$.

Le gain est borné par zéro, la perte ne l'est pas. Au-delà de $\|w\| = 5,38$, agrandir les coefficients coûte donc plus qu'il ne rapporte, et la descente cesse de le faire. La descente l'atteint en suivant le gradient. Le modèle de ce chapitre s'arrête un peu avant, à 4,89, parce que le compteur est coupé au quatre centième tour.

Ce mécanisme disparaît lorsqu'une droite sépare parfaitement les deux groupes — les données sont alors dites *linéairement séparables*. La part des mal classés est vide, la courbe orange de la figure A.2 est identiquement nulle, et il ne reste que la courbe bleue, décroissante : le coût diminue indéfiniment, $\|w\|$ diverge, et seul le plafond d'itérations arrête la descente (ch. 15).

$\ w\ $	1 564 bien classés	36 mal classés	total	
0,49	0,445	0,019	0,464	transition très étalée
4,89	0,041	0,067	0,108	modèle de ce chapitre
5,38	0,034	0,073	0,107	minimum
14,68	0,005	0,189	0,194	transition abrupte

TABLE A.1. Entre la première ligne et la dernière, la part des élèves bien classés est divisée par quatre-vingt-neuf, celle des mal classés multipliée par dix.

Reconnaître et traiter la divergence

Ce cas se diagnostique à trois signes conjoints : la descente consomme tout son plafond d'itérations sans jamais déclencher son critère d'arrêt, les coefficients continuent de croître régulièrement, et les probabilités affichées valent exactement 0 ou 1 après arrondi. La cause est alors dans les données, pas dans le programme.

Deux remèdes existent. Le plus simple est d'arrêter sur un nombre de tours fixé, ce que fait le plafond : la frontière obtenue est correcte, seule sa raideur est arbitraire. Le second consiste à ajouter au coût un terme $\frac{\mu}{2}\|w\|^2$ qui croît avec la norme — c'est la *régularisation*. La courbe bleue de la figure A.2 est alors relevée par une parabole, un minimum réapparaît même sur des données séparables, et le paramètre μ fixe où il tombe. La bibliothèque `scikit-learn` l'applique par défaut, ce qui explique qu'elle converge sur des données où une implémentation directe diverge.

Interprétation de la norme finale

La norme finale traduit le degré de séparation que les données justifient. Un recouvrement des deux populations la maintient basse et laisse une transition étalée ; une séparation nette la porte haut. La forcer davantage ferait annoncer une certitude que les données ne soutiennent pas, et une probabilité de 0,99 sur un cas limite est une information fausse.

Références

- [1] Trevor HASTIE, Robert TIBSHIRANI et Jerome FRIEDMAN. *The Elements of Statistical Learning*. 2^e éd. Springer, 2009.
- [2] Christopher M. BISHOP. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [3] Chris PIECH et Mehran SAHAMI. *Logistic Regression*. CS109, Probability for Computer Scientists, Stanford University. 2024. URL : <https://web.stanford.edu/class/archive/cs/cs109/cs109.1264/lectures/20-LogisticRegression/20-LogisticRegression.pdf> (visité le 31/07/2026).
- [4] Stephen BOYD et Lieven VANDENBERGHE. *Convex Optimization*. Cambridge University Press, 2004.
- [5] Andrew NG et Tengyu MA. *CS229 Lecture Notes*. Stanford University. 2018. URL : https://cs229.stanford.edu/main_notes.pdf (visité le 31/07/2026).