

# **Régression logistique**

Modèle, optimisation et évaluation

Sylvain Maitre

Version 2.0 — 1<sup>er</sup> août 2026

## Résumé

La régression logistique associe à une observation une probabilité d'appartenance, sous l'hypothèse que le logarithme de la cote est une fonction affine des variables observées. L'optimisation ajuste cette probabilité à partir des étiquettes de référence. Ce cours établit le modèle, le met en œuvre et en démontre les propriétés employées.

Le fil conducteur est un jeu de données de 1 600 élèves décrits par leurs notes, à répartir entre quatre classes. La première partie construit la chaîne complète — préparation, score, probabilité, coût, gradient, décision, évaluation — sur un sous-problème binaire à deux variables, choisi parce qu'il se dessine. La deuxième partie écrit le programme correspondant en Python sans bibliothèque de calcul, sous forme d'un atelier où chaque fonction est à compléter puis à contrôler contre une valeur connue d'avance. Les annexes portent les démonstrations, les rappels de prérequis, la géométrie en dimension quelconque et les questions de stabilité numérique.

Les valeurs numériques citées proviennent d'exécutions sur le fichier d'entraînement ; les conventions de reproduction figurent au chapitre 1.

Document rédigé avec l'assistance de modèles de langage (GPT, Claude) sur la base de mes instructions, de mon code et de mes données ; la sélection, la vérification numérique et la responsabilité éditoriale du contenu m'incombent. Diffusé sous licence CC-BY-SA 4.0.

# Table des matières

|          |                                                             |           |
|----------|-------------------------------------------------------------|-----------|
| <b>I</b> | <b>Modèle et interprétation</b>                             | <b>1</b>  |
| <b>1</b> | <b>Parcours, prérequis et conventions</b>                   | <b>2</b>  |
| 1.1      | Public et prérequis . . . . .                               | 2         |
| 1.2      | Carte et conventions . . . . .                              | 3         |
| <b>2</b> | <b>Problème de classification et protocole d'évaluation</b> | <b>5</b>  |
| 2.1      | Données, entrée et sortie . . . . .                         | 5         |
| 2.2      | Régression linéaire et régression logistique . . . . .      | 6         |
| 2.3      | Vue graphique globale . . . . .                             | 6         |
| 2.4      | Utilisation générale . . . . .                              | 8         |
| 2.5      | Résultat hors échantillon . . . . .                         | 8         |
| <b>3</b> | <b>Notes brutes et standardisation</b>                      | <b>10</b> |
| 3.1      | Fichier d'entraînement . . . . .                            | 10        |
| 3.2      | Notes absentes . . . . .                                    | 10        |
| 3.3      | Différence d'échelle entre les colonnes . . . . .           | 11        |
| 3.4      | Application à un élève . . . . .                            | 13        |
| <b>4</b> | <b>Nuage de points et frontière de décision</b>             | <b>14</b> |
| 4.1      | Séparation par une note . . . . .                           | 14        |
| 4.2      | Équation de la frontière . . . . .                          | 15        |
| 4.3      | Score . . . . .                                             | 16        |
| 4.4      | Variable cible . . . . .                                    | 17        |
| 4.5      | Propriétés requises de la transformation . . . . .          | 18        |

---

|          |                                                   |           |
|----------|---------------------------------------------------|-----------|
| <b>5</b> | <b>Probabilité d'appartenance</b>                 | <b>19</b> |
| 5.1      | Cote, logit et hypothèse du modèle . . . . .      | 19        |
| 5.2      | Fonction logistique . . . . .                     | 20        |
| 5.3      | Fonctions de liaison et alternatives . . . . .    | 21        |
| 5.4      | Calcul de la probabilité . . . . .                | 22        |
| <b>6</b> | <b>Perte individuelle et coût moyen</b>           | <b>24</b> |
| 6.1      | Perte associée à une prédiction . . . . .         | 24        |
| 6.2      | Coût moyen sur le fichier . . . . .               | 26        |
| 6.3      | Répartition de la perte . . . . .                 | 27        |
| 6.4      | Comptage et coût . . . . .                        | 27        |
| <b>7</b> | <b>Descente de gradient</b>                       | <b>30</b> |
| 7.1      | Correction à appliquer . . . . .                  | 30        |
| 7.2      | Premier pas de la descente . . . . .              | 31        |
| 7.3      | Coût au fil des itérations . . . . .              | 31        |
| 7.4      | Réglage du pas et arrêt . . . . .                 | 32        |
| 7.5      | Déplacement de la frontière . . . . .             | 33        |
| 7.6      | Surface de probabilité . . . . .                  | 34        |
| 7.7      | Niveau 0,5 de la sigmoïde . . . . .               | 35        |
| <b>8</b> | <b>Interprétation du modèle ajusté</b>            | <b>37</b> |
| 8.1      | Interprétation des coefficients . . . . .         | 37        |
| 8.2      | Paramètres appris et paramètres fixés . . . . .   | 39        |
| 8.3      | Classement d'une observation nouvelle . . . . .   | 40        |
| 8.4      | Extension à dix notes et quatre maisons . . . . . | 41        |
| <b>9</b> | <b>Classification à quatre maisons</b>            | <b>42</b> |
| 9.1      | Un modèle par maison . . . . .                    | 42        |
| 9.2      | Règle du score maximal . . . . .                  | 43        |
| 9.3      | Forme des régions . . . . .                       | 45        |

|            |                                                  |           |
|------------|--------------------------------------------------|-----------|
| 9.4        | Contenu du classifieur . . . . .                 | 45        |
| 9.5        | Somme des quatre probabilités . . . . .          | 45        |
| <b>II</b>  | <b>Implémentation et évaluation</b>              | <b>47</b> |
| <b>10</b>  | <b>Préparation, score et coût</b>                | <b>48</b> |
| 10.1       | Préparation des données . . . . .                | 49        |
| 10.2       | Le score d'une observation . . . . .             | 50        |
| 10.3       | La probabilité . . . . .                         | 50        |
| 10.4       | La perte d'une prédiction . . . . .              | 51        |
| 10.5       | La perte moyenne . . . . .                       | 52        |
| <b>11</b>  | <b>Optimisation des coefficients</b>             | <b>54</b> |
| 11.1       | La pente et sa vérification . . . . .            | 54        |
| 11.2       | Un pas . . . . .                                 | 55        |
| 11.3       | Itération jusqu'à stagnation . . . . .           | 56        |
| <b>12</b>  | <b>Classification multiclasse et évaluation</b>  | <b>58</b> |
| 12.1       | Extension un-contre-tous . . . . .               | 58        |
| 12.2       | Mesure sur des lignes mises de côté . . . . .    | 59        |
| 12.3       | Résultats et limites . . . . .                   | 61        |
| 12.4       | Seuil de décision, en binaire . . . . .          | 63        |
| 12.5       | Compléments pour un programme livrable . . . . . | 66        |
| 12.6       | Micro-cas de transfert . . . . .                 | 67        |
| <b>III</b> | <b>Fondements, démonstrations et compléments</b> | <b>68</b> |
| <b>A</b>   | <b>Notation et vocabulaire</b>                   | <b>69</b> |
| A.1        | Indices et dimensions . . . . .                  | 69        |
| A.2        | Données . . . . .                                | 71        |
| A.3        | Paramètres et modèle . . . . .                   | 71        |

|          |                                                            |           |
|----------|------------------------------------------------------------|-----------|
| A.4      | Fonctions et quantités calculées . . . . .                 | 71        |
| A.5      | États du modèle . . . . .                                  | 71        |
| A.6      | Glossaire . . . . .                                        | 71        |
| <b>B</b> | <b>Rappels de prérequis</b>                                | <b>73</b> |
| B.1      | Résumer une colonne de nombres . . . . .                   | 73        |
| B.2      | Exponentielle, logarithme, cote . . . . .                  | 74        |
| B.3      | Vecteurs, produit scalaire, norme . . . . .                | 74        |
| B.4      | Dérivée, dérivée partielle, gradient . . . . .             | 75        |
| B.5      | Dérivée seconde et courbure . . . . .                      | 75        |
| <b>C</b> | <b>Construction de la fonction logistique</b>              | <b>76</b> |
| C.1      | Première transformation : la cote . . . . .                | 76        |
| C.2      | Seconde transformation : le logarithme . . . . .           | 77        |
| C.3      | Expression de $p$ en fonction de $z$ . . . . .             | 77        |
| C.4      | Vérification numérique . . . . .                           | 78        |
| <b>D</b> | <b>Propriétés de la fonction logistique</b>                | <b>80</b> |
| D.1      | Symétrie . . . . .                                         | 80        |
| D.2      | Dérivée . . . . .                                          | 81        |
| D.3      | Variation de la probabilité avec le score . . . . .        | 82        |
| <b>E</b> | <b>Construction du coût par vraisemblance</b>              | <b>84</b> |
| E.1      | Probabilité d'une réponse observée . . . . .               | 84        |
| E.2      | Vraisemblance du fichier . . . . .                         | 84        |
| E.3      | Passage au logarithme . . . . .                            | 85        |
| E.4      | Changement de signe et moyenne . . . . .                   | 86        |
| E.5      | Forme du terme individuel . . . . .                        | 86        |
| <b>F</b> | <b>Calcul du gradient</b>                                  | <b>88</b> |
| F.1      | Composition à dériver . . . . .                            | 88        |
| F.2      | Première dérivée : la perte par rapport au score . . . . . | 88        |

|          |                                                                   |            |
|----------|-------------------------------------------------------------------|------------|
| F.3      | Seconde dérivée : le score par rapport à un coefficient . . . . . | 89         |
| F.4      | Assemblage . . . . .                                              | 90         |
| F.5      | Facteurs du gradient . . . . .                                    | 90         |
| <b>G</b> | <b>Convexité, existence et unicité du minimum</b>                 | <b>91</b>  |
| G.1      | Courbure d'une fonction d'une variable . . . . .                  | 91         |
| G.2      | Courbure du coût logistique . . . . .                             | 92         |
| G.3      | Positivité de la courbure . . . . .                               | 93         |
| G.4      | Rang déficient et multiplicité des minima . . . . .               | 93         |
| G.5      | Séparation linéaire et minimum à l'infini . . . . .               | 94         |
| <b>H</b> | <b>Croissance de la norme des coefficients</b>                    | <b>95</b>  |
| H.1      | Équilibre qui arrête la croissance . . . . .                      | 95         |
| <b>I</b> | <b>Surface de perte et longueur du pas</b>                        | <b>98</b>  |
| I.1      | Surface du coût . . . . .                                         | 98         |
| I.2      | Longueur du pas . . . . .                                         | 100        |
| I.3      | Condition de décroissance . . . . .                               | 101        |
| <b>J</b> | <b>Réécritures pour la stabilité numérique</b>                    | <b>103</b> |
| J.1      | Coût exprimé à partir du score . . . . .                          | 103        |
| J.2      | Formes protégées de softplus et de la sigmoïde . . . . .          | 104        |
| <b>K</b> | <b>Géométrie en dimension quelconque</b>                          | <b>106</b> |
| K.1      | Frontière pour un nombre quelconque de matières . . . . .         | 106        |
| K.2      | Rôle de chaque coefficient . . . . .                              | 107        |
| K.3      | Forme des régions du classifieur . . . . .                        | 108        |
| <b>L</b> | <b>Corrigés</b>                                                   | <b>111</b> |
| L.1      | Cahier pratique . . . . .                                         | 112        |
| L.2      | Exercices du fil principal . . . . .                              | 119        |
|          | <b>Références</b>                                                 | <b>121</b> |

# **Première partie I**

## **Modèle et interprétation**



# Chapitre 1

## Parcours, prérequis et conventions

### 1.1 Public et prérequis

Ce cours s'adresse à un étudiant ou un praticien qui veut construire un classifieur linéaire de bout en bout, formules comprises, plutôt qu'en appeler une implémentation. Les notions propres au modèle — cote, logit, entropie croisée, gradient, hessienne, convexité, un-contre-tous — sont l'objet du cours ; le reste est supposé acquis.

| domaine                 | attendu à l'entrée                             | rappel disponible  |
|-------------------------|------------------------------------------------|--------------------|
| statistique descriptive | moyenne, médiane, écart-type, valeur manquante | annexe B           |
| analyse                 | exponentielle, logarithme, fonction croissante | annexe B           |
| géométrie               | repère, droite, produit scalaire, norme        | annexe B, annexe K |
| calcul différentiel     | dérivée d'une fonction d'une variable          | annexe B           |
| programmation           | Python : fonctions, listes, boucles, imports   | aucun              |

TABLE 1.1: Prérequis. Les mathématiques couvrent la partie I et les annexes de démonstration ; la programmation intervient dans la partie II.

#### Objectifs évaluable de la partie I.

1. calculer le score et la probabilité d'une observation à partir des coefficients et des statistiques de préparation ;
2. écrire la perte d'entropie croisée sous une forme stable en double précision, et la contrôler en  $z = \pm 1000$  ;
3. prédire le signe et l'ordre de grandeur d'une composante du gradient ;
4. distinguer un protocole d'évaluation valide d'un protocole entaché de fuite du jeu de test ;
5. lire une matrice de confusion et l'assortir d'une incertitude ;
6. énoncer la portée exacte de la convexité ;
7. dire à quelles conditions les sorties d'un classifieur un-contre-tous se lisent comme des probabilités de classe.

La partie II écrit le programme correspondant et suppose la partie I. Les annexes portent les démonstrations et supposent la partie I ainsi que les rappels de l'annexe B. Le fil principal énonce les résultats employés ; les encadrés *approfondissement* renvoient à leurs démonstrations.

## 1.2 Carte et conventions




FIGURE 1.1: Vue d'ensemble du modèle. La rangée supérieure transforme une observation en classe prédite pour des coefficients fixés. La rangée inférieure relie l'étiquette observée à la perte, à l'optimisation des coefficients et au contrôle sur un jeu tenu hors de l'ajustement.

Le trajet supérieur de la figure 1.1 est celui d'une prédiction. Le trajet inférieur n'intervient que pendant l'apprentissage ; l'évaluation réutilise ensuite les statistiques de préparation et les coefficients figés, sans les réajuster sur le jeu de test.

**Notation.** Les symboles sont déclarés dans le tableau de l'annexe A, avec le glossaire français-anglais. Deux collisions y sont signalées :  $\sigma$  désigne l'écart-type d'une colonne comme la fonction logistique, selon le contexte ; la cote standard usuellement notée  $z$  est notée  $x$  ici, la lettre  $z$  étant réservée au score.

**États du modèle.** Les coefficients dépendent du point d'arrêt de la descente. Quatre états portent un nom, et chaque tableau ou figure indique lequel il emploie.

**Provenance des chiffres.** Statistiques descriptives, coefficients, coûts et taux proviennent du fichier `dataset_train.csv` du sujet DSLR de 42 et des scripts déposés dans `scripts/` ; les traces employées par les figures sont dans `data/`, et `scripts/verifie_chiffres.py` les recalcule toutes. Le jeu de données est synthétique et les personnages qu'il nomme sont fictifs.

| nom       | coefficients                 | obtenu par                                                                     |
|-----------|------------------------------|--------------------------------------------------------------------------------|
| $M_0$     | (0 ; 0 ; 0)                  | point de départ de toute descente                                              |
| $M_{400}$ | (−4,745 ; −3,454 ; +3,469)   | 400 tours à $\alpha = 1$ sur les 1 600 observations ; figures de la partie I   |
| $M_{arr}$ | (−5,176 ; −3,746 ; +3,787)   | même descente poursuivie jusqu'au critère de stagnation, 983 tours ; partie II |
| $M_4$     | quatre jeux de trois nombres | quatre descentes un-contre-tous, une par classe                                |

TABLE 1.2: États du modèle.  $M_{400}$  et  $M_{arr}$  diffèrent par la norme des coefficients : leurs rapports coïncident à trois millièmes près (ch. 7).

**Vocabulaire.** Une perte, un coût ou une erreur qualifient une *prédiction* portant sur une observation : le document écrit « perte associée à cette prédiction ». La règle maintient la responsabilité du côté du modèle lorsque les données décrivent des personnes. Le raisonnement général emploie *observation*, *variable* et *classe* ; *élève*, *note* et les maisons sont réservés aux exemples tirés du fichier.

**Limites du développement.** Régularisation, sélection de variables, validation croisée, calibration des probabilités, régression multinomiale complète, optimisation de second ordre, coûts asymétriques et dérive de distribution sont situés dans le cycle d'utilisation, sans démonstration ni implémentation complète. Leur rôle et la limite qu'ils imposent au résultat sont indiqués aux points concernés.

# Chapitre 2

## Problème de classification et protocole d'évaluation

**OBJECTIFS** distinguer régression linéaire et régression logistique ; énoncer la tâche, l'entrée, la sortie et la mesure ; lire le modèle et son entraînement sur une vue graphique globale ; ordonner les phases d'utilisation

**PRÉREQUIS** aucun

**PARCOURS** essentiel ; le protocole d'évaluation est détaillé au ch. 12

### 2.1 Données, entrée et sortie

Le fichier `dataset_train.csv` décrit 1 600 élèves par treize notes d'examen et une maison observée, parmi quatre. La tâche consiste à produire une règle qui, appliquée aux seules notes d'un élève, annonce sa maison.

| index | maison observée | Herbology | Ancient Runes | ...                  |
|-------|-----------------|-----------|---------------|----------------------|
| 0     | Ravenclaw       | +5,73     | 532,48        |                      |
| 1     | Slytherin       | −5,99     | 367,76        |                      |
| 3     | Gryffindor      | −6,497    | 523,982       |                      |
| 21    | Hufflepuff      | +4,12     | absente       | note non enregistrée |

TABLE 2.1: Quatre lignes du fichier, réduites aux deux colonnes employées dans la partie I. « maison observée » est l'étiquette de référence, seule colonne inaccessible à la règle au moment de prédire.

L'évaluation d'une telle règle porte sur trois quantités :

1. la proportion de prédictions correctes *sur des observations qui n'ont pas servi à la construire* ;
2. la comparaison de cette proportion à celle d'une règle triviale ;
3. la répartition des erreurs restantes, que le taux global agrège.

## 2.2 Régression linéaire et régression logistique

Une régression relie une variable à expliquer à des variables observées. La *régression linéaire* modélise une quantité réelle par

$$\hat{y} = \beta_0 + \sum_{j=1}^n \beta_j x_j.$$

Elle convient lorsque la sortie est continue — une durée, une masse, une température — et que sa moyenne conditionnelle peut être approchée par une fonction affine. Ses coefficients sont généralement ajustés en minimisant les écarts quadratiques entre valeurs observées et valeurs prédites.

Pour une étiquette binaire  $y \in \{0, 1\}$ , la même somme affine peut produire n'importe quel réel. La *régression logistique* conserve cette somme comme *score*

$$z = w_0 + \sum_{j=1}^n w_j x_j,$$

puis modélise la probabilité conditionnelle par

$$\mathbb{P}(y = 1 \mid \mathbf{x}) = \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Le nom « régression » vient de l'estimation de cette probabilité ; la décision de classe résulte ensuite d'un seuil.

Ce modèle est indiqué lorsque la réponse est binaire, qu'une probabilité est utile et que le logarithme des chances peut être raisonnablement décrit par une fonction affine des variables. Il offre alors des coefficients interprétables et un ajustement efficace. Des interactions persistantes, une frontière très courbe ou des données non structurées conduisent à comparer des modèles plus flexibles sur le même protocole hors échantillon.

### Portée de la fonction logistique

La frontière demeure une droite en deux dimensions et un hyperplan au-delà, car  $p = 0,5$  équivaut à  $z = 0$ . La sigmoïde a pour rôle de transformer le score en probabilité, de fournir une perte lisse adaptée à une réponse binaire et de rendre l'ajustement possible par dérivation. Une frontière non linéaire demande d'autres variables — interactions, polynômes — ou une autre famille de modèles.

## 2.3 Vue graphique globale

Les quatre panneaux de la figure 2.1 décrivent le modèle et son entraînement. Les deux panneaux supérieurs portent la prédiction ; les deux panneaux inférieurs montrent comment une étiquette observée transforme cette prédiction en correction des coefficients.




FIGURE 2.1: Vue globale. Le score affine fixe la frontière ; la sigmoïde lui associe une probabilité ; l'étiquette sélectionne une perte ; la moyenne des pertes définit la surface dont le gradient corrige les coefficients.

## 2.4 Utilisation générale

| phase    | décision                                                                      | contrôle                                                           |
|----------|-------------------------------------------------------------------------------|--------------------------------------------------------------------|
| formuler | définir la classe positive, l'unité d'observation et l'usage de la prédiction | coût relatif des deux erreurs, fréquence des classes               |
| séparer  | réserver apprentissage, validation éventuelle et test avant tout ajustement   | absence de doublons et de fuite entre ensembles                    |
| préparer | imputer, centrer et réduire à partir de l'apprentissage seul                  | mêmes variables, ordre et statistiques à l'application             |
| ajuster  | minimiser la perte logistique sur l'apprentissage                             | perte décroissante, gradient contrôlé, arrêt documenté             |
| décider  | fixer le seuil binaire ou l'argmax multiclasse selon l'usage                  | rappel, précision, matrice de confusion, coûts des erreurs         |
| évaluer  | consulter le test une fois, avec un plancher et une incertitude               | comparaison hors échantillon, analyse des erreurs                  |
| déployer | enregistrer préparation, coefficients, classes et seuil                       | dérive des variables, calibration et qualité après mise en service |

TABLE 2.2: Cycle d'utilisation d'une régression logistique. Le test mesure une procédure dont les réglages ont été fixés sur l'apprentissage et la validation.

Dans le cas étudié, deux notes standardisées produisent un score, puis une probabilité et une décision; l'étiquette observée détermine ensuite la perte et le gradient. Les chapitres 3 à 7 établissent successivement ces opérations; le chapitre 9 étend la décision aux quatre maisons.

## 2.5 Résultat hors échantillon

L'exactitude annoncée est mesurée sur des lignes mises de côté avant toute autre opération, statistiques de préparation comprises : découpage stratifié à 80/20, graine fixée, test consulté une fois. Le chapitre 12 détaille ce protocole, ses limites et la répartition des erreurs.

| mesure                             | valeur             | portée                           |
|------------------------------------|--------------------|----------------------------------|
| exactitude hors échantillon        | $311/320 = 0,9719$ | prédit une observation à venir   |
| intervalle de Wilson à 95 %        | $[0,9474; 0,9851]$ | largeur due aux 320 observations |
| exactitude sur l'apprentissage     | 0,9609             | optimiste par construction       |
| règle triviale, classe majoritaire | 0,3312             | plancher à dépasser              |

TABLE 2.3: Résultat des quatre modèles binaires ajustés sur 1 280 lignes et mesurés sur les 320 restantes.

**Énoncé du problème traité en partie I**

Reconnaître les 327 [Gryffindor](#) parmi les 1 600 élèves à partir de deux notes standardisées, en déterminant par le calcul les trois coefficients d'une frontière de décision. Le passage aux quatre maisons (ch. 9) et la mesure hors échantillon (ch. 12) reprennent ce même modèle sans le modifier.



# Chapitre 3

## Notes brutes et standardisation

**OBJECTIFS** justifier le choix d'une valeur d'imputation ; calculer une cote standard ; délimiter ce que la standardisation conserve du nuage ; dire sur quelles lignes ces statistiques doivent être ajustées

**PRÉREQUIS** moyenne, médiane, écart-type (annexe B) ; chapitre 2

**PARCOURS** essentiel

### 3.1 Fichier d'entraînement

`dataset_train.csv` contient 1 600 lignes, une par élève. Les six premières colonnes donnent l'index, la maison, le nom, la date de naissance et la main directrice ; les treize suivantes donnent une note par matière. La maison est renseignée pour les 1 600 élèves : c'est la réponse que le modèle doit retrouver.

Deux d'entre elles servent ici, **Herbology** et **Ancient Runes** : leurs distributions par maison se recouvrent peu, et elles suffisent à isoler les **Gryffindor** (ch. 4). Le modèle complet en retient dix. Ce choix de deux matières a été fait après examen du fichier étiqueté entier ; sa portée méthodologique est discutée au chapitre 2.

| matière              | absentes | minimum | maximum | médiane | moyenne | écart-type |
|----------------------|----------|---------|---------|---------|---------|------------|
| <b>Herbology</b>     | 33       | -10,30  | 11,61   | 3,469   | 1,189   | 5,175      |
| <b>Ancient Runes</b> | 35       | 283,87  | 745,40  | 463,918 | 495,052 | 105,186    |

TABLE 3.1: Les deux colonnes employées, telles qu'elles figurent dans le fichier. La moyenne et l'écart-type sont calculés après remplacement des notes absentes, donc sur les 1 600 lignes.

### 3.2 Notes absentes

Certaines cases du fichier sont vides. Le score étant une somme de produits, il exige une valeur pour chaque terme : une case vide arrête le traitement de la ligne entière.

Deux traitements existent. Écarter les lignes incomplètes coûte de l'effectif et suppose que les lignes écartées ressemblent aux lignes conservées, hypothèse invérifiable. Attribuer une valeur à chaque case vide — l'*imputation* — fabrique des mesures. Ce cours retient l'imputation par la médiane : coupant la colonne en deux moitiés de même effectif, elle résiste au déplacement des valeurs extrêmes, que la moyenne suit.

Toute imputation par une constante concentre les lignes incomplètes en un point du nuage et resserre la dispersion de la colonne. Sa validité tient à deux conditions : des cases vides rares, et une absence indépendante de la valeur qu'elles auraient prise. La seconde reste invérifiable sur les seules données [1].

#### CASES VIDES DES DEUX COLONNES

|                   | Herbology | Ancient Runes |                                         |
|-------------------|-----------|---------------|-----------------------------------------|
| notes absentes    | 33        | 35            | soit 68 élèves, 4,25 % du fichier       |
| médiane attribuée | 3,469     | 463,918       |                                         |
| moyenne avant     | 1,141     | 495,748       | sur les notes présentes                 |
| moyenne après     | 1,189     | 495,052       | elle monte d'un côté, baisse de l'autre |

Le remplissage déplace chaque moyenne de moins d'un centième d'écart-type : 0,009 pour **Herbology**, 0,007 pour **Ancient Runes**. Les 68 élèves concernés le sont chacun sur une seule des deux colonnes.

L'élève 21, dont la note d'**Ancient Runes** est absente, reçoit 463,918, soit  $-0,296$  une fois standardisée.

### 3.3 Différence d'échelle entre les colonnes

Les deux colonnes mesurent une performance scolaire, mais dans des unités sans rapport entre elles. Le score les additionne pourtant, après avoir multiplié chacune par son coefficient. À coefficient égal, une matière dont les notes s'étalent sur une large plage pèse alors davantage qu'une autre, pour la seule raison de son échelle de notation. Deux conséquences en découlent : les coefficients cessent d'être comparables entre eux, et la distance entre deux élèves du plan dépend du barème de chaque matière plutôt que de leurs résultats.

Une note d'**Herbology** se lit entre  $-10$  et  $+12$ , une note d'**Ancient Runes** autour de 500, et les secondes sont vingt fois plus dispersées : dans  $w_1x_1 + w_2x_2$ , un  $w_2$  de 1 produit donc un effet vingt fois plus grand qu'un  $w_1$  de 1.

Ramener les deux colonnes à une échelle commune demande de fixer une origine et une unité pour chacune d'elles.

Le *centrage* soustrait la moyenne  $\mu$  : l'écart  $v - \mu$  situe chaque note par rapport à la promotion, avec des valeurs positives au-dessus de la moyenne et négatives en dessous.

La *réduction* divise cet écart par l'écart-type  $\sigma$ , mesure de la dispersion des notes autour de leur moyenne. Chaque valeur s'exprime alors en nombre d'écarts-types.

$$x = \frac{\overbrace{v - \mu}^{\text{écart à la moyenne de la colonne}}}{\underbrace{\sigma}_{\text{écart-type de la colonne}}}$$

Le résultat porte le nom de *cote standard*, ou *z-score* en anglais ; on le note ici  $x$ , la lettre  $z$  étant réservée au score du modèle (ch. 4). Par construction, la colonne transformée a pour moyenne 0 et pour écart-type 1, quelle que soit la matière d'origine. Une valeur standardisée se lit alors directement : +1 désigne un élève situé une dispersion typique au-dessus de sa moyenne, en **Herbology** comme en **Ancient Runes**, et les deux colonnes deviennent comparables terme à terme.




FIGURE 3.1: Sur un seul axe, la transformation est affine croissante : elle déplace l'origine et change l'unité, sans modifier l'ordre des élèves. En rouge, l'élève 3.

Chaque axe est divisé par un nombre différent  $-5,175$  d'un côté,  $105,186$  de l'autre. La transformation conserve donc la structure affine du nuage : l'ordre sur chaque coordonnée, l'alignement des points, la position intermédiaire d'un point entre deux autres, et la correspondance terme à terme entre un modèle affine sur les notes standardisées et un modèle affine sur les notes brutes.

Distances euclidiennes, rapports de distances et angles relèvent en revanche du plan standardisé seul, où les deux axes portent la même unité. Les notions d'angle, de perpendiculaire et de distance employées au chapitre 4 s'entendent dans ce plan. La standardisation installe une géométrie, choisie parce qu'elle rend les coefficients comparables entre eux.




FIGURE 3.2: 534 élèves : **Gryffindor** en bleu, autres maisons en orangé. Les transformations affines des axes préservent l'ordre et les alignements ; les distances et les angles changent.

### 3.4 Application à un élève

L'élève 3 a  $-6,497$  en **Herbology** et  $523,982$  en **Ancient Runes**.

$$x_1 = \frac{-6,497 - 1,189}{5,175} = -1,485, \quad x_2 = \frac{523,982 - 495,052}{105,186} = +0,275.$$

Ces deux valeurs sont les coordonnées du point qui représente cet élève dans le plan  $(x_1, x_2)$ . La première le situe à un écart-type et demi au-dessous de la moyenne en **Herbology**, la seconde à un quart d'écart-type au-dessus en **Ancient Runes**.

#### Statistiques à conserver

La médiane, la moyenne et l'écart-type sont ajustés une fois, sur les seules lignes d'apprentissage, et font partie du modèle au même titre que les coefficients. Une observation nouvelle se standardise avec ces trois nombres figés (ch. 12).

# Chapitre 4

## Nuage de points et frontière de décision

**OBJECTIFS** écrire l'équation d'une frontière de décision à partir d'un vecteur normal et d'un point de passage ; calculer un score et l'interpréter comme une distance signée ; coder la variable cible

**PRÉREQUIS** produit scalaire, norme (annexe B) ; chapitre 3

**PARCOURS** essentiel ; géométrie en dimension quelconque à l'annexe K

### 4.1 Séparation par une note

**Herbology** sépare les maisons en deux groupes : **Gryffindor** et **Slytherin** d'un côté, **Hufflepuff** et **Ravenclaw** de l'autre. Sur cette seule note, un **Gryffindor** et un **Slytherin** sont indiscernables. **Ancient Runes** les sépare autrement : **Gryffindor** et **Ravenclaw** d'un côté, **Hufflepuff** et **Slytherin** de l'autre. Là encore, deux maisons restent confondues.




FIGURE 4.1: Répartition selon la seule note d'**Herbology** ; trois autres maisons hachurées, **Gryffindor** en aplat. Les deux populations partagent le mode de gauche : aucun seuil sur cet axe ne les sépare.

Prises ensemble, les deux notes situent chaque élève dans un plan, où les **Gryffindor** occupent une région que les trois autres maisons laissent presque vide. La séparation qu'aucune des deux notes ne produit seule résulte de leur combinaison.




FIGURE 4.2: Les mêmes élèves placés selon leurs deux notes. Le quadrant  $x_1 < 0, x_2 > 0$  contient 310 élèves dont 304 **Gryffindor** ; les 23 **Gryffindor** restants se trouvent ailleurs. Ce recouvrement borne ce qu'une droite peut atteindre.

## 4.2 Équation de la frontière

Les deux notes standardisées  $(x_1, x_2)$  sont des nombres sans dimension, exprimés dans la même unité — l'écart-type de leur colonne. Le plan qu'elles engendrent peut donc être muni d'un repère orthonormé, et c'est ce qui donne un sens aux notions d'angle, de perpendiculaire et de distance employées plus bas. Sur les notes brutes, où un axe se gradue en points et l'autre en centaines de points, ces deux notions dépendraient du barème de chaque matière.

Une droite du plan se construit à partir de deux données : une direction perpendiculaire et un point de passage. Notons  $w = (w_1, w_2)$  un vecteur perpendiculaire à la droite cherchée, et  $a$  un point par lequel elle passe. Un point  $x$  appartient alors à la droite lorsque le vecteur  $x - a$  est perpendiculaire à  $w$ , c'est-à-dire lorsque leur produit scalaire s'annule :

$$w \cdot (x - a) = 0, \quad \text{où} \quad w \cdot v = w_1 v_1 + w_2 v_2.$$

Développer ce produit et poser  $w_0 = -w \cdot a$  donne l'équation sous sa forme usuelle :

$$\underbrace{w_1 x_1 + w_2 x_2}_{\text{direction perpendiculaire}} + \underbrace{w_0}_{\text{position de la droite}} = 0$$




FIGURE 4.3: La droite est l'ensemble des points  $x$  tels que  $x - a$  soit perpendiculaire à  $w$ . Le vecteur  $w$  pointe vers le demi-plan où l'expression  $w \cdot x + w_0$  est positive.

Le couple  $(w_1, w_2)$  est le *vecteur normal* : perpendiculaire à la droite par construction, il pointe vers le demi-plan où  $w_0 + w_1x_1 + w_2x_2$  est positif, puisque s'éloigner de la droite dans sa direction fait croître le produit scalaire. Sa longueur, la *norme* de  $w$ , intervient dans la distance à la frontière et dans la raideur de la fonction logistique :

$$\|w\| = \sqrt{w_1^2 + w_2^2}$$

Le coefficient  $w_0$  règle la position. À direction fixée, le faire varier translate la droite parallèlement à elle-même, et la distance signée de l'origine à la droite vaut  $-w_0/\|w\|$ . On l'appelle le *biais* : c'est la valeur que prend l'expression pour une observation dont les deux notes valent zéro.

Trois coefficients apparaissent alors que deux nombres suffisent à désigner une droite du plan. La raison tient à la construction : multiplier  $w$  et  $w_0$  par un même  $\lambda \neq 0$  multiplie tout le produit scalaire par  $\lambda$  sans changer les points où il s'annule. Seuls les rapports entre coefficients fixent la droite.

#### Effet de chaque coefficient

Tracés de la frontière lorsqu'un coefficient varie, les autres restant fixés : annexe K, section 2.

## 4.3 Score

Le membre de gauche de cette équation se calcule pour tout élève du plan, sur la frontière ou ailleurs. On l'appelle le *score* :

$$z = \underbrace{w_0}_{\substack{\text{biais} \\ \text{le même pour tous}}} + \underbrace{w_1x_1}_{\substack{\text{apport de la note} \\ \text{d'Herbology}}} + \underbrace{w_2x_2}_{\substack{\text{apport de la note} \\ \text{d'Ancient Runes}}}$$

La frontière de décision est l'ensemble des points où ce nombre s'annule,  $\{x : z(x) = 0\}$ . Ailleurs, la construction de la section précédente en donne directement le sens : puisque  $w_0 = -w \cdot a$ , le score s'écrit

$$z = w \cdot x + w_0 = w \cdot (x - a).$$

Or un produit scalaire vaut le produit des longueurs par le cosinus de l'angle, et  $\|x - a\| \cos \theta$  est exactement la distance de  $x$  à la droite, comptée perpendiculairement et affectée du signe du côté. En notant  $d$  cette distance,

$$z = \|w\| d.$$

Le signe du score donne donc le côté de la frontière, et sa valeur absolue la distance, au facteur  $\|w\|$  près. Deux observations de même score se tiennent à la même distance de la frontière, du même côté. La conversion de ce score en probabilité fait l'objet du chapitre 5.




FIGURE 4.4: Frontière pour  $w = (-0,4; -0,6; 1)$ . Les distances orthogonales des points de scores  $+3,1$  et  $+0,2$  valent respectivement  $2,66$  et  $0,17$ .

## 4.4 Variable cible

La frontière de décision sépare le plan en exactement deux régions. Elle peut donc porter une question à deux réponses, et une seule, alors que le fichier en distingue quatre.

La construction traite donc une maison à la fois : **Gryffindor** contre les trois autres réunions. Les trois questions restantes se posent à l'identique et se résolvent séparément (ch. 9).

La réponse à cette question s'appelle la *variable cible*. Sa colonne se déduit ligne à ligne de la colonne `Hogwarts House` du fichier, et c'est la quantité que le modèle devra produire à partir



des seules notes :

$$y_i = \begin{cases} 1 & \text{si l'observation } i \text{ appartient à Gryffindor,} \\ 0 & \text{sinon,} \end{cases}$$

soit 327 valeurs égales à 1 et 1 273 égales à 0.

Ce codage rend la moyenne de la colonne  $y$  égale à la proportion de Gryffindor,  $327/1\,600 = 0,2044$ , et la rend comparable ligne à ligne à la colonne des probabilités produite au chapitre suivant : leur différence mesure l'écart entre annoncé et observé.

## 4.5 Propriétés requises de la transformation

Le signe de  $z$  fournit déjà une règle de décision : Gryffindor si  $z > 0$ , autre maison sinon. Deux exigences conduisent à lui préférer une quantité qui varie de façon continue.

La première est de rendre compte de la fiabilité. Deux observations situées du même côté reçoivent la même réponse, que l'une se tienne loin de la frontière et l'autre tout contre, là où une note manquante ou une erreur de saisie suffit à la faire changer de classe. La valeur du score porte cette différence, absente de son signe : les deux points marqués sur la figure 4.4 ont pour scores  $+3,1$  et  $+0,2$ .

La seconde est de rendre la frontière corrigeable. Déterminer sa position par le calcul suppose de mesurer de combien elle est mal placée, de la déplacer d'autant, et de recommencer. Une réponse binaire garde la même valeur sur tout un intervalle de positions, et le calcul y reçoit partout la même indication. Il faut une quantité qui réponde à un déplacement, si petit soit-il.

### Transformation cherchée

Transformer le score  $z$ , qui parcourt  $\mathbb{R}$ , en une probabilité comprise entre 0 et 1, par une fonction continue — un petit déplacement de la droite produit un petit changement de probabilité — et croissante.

Une infinité de fonctions remplissent ces deux conditions : la fonction de répartition de la loi normale, qui fonde le modèle *probit*, et la fonction logistique, retenue ici. Ce choix est une décision de modélisation (annexe C).

Le modèle complet du projet retient dix matières : une observation est alors un point de  $\mathbb{R}^n$  et la frontière un *hyperplan affine* de dimension  $n - 1$ . Le vecteur normal, la distance  $|z|/\|w\|$  et le signe de  $z$  gardent leur rôle ; l'équation et le décompte des coefficients en dimensions 1, 2 et 3 sont détaillés dans l'annexe K. Le code de la partie II travaille sur la liste COURSES, dont la longueur fixe le nombre de matières.

### Exercice 4.1 — Vecteur normal et distance

Pour  $w = (-4,745 ; -3,454 ; +3,469)$ , calculer  $\|w\|$ , la distance signée de l'origine à la frontière, et le score de l'observation  $x = (0 ; 0)$ . Vérifier que le signe obtenu place l'élève moyen du côté attendu au vu de la figure 4.2.

# Chapitre 5

## Probabilité d'appartenance

**OBJECTIFS** énoncer l'hypothèse de modélisation que pose la régression logistique ; appliquer la fonction logistique à un score et interpréter le résultat ; comparer sigmoïde, seuil, fonction affine par morceaux, tangente hyperbolique et probit ; calculer une probabilité de bout en bout à partir de notes brutes

**PRÉREQUIS** exponentielle et logarithme (annexe B) ; chapitre 4

**PARCOURS** essentiel ; propriétés de  $\sigma$  à l'annexe D

### 5.1 Cote, logit et hypothèse du modèle

Le score du chapitre précédent situe une observation par rapport à la frontière. La régression logistique pose que ce score est le logarithme d'une cote.

La *cote* d'un événement est le rapport entre sa probabilité et celle de l'événement contraire :

$$\text{cote}(p) = \frac{\overbrace{p}^{\text{probabilité de l'événement}}}{\underbrace{1-p}_{\text{probabilité du contraire}}}$$

C'est la quantité employée dans les paris. Un élève auquel on accorde  $p = 0,8$  d'être **Gryffindor** a ainsi une cote de

$$\frac{0,8}{0,2} = 4,$$

soit quatre fois plus de chances d'en être que de ne pas en être. Une cote de 1 correspond à  $p = 0,5$ , les deux réponses étant alors également probables. Quand  $p$  parcourt  $]0, 1[$ , la cote parcourt  $]0, +\infty[$  : elle tend vers 0 lorsque la probabilité s'annule, et croît sans borne lorsqu'elle approche 1.

Le *logit* est le logarithme de cette cote,

$$\text{logit}(p) = \log \frac{p}{1-p}.$$

Il vaut 0 pour  $p = 0,5$ , il est négatif en dessous et positif au-dessus, et il parcourt  $\mathbb{R}$  tout entier, comme le score. L'hypothèse de modélisation s'écrit donc

$$\log \frac{p}{1-p} = z = w_0 + w_1 x_1 + w_2 x_2.$$

Le logit de la probabilité cherchée est supposé être une fonction *affine* des notes, c'est-à-dire une somme de leurs multiples augmentée d'une constante. L'expression de  $p$  en fonction de  $z$  s'en déduit (annexe C).

Cette égalité est une hypothèse de modélisation. Que le logit et le score parcourent tous deux  $\mathbb{R}$  la rend *possible*; d'autres fonctions conviendraient (ch. 4). Le choix du logit tient à trois propriétés : il donne aux coefficients une lecture en log-cotes (ch. 8), il conduit à la vraisemblance de Bernoulli et à un coût convexe (annexe E), et il produit un gradient simple (annexe F). C'est le lien canonique du modèle linéaire généralisé binomial [2].

Deux autres hypothèses interviennent ailleurs : l'indépendance conditionnelle des observations, employée pour écrire la vraisemblance comme un produit (annexe E), et le choix des variables retenues, qui fixe ce que le modèle peut voir.

L'élève 3, dont le score vaut +1,34, a une cote de  $e^{1,34} = 3,82$  d'être **Gryffindor**, soit une probabilité de  $3,82/4,82 = 0,79$ .

## 5.2 Fonction logistique

L'hypothèse se lit dans les deux sens : elle donne  $z$  à partir de  $p$ , et c'est  $p$  à partir de  $z$  dont le programme a besoin. L'inversion procède en quatre opérations réversibles.

$$\begin{aligned} \log \frac{p}{1-p} &= z \\ \frac{p}{1-p} &= e^z && \text{exponentielle des deux membres} \\ p &= e^z(1-p) = e^z - p e^z && \text{on multiplie par } 1-p \\ p(1+e^z) &= e^z && \text{on regroupe les termes en } p \\ p &= \frac{e^z}{1+e^z} = \frac{1}{1+e^{-z}} && \text{on divise en haut et en bas par } e^z \end{aligned}$$

La fonction ainsi obtenue s'appelle la *fonction logistique*, et se note  $\sigma$  :

$$\underbrace{z}_{\substack{\text{score} \\ \text{parcourt } \mathbb{R}}} \mapsto \underbrace{\sigma(z) = \frac{1}{1+e^{-z}}}_{\substack{\text{probabilité} \\ \text{dans } ]0, 1[}}$$

Ses valeurs se déduisent de l'écriture  $1/(1+e^{-z})$ . Pour  $z$  très négatif,  $e^{-z}$  est immense et le quotient tend vers zéro ; pour  $z$  très positif,  $e^{-z}$  tend vers zéro et le quotient vers 1 ; en  $z = 0$ ,




FIGURE 5.1: Fonction logistique. Les trois points marqués sont des élèves du fichier, dont les scores figurent au tableau 5.2.

l'exponentielle vaut 1 et le quotient exactement 0,5. Sur la frontière, les deux réponses reçoivent donc la même probabilité.

La fonction est croissante — classer par score ou par probabilité revient au même — et symétrique autour de 0,5,  $\sigma(-z)$  valant  $1 - \sigma(z)$  (annexe D).

### 5.3 Fonctions de liaison et alternatives

Toute transformation croissante centrée en  $p = 0,5$  conserve l'ordre des scores et la frontière  $z = 0$ . Le choix de la fonction porte donc sur le sens probabiliste, la régularité de la perte et le comportement loin de la frontière, tandis que la forme de la frontière provient du score.

| transformation                                         | propriété                                    | conséquence pour l'ajustement                                                                                                                    |
|--------------------------------------------------------|----------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------|
| seuil $1_{z \geq 0}$                                   | sortie binaire, discontinuité en zéro        | dérivée nulle ailleurs qu'au seuil : la sortie indique une décision, mais aucune direction de correction                                         |
| affine écrêtée<br>$\min(1, \max(0, \frac{1}{2} + az))$ | probabilité par morceaux, angles et plateaux | gradient nul dans les zones écrêtées et rupture aux angles ; une prédiction assurée incorrecte peut cesser de fournir une correction exploitable |
| logistique $\sigma(z)$                                 | lisse, symétrique, valeurs dans $]0, 1[$     | vraisemblance de Bernoulli, coût convexe pour un score affine et gradient $p - y$                                                                |
| tangente hyperbolique                                  | $\frac{1}{2}[1 + \tanh(z/2)] = \sigma(z)$    | même modèle après changement d'échelle ; les étiquettes $-1, +1$ donnent une notation équivalente                                                |
| probit $\Phi(z)$                                       | fonction de répartition normale, lisse       | autre modèle probabiliste valide, à queues différentes, ajusté lui aussi par vraisemblance                                                       |

TABLE 5.1: Transformations possibles d'un score réel. Le seuil sert à décider ; les fonctions lisses servent à estimer et à ajuster une probabilité.

Le lien complémentaire log-log fournit une autre option probabiliste, cette fois asymétrique. Pour des classes mutuellement exclusives, la régression *softmax* remplace les sigmoïdes indépendantes par une distribution dont les composantes somment à 1. Une machine à vecteurs de support optimise une marge avec une perte charnière ; elle produit d'abord un score de décision, dont la conversion en probabilité demande une calibration séparée.

Une fonction de liaison différente modifie les probabilités et parfois l'efficacité statistique, mais conserve une frontière affine tant que le score reste affine. Des interactions, des fonctions polynomiales, un noyau, un arbre ou un réseau peuvent produire une frontière courbe ; leur souplesse supplémentaire augmente aussi les besoins en données, en réglage et en contrôle du surapprentissage.

## 5.4 Calcul de la probabilité

La figure 2.1 associe la standardisation du chapitre 3, le score du chapitre 4 et la relation  $p = \sigma(z)$ . Ses constantes proviennent du fichier et de l'entraînement.

CONSTANTES DU MODÈLE

|                     | Herbology | Ancient Runes | origine        |
|---------------------|-----------|---------------|----------------|
| moyenne $\mu$       | 1,189     | 495,052       | le fichier     |
| écart-type $\sigma$ | 5,175     | 105,186       | le fichier     |
| coefficient $w_j$   | -3,454    | +3,469        | l'entraînement |
| biais $w_0$         | -4,745    |               | l'entraînement |

Les deux coefficients sont de signes opposés et de tailles voisines : une note basse en **Herbology** et une note haute en **Ancient Runes** poussent toutes deux le score vers le haut.

| élève | classe observée | Herbo. | $x_1$  | A. Runes | $x_2$  | $z$   | $p$   |
|-------|-----------------|--------|--------|----------|--------|-------|-------|
| 3     | Gryffindor      | -6,497 | -1,485 | 523,982  | +0,275 | +1,34 | 0,792 |
| 4     | Gryffindor      | -7,82  | -1,741 | 599,33   | +0,991 | +4,71 | 0,991 |
| 1     | Slytherin       | -5,99  | -1,387 | 367,76   | -1,210 | -4,15 | 0,016 |
| 0     | Ravenclaw       | +5,73  | +0,877 | 532,48   | +0,356 | -6,54 | 0,001 |

TABLE 5.2: Quatre élèves du fichier, de la note brute à la probabilité d'être **Gryffindor**.




FIGURE 5.2: Les trois termes du score de l'élève 3, à l'échelle : +1,34 pour des contributions individuelles de l'ordre de 5.

Ses notes standardisées valent  $x_1 = -1,485$  et  $x_2 = +0,275$ , d'où

$$z = -4,745 + (-3,454) \times (-1,485) + 3,469 \times 0,275 = +1,34, \quad p = \frac{1}{1 + e^{-1,34}} = 0,792.$$

Chaque terme du score est un produit de deux nombres signés, et le signe du produit fixe le sens de la contribution : positif vers **Gryffindor**, négatif vers les autres classes. Le signe du coefficient est une propriété de la variable, fixée par l'entraînement ; celui de la note standardisée situe l'observation par rapport à la moyenne de sa colonne. Le biais entre sans facteur, contribution identique pour toutes les observations, ici vers les autres classes : une observation est classée **Gryffindor** lorsque les deux termes de notes l'emportent sur lui.

L'élève 3 a une note d'**Herbology** basse et un coefficient négatif, donc un terme positif ; sa note d'**Ancient Runes**, légèrement au-dessus de la moyenne, contribue dans le même sens. Les deux l'emportent de peu sur le biais :  $z = +1,34$ ,  $p = 0,79$ , soit une position proche de la frontière. L'élève 4 cumule une note d'**Herbology** très basse et une note d'**Ancient Runes** élevée, d'où  $z = +4,71$  et  $p = 0,99$ .

#### Apport de la probabilité

Deux observations rangées dans la même classe peuvent l'être à des distances très différentes de la frontière. La probabilité chiffre cet écart là où la décision binaire les confond, et c'est cette quantité continue qui permet, au chapitre suivant, de mesurer de combien la frontière est mal placée.

#### Exercice 5.1 — Probabilité de bout en bout

L'élève 21 a  $+4,12$  en **Herbology** et sa note d'**Ancient Runes** est absente. Standardiser ses deux notes avec les constantes ci-dessus, calculer  $z$  puis  $p$ , et dire de quel côté de la frontière il se situe. Comparer le résultat à celui de l'élève 3 et attribuer l'écart à l'une des deux variables.

# Chapitre 6

## Perte individuelle et coût moyen

**OBJECTIFS** calculer la perte associée à une prédiction et la perte moyenne d'un modèle ; comparer erreur de classement, erreur quadratique et perte logistique ; expliquer pourquoi la dérivée transforme le critère en correction ; identifier ce que la moyenne masque

**PRÉREQUIS** logarithme (annexe B) ; chapitre 5

**PARCOURS** essentiel ; la dérivation par vraisemblance est reportée à l'annexe E

### 6.1 Perte associée à une prédiction

Mesurer l'erreur d'une prédiction demande de comparer la sortie du modèle à l'étiquette de référence. Le modèle produit une probabilité d'appartenir à [Gryffindor](#) ; le fichier donne une classe. Une seule quantité fait le lien : la probabilité que le modèle accordait à la classe observée. Elle vaut  $p$  lorsque l'étiquette est [Gryffindor](#), et  $1 - p$  sinon, ces deux cas épuisant les possibilités.

Cette probabilité vaut 1 pour une prédiction correcte et assurée, et tend vers 0 pour une prédiction incorrecte et assurée. La perte la renverse pour en faire une erreur, et prend son logarithme :

$$\ell = -\log(\text{probabilité accordée à la classe observée}).$$

Elle vaut zéro pour une probabilité de 1, croît lentement tant que celle-ci reste grande, puis sans borne lorsqu'elle approche zéro. Une prédiction incorrecte assortie d'une forte probabilité pèse donc beaucoup plus qu'une prédiction incertaine ; la figure 6.1 en donne l'allure exacte.

Cette fonction s'appelle l'*entropie croisée binaire*, ou log-vraisemblance négative, et l'annexe E la déduit du calcul des probabilités.

Les quatre pertes du tableau restent faibles parce que les quatre prédictions sont correctes. Une prédiction incorrecte et assurée produit l'effet inverse : la probabilité accordée à la classe observée  $y$  est proche de zéro, et son logarithme diverge.

Cette divergence porte sur la perte seule. La correction appliquée aux coefficients dépend de la dérivée de la perte par rapport au score,  $p - y$ , bornée par 1 en valeur absolue (annexe F) : une perte cent fois supérieure à la moyenne contribue au gradient dans un rapport très inférieur.

| élève | classe observée | $p$ (Gryffindor) | accordée à sa classe | perte $\ell$ |
|-------|-----------------|------------------|----------------------|--------------|
| 3     | Gryffindor      | 0,792            | 0,792                | 0,233        |
| 4     | Gryffindor      | 0,991            | 0,991                | 0,009        |
| 1     | Slytherin       | 0,016            | 0,984                | 0,016        |
| 0     | Ravenclaw       | 0,001            | 0,999                | 0,001        |

TABLE 6.1: Les quatre élèves du chapitre précédent. La quatrième colonne reprend la troisième pour les Gryffindor, son complément à 1 pour les autres classes.




FIGURE 6.1: Perte associée à une prédiction. Elle vaut  $\log 2$  en 0,5, tend vers zéro à droite et croît sans borne à gauche.



## 6.2 Coût moyen sur le fichier

La perte précédente quantifie une prédiction. Le placement de la frontière demande un critère portant sur les 1 600 prédictions, afin de comparer deux jeux de coefficients. Déplacer la frontière améliore certaines pertes individuelles et en dégrade d'autres. Leur moyenne fournit un critère unique.

La moyenne des pertes individuelles fournit cette quantité, et convient mieux que leur somme : celle-ci croît avec le nombre d'observations, si bien que le même modèle afficherait une valeur dix fois plus grande sur un fichier dix fois plus long. Divisée par  $m$ , la valeur se compare d'un fichier à l'autre — entre l'entraînement et le test, notamment — et la longueur du pas de la descente garde le même sens quel que soit l'effectif.

En notant  $y_i$  la réponse, valant 1 pour un **Gryffindor** et 0 sinon, et  $p_i$  la probabilité annoncée :

$$J = - \underbrace{\frac{1}{m} \sum_{i=1}^m}_{\text{moyenne sur les élèves}} \left[ \underbrace{y_i \log p_i}_{\substack{\text{seul terme retenu} \\ \text{si } y_i = 1}} + \underbrace{(1 - y_i) \log(1 - p_i)}_{\substack{\text{seul terme retenu} \\ \text{si } y_i = 0}} \right]$$

Un seul des deux termes agit pour chaque observation. Pour un **Gryffindor**,  $y_i = 1$  : le second s'annule et il reste  $-\log p_i$ . Pour une autre maison,  $y_i = 0$  : le premier s'annule et il reste  $-\log(1 - p_i)$ . Le facteur  $y_i$  joue le rôle d'un interrupteur, et cette écriture en une seule ligne remplace un branchement, ce qui la rend dérivable d'un bout à l'autre — propriété dont le chapitre suivant a besoin.

La somme justifie après coup le logarithme de la perte individuelle : sans lui, les 1 600 probabilités se multiplieraient au lieu de s'ajouter. Un produit de 1 600 facteurs strictement inférieurs à 1 sous-dépasse le domaine des flottants et s'arrondit à zéro (annexe E).

### Coût au point de départ

Si tous les coefficients valent zéro, tous les scores valent zéro, donc toutes les probabilités valent 0,5. Chaque prédiction contribue alors pour  $-\log(0,5)$ , et la moyenne aussi :

$$J = \log 2 = 0,693147.$$

C'est la première valeur qu'affiche un entraînement partant de zéro ; toute autre valeur situe l'erreur dans le calcul du score ou dans l'initialisation.

Cette valeur dépend des coefficients, seule chose qui varie une fois le fichier fixé : les probabilités  $p_i$  viennent des scores, les scores viennent des coefficients. Déplacer la frontière change les 1 600 probabilités, donc les 1 600 pertes, et avec elles leur moyenne. Le coût s'écrit ainsi comme une fonction des trois coefficients, et se note  $J(w)$ .

Cette dépendance convertit le placement géométrique de la frontière en une minimisation de fonction à trois variables : le programme cherche les trois coefficients qui rendent  $J(w)$  minimal.

Les deux questions ont des réponses distinctes : le minimum de  $J$  et le minimum du nombre d'erreurs à seuil fixé tombent à des endroits différents, ce que le tableau 6.3 et la figure 6.2

mesurent sur ces données. La portée de  $J$  tient à trois propriétés : c'est l'estimateur du maximum de vraisemblance sous le modèle posé, c'est une règle de score propre, minimisée par les probabilités conditionnelles exactes, et c'est une fonction dérivable, donc optimisable. L'exactitude relève d'un autre critère, mesuré séparément (ch. 12).

### Formulation du problème

$$\underbrace{\text{où placer la frontière?}}_{\text{géométrie}} \longrightarrow \underbrace{\text{quel } w \text{ minimise } J(w)?}_{\text{calcul}}$$

La méthode suit la pente de  $J(w)$  vers le bas ; la surface correspondante est tracée à l'annexe I.

## 6.3 Répartition de la perte

La perte moyenne de  $M_{400}$  vaut 0,108, valeur qui agrège 1 600 nombres très inégaux. L'inégalité tient à la forme de la perte individuelle. Loin de la frontière, dans le demi-plan de la classe observée, la probabilité associée à cette classe approche 1 et la contribution tend vers zéro. Dans le demi-plan opposé, cette probabilité décroît avec la distance et  $-\log p$  croît sans borne. Quelques prédictions incorrectes assorties d'une probabilité élevée portent donc l'essentiel de la moyenne.

CONCENTRATION DE LA PERTE, ÉTAT  $M_{400}$

|                                                                         |        |
|-------------------------------------------------------------------------|--------|
| part de $J$ portée par les 2 % de pertes individuelles les plus élevées | 60,5 % |
| perte maximale sur une prédiction                                       | 11,1   |
| perte moyenne                                                           | 0,108  |

L'observation concernée porte une étiquette **Gryffindor** alors que sa note d'**Herbology** dépasse la moyenne et que celle d'**Ancient Runes** lui est inférieure : elle se situe dans la région associée aux trois autres classes.

### Conséquence sur l'entraînement

La valeur de  $J$  est portée par un petit nombre d'observations atypiques au regard des deux variables employées : le critère est sensible aux valeurs extrêmes. La correction, elle, pondère chaque observation par  $p - y$ , borné par 1 (annexe F). L'examen des prédictions incorrectes une à une complète donc la lecture de la moyenne.

## 6.4 Comptage et coût

Deux mesures caractérisent le placement d'une frontière. Le nombre d'observations correctement classées est un entier directement interprétable. La moyenne des pertes est un nombre réel employé par l'entraînement en raison de sa variation continue lorsque la frontière se déplace.

Le comptage change par sauts. Il garde la même valeur tant qu’aucune observation ne traverse la frontière, puis saute d’une unité. Sur tout l’intervalle qui sépare deux sauts, il rend la même réponse pour des frontières différentes, et un calcul qui chercherait à l’améliorer recevrait partout la même information.

La perte moyenne répond à tout déplacement. Chaque observation y contribue par la probabilité que le modèle lui accorde, et cette probabilité change dès que la frontière bouge, fût-ce d’un millièm d’écart-type ; le sens de variation de la moyenne indique celui du déplacement à faire.

| critère                        | propriété                                                                                                     | usage                                                                                 |
|--------------------------------|---------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
| erreur 0–1                     | vaut 0 ou 1 après application du seuil ; constante entre deux franchissements de la frontière                 | mesure finale de classement, accompagnée de la matrice de confusion                   |
| erreur quadratique $(p - y)^2$ | continue ; avec une sigmoïde, son gradient contient le facteur $p(1 - p)$ et le coût peut perdre sa convexité | critère calculable, mais moins adapté à la vraisemblance d’une réponse de Bernoulli   |
| perte logistique               | continue, convexe pour un score affine, forte sur une probabilité assurée incorrecte ; gradient $p - y$       | critère d’ajustement retenu dans ce cours                                             |
| perte logistique pondérée      | multiplie les contributions selon la classe ou le type d’erreur                                               | apprentissage sensible à un coût asymétrique ou à un plan d’échantillonnage documenté |

TABLE 6.2: Un critère d’ajustement fournit une direction de calcul ; une mesure d’évaluation décrit la décision obtenue. Les deux fonctions peuvent différer.

Trois jeux de coefficients, mesurés sur les mêmes 1 600 observations, séparent les deux mesures.

| coefficients                 | frontière                 | prédictions correctes | coût $J$ |
|------------------------------|---------------------------|-----------------------|----------|
| $w$ au 50 <sup>e</sup> tour  | —                         | 1 563                 | 0,1438   |
| $w$ au 400 <sup>e</sup> tour | voisine de la précédente  | 1 564                 | 0,1081   |
| 1,5 $w$ au 400 <sup>e</sup>  | identique à la précédente | 1 564                 | 0,1155   |

TABLE 6.3: Les deux premières lignes séparent presque les mêmes élèves ; la troisième multiplie les coefficients par 1,5, ce qui laisse la frontière exactement où elle est.

Les deux premières lignes portent des frontières voisines, que le comptage sépare d’une unité et le coût d’un quart de sa valeur : trois cent cinquante tours de travail apparaissent dans une seule des deux mesures. En multipliant les trois coefficients par un même facteur, la troisième garde la frontière exactement où elle était, puisque  $w$  et  $\lambda w$  s’annulent aux mêmes points. Les mêmes observations restent dans le demi-plan de leur classe et le comptage rend le même nombre ; le coût distingue les deux modèles, l’écartement des probabilités profitant peu aux observations déjà correctement classées et beaucoup aux trente-six autres.




FIGURE 6.2: Coût et nombre d'erreurs selon le biais, à  $w_1, w_2$  fixés. Leurs minima diffèrent :  $w_0 = -4,80$  pour le coût,  $-5,68$  pour les erreurs.

La valeur  $J(w)$  classe un jeu de coefficients selon sa qualité moyenne. Sa dérivée ajoute l'information opératoire :  $\partial J / \partial w_j$  mesure l'effet local d'une variation de  $w_j$ . Le gradient réunit ces sensibilités et donne ainsi une direction et une amplitude de correction ; la dérivation convertit le critère d'erreur en règle de mise à jour.

# Chapitre 7

## Descente de gradient

**OBJECTIFS** appliquer une itération de descente de gradient à la main; prédire le signe d'une composante du gradient; énoncer la condition sous laquelle un pas fait baisser la perte; régler  $\alpha$  à partir d'une courbe de perte; définir un critère d'arrêt et diagnostiquer un entraînement

**PRÉREQUIS** dérivée partielle et gradient (annexe B); chapitre 6

**PARCOURS** essentiel; la formule du gradient est établie à l'annexe F, la convexité à l'annexe G

### 7.1 Correction à appliquer

Le coût  $J(w)$  atteint son minimum quelque part dans l'espace des coefficients, et la descente doit s'y rendre sans en connaître la position. Ce qu'elle peut mesurer, en revanche, c'est la pente du coût au point où elle se trouve : de combien  $J$  varie lorsqu'on modifie légèrement un coefficient.

Cette pente est la *dérivée partielle*  $\partial J / \partial w_j$ , variation de  $J$  par unité de  $w_j$ , les autres coefficients restant fixés. Son signe suffit à décider du sens. Positive, elle indique qu'augmenter  $w_j$  augmente le coût, et qu'il faut donc le diminuer; négative, elle indique l'inverse. Se déplacer à l'opposé de la pente fait baisser  $J$ , pourvu que le déplacement reste assez petit pour que la pente mesurée décrive encore le terrain.

$$\underbrace{w_j}_{\text{nouvelle valeur}} \leftarrow \underbrace{w_j}_{\text{ancienne valeur}} - \underbrace{\alpha}_{\text{taux d'apprentissage}} \underbrace{\frac{\partial J}{\partial w_j}}_{\text{pente du coût en ce point}} \quad \text{pour tous les } j \text{ à la fois.}$$

Le signe moins porte la logique de la méthode :  $-\nabla J$  est la direction de plus forte décroissance locale de  $J$  au point courant. Le facteur  $\alpha$  fixe la longueur du pas dans cette direction; c'est le *taux d'apprentissage*, seul paramètre réglé à la main dans ce cours.

Les coefficients sont corrigés simultanément, à partir des mêmes valeurs antérieures. Corriger  $w_0$  puis calculer la correction de  $w_1$  avec le  $w_0$  déjà modifié évaluerait les deux dérivées en deux points distincts.

Pour le coût logistique, cette pente prend une forme dont tous les termes s'interprètent :

$$\frac{\partial J}{\partial w_j} = \underbrace{\frac{1}{m} \sum_{i=1}^m}_{\text{moyenne sur les } m \text{ observations}} \underbrace{(p_i - y_i)}_{\text{résidu de l'observation } i} \underbrace{x_{ij}}_{\text{sa valeur pour la variable } j}$$

$p_i - y_i$  est le *résidu* de l'observation  $i$  : la probabilité annoncée moins la réponse observée. Pour un **Gryffindor**, il vaut  $-0,9$  lorsque la probabilité produite vaut  $0,1$ , et  $-0,01$  lorsqu'elle vaut  $0,99$ . La correction est donc négligeable sur une observation correctement classée, maximale sur une observation classée dans l'autre catégorie avec une probabilité élevée.

$x_{ij}$  pondère la contribution de ce résidu au coefficient  $j$  : une observation aux valeurs extrêmes contribue fortement, une observation moyenne, dont la note standardisée avoisine zéro, presque pas.

## 7.2 Premier pas de la descente

La descente part ici de coefficients nuls, état  $M_0$ . Le coût étant convexe, toute limite atteinte est un minimum global. L'unicité de ce minimum et la convergence de tous les départs vers un même point demandent les conditions énoncées à l'annexe G.

Partir de zéro rend surtout le premier tour calculable à la main, tous les scores valant alors zéro et toutes les probabilités  $0,5$ . La correction du biais s'écrit, puisque  $x_{i0}$  vaut 1 pour toutes les observations,

$$\frac{\partial J}{\partial w_0} = \frac{1}{m} \sum_{i=1}^m (\underbrace{0,5}_{\text{annoncé}} - \underbrace{y_i}_{\text{observé}}) = \underbrace{0,5}_{\text{proportion annoncée}} - \underbrace{\frac{327}{1\,600}}_{\text{proportion réelle}} = 0,5 - 0,2044 = 0,2956$$

La descente donne exactement cette valeur, 327 élèves sur 1 600 étant **Gryffindor**. Avec  $\alpha = 1$ , le biais passe de 0 à  $-0,2956$ .

Les coefficients nuls produisaient une probabilité moyenne de 50 % pour une fréquence observée de 20,44 %. Le biais diminue tant que la probabilité moyenne dépasse cette fréquence.

## 7.3 Coût au fil des itérations

Répéter l'opération précédente quatre cents fois produit une suite de coûts, dont le tracé résume la descente entière. La baisse y est d'abord rapide, puis de plus en plus lente, et cette forme se déduit de la formule de correction.

Au départ, toutes les probabilités valent  $0,5$  : le résidu  $p_i - y_i$  vaut  $\pm 0,5$  partout, et les 1 600 contributions s'additionnent. À mesure que les probabilités s'ajustent, ce résidu tend vers zéro

| itération | $w_0$ (biais) | $w_1$ ( <b>Herbology</b> ) | $w_2$ ( <b>Ancient Runes</b> ) | coût $J$ |
|-----------|---------------|----------------------------|--------------------------------|----------|
| 0         | 0,0000        | 0,0000                     | 0,0000                         | 0,693147 |
| 1         | -0,2956       | -0,2289                    | 0,1924                         | 0,538507 |
| 2         | -0,5194       | -0,4005                    | 0,3364                         | 0,449297 |
| 5         | -0,9622       | -0,7378                    | 0,6266                         | 0,325975 |
| 10        | -1,3952       | -1,0678                    | 0,9338                         | 0,250029 |
| 50        | -2,7318       | -2,0538                    | 1,9613                         | 0,143846 |
| 400       | -4,7454       | -3,4535                    | 3,4688                         | 0,108113 |

TABLE 7.1: Descente réelle,  $\alpha = 1$ , sur les 1 600 élèves. Le coût initial vaut  $\log 2$ . Les signes des coefficients se fixent dès le premier tour et ne changent plus : négatif pour **Herbology**, positif pour **Ancient Runes**.

pour les observations correctement classées. La correction provient alors des observations proches de la frontière ou incorrectement classées, peu nombreuses. Le nombre de termes non négligeables de la somme décroît donc tour après tour.




FIGURE 7.1: Perte moyenne aux itérations 0, 10, 50 et 400. Les dix premiers tours couvrent 75,7 % de la baisse totale ; les 350 derniers, 6 %.

La longueur du gradient mesure cet épuisement directement : elle passe de 0,42 à 0,0026 sur les quatre cents itérations, soit une division par cent soixante (annexe I). De cette décroissance vient le critère d'arrêt : une correction devenue assez petite laisse les coefficients là où ils sont.

## 7.4 Réglage du pas et arrêt

Le taux  $\alpha$  dépend de l'échelle et des corrélations des variables, donc de la courbure de  $J$ . Le nombre d'itérations dépend ensuite de cette courbure, de  $\alpha$ , du point de départ et de la précision demandée. Ces deux nombres ne possèdent pas de valeur universelle déterminable avant d'examiner les données.

La standardisation précède le réglage. Une série de valeurs de  $\alpha$  espacées sur une échelle logarithmique est ensuite comparée sur les premières itérations, à partir du même point :

1. conserver les réglages pour lesquels la perte reste finie et décroît ;
2. augmenter  $\alpha$  lorsque la baisse est régulière mais très lente ;
3. réduire  $\alpha$  dès qu'apparaissent remontées ou oscillations ;
4. retenir le réglage qui atteint rapidement le plateau sans instabilité.

Une recherche linéaire par *backtracking* automatise cette opération : elle réduit le pas jusqu'à vérifier une baisse suffisante. La borne théorique  $\alpha < 2/L$ , lorsque le gradient est  $L$ -lipschitzien, et l'effet de la standardisation sont établis à l'annexe I. Le choix  $\alpha = 1$  convient ici à une perte *moyenne* et à des variables standardisées ; il doit être reconstrôlé sur un autre problème.

Le nombre d'itérations est produit par une règle d'arrêt plutôt que fixé comme un objectif. Le programme combine une baisse relative de  $J$  inférieure à  $10^{-6}$  et un plafond de 6 000 tours. D'autres règles suivent  $\|\nabla J\|$ , le déplacement relatif de  $w$ , ou la performance sur un ensemble de validation. Plusieurs tours consécutifs doivent confirmer le plateau lorsqu'une estimation par mini-lots rend la courbe bruitée.

| signal observé                                             | diagnostic probable                                    | action                                                         |
|------------------------------------------------------------|--------------------------------------------------------|----------------------------------------------------------------|
| $J$ augmente ou oscille                                    | pas trop long, signe du gradient erroné                | réduire $\alpha$ ; comparer le gradient à une différence finie |
| $J$ baisse lentement, gradient encore élevé                | pas trop court                                         | augmenter progressivement $\alpha$                             |
| $J$ et $\ \nabla J\ $ se stabilisent                       | convergence numérique                                  | arrêter selon la tolérance prévue                              |
| $J_{\text{train}}$ baisse, mesure de validation se dégrade | surapprentissage                                       | arrêter, régulariser ou réduire la complexité                  |
| valeur non finie                                           | formule numériquement instable ou déplacement excessif | employer les formes stables et réduire $\alpha$                |
| plafond atteint, perte en baisse et norme croissante       | données possiblement séparables, minimum à l'infini    | régulariser et conserver le plafond de sécurité                |

TABLE 7.2: Lecture du retour d'entraînement. La courbe de perte sert à régler l'optimisation ; l'ensemble de validation sert à choisir la généralisation.

## 7.5 Déplacement de la frontière

La frontière  $w_0 + w_1x_1 + w_2x_2 = 0$  se trace sous sa forme résolue,

$$x_2 = -\frac{w_0 + w_1x_1}{w_2},$$

qui donne son ordonnée pour chaque abscisse. Reportée à trois moments de la descente, elle occupe presque la même position, et il faut agrandir le tracé pour séparer les trois droites.






FIGURE 7.2: Frontière aux itérations 1, 10 et 400 ; le rectangle agrandi sépare les trois droites. Elles pivotent autour d'un point central du nuage, pour un déplacement total d'un tiers d'écart-type.

Trois cent quatre-vingt-dix-neuf itérations pour un tiers d'écart-type : la descente consacre donc l'essentiel de son travail à autre chose qu'au déplacement de cette droite. Pour voir ce travail, il faut regarder la quantité que la descente modifie réellement, la probabilité, qui est définie en tout point du plan et pas seulement sur la frontière.

## 7.6 Surface de probabilité

À chaque point du plan des notes, le modèle associe une probabilité d'appartenir à [Gryffindor](#). Porter cette probabilité en altitude au-dessus du point qui la produit définit une surface, que les trois figures suivantes donnent aux itérations 1, 10 et 400.

Le premier tour montre une surface presque plane, traversant le nuage à mi-hauteur : la probabilité vaut 0,5 ou presque en tout point. Au dixième, deux plateaux se dégagent, l'un au-dessus du groupe des [Gryffindor](#), l'autre au-dessus des trois autres, séparés par une pente encore large. Au quatre-centième, les plateaux sont établis et la transition tient sur moins d'un demi-écart-type.

Une chose reste pourtant fixe d'une figure à l'autre : la ligne noire tracée à mi-hauteur, où la surface vaut exactement 0,5. Sa projection au sol est la frontière du paragraphe précédent, et c'est de là que vient sa quasi-immobilité pendant que la surface, elle, change du tout au tout.




FIGURE 7.3: Surfaces de probabilité après 1 et 400 itérations, axes et échelles identiques. Trait rouge : niveau 0,5 ; pointillé : sa projection au sol, la frontière de décision.

## 7.7 Niveau 0,5 de la sigmoïde

Cette surface est la sigmoïde composée avec le score. La frontière de décision est sa ligne de niveau 0,5.

Notons  $d$  la distance d'une observation à la frontière, comptée perpendiculairement et affectée du signe du côté où il se situe. Alors

$$z = \|w\| d \quad \text{donc} \quad p = \sigma(\|w\| d).$$

Le rapport des coefficients fixe la position de la frontière et leur norme  $\|w\|$  fixe la rapidité avec laquelle la probabilité passe de 0 à 1 de part et d'autre : les deux quantités agissent séparément. Relevée le long de cette perpendiculaire, la probabilité décrit toujours une sigmoïde, d'autant plus comprimée que  $\|w\|$  est grand.

La largeur de cette transition se mesure par la distance à parcourir pour que la probabilité passe de 25 % à 75 %, soit  $2 \log 3 / \|w\|$  : inversement proportionnelle à la norme, elle se resserre à mesure que celle-ci grandit.

$\|w\|$  passe de 0,30 à 4,89 entre le premier tour et le quatre-centième, et la largeur de transition de 7,35 écarts-types à 0,45 : divisée par seize, comme la norme est multipliée par seize.

La frontière, elle, garde sa place : le tracé de la figure 7.2 le montrait, les deux courbes de la figure 7.4 le mesurent tour par tour.




FIGURE 7.4: La pente atteint 0,996 en une cinquantaine de tours. La norme croît ensuite de 2,84 à 4,89 et resserre la sigmoïde autour de cette frontière.

### Régimes successifs et critère d'arrêt

Une cinquantaine d'itérations orientent la frontière. Les suivantes augmentent la norme des coefficients, ce qui écarte les probabilités de 0,5 à décisions constantes ; le coût continue de décroître, puisqu'il baisse dès que la probabilité accordée à la réponse observée augmente. Cette croissance de la norme trouve une limite, que l'annexe H établit.

L'arrêt combine donc deux critères : une baisse relative passée sous  $\varepsilon$  — indice que le dernier pas a peu progressé — et un plafond d'itérations. Sur ces données, la baisse relative passe sous  $10^{-6}$  longtemps après la stabilisation du classement : la stagnation numérique et la stabilité des décisions se produisent à des moments distincts.

#### Exercice 7.1 — Signe d'une composante du gradient

Au premier tour,  $\partial J / \partial w_1$  vaut  $-0,2289$  pour **Herbology**. Retrouver ce signe sans calculer la somme, à partir de la seule position des **Gryffindor** dans le nuage (figure 4.2) et de la formule du gradient. Prédire ensuite le signe de  $\partial J / \partial w_2$ .

# Chapitre 8

## Interprétation du modèle ajusté

**OBJECTIFS** lire le signe et la valeur d'un coefficient standardisé sans surinterpréter ; énoncer le contenu complet d'un modèle enregistré ; distinguer paramètres ajustés et décisions préalables

**PRÉREQUIS** cote et logit (annexe B) ; chapitre 7

**PARCOURS** essentiel

### 8.1 Interprétation des coefficients

La descente s'arrête sur trois nombres, qui portent tout ce que l'ajustement a extrait des 1 600 observations :

$$w_0 = -4,745, \quad w_1 = -3,454 \text{ (Herbology)}, \quad w_2 = +3,469 \text{ (Ancient Runes)}.$$

Le *signe* donne le sens de l'effet. Le coefficient d'**Herbology** est négatif : à note d'**Ancient Runes** fixée, une note d'**Herbology** plus haute abaisse le score, donc la probabilité annoncée. Celui d'**Ancient Runes** est positif : l'effet est inverse. Dans le nuage, les **Gryffindor** occupent ainsi la région en haut à gauche.

La *valeur absolue* mesure l'effet d'un écart-type de cette variable sur la log-cote, *les autres variables restant fixées*. Les deux valeurs 3,45 et 3,47 sont presque égales : un écart-type de l'une ou de l'autre déplace le score de la même quantité. Cette comparaison n'a de sens que parce que les notes ont été standardisées : sur les notes brutes, le coefficient d'**Ancient Runes** serait vingt fois plus petit que celui d'**Herbology** pour la seule raison que ses valeurs sont vingt fois plus dispersées.

La portée de cette lecture est celle d'un effet conditionnel. Avec des variables corrélées, retirer une colonne modifie les coefficients de celles qui restent, parfois jusqu'au changement de signe ; un coefficient nul signifie « aucun apport une fois les autres variables connues ». L'ajustement porte par ailleurs sur des associations observées, et laisse ouverte la question de savoir si agir sur une note modifierait la classe. Classer des variables par  $|w_j|$  suppose donc des colonnes standardisées et peu corrélées, et reste une lecture descriptive du modèle.

Le *biais*  $w_0$  est le seul des trois à s'appliquer identiquement à toutes les observations. Il vaut la log-cote prédite pour une observation dont toutes les notes standardisées sont nulles, c'est-à-dire moyennes dans chaque matière.

Le biais égale le logit de la proportion de **Gryffindor** dans le seul cas d'un modèle réduit au biais, sans variable — le cas du premier pas de la descente. Dès que des variables corrélées à la classe entrent dans le score, il s'en écarte : ici  $\sigma(-4,745) = 0,0087$ , contre une proportion observée de 0,2044.

Ces trois nombres se lisent aussi de façon quantitative, en revenant à la cote. Le score étant le logarithme de la cote, ajouter une unité à une note standardisée augmente le score de  $w_j$ , donc multiplie la cote par  $e^{w_j}$  :

$$\frac{p'/(1-p')}{p/(1-p)} = e^{w_j} \quad \text{lorsque } x_j \text{ augmente de 1.}$$

Un écart-type de plus en **Ancient Runes** multiplie ainsi par  $e^{3,469} = 32$  la cote d'appartenir à **Gryffindor**, la note d'**Herbology** restant fixée ; un écart-type de plus en **Herbology** la divise par  $e^{3,454} = 32$  également, les deux coefficients étant presque opposés. Le biais donne la cote prédite pour une observation moyenne dans les deux matières :  $e^{-4,745} = 0,0087$ , soit une chance sur cent quinze.

Les deux panneaux ci-dessous font varier  $w_0$  puis  $w_1$  autour du modèle obtenu, les autres coefficients restant à leur valeur. Un troisième panneau pour  $w_2$  montrerait un pivotement identique à celui de  $w_1$  : c'est le rapport  $w_1/w_2$  qui fixe la direction de la frontière, et le faire varier par l'un ou par l'autre revient au même.




FIGURE 8.1: Variation isolée du biais, à gauche : translation. Variation isolée de  $w_1$ , à droite : rotation et modification de la pente de la sigmoïde.

**coefficients ajustés**

$$\begin{aligned}w_0 &= -4,745 \\w_1 &= -3,454 \\w_2 &= +3,469\end{aligned}$$

**conventions**

ordre des matières : **Herbology**, **Ancient Runes**  
réponse associée : **Gryffindor** ou non

**statistiques d'entraînement**

| matière              | médiane | moyenne | écart-type |
|----------------------|---------|---------|------------|
| <b>Herbology</b>     | 3,469   | 1,189   | 5,175      |
| <b>Ancient Runes</b> | 463,918 | 495,052 | 105,186    |

FIGURE 8.2: Contenu d'un modèle enregistré, référence unique pour tout le document : coefficients, six statistiques de préparation, ordre des matières et réponse associée. Chaque élément est nécessaire à la prédiction.

## 8.2 Paramètres appris et paramètres fixés

Les trois coefficients sortent du calcul ; tout le reste a été décidé avant lui, et d'autres décisions auraient donné un autre modèle sur le même fichier.

|                                  | valeur ici                  | ce qui la fixe                                 |
|----------------------------------|-----------------------------|------------------------------------------------|
| <b>déterminé par la descente</b> |                             |                                                |
| coefficients $w$                 | les trois valeurs ci-dessus | les notes et les maisons du fichier            |
| <b>posé avant la descente</b>    |                             |                                                |
| matières retenues                | Herbology, Ancient Runes    | le choix de deux matières qui se dessinent     |
| remplissage des vides            | la médiane                  | un arbitrage entre deux méthodes (ch. 3)       |
| échelle des notes                | centrage-réduction          | rendre les coefficients comparables            |
| coefficients de départ           | tous nuls                   | un point de départ quelconque convient         |
| longueur du pas $\alpha$         | 1                           | un essai contrôlé sur la courbe de coût        |
| critère d'arrêt                  | $\varepsilon$ et un plafond | le temps de calcul accordé                     |
| seuil de décision                | 0,5                         | les deux erreurs comptées au même prix (ch. 5) |

TABLE 8.1: Le calcul produit trois nombres ; les sept décisions le précèdent.

Ces décisions restent invisibles dans les trois coefficients enregistrés, et doivent être consignées à côté d'eux pour qu'un tiers puisse refaire le résultat.

### 8.3 Classement d'une observation nouvelle

Le calcul est celui de la figure 1.1, la classe n'étant plus connue mais déduite : standardiser les deux notes avec les statistiques d'entraînement, calculer  $z = w_0 + w_1x_1 + w_2x_2$ , annoncer Gryffindor si  $z \geq 0$ . Cette comparaison à zéro équivaut à comparer  $p$  à 0,5, la sigmoïde étant croissante ; le calcul de  $p$  est réservé à l'affichage.

Sur les 1 600 lignes du fichier, cette règle en classe correctement 1 564. Les trente-six prédictions incorrectes relèvent de deux situations que la distance à la frontière sépare.

La première est le recouvrement des deux groupes. Dans la bande où les deux populations occupent la même région du plan, aucune droite ne peut les séparer sans erreur, et déplacer la frontière ne fait que changer lesquelles. Ces prédictions se reconnaissent à leur score, faible en valeur absolue, et à la probabilité qui l'accompagne, voisine de 0,5.

La seconde tient à des observations dont les notes contredisent l'étiquette. Situées loin dans la région de l'autre groupe, elles reçoivent une prédiction incorrecte assortie d'une probabilité élevée : ce sont les observations atypiques dont la perte individuelle dépasse cent fois la moyenne. La plus éloignée est incorrectement classée à une distance de 2,27 écarts-types de la frontière.

## ERREURS PAR DISTANCE À LA FRONTIÈRE

| distance                | prédictions |                                      |
|-------------------------|-------------|--------------------------------------|
| moins de 0,5 écart-type | 20          | recouvrement des deux groupes        |
| de 0,5 à 1,0            | 11          |                                      |
| plus de 1,0             | 5           | observations atypiques, jusqu'à 2,27 |
| <b>total</b>            | <b>36</b>   | sur 1 600, soit 97,75 % de correctes |

La distance est comptée perpendiculairement à la frontière, en écarts-types, soit  $|z|/\|w\|$ .

Le taux de 97,75 % est l'*exactitude sur l'échantillon d'ajustement* : il sert de contrôle de cohérence, une valeur anormalement basse signalant un défaut d'ajustement. L'exactitude hors échantillon, assortie de son incertitude, est mesurée au chapitre 12.

## 8.4 Extension à dix notes et quatre maisons

Passer de deux notes à dix ajoute huit coefficients et laisse les formules identiques : la frontière devient un hyperplan de  $\mathbb{R}^{10}$ . Ce qui change ici est la taille du fichier enregistré.

| matières | une maison   |              | quatre maisons |              |
|----------|--------------|--------------|----------------|--------------|
|          | coefficients | statistiques | coefficients   | statistiques |
| 2        | 3            | 6            | 12             | 6            |
| 10       | 11           | 30           | 44             | 30           |
| $n$      | $n + 1$      | $3n$         | $4(n + 1)$     | $3n$         |

TABLE 8.2: Taille du modèle enregistré. Les coefficients se multiplient par le nombre de maisons, les statistiques non : médiane, moyenne et écart-type sont calculés une fois par matière et servent aux quatre modèles.

Le passage à quatre maisons ajoute une décision : quatre modèles comme celui-ci — [Gryffindor](#) contre le reste, puis [Hufflepuff](#) contre le reste, et ainsi de suite — donnent quatre scores pour une même observation, et la classe retenue est celle du plus grand (ch. 9).

### Exercice 8.1 — Lecture d'un coefficient

Un modèle ajusté sur les notes *brutes* donnerait  $w_2 \approx +0,033$  pour [Ancient Runes](#). Montrer que ce coefficient décrit la même frontière que  $+3,469$ , et dire lequel des deux se compare à celui d'[Herbology](#). Par quel facteur un écart-type de plus en [Ancient Runes](#) multiplie-t-il la cote, et pourquoi ce facteur ne dépend-il pas de l'échelle retenue ?



# Chapitre 9

## Classification à quatre maisons

**OBJECTIFS** construire les quatre cibles binaires d'un classifieur un-contre-tous ; appliquer la règle du score maximal ; délimiter la portée des quatre sorties sigmoïdées

**PRÉREQUIS** chapitres 5 et 8

**PARCOURS** essentiel ; la géométrie des régions est reportée à l'annexe K

### 9.1 Un modèle par maison

Une frontière sépare le plan en exactement deux régions. Quatre classes demandent donc une construction supplémentaire ; deux approches sont classiques.

La première conçoit un modèle qui produit directement quatre probabilités de somme 1 : c'est la régression *softmax*, extension multinomiale du modèle binaire, dont la dérivation diffère de celle menée ici. La seconde ramène le problème à quatre questions binaires, chacune traitée par le modèle déjà en place, puis combine les quatre réponses [3]. Ce cours retient la seconde, parce qu'elle réemploie tout ce qui précède sans modification ; le prix de ce choix est décrit à la dernière section.

Elle porte le nom d'*un contre tous*, ou *one-vs-rest*. Pour chaque classe, le procédé est repris à l'identique, seule la cible changeant :

$$y_i = 1 \text{ si l'élève } i \text{ appartient à la maison traitée,} \quad y_i = 0 \text{ sinon.}$$

Les notes et leur préparation sont inchangées, le tableau **X** est le même pour les quatre modèles ; seule la colonne des réponses change.

| maison     | $y^{(G)}$ | $y^{(H)}$ | $y^{(R)}$ | $y^{(S)}$ |
|------------|-----------|-----------|-----------|-----------|
| Gryffindor | 1         | 0         | 0         | 0         |
| Slytherin  | 0         | 0         | 0         | 1         |
| Ravenclaw  | 0         | 0         | 1         | 0         |
| Hufflepuff | 0         | 1         | 0         | 0         |

FIGURE 9.1: Quatre colonnes de réponses construites depuis la même colonne de maisons. Chaque ligne porte exactement un 1, contrainte qu'aucun des quatre modèles ajustés séparément ne connaît.

Quatre descentes indépendantes donnent quatre jeux de coefficients. Sur les deux matières employées ici :

| maison traitée | $w_0$  | $w_1$ (Herbology) | $w_2$ (Ancient Runes) |
|----------------|--------|-------------------|-----------------------|
| Gryffindor     | -5,176 | -3,746            | +3,787                |
| Hufflepuff     | -3,103 | +3,946            | -4,422                |
| Ravenclaw      | -3,800 | +4,143            | +3,931                |
| Slytherin      | -4,627 | -3,399            | -3,621                |

TABLE 9.1: Les quatre modèles binaires, état  $M_4$ . Chaque maison occupe un couple de signes distinct, et les quatre combinaisons possibles sont employées.

Ces douze nombres se lisent sur le nuage par le procédé du chapitre 8 : le signe de  $w_1$  dit de quel côté en **Herbology** se trouve la maison traitée, celui de  $w_2$  fait de même en **Ancient Runes**. Les quatre maisons occupant chacune un coin du nuage, les quatre couples de signes possibles se trouvent employés, un par maison.

Les quatre biais sont négatifs pour une raison commune : chaque maison est minoritaire face aux trois autres réunies, si bien qu'un élève pris au hasard reçoit un score négatif dans les quatre modèles.

## 9.2 Règle du score maximal

Un nouvel élève reçoit quatre scores, un par maison, et il faut en tirer une réponse. Chaque score mesure à quel point son modèle penche pour sa maison : retenir le plus élevé est la règle la plus directe.

$$\text{maison prédite} = \arg \max_k z_k, \quad z_k = w_{k0} + w_{k1}x_1 + w_{k2}x_2$$

Cette règle suppose les quatre scores comparables entre eux. Leur ajustement séparé, chacun sur sa propre question, laisse cette échelle commune indéterminée. Le partage d'une même famille de fonctions, des mêmes notes standardisées et de la même sigmoïde garantit un seul point : comparer les scores ou les probabilités donne le même classement,  $\sigma$  étant croissante et commune aux quatre.

Le statut de l'argmax un-contre-tous tient donc en deux énoncés parallèles. Comme règle de décision, il est solide et compétitif en pratique [3]. Comme estimation de probabilité de classe, il demande une condition supplémentaire, que la section 9.5 mesure sur ces données.

La règle du maximum désigne toujours exactement une maison. Un seuil de 0,5 appliqué séparément à chaque modèle en désignerait zéro ou plusieurs selon les valeurs obtenues.

L'élève 3, de notes standardisées  $x_1 = -1,485$  et  $x_2 = +0,275$ , donne

$$\begin{aligned} z_G &= -5,176 - 3,746 \times (-1,485) + 3,787 \times 0,275 = +1,431, \\ z_H &= -3,103 + 3,946 \times (-1,485) - 4,422 \times 0,275 = -10,181, \\ z_R &= -3,800 + 4,143 \times (-1,485) + 3,931 \times 0,275 = -8,872, \\ z_S &= -4,627 - 3,399 \times (-1,485) - 3,621 \times 0,275 = -0,573. \end{aligned}$$

Le maximum est  $z_G$ , et la maison prédite est celle observée pour cet élève. Le deuxième score se tient deux unités en dessous.

| élève | $z_G$         | $z_H$   | $z_R$         | $z_S$  | prédiction                                           |
|-------|---------------|---------|---------------|--------|------------------------------------------------------|
| 3     | <b>+1,431</b> | -10,181 | -8,872        | -0,573 | <b>Gryffindor</b> , classe observée                  |
| 571   | -7,068        | -1,144  | <b>-1,064</b> | -6,903 | <b>Ravenclaw</b> , classe observée <b>Hufflepuff</b> |

TABLE 9.2: Deux élèves passés aux quatre modèles, état  $M_4$ ; score retenu en gras. Pour l'élève 571, l'écart entre **Ravenclaw** et **Hufflepuff** vaut 0,080 et ses quatre scores sont négatifs.




FIGURE 9.2: À gauche, les quatre frontières binaires. À droite, le découpage du plan par la règle du score maximal; les limites entre régions ont leur propre direction.

## 9.3 Forme des régions

La règle du maximum attribue une classe à chaque point du plan. La région attribuée à une classe donnée est l'intersection de trois demi-plans — ceux où son score dépasse chacun de ses rivaux — donc un ensemble convexe, borné ou non. Deux conséquences servent ici : une classe ne peut pas occuper deux zones séparées, et les limites entre régions ne coïncident pas avec les quatre frontières binaires  $z_k = 0$  du début de chapitre. Ces deux questions sont distinctes :  $z_k = 0$  sépare les décisions binaires positives et négatives du modèle  $k$  ; la décision finale compare les quatre scores entre eux.

### Géométrie des régions

Équations des limites, convexité, bornitude, règle de départage en cas d'égalité : annexe K, section 2.

## 9.4 Contenu du classifieur

Avec dix matières au lieu de deux, chaque modèle a onze coefficients au lieu de trois, sans autre modification. Le fichier enregistré est celui de la figure 8.2, répliqué quatre fois :

- quatre vecteurs de onze coefficients, soit 44 nombres ;
- la liste ordonnée des dix matières, qui dit à quelle note s'applique chaque coefficient ;
- la liste ordonnée des quatre maisons, qui dit quel vecteur correspond à quelle réponse ;
- pour chaque matière, la valeur d'imputation, la moyenne et l'écart-type appris à l'entraînement.

### Ordre des colonnes et des maisons

Un vecteur de coefficients s'applique aux notes dans l'ordre où il a été ajusté, et l'indice du maximum ne devient une maison que par la liste des libellés. Perdre l'un ou l'autre de ces ordres donne un classifieur qui calcule des scores justes et rend des maisons fausses : une défaillance qui ne provoque aucune erreur d'exécution.

## 9.5 Somme des quatre probabilités

Chaque  $\sigma(z_k)$  répond à sa propre question binaire : *cette observation appartient-elle à Gryffindor ?*, puis la même pour les trois autres classes. Quatre estimations séparées, donc quatre nombres libres les uns des autres, dont la somme prend une valeur quelconque entre 0 et 4.




FIGURE 9.3: Quatre sorties sigmoïdées et leur somme, pour trois élèves ; barres numérotées de 0 à 3 dans l'ordre des classes. État  $M_4$ . Sur les 1 600 élèves, la somme excède 1 dans 975 cas.

La classe prédite dépend de l'ordre de ces quatre nombres, qui reste valide quelle que soit leur somme. Les lire comme les parts d'un tout demanderait en revanche que la somme vaille 1 ; c'est à cette condition qu'une phrase telle que « 0,95 de chances d'appartenir à **Gryffindor** » aurait un sens, et l'élève 1067 montre où elle conduit ici, avec 0,952 pour **Gryffindor** et 0,899 pour **Ravenclaw**.

Chaque  $\sigma(z_k)$  estime  $\mathbb{P}(\text{classe} = k \mid \mathbf{x})$  pour un problème binaire *séparé* : c'est la portée que la construction garantit. Que les quatre estimations forment une distribution sur les quatre classes dépend des données, et leur calibration individuelle reste à établir — une sortie calibrée de 0,9 signifierait que 90 % des observations recevant cette valeur appartiennent à la classe.

Deux voies mènent à des probabilités de classe : calibrer ces quatre sorties et vérifier la calibration sur des données mises de côté, ou employer un modèle multiclassés cohérent — la régression *softmax*, qui ajuste les quatre jeux de coefficients ensemble sous la contrainte d'une somme égale à 1. Le périmètre de ce cours retient ces quatre nombres pour leur ordre seul (ch. 1).

#### Paramètres du classifieur

Quatre modèles binaires ajustés indépendamment sur les mêmes notes, et une comparaison de leurs quatre scores.

Exactitude sur l'échantillon d'ajustement : 1 540/1 600, soit 96,25 % sur **Herbology** et **Ancient Runes**, et plus de 98 % avec les dix matières du modèle complet. L'exactitude hors échantillon est mesurée au chapitre 12.

#### Exercice 9.1 — Portée des quatre sorties

L'élève 1067 reçoit 0,952 pour **Gryffindor** et 0,899 pour **Ravenclaw**. Écrire la question binaire à laquelle chacun de ces deux nombres répond, puis dire laquelle des deux phrases suivantes le modèle autorise : « cet élève a 95 % de chances d'être **Gryffindor** », ou « le modèle **Gryffindor** répond oui plus fermement que le modèle **Ravenclaw** ». Justifier par la somme des quatre sorties.

# **Deuxième partie II**

## **Implémentation et évaluation**

# Chapitre 10

## Préparation, score et coût

**OBJECTIFS** écrire la préparation des données, un score, une sigmoïde protégée, une perte stable et une perte moyenne; séparer l'ajustement des statistiques de leur application; contrôler chaque fonction contre une valeur connue d'avance

**PRÉREQUIS** partie I; Python : fonctions, listes, boucles

**PARCOURS** cahier pratique; chaque étape se tente avant de consulter son corrigé

Le programme se répartit en onze fichiers exécutables l'un après l'autre, puis un douzième les réemploie sur d'autres données. Chacun importe le précédent, ajoute une fonction et affiche un nombre de contrôle.

Chaque étape donne le contrat de la fonction, le contrôle qu'elle doit passer, deux indices gradués et une question de transfert. Le code correspondant est à l'annexe L : l'écrire puis l'exécuter avant de l'y lire est ce qui distingue ce cahier d'une lecture.

|                       |                      |                                             |
|-----------------------|----------------------|---------------------------------------------|
| le coût               | step0_prepare.py     | lecture, préparation ajustée puis appliquée |
|                       | step1_score.py       | le score d'une observation                  |
|                       | step2_sigmoid.py     | la sigmoïde sous forme numériquement stable |
|                       | step3_single_cost.py | la perte d'une prédiction, forme stable     |
|                       | step4_total_cost.py  | la perte moyenne sur un tableau             |
| la descente           | step5_gradient.py    | le gradient, et son contrôle par mesure     |
|                       | step6_one_step.py    | un pas de descente                          |
|                       | step7_loop.py        | la boucle et ses deux arrêts                |
| classes et évaluation | step8_four_houses.py | quatre descentes, le plus grand score       |
|                       | step9_holdout.py     | l'exactitude sur les lignes mises de côté   |
|                       | step10_evaluation.py | matrice de confusion, incertitude, plancher |

FIGURE 10.1: Les dix derniers fichiers importent step0, dont load, fit\_stats et design servent jusqu'à la fin. La séparation entre fit\_stats et design est ce qui rend l'étape 10 valide.

## 10.1 Préparation des données

La préparation se scinde en deux fonctions. `fit_stats` *ajuste* les statistiques sur un ensemble de lignes donné et rend, pour chaque colonne, la valeur d'imputation, la moyenne et l'écart-type. `design` *applique* ces statistiques, figées, à un ensemble de lignes quelconque, et construit le tableau **X**.

### Séparation entre ajustement et application

Une fonction unique qui standardiserait une colonne entière mesurerait moyenne et écart-type sur toutes les lignes, test compris. Le test entrerait alors dans la préparation et le taux mesuré ensuite serait invalide (ch. 12).

Avec cette séparation, l'étape 10 appelle `fit_stats` sur les seules lignes d'apprentissage, puis `design` deux fois — une fois sur l'apprentissage, une fois sur le test — avec les mêmes six nombres.

**Herbology** compte 33 notes absentes et **Ancient Runes** 35, sur 1 600 lignes. Elles reçoivent la médiane de leur colonne (ch. 3). Les deux colonnes n'ont ensuite ni le même centre ni la même dispersion : **Herbology** a pour moyenne 1,19 et pour écart-type 5,18, **Ancient Runes** 495,05 et 105,19. Après retrait de la moyenne et division par l'écart-type, les deux colonnes ont pour moyenne 0 et pour écart-type 1.

### Étape 1 —

Préparation des données

**CONTRAT** `load()` rend les deux colonnes de notes et celle des maisons. `fit_stats` prend `columns` et `rows`, puis rend pour chaque colonne le triplet (médiane, moyenne, écart-type) calculé sur les lignes indiquées. Les notes absentes reçoivent d'abord la médiane. `design` prend `columns`, `stats` et `rows`, puis rend le tableau **X** : une ligne par observation, une première colonne valant 1,0, puis les notes standardisées.

**CONTRÔLE** Sur les 1 600 lignes,

```
Herbology median 3.469 mean 1.189 sd 5.175
Ancient Runes median 463.918 mean 495.052 sd 105.186
student 3: [1.0, -1.485, 0.275]
```

**INDICE 1** La médiane d'une liste de longueur paire est la demi-somme des deux valeurs centrales ; trier les valeurs *connues* avant de la prendre.

**INDICE 2** `fit_stats` calcule la moyenne et l'écart-type *après* imputation, pour que les six nombres décrivent la colonne telle que `design` la produira.

**TRANSFERT** Une matière absente pour 40 % des lignes est ajoutée aux deux existantes. Quelle statistique de `fit_stats` devient trompeuse, et qu'observerait-on dans le nuage des trois variables ?

Corrigé : annexe L, `step0_prepare.py`.






FIGURE 10.2: La médiane d'**Ancient Runes**, 463,92, remplace la note absente de la troisième ligne et donne  $-0,296$  après standardisation. Les six nombres employés proviennent de `fit_stats`.

## 10.2 Le score d'une observation

Le score est une somme de produits, la première colonne de **X** portant le biais.

### Étape 2 —

Le score

**CONTRAT** `score_of(weights, x)` rend  $\sum_j \text{weights}[j] \times x[j]$ , où **x** est une ligne de **X**, première colonne comprise.

**CONTRÔLE** Sur la ligne de l'élève 3 : 0,0 avec des coefficients nuls, +1,339 avec  $M_{400} = (-4,7454; -3,4535; +3,4688)$ .

**INDICE 1** Le 1,0 en tête de **x** fait entrer `weights[0]` dans la somme sans le multiplier par une donnée : aucun cas particulier n'est à écrire pour le biais.

**INDICE 2** Parcourir les indices de `weights` plutôt que ceux de **x** laisse la fonction inchangée quand le nombre de matières augmente.

**TRANSFERT** Sans la colonne de 1, quelles formules du chapitre 11 devraient traiter `weights[0]` à part ?

Corrigé : annexe L, `step1_score.py`.

## 10.3 La probabilité

Le score parcourt tout  $\mathbb{R}$ , la probabilité tombe entre 0 et 1 ; la fonction logistique opère ce passage (annexe C).

En double précision,  $e^u$  dépasse le plus grand flottant représentable dès  $u > 709,78$  : l'écriture  $1/(1 + e^{-z})$  échoue pour tout score inférieur à  $-710$ , alors que la valeur cherchée vaut 0. Multiplier haut et bas par  $e^z$  donne  $e^z/(1 + e^z)$ , dont l'exposant reste négatif de ce côté :  $e^{-800}$  passe sous le plus petit flottant, vaut 0 sans lever d'exception, et le quotient rend 0.

**Étape 3 —**

La sigmoïde protégée

**CONTRAT** `sigmoid(z)` rend  $1/(1 + e^{-z})$  pour tout flottant  $z$ , sans lever d'exception.

**CONTRÔLE**

`sigmoid(0) = 0.5    sigmoid(2) = 0.8808    sigmoid(-800) = 0.0`

La même expression à une seule branche lève `OverflowError` sur la troisième valeur.

**INDICE 1** Deux écritures donnent la même valeur :  $1/(1 + e^{-z})$  et  $e^z/(1 + e^z)$ . Chacune est sûre d'un côté de zéro.

**INDICE 2** Le test porte sur le signe de  $z$  ; choisir la branche dont l'exposant reste négatif.

**TRANSFERT** Un score de  $-800$  apparaît dès qu'un coefficient diverge (annexe H). Quelle valeur de  $\sigma$  la boucle d'entraînement verrait-elle alors, et quelle perte en découlerait pour une étiquette valant 1 ?

Corrigé : annexe L, `step2_sigmoid.py`.

**Valeur de référence en zéro**

$\sigma(0)$  vaut 0,5 exactement. Une valeur différente en zéro indique une erreur dans la fonction. Ce contrôle précède l'implémentation de la perte et du coût.

## 10.4 La perte d'une prédiction

L'écriture directe,  $-[y \log p + (1 - y) \log(1 - p)]$ , est celle de la formule. Elle échoue en machine, pour une raison qui vaut d'être vue avant de la remplacer.

**Stabilité numérique de la perte**

Dans tout langage à évaluation stricte, Python compris, les arguments sont évalués avant l'opération qui les combine : un facteur nul annule son terme, mais seulement après que le logarithme correspondant a été calculé. Dans

`-(expected * log(p) + (1 - expected) * log(1 - p))`

les deux appels à `log` sont évalués *avant* les multiplications. Avec `expected = 0.0` et un score de  $-800$ , la sigmoïde rend 0,0, `log(p)` lève une exception, et le facteur 0 qui devait le neutraliser n'a jamais l'occasion d'agir.

C'est exactement le cas qu'une prédiction incorrecte et assurée produit, donc celui que la perte est censée signaler.

La réécriture par `softplus` supprime le problème en éliminant la sigmoïde du calcul (annexe J) :

$$\ell(y, z) = \text{softplus}(z) - yz, \quad \text{softplus}(z) = \max(z, 0) + \log(1 + e^{-|z|}).$$




FIGURE 10.3: Les deux cas de la forme stable. L'étiquette intervient dans un terme linéaire au lieu d'un logarithme, ce qui rend l'expression finie pour tout score.

#### Étape 4 —

La perte d'une prédiction

**CONTRAT** `student_cost(z, expected)` rend  $\text{softplus}(z) - \text{expected} \times z$ , fini pour tout couple d'entrées.

**CONTRÔLE**

|                           |          |
|---------------------------|----------|
| $z = 0$ , expected 0 ou 1 | 0.693147 |
| $z = 6$ , expected 1      | 0.002476 |
| $z = 6$ , expected 0      | 6.002476 |
| $z = -1000$ , expected 0  | 0.0      |
| $z = -1000$ , expected 1  | 1000.0   |

Les quatre appels  $(y, z)$  pour  $(0, \pm 1000)$  et  $(1, \pm 1000)$  doivent rendre des nombres finis. Une implémentation qui lève une exception sur l'un des quatre interrompra l'entraînement au premier coefficient un peu grand.

**INDICE 1** L'exposant  $-|z|$  est toujours négatif ou nul : l'exponentielle ne déborde jamais.

**INDICE 2** `log1p(u)` calcule  $\log(1 + u)$  avec précision pour  $u$  petit, là où  $\log(1+u)$  perdrait les chiffres significatifs.

**TRANSFERT** Pourquoi la perte croît-elle comme  $|z|$ , et non comme  $z^2$  ni comme une constante, pour une prédiction incorrecte assortie d'un score élevé ? Relier la réponse à la borne du gradient.

Corrigé : annexe L, `step3_single_cost.py`.

Les deux premières lignes du contrôle correspondent à  $z = 0$ , donc  $p = 0,5$  : la perte vaut  $\log 2$  quelle que soit l'étiquette. Pour les deux suivantes,  $z = 6$  et  $p = 0,9975$  : cette probabilité coûte 0,0025 portée sur l'étiquette observée et 6,0025 portée sur l'autre. Les deux dernières sont le contrôle décisif : à  $z = -1000$ , l'écriture directe lève une exception, celle-ci rend 0 et 1 000, valeurs exactes.

## 10.5 La perte moyenne

La perte moyenne se calcule ligne par ligne, en réutilisant les trois fonctions précédentes.




FIGURE 10.4: L'élève 3 traversant les trois fonctions, coefficients nuls. Les coefficients n'interviennent qu'au premier passage, la réponse attendue qu'au dernier.

### Étape 5 —

La perte moyenne

**CONTRAT** `total_cost(weights, X, target)` rend la moyenne des pertes individuelles sur les lignes de `X`, appariées aux étiquettes de `target`.

**CONTRÔLE** Sur des coefficients nuls, 0,693147. Cette valeur est la même pour tout fichier, tout choix de matières et tout effectif : un écart localise l'erreur dans le score, la sigmoïde ou la perte.

**INDICE 1** `student_cost` calcule la perte directement à partir du score.

**INDICE 2** Diviser par `len(X)` et non par une constante : c'est ce qui rend la valeur comparable entre l'apprentissage et le test.

**TRANSFERT** Un fichier deux fois plus long, de même composition, donnerait quelle somme et quelle moyenne ? Laquelle des deux permet de comparer les deux fichiers, et pourquoi le réglage de  $\alpha$  dépend-il de ce choix ?

Corrigé : annexe L, `step4_total_cost.py`.

```
1600 students, 3 columns (bias included)
cost with zero weights: 0.693147
```

La fonction `total_cost` fournit le critère employé au chapitre suivant pour optimiser les coefficients.

# Chapitre 11

## Optimisation des coefficients

**OBJECTIFS** écrire le gradient et le contrôler contre une mesure par différences finies ; écrire un pas ; écrire une boucle dont le critère d'arrêt teste une baisse et rend des coefficients cohérents avec la perte retournée

**PRÉREQUIS** chapitre 10 ; annexe F

**PARCOURS** cahier pratique

Un jeu de coefficients étant évalué, trois étapes séparent ce point d'une boucle d'entraînement : la direction du déplacement, sa vérification, puis son itération.

### 11.1 La pente et sa vérification

La pente du coût par rapport à chaque coefficient s'obtient par une formule démontrée à l'annexe F. Les trois pentes sortent ensemble d'un seul passage sur les observations.

Une erreur de signe ou un indice décalé produit ici un programme qui s'exécute, converge lentement et reste silencieux. La formule se contrôle sans démonstration, en mesurant ce qu'elle prétend calculer : une pente est un rapport d'accroissements, obtenu en déplaçant un coefficient dans les deux sens et en divisant l'écart de coût par la distance parcourue.

#### Étape 6 —

Gradient et contrôle numérique

**CONTRAT** `gradient(weights, X, target)` rend la liste des  $\partial J / \partial w_j$ , calculée en un seul passage sur X. `measured_slope(weights, X, target, j, h)` rend la même dérivée par différence centrée, en appelant deux fois `total_cost`.

**CONTRÔLE** En  $(0,3 ; -0,7 ; 0,4)$  et  $h = 10^{-5}$  :

| colonne | formule      | mesure       |
|---------|--------------|--------------|
| 0       | +0.358202569 | +0.358202569 |
| 1       | +0.071184453 | +0.071184453 |
| 2       | -0.098350181 | -0.098350181 |

Écart attendu : de l'ordre de  $10^{-10}$ .

**INDICE 1** La formule est  $\frac{1}{m} \sum_i (p_i - y_i) x_{ij}$  : accumuler un résidu par ligne, puis le répartir sur les colonnes de cette ligne.

**INDICE 2** `measured_slope` ignore tout de la régression logistique : elle déplace `weights[j]` de  $\pm h$ , rappelle `total_cost`, et divise par  $2h$ .

**TRANSFERT** Le point d'évaluation est choisi loin de zéro. Montrer qu'en  $(0, 0, 0)$  un facteur  $1/m$  omiss passerait inaperçu, et proposer un second point de contrôle qui révélerait un indice décalé.

Corrigé : annexe L, `step5_gradient.py`.




FIGURE 11.1: Deux chemins indépendants vers la même dérivée. Le point d'évaluation est choisi loin de zéro, où plusieurs erreurs classiques rendent zéro des deux côtés.

L'écart résiduel vient de la mesure. Centrée sur un pas  $h$ , une différence commet une erreur en  $h^2$ , soit  $10^{-10}$  pour  $h = 10^{-5}$ , ce que les trois lignes retrouvent. Un  $h$  plus grand mesurerait une corde au lieu d'une tangente ; un  $h$  plus petit ferait perdre à la soustraction ses décimales significatives.

### Ordre de grandeur de l'écart

Un écart de l'ordre de  $10^{-10}$  valide la formule. Un écart de  $10^{-2}$  désigne un facteur oublié, un signe opposé désigne une soustraction inversée, et une seule colonne fausse désigne l'indice.

## 11.2 Un pas

Descendre consiste à retrancher la pente, multipliée par la longueur du pas.

### Étape 7 —

Un pas de descente

**CONTRAT** `one_step(weights, X, target)` rend une *nouvelle* liste de coefficients, chacun diminué de ALPHA fois sa dérivée.

**CONTRÔLE** À partir de coefficients nuls et  $\alpha = 1$  :

```
turn 0  cost 0.693147  weights +0.0000 +0.0000 +0.0000
turn 1  cost 0.538507  weights -0.2956 -0.2289 +0.1924
turn 2  cost 0.449297  weights -0.5194 -0.4005 +0.3364
turn 3  cost 0.393020  weights -0.6955 -0.5348 +0.4500
```

Le premier biais,  $-0,2956$ , se recalcule à la main : voir ci-dessous.

**INDICE 1** Construire la liste neuve plutôt que modifier en place. Corriger `weights[0]` avant de calculer la correction de `weights[1]` évaluerait les deux pentes en deux points différents.

**INDICE 2** Le signe est un moins : on se déplace à l'opposé de la pente. Si le coût monte au premier tour, la cause est le signe ou la valeur d'ALPHA.

**TRANSFERT** Prédire, sans exécuter, le signe de  $w_1$  et de  $w_2$  après le premier tour, à partir de la position des **Gryffindor** dans le nuage (figure 4.2).

Corrigé : annexe L, `step6_one_step.py`.

Les coefficients étant nuls, le modèle produit 0,5 pour les 1 600 lignes, et la pente du biais vaut la moyenne des résidus  $\sigma(z) - y$ , où  $y$  vaut 1 pour les **Gryffindor** et 0 pour les autres.

Gryffindor, 20,44 %

|     |                                       |
|-----|---------------------------------------|
| 327 | 1 273 élèves des trois autres maisons |
|-----|---------------------------------------|

$$\sigma(0) - 1 = -0,5$$

$$\sigma(0) - 0 = +0,5$$

$$\text{moyenne} = \frac{1\,273 \times 0,5 - 327 \times 0,5}{1\,600} = 0,2956$$

FIGURE 11.2: Le pas retranche cette moyenne au biais, d'où  $-0,2956$  au premier tour : le biais rejoint la valeur qui fait annoncer 20,44 % à toutes les observations.

## 11.3 Itération jusqu'à stagnation

Un pas isolé fait baisser la perte d'une fraction. La descente répète ce pas jusqu'à ce que la baisse devienne négligeable, ce qui demande une boucle et deux conditions d'arrêt.

### Étape 8 —

La boucle et ses deux arrêts

**CONTRAT** `descend(X, target)` rend le couple (`weights`, `cost`) correspondant au même état, ainsi que le nombre de tours consommés. La boucle s'arrête sur une baisse relative inférieure à  $\text{EPSILON} = 10^{-6}$ , ou sur un plafond de 6 000 tours.

**CONTRÔLE**

```
stopped after 983 iterations, cost 0.107257
weights: -5.1755 -3.7460 +3.7874
```

Le nombre d'itérations se lit en premier : à 983 pour un plafond de 6 000, c'est le critère de stagnation qui a mis fin à la boucle. Une valeur égale au plafond signifierait un pas trop court, ou l'absence de minimum fini (annexe H).

**INDICE 1** Le test doit porter sur `previous - cost`, une baisse, et non sur `abs(previous - cost)`.

**INDICE 2** Appliquer le pas *avant* de calculer la perte retournée : les deux valeurs décrivent alors le même état.

**TRANSFERT** Le seuil relatif  $10^{-6}$  est atteint après 983 tours, alors que la frontière a cessé de se déplacer bien avant (ch. 7). Proposer un critère d'arrêt qui testerait la stabilité des *décisions*, et dire ce qu'il coûterait par tour.

Corrigé : annexe L, `step7_loop.py`.

### Trois pièges du critère d'arrêt

**Valeur absolue.** Écrire `abs(previous - cost) < seuil` accepte aussi une hausse faible de la perte et peut donc arrêter à tort une boucle instable.

**Relatif ou absolu.** Écrire `... / max(1, abs(cost))` ne normalise pas le coût lorsqu'il est inférieur à 1. La forme `previous - cost < EPSILON * abs(previous)` conserve une interprétation relative.

**Cohérence entre retours.** La perte et les coefficients retournés doivent décrire le même état ; appliquer un pas après le dernier calcul de perte les décale d'une itération.




FIGURE 11.3: Le coût est calculé une fois par tour, pour le seul test d'arrêt. Le gradient constitue un second passage sur les 1 600 lignes : une itération en coûte deux.

Le seuil relatif arrête les itérations lorsque la baisse du coût devient négligeable. Le plafond couvre les configurations où les coefficients divergent et où ce seuil n'est jamais atteint (annexe H).

Ces coefficients constituent l'état  $M_{\text{arr}}$ . Les figures de la partie I emploient  $M_{400}$ , arrêté au quatre-centième tour :  $-4,745$ ,  $-3,454$ ,  $+3,469$ . Les deux états diffèrent d'environ 9 % en norme, et leurs rapports coïncident à trois millièmes près : la frontière se stabilise avant la perte, tandis que les derniers tours resserrent la sigmoïde.



# Chapitre 12

## Classification multiclasse et évaluation

**OBJECTIFS** appliquer la même descente aux quatre classes et combiner les résultats par argmax ; construire un découpage stratifié ; ajuster les statistiques de préparation sur l'apprentissage seul ; lire une matrice de confusion et l'assortir d'une incertitude ; arbitrer un seuil de décision binaire

**PRÉREQUIS** chapitres 9 et 11

**PARCOURS** cahier pratique ; le protocole d'évaluation se met en place ici

La boucle précédente traite une question binaire. La classification multiclasse en ajuste quatre, les combine en une réponse unique, puis mesure cette réponse sur des lignes absentes de l'ajustement.

### 12.1 Extension un-contre-tous

La descente, le coût et le gradient sont ceux de l'étape précédente, appelés quatre fois de suite. Seule la colonne des réponses est refaite à chaque tour : elle vaut 1 pour la maison traitée et 0 pour les trois autres.

#### Étape 9 —

Quatre descentes et l'argmax

**CONTRAT** `train(X, houses)` rend un jeu de coefficients par classe, dans l'ordre de HOUSES. `predict(models, x)` rend le libellé de la classe dont le score est le plus élevé.

**CONTRÔLE**

```
Gryffindor cost 0.1073 983 iterations
Hufflepuff cost 0.1368 779 iterations
Ravenclaw cost 0.1309 818 iterations
Slytherin cost 0.1353 814 iterations
1540 students out of 1600, that is 0.9625
```

Les quatre pertes sont du même ordre ; chaque descente atteint le critère de stagnation avant le plafond d'itérations.

**INDICE 1** Le tableau `X` est construit une seule fois : seule la colonne `target` change d'une classe à l'autre.

**INDICE 2** `predict` compare directement les scores. La croissance de  $\sigma$ , commune aux quatre modèles, conserve leur classement.

**TRANSFERT** Une cinquième classe est ajoutée au fichier. Combien de descentes, combien de coefficients, et quelles lignes de `train` et de `predict` changent ?

Corrigé : annexe L, `step8_four_houses.py`.

Ce taux de 0,9625 est l'exactitude sur l'échantillon d'ajustement : il porte sur les lignes qui ont servi à placer les quatre frontières. L'étape suivante le mesure hors échantillon.

|                   | quatre jeux de coefficients |         |         | scores  |                         |
|-------------------|-----------------------------|---------|---------|---------|-------------------------|
| <b>Gryffindor</b> | -5,176                      | - 3,746 | + 3,787 | +1,431  | → predict<br>Gryffindor |
| <b>Hufflepuff</b> | -3,103                      | + 3,946 | - 4,422 | -10,181 |                         |
| <b>Ravenclaw</b>  | -3,800                      | + 4,143 | + 3,931 | -8,872  |                         |
| <b>Slytherin</b>  | -4,627                      | - 3,399 | - 3,621 | -0,573  |                         |

FIGURE 12.1: L'élève 3 passé aux quatre modèles, état  $M_4$ . **Slytherin** arrive deuxième : ses coefficients partagent le signe de **Gryffindor** sur **Herbology** et s'y opposent sur **Ancient Runes**.

`predict` retient le plus grand des quatre scores. Comparer les scores ou les probabilités donne le même classement, la sigmoïde étant croissante et commune aux quatre modèles. La comparabilité des probabilités *entre* modèles relève d'une condition distincte (ch. 9); leur calcul est réservé à l'affichage.

## 12.2 Mesure sur des lignes mises de côté

La mesure hors échantillon scinde le fichier en un *ensemble d'apprentissage*, qui sert à tout ajuster, et un *ensemble de test* mis de côté avant toute opération et consulté une seule fois.




FIGURE 12.2: Les statistiques de préparation sont des paramètres ajustés au même titre que les coefficients. Les flèches en pointillé transportent des nombres figés, jamais un nouvel ajustement.

Le découpage porte sur les *indices*, avant toute lecture des notes. Les statistiques de préparation sont ensuite ajustées sur les seuls indices d'apprentissage, puis appliquées aux deux ensembles.




FIGURE 12.3: Teinte pleine, les 1 280 élèves d'apprentissage ; teinte claire, les 320 mis de côté. Le tirage stratifié prend 80 % de chaque maison, ce qui fixe les quatre proportions d'une exécution à l'autre.

Le mélange se fait sur les indices, par un générateur écrit sur place plutôt que par `random.shuffle`. Chaque nombre tiré s'obtient du précédent par

$$\text{état} \leftarrow (a \text{ état} + c) \bmod 2^{31},$$

avec deux constantes éprouvées. Repartir du même état initial — la graine 0 — redonne la même suite, donc le même découpage à chaque exécution, condition de comparabilité entre deux mesures.

#### Étape 10 —

Découpage stratifié et exactitude hors échantillon

**CONTRAT** `split(houses, seed)` rend deux listes d'indices, apprentissage et test, contenant 80 % et 20 % de *chaque* classe. Le programme ajuste ensuite `fit_stats` sur les seuls indices d'apprentissage, appelle `design` sur les deux ensembles, entraîne, et mesure trois exactitudes.

**CONTRÔLE**

```

1280 students to learn from, 320 set aside
median, mean and sd fitted on the learning rows only
on students already seen : 0.9609
on students never seen    : 0.9719
everyone into Hufflepuff : 0.3312

```

**INDICE 1** Grouper les indices par classe, mélanger chaque groupe, puis prendre les quatre premiers cinquièmes de chacun : le découpage porte sur les indices, avant toute lecture des notes.

**INDICE 2** Un seul appel à `fit_stats`, deux appels à `design`. Un second appel à `fit_stats` sur le test annulerait tout le protocole.

**TRANSFERT** Le tirage stratifié est remplacé par un tirage global de 20 %. Quelle classe voit sa part varier le plus d'une graine à l'autre, et pourquoi ? Estimer l'effet sur la largeur de l'intervalle de Wilson.

Corrigé : annexe L, `step9_holdout.py`.




FIGURE 12.4: Plancher : exactitude d'une règle attribuant **Hufflepuff** à tout le monde. L'écart apprentissage-test vaut onze millièmes, soit trois ou quatre élèves sur 320.

Le premier chiffre est l'exactitude sur l'échantillon d'ajustement, optimiste par construction. Le deuxième porte sur 320 observations absentes de l'ajustement : c'est celui qui prédit une observation à venir. Le troisième donne le plancher, obtenu par une règle qui met tout le monde dans la classe majoritaire ; un modèle doit le dépasser nettement pour démontrer un apport.

Ici le second dépasse le premier, d'un écart qui reste dans la marge d'un échantillon de 320 lignes. Un modèle à 99 % sur l'apprentissage et 85 % sur le test aurait au contraire ajusté le bruit des lignes vues plutôt que la régularité : c'est le *surapprentissage*.

Cet écart en est un révélateur parmi d'autres, souvent moins sensible qu'une courbe d'apprentissage, une validation croisée, la comparaison des pertes ou la stabilité des coefficients d'un découpage à l'autre. Trois coefficients par classe offrent peu de liberté, et le surapprentissage tient aussi à la sélection des variables, au réglage répété sur les mêmes données, à un échantillon petit ou bruyé. Les deux matières employées ici ont été choisies après examen du fichier étiqueté entier : ce canal précède le découpage, et l'écart apprentissage-test reste par construction aveugle à son effet. Un protocole complet choisirait les variables sur les seules lignes d'apprentissage, ou sur un ensemble de validation distinct du test.

## 12.3 Résultats et limites

Un taux global agrège des erreurs de natures différentes et laisse sa propre précision indéterminée. Deux compléments le complètent, et tiennent en une trentaine de lignes.

**La matrice de confusion** croise classe observée et classe prédite. Ses seize cases distinguent une classe systématiquement manquée d'erreurs réparties au hasard, ce que le taux global confond.

| observée   | prédite    |            |           |           | total |
|------------|------------|------------|-----------|-----------|-------|
|            | Gryffindor | Hufflepuff | Ravenclaw | Slytherin |       |
| Gryffindor | <b>62</b>  | 1          | 2         | 0         | 65    |
| Hufflepuff | 0          | <b>105</b> | 1         | 0         | 106   |
| Ravenclaw  | 0          | 2          | <b>86</b> | 1         | 89    |
| Slytherin  | 0          | 2          | 0         | <b>58</b> | 60    |

TABLE 12.1: Matrice de confusion sur les 320 lignes mises de côté; diagonale en gras, 311 prédictions correctes. Les neuf erreurs se répartissent inégalement : trois **Gryffindor** manqués, cinq prédictions **Hufflepuff** excédentaires.

**L'incertitude.** Pour 311 succès sur 320 lignes, l'intervalle de Wilson à 95 % [4] vaut

$$[0,9474 ; 0,9851].$$

Sa largeur, proche de quatre points, donne la précision justifiée par l'effectif.

| classe     | rappel | précision | $F_1$  | effectif |
|------------|--------|-----------|--------|----------|
| Gryffindor | 0,9538 | 1,0000    | 0,9764 | 65       |
| Hufflepuff | 0,9906 | 0,9545    | 0,9722 | 106      |
| Ravenclaw  | 0,9663 | 0,9663    | 0,9663 | 89       |
| Slytherin  | 0,9667 | 0,9831    | 0,9748 | 60       |

TABLE 12.2: Mesures par classe. Le *rappel* est la part d'une classe retrouvée, la *précision* la part des prédictions d'une classe qui lui reviennent. Sur ces effectifs, les écarts restent dans la marge d'échantillonnage.

### Étape 11 –

Matrice de confusion et incertitude

**CONTRAT** À partir des prédictions sur le test, produire la matrice  $4 \times 4$  observée  $\times$  prédite, les couples rappel-précision par classe, l'exactitude globale, son intervalle de Wilson à 95 % et le plancher de la classe majoritaire.

**CONTRÔLE**

$$\begin{aligned} \text{accuracy } 311/320 &= 0.9719 & \text{Wilson } 95\% & [0.9474 ; 0.9851] \\ \text{baseline, everyone into Hufflepuff} &: 0.3312 \end{aligned}$$

Les seize cases doivent totaliser 320, et la diagonale 311.

**INDICE 1** Indexer la matrice par la position de la classe dans HOUSES, non par son libellé : les totaux de ligne et de colonne s'obtiennent alors par simple somme.

**INDICE 2** L'intervalle de Wilson pour  $k$  succès sur  $n$  tirages s'écrit avec  $z_{0,975} = 1,96$ ; il n'est pas symétrique autour de  $k/n$ , ce qui se vérifie sur les bornes attendues.

**TRANSFERT** Une classe obtient un rappel de 0,55 pour une précision de 0,98. Décrire le comportement du modèle sur cette classe, dire quelle case de la matrice le révèle, et indiquer si déplacer un seuil pourrait le corriger.

Corrigé : annexe L, `step10_evaluation.py`.

La portée de ces chiffres s'arrête à trois limites. Un seul découpage mesure un seul découpage : plusieurs graines, ou une validation croisée à  $k$  blocs, donneraient en outre une dispersion. Le choix des deux matières reste antérieur au découpage. Et la calibration reste à vérifier, de sorte que les probabilités affichées valent pour leur ordre plutôt que comme des fréquences.

## 12.4 Seuil de décision, en binaire

Le classifieur à quatre classes tranche par comparaison de scores. Sur le sous-problème binaire du chapitre 5, la conversion d'une probabilité en réponse demande un *seuil* : au-dessus, la classe prédite est [Gryffindor](#). Le cours adopte  $s = 0,5$ , ce qui compte les deux erreurs au même prix.

Le seuil se fixe après l'entraînement, qui détermine les coefficients et avec eux les probabilités. Les mêmes probabilités, lues avec deux seuils, donnent deux classements.

Sur 0,5, la comparaison se ramène au signe du score,

$$p \geq 0,5 \iff z \geq 0 \iff \text{l'observation appartient au demi-plan } \text{Gryffindor},$$

les trois formulations étant équivalentes puisque  $\sigma$  est croissante et vaut 0,5 en zéro. Le programme peut donc s'en tenir aux scores lorsque seule la maison intéresse, et calculer les probabilités uniquement pour les afficher.

Déplacer le seuil échange une erreur contre l'autre, les deux portant sur des observations distinctes : un [Gryffindor](#) dont la probabilité tombe sous le seuil est manqué, une observation d'une autre classe dont la probabilité le dépasse est désignée à tort. Monter le seuil raréfie les secondes et multiplie les premières ; le descendre produit l'effet inverse. Choisir un seuil revient donc à choisir la proportion entre les deux.




FIGURE 12.5: Probabilités par classe observée, en haut ; hachures : erreurs au seuil 0,5. Nombre d'erreurs selon le seuil, en bas ; minimum cerclé.

Un seuil  $s$  quelconque revient de même à comparer le score au logit de  $s$ , donc à tracer la droite  $z = \text{logit}(s)$ , parallèle à celle de 0,5. Changer le seuil translate la frontière sans la faire pivoter, ce qui revient à déplacer le seul biais  $w_0$  (ch. 4).




FIGURE 12.6: Nuage standardisé et droites des seuils 0,3, 0,5 et 0,7 : même direction, biais décalés. L'agrandissement porte les observations qui changent de réponse d'une droite à l'autre.

Les trois seuils reviennent aux biais  $-3,898$ ,  $-4,745$  et  $-5,593$ , soit des droites distantes de 0,17 écart-type.



ERREURS SELON LE SEUIL, ÉTAT  $M_{400}$ 

| seuil  | Gryffindor manqués | désignés à tort | total |                        |
|--------|--------------------|-----------------|-------|------------------------|
| 0,30   | 22                 | 33              | 55    |                        |
| 0,50   | 24                 | 12              | 36    | seuil retenu           |
| 0,58   | 24                 | 7               | 31    |                        |
| 0,5824 | 23                 | 7               | 30    | minimum sur ce fichier |
| 0,70   | 27                 | 4               | 31    |                        |

Le minimum n'apparaît qu'en balayant les seuils au dix-millième ; une grille plus grossière rend 31. Un seuil obtenu par balayage sur les données d'ajustement est une valeur ajustée de plus, qui se déplacerait sur un autre échantillon.

L'origine de ce décalage tient à l'échantillon, non au déséquilibre des classes. Sous des probabilités conditionnelles correctement estimées et deux erreurs comptées au même prix, le seuil qui minimise le nombre d'erreurs vaut 0,5 quel que soit le déséquilibre : c'est la règle de décision de Bayes, et les proportions de classes n'y interviennent pas. Le rapport de 327 Gryffindor à 1 273 autres élèves est d'ailleurs déjà absorbé par le biais  $w_0$ , qui s'ajuste sur la fréquence de base (ch. 7).

Le décalage observé a trois causes : calibration imparfaite des probabilités estimées, spécification affine approchée de la vraie frontière, et taille finie de l'échantillon — déplacer le seuil de 0,5 à 0,58 fait basculer une poignée d'observations, l'ordre de grandeur du bruit d'échantillonnage. Le programme garde 0,5, issu d'une décision explicite plutôt que d'un ajustement sur ce fichier.

Un seuil franchement différent se justifie lorsque les deux erreurs coûtent des prix différents. Recenser toutes les observations d'une classe quitte à en désigner quelques-unes de trop conduit à abaisser le seuil ; ne désigner que des cas sûrs conduit à l'élever. Ce choix relève de l'usage fait des prédictions, que les données seules laissent ouvert.

À quatre classes, la décision compare les quatre scores et retient le plus grand (ch. 9) ; le seuil ne s'applique donc qu'au sous-problème binaire. La valeur 0,5 garde partout son autre rôle : probabilité rendue par  $\sigma$  en zéro, elle situe la frontière et donne le coût de départ.

## 12.5 Compléments pour un programme livrable

Trois ajouts séparent ce qui précède d'un programme utilisable sur un fichier d'élèves inconnus.

**Enregistrer le modèle.** Les quatre vecteurs, mais aussi les trois statistiques par matière, la liste ordonnée des matières et celle des maisons. Un coefficient s'applique à la note qui occupait sa place pendant l'entraînement, et le plus grand score ne devient une maison que par la liste des libellés. Perdre l'un de ces ordres donne des scores justes et des réponses fausses, sans aucune erreur d'exécution.

**Appliquer les statistiques d'entraînement à la prédiction.** Un élève inconnu reçoit la médiane, la moyenne et l'écart-type appris sur les élèves d'entraînement, jamais les siens.

Recalculer ces trois nombres sur les nouvelles données placerait les scores dans une autre échelle ; sur un fichier d'un seul élève, l'écart-type serait nul et l'opération n'aurait pas de sens.

**Consigner le protocole.** La graine du découpage, la proportion retenue, les statistiques ajustées et la date de la mesure. Ces quatre éléments rendent le chiffre annoncé reproductible, condition pour qu'il constitue un résultat.

## 12.6 Micro-cas de transfert

Le fil rouge a fourni un seul jeu de données. Le micro-cas suivant reprend la chaîne entière sur douze observations d'un autre domaine, dans d'autres unités, et fait apparaître un comportement que les 1 600 élèves masquaient.

| mesures  |          |   | classe |  |  | mesures  |          |   | classe |  |  | mesures  |          |   | classe |  |  |
|----------|----------|---|--------|--|--|----------|----------|---|--------|--|--|----------|----------|---|--------|--|--|
| <i>d</i> | <i>H</i> |   |        |  |  | <i>d</i> | <i>H</i> |   |        |  |  | <i>d</i> | <i>H</i> |   |        |  |  |
| 10,02    | 121      | 0 |        |  |  | 9,96     | 127      | 0 |        |  |  | 10,35    | 147      | 1 |        |  |  |
| 10,05    | 118      | 0 |        |  |  | 10,07    | 116      | 0 |        |  |  | 9,71     | 145      | 1 |        |  |  |
| 9,98     | 124      | 0 |        |  |  | 10,31    | 143      | 1 |        |  |  | 10,24    | 136      | 1 |        |  |  |
| 10,01    | 119      | 0 |        |  |  | 10,28    | 139      | 1 |        |  |  | 9,68     | 141      | 1 |        |  |  |

TABLE 12.3: Douze pièces usinées : diamètre  $d$  en millimètres, dureté  $H$  en vickers, classe 1 pour un rebut. Les deux colonnes diffèrent d'un facteur cinquante en échelle.

### Étape 12 —

Transfert : douze pièces, deux mesures

**CONTRAT** Reprendre `score_of`, `sigmoid`, `student_cost`, `gradient` et la boucle sans les modifier ; n'écrire que la lecture du tableau et la standardisation des deux colonnes.

**CONTRÔLE**

```
diametre mean 10.0550 sd 0.2071
durete mean 131.3333 sd 11.1305
cost with zero weights: 0.693147
stopped after 6000 iterations (plafond), cost 0.000595
weights: -0.2721 +1.8591 +11.6553
12/12 pieces classees correctement
```

**INDICE 1** Le coût de départ vaut  $\log 2$  ici comme ailleurs : il ne dépend ni du nombre d'observations, ni de leurs unités.

**INDICE 2** La boucle sort par le plafond, non par la stagnation. Comparer  $\|w\|$  au tour 1 000 et au tour 6 000 avant de conclure à une erreur de programmation.

**TRANSFERT** Les douze pièces sont linéairement séparables. Expliquer pourquoi la perte tend vers zéro sans que la descente s'arrête, en quoi le plafond d'itérations est ici le seul critère qui puisse trancher, et ce que deviendrait la frontière avec un plafond dix fois plus grand (annexe H). Prédire ensuite la classe d'une pièce mesurant 10,20 mm pour 133 HV, puis vérifier :  $x = (+0,700 ; +0,150)$  et  $z = +2,775$ .

Corrigé : annexe L, `transfert_micro.py`.

## **Troisième partie III**

### **Fondements, démonstrations et compléments**

# Annexe A

## Notation et vocabulaire

**OBJECTIFS** retrouver la définition, la dimension et le lieu d'introduction d'un symbole ; passer du vocabulaire français au vocabulaire anglais de référence

**PRÉREQUIS** aucun

**PARCOURS** référence ponctuelle ; revenir au chapitre indiqué dans la dernière colonne

### A.1 Indices et dimensions

| symbole | désignation                                                                    | introduit |
|---------|--------------------------------------------------------------------------------|-----------|
| $m$     | nombre d'observations d'un ensemble ;<br>1 600 pour le fichier entier          | ch. 2     |
| $n$     | nombre de variables explicatives ; 2 en<br>partie I, 10 pour le modèle complet | ch. 4     |
| $i$     | indice d'observation, de 1 à $m$                                               | ch. 6     |
| $j, k$  | indices de coefficient, de 0 à $n$ ; l'indice 0<br>est celui du biais          | ch. 7     |
| $K$     | nombre de classes ; 4 ici                                                      | ch. 9     |

TABLE A.1: La somme sur les coefficients commence à  $j = 0$  parce que le biais est traité comme un coefficient ordinaire, associé à une colonne de 1.

| symbole      | désignation                                                                     | introduit |
|--------------|---------------------------------------------------------------------------------|-----------|
| $v$          | note brute, telle qu'elle figure dans le fichier                                | ch. 3     |
| $\mu$        | moyenne d'une colonne, mesurée sur l'apprentissage                              | ch. 3     |
| $\sigma$     | écart-type d'une colonne, mesuré sur l'apprentissage                            | ch. 3     |
| $x_j$        | note standardisée dans la matière $j$ , soit $(v - \mu)/\sigma$                 | ch. 3     |
| $x_0$        | colonne constante égale à 1, porteuse du biais                                  | ch. 10    |
| $\mathbf{x}$ | vecteur $(x_0, x_1, \dots, x_n)$ d'une observation                              | ch. 4     |
| $x_{ij}$     | note standardisée de l'observation $i$ dans la matière $j$                      | ch. 7     |
| $\mathbf{X}$ | tableau des $m$ vecteurs d'observation                                          | ch. 9     |
| $y_i$        | étiquette de référence de l'observation $i$ : 1 pour la classe traitée, 0 sinon | ch. 4     |

TABLE A.2: La cote standard  $(v - \mu)/\sigma$  est notée  $x$  et non  $z$ , contrairement à l'usage statistique, la lettre  $z$  étant réservée au score du modèle.

| symbole                | désignation                                                                                      | introduit |
|------------------------|--------------------------------------------------------------------------------------------------|-----------|
| $w_0$                  | biais, coefficient de la colonne constante                                                       | ch. 4     |
| $w_j$                  | coefficient de la matière $j$                                                                    | ch. 4     |
| $\mathbf{w}$           | vecteur $(w_0, w_1, \dots, w_n)$ de tous les coefficients                                        | ch. 6     |
| $w$                    | vecteur normal $(w_1, \dots, w_n)$ , <i>biais exclu</i> , employé dans les passages géométriques | ch. 4     |
| $\ w\ $                | norme du seul vecteur normal ; vaut 4,89 pour $M_{400}$                                          | ch. 4     |
| $\ \mathbf{w}\ $       | norme de tous les coefficients ; vaut 6,82 pour $M_{400}$                                        | annexe H  |
| $\alpha$               | taux d'apprentissage                                                                             | ch. 7     |
| $\varepsilon$          | seuil de stagnation du critère d'arrêt                                                           | ch. 11    |
| $s$                    | seuil de décision sur la probabilité ; 0,5 ici                                                   | ch. 5     |
| $\mu$ (régularisation) | coefficient du terme $\frac{\mu}{2} \ \mathbf{w}\ ^2$                                            | annexe H  |

TABLE A.3: Deux normes distinctes.  $\|w\|$ , sans le biais, fixe la raideur de la sigmoïde le long de la perpendiculaire à la frontière ;  $\|\mathbf{w}\|$ , biais compris, sert à la régularisation et à la divergence.

## A.2 Données

## A.3 Paramètres et modèle

## A.4 Fonctions et quantités calculées

| symbole              | désignation                                                     | introduit |
|----------------------|-----------------------------------------------------------------|-----------|
| $z$                  | score, $\sum_j w_j x_j$                                         | ch. 4     |
| $\sigma(z)$          | fonction logistique, $1/(1 + e^{-z})$                           | ch. 5     |
| $p$                  | probabilité annoncée pour la classe traitée,<br>$p = \sigma(z)$ | ch. 5     |
| $\ell$               | perte associée à une prédiction                                 | ch. 6     |
| $J(\mathbf{w})$      | perte moyenne sur un ensemble<br>d'observations                 | ch. 6     |
| $L(\mathbf{w})$      | vraisemblance                                                   | annexe E  |
| $\nabla J$           | gradient de $J$ , vecteur des $n + 1$ dérivées<br>partielles    | ch. 7     |
| $\text{softplus}(z)$ | $\log(1 + e^z)$                                                 | annexe J  |
| $\text{logit}(p)$    | $\log(p/(1 - p))$                                               | ch. 4     |
| $d$                  | distance signée d'une observation à la<br>frontière, $z/\ w\ $  | ch. 4     |
| $s_i$                | $\sigma(z_i)(1 - \sigma(z_i))$ , facteur de la hessienne        | annexe G  |

TABLE A.4: La lettre  $\sigma$  désigne l'écart-type d'une colonne dans les passages sur la préparation des données, et la fonction logistique partout ailleurs. La distinction se lit à l'argument :  $\sigma$  seul est un écart-type,  $\sigma(z)$  est une fonction.

## A.5 États du modèle

Le tableau 1.2 du chapitre 1 nomme les quatre jeux de coefficients employés :  $M_0$ ,  $M_{400}$ ,  $M_{\text{arr}}$  et  $M_4$ . Toute valeur numérique citée dans le document se rapporte à l'un d'eux, et le nom est rappelé dans la légende de la figure ou du tableau concerné.

## A.6 Glossaire

| français                     | anglais                         | remarque                                                             |
|------------------------------|---------------------------------|----------------------------------------------------------------------|
| cote                         | odds                            | rapport $p/(1 - p)$ , non une probabilité                            |
| log-cote, logit              | log-odds, logit                 |                                                                      |
| fonction logistique          | logistic function, sigmoid      |                                                                      |
| score                        | score, logit, linear predictor  | « logit » désigne aussi le score dans la littérature d'apprentissage |
| entropie croisée binaire     | binary cross-entropy            | aussi <i>log-loss</i>                                                |
| vraisemblance                | likelihood                      |                                                                      |
| descente de gradient         | gradient descent                | ici en lot complet, <i>batch</i>                                     |
| taux d'apprentissage         | learning rate                   |                                                                      |
| frontière de décision        | decision boundary               |                                                                      |
| vecteur normal               | normal vector, weight vector    |                                                                      |
| hyperplan affine             | affine hyperplane               |                                                                      |
| un-contre-tous               | one-vs-rest, one-vs-all         | [3]                                                                  |
| matrice de confusion         | confusion matrix                |                                                                      |
| rappel                       | recall, sensitivity             |                                                                      |
| précision                    | precision                       |                                                                      |
| apprentissage / test         | training / test set             |                                                                      |
| fuite de données             | data leakage                    |                                                                      |
| surapprentissage             | overfitting                     |                                                                      |
| convexe, strictement convexe | convex, strictly convex         | deux propriétés distinctes (annexe G)                                |
| séparabilité linéaire        | linear separability             | [5]                                                                  |
| régularisation               | regularisation                  |                                                                      |
| cote standard                | <i>z</i> -score, standard score | notée <i>x</i> ici                                                   |
| imputation                   | imputation                      | [1]                                                                  |

TABLE A.5: Les sorties console des programmes de la partie II sont en anglais, comme les noms de fonctions : c'est la langue des identifiants du projet. Le texte, lui, emploie systématiquement le terme français.

# Annexe B

## Rappels de prérequis

**OBJECTIFS** réactiver les outils de statistique, d'analyse et de géométrie employés par le cours

**PRÉREQUIS** aucun

**PARCOURS** référence ponctuelle ; chaque section indique le chapitre ou l'annexe de retour

### B.1 Résumer une colonne de nombres

Soit  $v_1, \dots, v_m$  les valeurs observées dans une colonne.

**Moyenne.**  $\mu = \frac{1}{m} \sum_i v_i$ . Elle se déplace avec chaque valeur : ajouter mille points à la plus haute note déplace  $\mu$  de  $1000/m$ .

**Médiane.** La valeur qui coupe la colonne triée en deux moitiés de même effectif ; pour un effectif pair, la demi-somme des deux valeurs centrales. Déplacer la plus haute note ne la change pas tant que l'ordre des valeurs centrales est préservé. C'est cette insensibilité qu'on appelle *robustesse*.

**Écart-type.**  $\sigma = \sqrt{\frac{1}{m} \sum_i (v_i - \mu)^2}$  : la racine de la moyenne des carrés des écarts à la moyenne. Il s'exprime dans l'unité de la colonne et mesure la dispersion typique autour de  $\mu$ .

**Cote standard.**  $(v - \mu)/\sigma$  exprime un écart en nombre d'écarts-types. La colonne transformée a pour moyenne 0 et pour écart-type 1.

Employés au chapitre 3.

#### Valeur manquante

Une case vide représente une valeur inconnue. Trois traitements existent : écarter la ligne, écarter la colonne, ou attribuer une valeur — l'*imputation*. Le choix dépend du mécanisme qui a produit l'absence, question développée dans [1] et que ce cours n'aborde pas.



## B.2 Exponentielle, logarithme, cote

$e^a$  est strictement positive, strictement croissante, et transforme les sommes en produits :  $e^{a+b} = e^a e^b$ . Elle parcourt  $]0, +\infty[$  quand  $a$  parcourt  $\mathbb{R}$ .

$\log$  est sa réciproque : définie sur  $]0, +\infty[$ , strictement croissante, elle parcourt  $\mathbb{R}$ . Trois égalités servent constamment :

$$\log(ab) = \log a + \log b, \quad \log \frac{a}{b} = \log a - \log b, \quad \log a^b = b \log a.$$

Avec  $\log 1 = 0$  et  $\log e^a = a$ .

Le logarithme employé dans tout le document est le logarithme népérien, celui de base  $e$  ; c'est celui que `math.log` calcule en Python.

**Cote.** Le rapport  $p/(1-p)$  d'une probabilité à son complément. Une probabilité de 0,8 donne une cote de 4 : quatre fois plus de chances que l'événement se produise que le contraire. Quand  $p$  parcourt  $]0, 1[$ , la cote parcourt  $]0, +\infty[$  et son logarithme parcourt  $\mathbb{R}$ .

Employés aux chapitres 4 et 6, et à l'annexe C.

## B.3 Vecteurs, produit scalaire, norme

Dans  $\mathbb{R}^n$  muni d'un repère orthonormé, le *produit scalaire* de  $u = (u_1, \dots, u_n)$  et  $v = (v_1, \dots, v_n)$  vaut

$$u \cdot v = \sum_{j=1}^n u_j v_j = \|u\| \|v\| \cos \theta,$$

où  $\theta$  est l'angle entre les deux vecteurs et  $\|u\| = \sqrt{\sum_j u_j^2}$  la *norme* de  $u$ , c'est-à-dire sa longueur.

Trois conséquences employées au chapitre 4 :

- $u \cdot v = 0$  équivaut à  $u \perp v$ , les deux vecteurs étant non nuls ;
- $\|v\| \cos \theta$  est la longueur de la projection de  $v$  sur la direction de  $u$ , comptée avec un signe ;
- multiplier  $u$  par  $\lambda > 0$  multiplie  $u \cdot v$  par  $\lambda$  sans changer le signe ni la direction.

### Le repère doit être orthonormé

Angle, perpendiculaire et distance n'ont le sens usuel que si les deux axes portent la même unité. Sur les notes brutes, où un axe se gradue en points et l'autre en centaines de points, ces notions dépendent du barème. La standardisation du chapitre 3 fournit un système d'unités commun ; elle ne rend pas pour autant la géométrie obtenue équivalente à celle des données brutes, point discuté au même chapitre.

## B.4 Dérivée, dérivée partielle, gradient

La *dérivée*  $f'(a)$  mesure la variation de  $f$  par unité de variation de son argument, au voisinage de  $a$  : c'est la pente de la tangente en ce point. Son signe indique le sens de variation, sa valeur absolue la rapidité.

Trois règles suffisent aux calculs du document :

$$(u + v)' = u' + v', \quad \left(\frac{1}{u}\right)' = -\frac{u'}{u^2}, \quad (f \circ g)'(a) = f'(g(a)) g'(a).$$

La troisième est la *règle de chaîne*, employée dans toute l'annexe F.

La *dérivée partielle*  $\partial J / \partial w_j$  est la dérivée de  $J$  considérée comme fonction du seul  $w_j$ , les autres coefficients étant tenus pour constants. Le *gradient*  $\nabla J$  est le vecteur de ces dérivées partielles.

Deux propriétés servent au chapitre 7 :

- $-\nabla J$  est la direction de plus forte décroissance locale de  $J$  au point considéré ;
- $\nabla J$  est orthogonal à la ligne de niveau de  $J$  passant par ce point.

### Approximation locale

Pour un déplacement  $\delta$  petit,  $J(\mathbf{w} + \delta) \approx J(\mathbf{w}) + \nabla J(\mathbf{w}) \cdot \delta$ . Cette approximation est locale : elle cesse de décrire  $J$  dès que  $\delta$  sort du voisinage où la pente mesurée reste représentative. C'est la raison pour laquelle un pas de descente trop long peut faire monter le coût (ch. 7).

## B.5 Dérivée seconde et courbure

La dérivée seconde  $f''$  mesure la variation de la pente. Positive sur un intervalle, elle y rend  $f'$  croissante, donc  $f'$  y traverse zéro au plus une fois.

Pour une fonction de plusieurs variables, la *hessienne* est le tableau carré des dérivées secondes  $\partial^2 J / \partial w_j \partial w_k$ . La courbure de  $J$  dans une direction  $\mathbf{v}$  vaut  $\mathbf{v}^\top H \mathbf{v}$ . Ces notions servent à l'annexe G.

# Annexe C

## Construction de la fonction logistique

**OBJECTIFS** construire le logit comme composée de la cote et du logarithme ; inverser l'hypothèse (★) pour obtenir  $\sigma$  ; énoncer ce que cette construction établit et ce qu'elle suppose

**PRÉREQUIS** exponentielle, logarithme, cote (annexe B) ; chapitre 4

**PARCOURS** approfondissement ; le fil principal n'emploie que la formule encadrée

### C.1 Première transformation : la cote

Une probabilité  $p$  appartient à  $[0, 1]$ . Le rapport

$$\frac{p}{1-p}$$

s'appelle la *cote*. C'est le langage des paris : une cote de 3 signifie trois chances contre une. Ce rapport vaut 0 quand  $p = 0$ , vaut 1 quand  $p = 0,5$ , et croît sans borne quand  $p$  approche 1.

| $p$  | $1-p$ | cote $p/(1-p)$ | log de la cote |
|------|-------|----------------|----------------|
| 0,10 | 0,90  | 0,111          | -2,197         |
| 0,25 | 0,75  | 0,333          | -1,099         |
| 0,50 | 0,50  | 1,000          | 0,000          |
| 0,75 | 0,25  | 3,000          | +1,099         |
| 0,90 | 0,10  | 9,000          | +2,197         |

TABLE C.1: La cote transporte  $[0, 1]$  vers  $[0, +\infty[$ , son logarithme vers  $\mathbb{R}$  tout entier. La dernière colonne est symétrique autour de  $p = 0,5$  : c'est la propriété que le score doit posséder.

La cote atteint ainsi toutes les valeurs positives ; restent les négatives.




FIGURE C.1: Les trois intervalles. La cote étire  $]0, 1[$  sur  $]0, +\infty[$  en envoyant 0,5 sur 1 ; le logarithme envoie ce demi-axe sur  $\mathbb{R}$ . La composée est une bijection croissante de  $]0, 1[$  sur  $\mathbb{R}$ , l’une des infinités qui rendent l’égalité avec le score possible (section 2).

## C.2 Seconde transformation : le logarithme

Le logarithme envoie  $]0, +\infty[$  sur  $\mathbb{R}$  : il vaut  $-\infty$  près de zéro, 0 en 1, et croît sans borne. En le composant avec la cote, on obtient la *log-cote*

$$\log \frac{p}{1-p},$$

qui prend toutes les valeurs réelles, comme le score  $z$ . Les deux quantités parcourant le même ensemble, poser leur égalité est *possible* :

$$\log \frac{p}{1-p} = z = \sum_{j=0}^n w_j x_j \quad (\star)$$

L’égalité  $(\star)$  constitue un choix parmi les bijections croissantes de  $]0, 1[$  sur  $\mathbb{R}$ . La réciproque de la fonction de répartition de la loi normale donne le modèle *probit*, celle de la loi de Gumbel le modèle *complémentaire log-log* (ch. 4). Le logit est donc une hypothèse de modélisation, retenue pour trois raisons : il donne aux coefficients une lecture directe en log-cotes, il est le lien canonique du modèle linéaire généralisé binomial, ce qui produit les formules les plus simples [2], et il conduit à une perte convexe (annexe G). Le modèle en compte deux autres, posées ailleurs : l’indépendance conditionnelle des observations (annexe E) et le choix des variables retenues.

Les annexes suivantes tirent les conséquences de  $(\star)$  : l’expression de  $p$  en fonction de  $z$  ci-dessous, les propriétés de  $\sigma$  (annexe D), la perte (annexe E) et le gradient (annexe F).

## C.3 Expression de $p$ en fonction de $z$

L’équation  $(\star)$  donne  $z$  à partir de  $p$ , alors que le programme part de  $z$  pour obtenir la probabilité. L’inversion consiste à isoler  $p$  ; chaque ligne porte à droite l’opération qui la produit.

$$\begin{aligned}
\log \frac{p}{1-p} &= z && \text{on applique } e^{\cdot} \text{ aux deux membres} \\
e^{\log \frac{p}{1-p}} &= e^z && \text{car } e^{\log a} = a \\
\frac{p}{1-p} &= e^z && \text{on multiplie les deux membres par } 1-p \\
p &= e^z(1-p) && \text{on développe} \\
p &= e^z - e^z p && \text{on rassemble les } p \\
p + e^z p &= e^z && \text{on met } p \text{ en facteur} \\
p(1 + e^z) &= e^z && \text{on divise par } 1 + e^z, \text{ qui n'est jamais nul} \quad (\text{C.2}) \\
p &= \frac{e^z}{1 + e^z}
\end{aligned}$$

Cette écriture se met sous une forme plus courante en divisant numérateur et dénominateur par  $e^z$  :

$$\begin{aligned}
p &= \frac{e^z}{1 + e^z} = \frac{e^z/e^z}{(1 + e^z)/e^z} && \text{on divise en haut et en bas par } e^z \neq 0 \\
&= \frac{1}{1/e^z + 1} && \text{car } e^z/e^z = 1 \\
&= \frac{1}{1 + e^{-z}} && \text{car } 1/e^z = e^{-z} \quad (\text{C.3})
\end{aligned}$$

### Fonction logistique

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{e^z}{1 + e^z}.$$

Les deux écritures désignent la même fonction, obtenue en inversant l'hypothèse (\*).

Chacune des deux formes échoue là où l'autre tient. Pour  $z$  très négatif,  $e^{-z}$  devient gigantesque et  $1/(1 + e^{-z})$  déborde la capacité de la machine, tandis que  $e^z/(1 + e^z)$  rend 0. Pour  $z$  très positif, c'est l'inverse. Le programme utilise donc l'une ou l'autre selon le signe de  $z$  (annexe J).

## C.4 Vérification numérique

La table C.1 se relit dans l'autre sens. Pour  $z = 1,099$  :

$$e^{-1,099} = 0,3333, \quad \sigma(1,099) = \frac{1}{1 + 0,3333} = \frac{1}{1,3333} = 0,75.$$

On retrouve la ligne  $p = 0,75$ , dont la log-cote valait  $+1,099$ . Pour  $z = 0$  :

$$\sigma(0) = \frac{1}{1 + e^0} = \frac{1}{1 + 1} = 0,5.$$

Un élève situé exactement sur la droite reçoit une probabilité de 0,5 : la frontière (ch. 4) est la ligne de niveau 0,5 du modèle.




FIGURE C.2: La fonction logistique envoie  $\mathbb{R}$  dans l'intervalle  $]0, 1[$ , sans jamais atteindre les bornes, et passe par 0,5 à l'origine.

### Valeurs prises par $\sigma$

Pour  $z$  fini,  $1 + e^{-z}$  reste strictement plus grand que 1, donc  $\sigma(z)$  reste strictement compris entre 0 et 1. Toute probabilité produite par le modèle appartient donc à l'intervalle ouvert  $]0, 1[$ . En machine,  $\sigma(40)$  vaut pourtant exactement 1 après arrondi : l'écart disparaît à partir d'un score d'environ 37, avec les conséquences que cela entraîne dans un logarithme (annexe J).

# Annexe D

## Propriétés de la fonction logistique

**OBJECTIFS** établir  $\sigma(-z) = 1 - \sigma(z)$  et  $\sigma' = \sigma(1 - \sigma)$ ; distinguer le rôle de  $\sigma'$  dans la sensibilité de la probabilité et dans le gradient

**PRÉREQUIS** règle de chaîne, dérivée d'un inverse (annexe B)

**PARCOURS** approfondissement; le fil principal n'emploie que les deux égalités encadrées

### D.1 Symétrie

Échanger les deux réponses revient à changer le signe du score, la frontière étant le lieu où il s'annule. La fonction logistique doit donc échanger  $p$  et  $1 - p$  lorsqu'on passe de  $z$  à  $-z$ , ce que le calcul confirme.

$$\begin{aligned}\sigma(-z) &= \frac{1}{1 + e^{-(-z)}} \\ &= \frac{1}{1 + e^z}\end{aligned}$$

définition, avec  $-z$  à la place de  $z$

car  $-(-z) = z$

et par ailleurs

$$\begin{aligned}
 1 - \sigma(z) &= 1 - \frac{1}{1 + e^{-z}} && \text{définition} \\
 &= \frac{(1 + e^{-z}) - 1}{1 + e^{-z}} && \text{même dénominateur} \\
 &= \frac{e^{-z}}{1 + e^{-z}} && \text{on simplifie le numérateur} \\
 &= \frac{e^{-z}}{1 + e^{-z}} \cdot \frac{e^z}{e^z} && \text{on multiplie par 1 écrit } e^z/e^z \\
 &= \frac{e^{-z}e^z}{e^z + e^{-z}e^z} && \text{on distribue} \\
 &= \frac{1}{e^z + 1} && \text{car } e^{-z}e^z = e^0 = 1
 \end{aligned} \tag{D.1}$$

Les deux résultats coïncident, donc

$$\sigma(-z) = 1 - \sigma(z)$$

La probabilité accordée à « [Gryffindor](#) » pour un score  $z$  égale donc celle accordée à « pas [Gryffindor](#) » pour le score  $-z$ .

$\sigma(2) = 0,8808$  et  $\sigma(-2) = 0,1192$ , de somme 1.

## D.2 Dérivée

Écris  $\sigma = 1/u$  avec  $u = 1 + e^{-z}$ , la fonction se dérive par la règle de l'inverse, la chaîne fournissant  $u'$ . Le résultat s'exprime avec  $\sigma$  elle-même, ce qui évite d'avoir à réévaluer une exponentielle dans le calcul du gradient.



$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{1}{u}, \quad u = 1 + e^{-z}$$

$$u' = (1 + e^{-z})' = 0 + e^{-z} \cdot (-1) = -e^{-z}$$

dérivée d'une somme, puis chaîne sur  $e^{-z}$

$$\sigma'(z) = -\frac{u'}{u^2}$$

dérivée d'un inverse :  $(1/u)' = -u'/u^2$

$$= -\frac{-e^{-z}}{(1 + e^{-z})^2}$$

on remplace  $u$  et  $u'$

$$= \frac{e^{-z}}{(1 + e^{-z})^2}$$

les deux signes moins s'annulent

$$= \frac{1}{1 + e^{-z}} \cdot \frac{e^{-z}}{1 + e^{-z}}$$

on sépare le carré en deux facteurs

$$= \sigma(z) \cdot (1 - \sigma(z))$$

le second facteur est  $1 - \sigma(z)$ , établi en (D.1)

(D.2)

### Dérivée de la sigmoïde

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)).$$

La pente se calcule donc sans nouvelle exponentielle : si l'on connaît déjà  $p = \sigma(z)$ , la pente vaut  $p(1 - p)$ .

## D.3 Variation de la probabilité avec le score

La quantité  $p(1-p)$  atteint son maximum, 0,25, en  $p = 0,5$ , et décroît vers 0 aux deux extrémités : la probabilité varie fortement avec le score près de la frontière, et très peu lorsqu'elle est déjà proche de 0 ou de 1.




FIGURE D.1: La dérivée atteint son maximum, 0,25, en  $z = 0$ , et tend vers zéro dès que la probabilité approche 0 ou 1.

Cette cloche gouverne deux quantités. La première est la sensibilité de la *probabilité* au score :  $p$  varie fortement avec  $z$  près de la frontière et très peu une fois proche de 0 ou de 1, ce qui explique qu'agrandir la norme des coefficients modifie les probabilités sans déplacer la frontière (annexe H). La seconde est la *courbure* de la perte, dont  $\sigma'$  fournit le facteur  $s_i$  de la hessienne (annexe G).

Le poids d'une observation dans le gradient est en revanche  $\partial\ell/\partial z = p - y$  (annexe F) : le facteur  $\sigma(1 - \sigma)$  apparaît dans la dérivation, puis se simplifie avec les dénominateurs venus du logarithme. Les deux quantités se séparent nettement. Sur la frontière,  $p = 0,5$  :  $\sigma'$  atteint son maximum  $\frac{1}{4}$  tandis que  $|p - y|$  vaut 0,5 ; pour une observation d'étiquette  $y = 1$  classée à  $p = 0,02$ ,  $\sigma'$  tombe à 0,0196 tandis que  $|p - y|$  monte à 0,98. La correction est donc portée par les prédictions incorrectes et assurées.

# Annexe E

## Construction du coût par vraisemblance

**OBJECTIFS** écrire la vraisemblance d'un jeu d'étiquettes sous le modèle ; la transformer en somme par le logarithme ; en déduire la perte employée par le fil principal ; nommer les hypothèses qui interviennent

**PRÉREQUIS** logarithme, exposants (annexe B) ; chapitre 6

**PARCOURS** approfondissement ; le fil principal n'emploie que la formule encadrée

### E.1 Probabilité d'une réponse observée

Notons  $y_i$  l'étiquette : 1 si l'observation  $i$  appartient à [Gryffindor](#), 0 sinon, et  $p_i = \sigma(z_i)$  la probabilité produite par le modèle. La probabilité que celui-ci attribue à l'étiquette effectivement observée vaut  $p_i$  si  $y_i = 1$ , et  $1 - p_i$  si  $y_i = 0$ . Ces deux cas se rassemblent :

$$\mathbb{P}(y_i) = p_i^{y_i} (1 - p_i)^{1-y_i}.$$

Vérification des deux cas, en se souvenant que  $a^0 = 1$  et  $a^1 = a$  :

$$y_i = 1 : \quad p_i^1 (1 - p_i)^0 = p_i \cdot 1 = p_i, \quad y_i = 0 : \quad p_i^0 (1 - p_i)^1 = 1 \cdot (1 - p_i) = 1 - p_i.$$

L'exposant nul ramène à 1 le facteur qui ne correspond pas au cas observé.

### E.2 Vraisemblance du fichier

Une seconde hypothèse intervient ici, distincte de celle du lien logit : les étiquettes sont supposées conditionnellement indépendantes, une fois les notes connues. C'est elle qui autorise à écrire la probabilité d'observer l'ensemble des étiquettes du fichier comme le produit des probabilités individuelles :

$$L(\mathbf{w}) = \prod_{i=1}^m p_i^{y_i} (1 - p_i)^{1-y_i}.$$

$L$  s'appelle la *vraisemblance*. Elle dépend des coefficients  $\mathbf{w}$ , car ce sont eux qui produisent les  $p_i$ . Chercher les meilleurs coefficients, c'est chercher ceux qui rendent  $L$  maximale.

### Sous-dépassement du produit

Le produit compte 1 600 facteurs, tous strictement inférieurs à 1, et décroît donc très vite. Le plus petit double normal vaut environ  $2,2 \times 10^{-308}$  ; en dessous, la précision se dégrade puis le nombre s'arrondit à zéro [6].

Le seuil se franchit facilement. Si chaque facteur valait 0,5 — un modèle sans opinion — le produit vaudrait  $0,5^{1600} \approx 10^{-482}$ , qui s'arrondit à zéro. Si chacun valait 0,9, le produit vaudrait  $6,1 \times 10^{-74}$  : représentable, mais déjà privé de toute marge, et un fichier dix fois plus long le ferait sous-dépasser. Une fois deux vraisemblances arrondies à zéro, aucune comparaison n'est plus possible.

Le logarithme supprime le problème en transformant le produit en somme, dont l'ordre de grandeur reste celui du nombre d'observations.




FIGURE E.1: Le produit des probabilités individuelles mesure la plausibilité du jeu de coefficients. Le logarithme le convertit en somme à optimum inchangé ; le facteur  $-1/m$  change la maximisation en minimisation et rend la valeur indépendante de l'effectif.

## E.3 Passage au logarithme

La vraisemblance est un produit de mille six cents facteurs, forme peu commode à dériver et impossible à évaluer en machine. Le logarithme la transforme en somme sans déplacer le point où elle est maximale, puisqu'il est strictement croissant.

$$\begin{aligned}
 \log L(\mathbf{w}) &= \log \prod_{i=1}^m p_i^{y_i} (1 - p_i)^{1-y_i} \\
 &= \sum_{i=1}^m \log \left[ p_i^{y_i} (1 - p_i)^{1-y_i} \right] && \text{le log d'un produit, sur les } m \text{ facteurs} \\
 &= \sum_{i=1}^m \left[ \log p_i^{y_i} + \log (1 - p_i)^{1-y_i} \right] && \text{le log d'un produit, sur deux termes} \\
 &= \sum_{i=1}^m \left[ y_i \log p_i + (1 - y_i) \log (1 - p_i) \right] && \log a^b = b \log a
 \end{aligned} \tag{E.1}$$

Le passage au logarithme est légitime pour chercher un maximum :  $\log$  est strictement croissante, donc elle conserve l'ordre. Le  $\mathbf{w}$  qui maximise  $L$  est exactement celui qui maximise  $\log L$ .

## E.4 Changement de signe et moyenne

Les algorithmes d'optimisation minimisent par convention. On change donc le signe, et on divise par  $m$  pour obtenir une valeur moyenne, indépendante de l'effectif :

$$J(\mathbf{w}) = -\frac{1}{m} \sum_{i=1}^m \left[ y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] \quad (\dagger)$$

Maximiser  $\log L$  et minimiser  $J$  sont la même opération : multiplier par  $-1/m$  retourne la fonction et la met à l'échelle, sans déplacer l'argument où l'optimum est atteint. C'est la formule que donne le sujet du projet.

## E.5 Forme du terme individuel

Le terme d'une observation vaut  $-\log p_i$  si son étiquette est [Gryffindor](#), et  $-\log(1 - p_i)$  sinon : dans les deux cas, l'opposé du logarithme de la probabilité accordée à l'étiquette observée.

| $y_i$ | $p_i$ | probabilité accordée à l'étiquette | perte $-\log(\cdot)$ |
|-------|-------|------------------------------------|----------------------|
| 1     | 0,99  | 0,99                               | 0,010                |
| 1     | 0,75  | 0,75                               | 0,288                |
| 1     | 0,50  | 0,50                               | 0,693                |
| 1     | 0,10  | 0,10                               | 2,303                |
| 1     | 0,01  | 0,01                               | 4,605                |
| 0     | 0,10  | 0,90                               | 0,105                |
| 0     | 0,90  | 0,10                               | 2,303                |

TABLE E.1: Perte selon la probabilité accordée à l'étiquette observée : presque nulle pour une prédiction correcte et assurée, divergente quand cette probabilité tend vers zéro.




FIGURE E.2: La perte d'une prédiction en fonction de la probabilité que le modèle attribuait à la classe observée. Le point 0,693 correspond à un modèle qui produit 0,5.

La formule rend compte du contrôle employé depuis le chapitre 6 : des coefficients nuls donnent  $p_i = \sigma(0) = 0,5$  pour chaque observation, donc une perte moyenne de  $-\log(0,5) = \log 2$ .

# Annexe F

## Calcul du gradient

**OBJECTIFS** dériver la perte par rapport à un coefficient en enchaînant deux dérivées; établir  $\partial \ell / \partial z = p - y$ ; en déduire la formule du gradient employée par le fil principal  
**PRÉREQUIS** règle de chaîne (annexe B); annexe D, annexe E  
**PARCOURS** approfondissement; le fil principal n'emploie que la formule encadrée

### F.1 Composition à dériver

La dépendance de  $J$  envers le coefficient  $w_j$  suit la composition :

$$w_j \longrightarrow z_i = \sum_j w_j x_{ij} \longrightarrow p_i = \sigma(z_i) \longrightarrow \ell_i \longrightarrow J.$$

La règle de dérivation des fonctions composées traverse cette suite : chaque facteur se calcule séparément, puis les facteurs se multiplient.




FIGURE F.1: Le coefficient agit sur le coût par cette seule chaîne. Les deux dérivées encadrées se multiplient, et la moyenne donne  $\partial J / \partial w_j$ . La propriété  $\sigma' = \sigma(1 - \sigma)$  réduit les deux facteurs intermédiaires à  $p_i - y_i$ .

### F.2 Première dérivée : la perte par rapport au score

Posons, pour un élève dont on omet l'indice,

$$\ell = -[y \log \sigma(z) + (1 - y) \log(1 - \sigma(z))].$$

$$\begin{aligned}
\frac{\partial \ell}{\partial z} &= - \left[ y \cdot \frac{1}{\sigma(z)} \cdot \sigma'(z) + (1-y) \cdot \frac{1}{1-\sigma(z)} \cdot (-\sigma'(z)) \right] && \text{chaîne sur log} \\
&= - \left[ \frac{y \sigma'(z)}{\sigma(z)} - \frac{(1-y) \sigma'(z)}{1-\sigma(z)} \right] && \text{on range} \\
&= - \left[ \frac{y \sigma(z)(1-\sigma(z))}{\sigma(z)} - \frac{(1-y) \sigma(z)(1-\sigma(z))}{1-\sigma(z)} \right] && \sigma' = \sigma(1-\sigma) \\
&= - [y(1-\sigma(z)) - (1-y)\sigma(z)] && \text{on simplifie chaque fraction} \\
&= - [y - y\sigma(z) - \sigma(z) + y\sigma(z)] && \text{on développe} \\
&= - [y - \sigma(z)] && \text{les } y\sigma(z) \text{ s'annulent} \\
&= \sigma(z) - y && \text{(F.1)}
\end{aligned}$$

Le troisième passage repose entièrement sur la propriété  $\sigma' = \sigma(1 - \sigma)$  (annexe D) : c'est elle qui fait disparaître les dénominateurs.

#### Résidu

$$\frac{\partial \ell}{\partial z} = \sigma(z) - y = p - y.$$

La pente de la perte par rapport au score est l'écart entre la probabilité produite et l'étiquette observée. Pour une observation d'étiquette  $y = 1$ , elle vaut  $-0,9$  lorsque la probabilité produite vaut  $0,1$ , puis  $-0,01$  lorsque cette probabilité atteint  $0,99$ .

Deux conséquences en découlent. La contribution d'une prédiction correcte et assurée est négligeable. Cette pente est *bornée* :  $|p - y| < 1$  toujours, même lorsque la perte  $\ell$  diverge. Le facteur  $\sigma'$  a disparu du résultat en se simplifiant avec les dénominateurs du logarithme (annexe D).

## F.3 Seconde dérivée : le score par rapport à un coefficient

Le second facteur de la chaîne demande de dériver le score par rapport à l'un des coefficients. Le score étant une somme où chaque coefficient apparaît une seule fois, la dérivation ne laisse subsister qu'un terme.

$$\begin{aligned}
\frac{\partial z_i}{\partial w_j} &= \frac{\partial}{\partial w_j} \sum_{k=0}^n w_k x_{ik} \\
&= \sum_{k=0}^n \frac{\partial (w_k x_{ik})}{\partial w_j} && \text{la dérivée entre dans la somme} \\
&= x_{ij} && \text{dérivée partielle} \quad \text{(F.2)}
\end{aligned}$$



Dans la somme, un seul terme contient  $w_j$ , c'est  $w_j x_{ij}$ , et sa dérivée par rapport à  $w_j$  vaut  $x_{ij}$ . Les autres termes  $w_k x_{ik}$ , avec  $k \neq j$ , sont des constantes du point de vue de cette dérivée, qui est donc nulle.

## F.4 Assemblage

Les deux dérivées précédentes se composent. La dérivation entre dans la moyenne, puisque la somme est finie et le facteur  $1/m$  constant ; chaque terme fournit alors le produit du résidu par la note, et la moyenne de ces produits constitue le gradient cherché.

$$\begin{aligned}
 \frac{\partial J}{\partial w_j} &= \frac{\partial}{\partial w_j} \left[ \frac{1}{m} \sum_{i=1}^m \ell_i \right] \\
 &= \frac{1}{m} \sum_{i=1}^m \frac{\partial \ell_i}{\partial w_j} && \text{la dérivée entre, } 1/m \text{ sort} \\
 &= \frac{1}{m} \sum_{i=1}^m \frac{\partial \ell_i}{\partial z_i} \cdot \frac{\partial z_i}{\partial w_j} && \text{règle de chaîne} \\
 &= \frac{1}{m} \sum_{i=1}^m (\sigma(z_i) - y_i) x_{ij} && \text{les deux dérivées calculées ci-dessus} \quad (\text{F.3})
 \end{aligned}$$

### Gradient

$$\frac{\partial J}{\partial w_j} = \underbrace{\frac{1}{m} \sum_{i=1}^m}_{\text{moyenne}} \underbrace{(p_i - y_i)}_{\text{erreur}} \underbrace{x_{ij}}_{\text{note}}$$

C'est la formule du sujet,  $\frac{1}{m} \sum (h_\theta(x^i) - y^i) x_j^i$ , obtenue sans hypothèse supplémentaire. Le gradient  $\nabla J$  est le vecteur de ces  $n + 1$  dérivées partielles, une par coefficient. Pour  $j = 0$ ,  $x_{i0} = 1$  : la dérivée du biais est la moyenne des résidus.

## F.5 Facteurs du gradient

Chaque élève contribue au gradient du coefficient  $j$  par le produit de deux facteurs : son erreur  $p_i - y_i$ , et sa note  $x_{ij}$ .

Le premier facteur donne le sens et l'intensité de la correction. Il est négatif quand le modèle sous-estime un **Gryffindor**, positif quand il surestime un autre élève, et proche de zéro dès que la prédiction est correcte.

Le second répartit la correction entre les coefficients. Un élève dont la note d'**Herbology** est extrême pèse fortement sur  $w_1$ , tandis qu'un élève de note moyenne, dont la valeur standardisée est proche de zéro, n'y contribue presque pas.

# Annexe G

## Convexité, existence et unicité du minimum

**OBJECTIFS** établir la convexité de la perte logistique; énoncer séparément ce que garantit la convexité, ce qu'exige l'unicité, ce qu'exige l'existence, et ce que garantit l'algorithme

**PRÉREQUIS** dérivée seconde, hessienne, forme quadratique (annexe B); annexe F

**PARCOURS** approfondissement; le fil principal n'emploie que la conclusion encadrée

### Portée des quatre propriétés

1. **Convexité.**  $J$  est convexe sans condition; tout minimum local est global. Démonstration ci-dessous.
2. **Unicité.** Le rang plein de  $X$  en colonnes assure la stricte convexité. Des colonnes proportionnelles produisent plusieurs minima.
3. **Existence à distance finie.** Elle correspond aux données non séparables et non quasi-séparables [5].
4. **Convergence de l'algorithme.** Elle dépend en outre du pas  $\alpha$  et du critère d'arrêt (ch. 7).

Les points 2 et 3 sont indépendants : un minimum unique peut se situer à l'infini; un minimum fini peut former tout un sous-espace.

### G.1 Courbure d'une fonction d'une variable

La descente s'arrête là où la pente s'annule. Encore faut-il savoir combien de tels points une fonction possède : s'ils sont plusieurs, le point d'arrivée dépend du point de départ, et deux exécutions du même programme peuvent rendre deux modèles.

La dérivée seconde répond à cette question, car elle mesure la variation de la pente. Deux cas sont à distinguer, et c'est leur confusion qui produit la plupart des énoncés faux sur ce sujet.

Si la dérivée seconde est *strictement* positive partout, la pente est strictement croissante, donc elle traverse zéro au plus une fois : il existe au plus un point critique, et c'est un minimum. On dit alors la fonction *strictement convexe*, et le minimum, s'il existe, est unique.

Si la dérivée seconde est seulement *positive ou nulle*, la fonction est dite *convexe*. Sa pente est croissante : tout minimum local est global. L'ensemble des minima peut toutefois former un intervalle entier, par exemple le palier horizontal d'une fonction affine par morceaux, ou être vide, comme pour  $x \mapsto e^x$ .




FIGURE G.1: Fonction strictement convexe à minimum unique, à gauche ; fonction à deux minima locaux, à droite. La stricte convexité de la perte logistique demande une condition supplémentaire (section 3).

## G.2 Courbure du coût logistique

Reprenons la dérivée première (annexe F) :

$$\frac{\partial J}{\partial w_j} = \frac{1}{m} \sum_{i=1}^m (\sigma(z_i) - y_i) x_{ij}.$$

Dérivons une seconde fois, par rapport à un autre coefficient  $w_k$  :

$$\begin{aligned} \frac{\partial^2 J}{\partial w_j \partial w_k} &= \frac{1}{m} \sum_{i=1}^m \frac{\partial}{\partial w_k} [(\sigma(z_i) - y_i) x_{ij}] && \text{la dérivée entre dans la somme} \\ &= \frac{1}{m} \sum_{i=1}^m x_{ij} \sigma'(z_i) \frac{\partial z_i}{\partial w_k} && \text{chaîne, et } y_i \text{ est constant} \\ &= \frac{1}{m} \sum_{i=1}^m x_{ij} \sigma(z_i) (1 - \sigma(z_i)) x_{ik} && \text{annexe D, et } \partial z_i / \partial w_k = x_{ik} \end{aligned} \quad (\text{G.1})$$

Ces nombres, rangés dans un tableau carré dont la case  $(j, k)$  porte  $\partial^2 J / \partial w_j \partial w_k$ , forment la *hessienne* de  $J$  : la matrice de ses dérivées secondes. Posons  $s_i = \sigma(z_i)(1 - \sigma(z_i))$ , facteur commun à chaque terme. En notation matricielle, avec  $S$  la matrice diagonale des  $s_i$ ,

$$H = \frac{1}{m} \mathbf{X}^\top S \mathbf{X}.$$

Chaque  $s_i$  vérifie  $0 < s_i \leq \frac{1}{4}$ ,  $\sigma$  étant strictement comprise entre 0 et 1 ; cette borne porte sur  $S$  seule. La hessienne fait intervenir  $\mathbf{X}$  de part et d'autre, de sorte que sa plus grande valeur propre est majorée par  $\frac{1}{4m} \|\mathbf{X}\|^2$  et dépend de l'échelle et des corrélations des colonnes. C'est cette quantité qui gouverne le pas admissible (ch. 7).

### G.3 Positivité de la courbure

Prenons une direction quelconque dans l'espace des coefficients, décrite par un vecteur  $\mathbf{v} = (v_0, \dots, v_n)$ . La courbure de  $J$  le long de cette direction vaut

$$\begin{aligned} \sum_j \sum_k v_j \frac{\partial^2 J}{\partial w_j \partial w_k} v_k &= \frac{1}{m} \sum_{i=1}^m s_i \left( \sum_j v_j x_{ij} \right) \left( \sum_k v_k x_{ik} \right) \quad \text{on regroupe} \\ &= \frac{1}{m} \sum_{i=1}^m s_i \left( \sum_j v_j x_{ij} \right)^2 \quad \text{les deux facteurs sont égaux} \\ &\geq 0 \end{aligned} \tag{G.2}$$

La dernière ligne tient parce que chaque terme de la somme est le produit de deux quantités positives ou nulles : un carré, toujours positif ou nul, et  $s_i$ , qui vaut  $\sigma(z_i)(1 - \sigma(z_i))$  avec  $\sigma$  strictement comprise entre 0 et 1, donc lui aussi positif.

#### Convexité

La courbure de  $J$  est positive ou nulle dans toutes les directions, quelle que soit la position des coefficients. La perte est donc convexe : tout point stationnaire est un minimum global et tout minimum local est global. L'existence et l'unicité demandent deux hypothèses supplémentaires, examinées dans les sections suivantes. Le départ en zéro fixe seulement la reproductibilité du calcul.

### G.4 Rang déficient et multiplicité des minima

*Positive ou nulle* : la nuance a des conséquences. La courbure s'annule dans une direction  $\mathbf{v}$  dès que  $\sum_j v_j x_{ij} = 0$  pour toutes les observations, c'est-à-dire lorsque les colonnes de  $\mathbf{X}$  sont linéairement dépendantes et que  $\mathbf{X}$  n'est pas de rang plein en colonnes.  $J$  est alors constante le long de  $\mathbf{v}$ , et l'ensemble des minima est une droite, ou un sous-espace de dimension supérieure.

Deux colonnes proportionnelles produisent ce cas. Si *Astronomy* vaut  $-100$  fois *Defense Against the Dark Arts*, augmenter un coefficient et diminuer l'autre dans le rapport correspondant laisse tous les scores inchangés. Les prédictions sont identiques, la perte aussi ; les coefficients, eux, ne sont pas identifiables.

La descente reste pourtant stable le long de cette direction plate. Le gradient de  $J$  est orthogonal à toute direction où  $J$  est constante : une descente de gradient exacte partie de  $\mathbf{0}$  ne se déplace

jamais selon  $\mathbf{v}$ , et s'arrête sur un point particulier du sous-espace des minima — celui de plus petite norme parmi ceux atteignables. La difficulté porte donc sur l'interprétation et non sur la convergence : les coefficients obtenus sont déterminés par l'implémentation autant que par les données, et un autre ordre de colonnes ou une régularisation en donneraient d'autres, tout aussi optimaux. Lire l'importance d'une variable dans un tel coefficient n'a pas de sens.

## G.5 Séparation linéaire et minimum à l'infini

### Séparation complète et quasi-séparation

Un second cas éloigne le minimum à l'infini. Si un hyperplan sépare parfaitement les deux classes — les données sont alors dites *linéairement séparables* — multiplier tous les coefficients par 10 rapproche encore les probabilités de 0 et de 1, et fait donc encore baisser la perte. Chaque jeu de coefficients en admet un meilleur, l'infimum vaut 0 et n'est pas atteint : le maximum de vraisemblance n'existe pas à distance finie [5].

La quasi-séparation — séparation parfaite sur un sous-ensemble des observations, avec les autres exactement sur l'hyperplan — produit le même effet sur une partie des coefficients. La convexité persiste dans ces deux cas, tandis que l'infimum reste hors de l'espace des coefficients finis. Le comportement de la descente dans cette situation et le rôle du plafond d'itérations sont traités à l'annexe H.

# Annexe H

## Croissance de la norme des coefficients

**OBJECTIFS** expliquer pourquoi la norme des coefficients cesse de croître sur des données non séparables ; décrire ce qui se passe lorsqu'elles le sont ; justifier la présence de deux conditions d'arrêt

**PRÉREQUIS** chapitres 7 et 11 ; annexe G

**PARCOURS** approfondissement

### H.1 Équilibre qui arrête la croissance

La norme du vecteur normal passe de 0,30 au premier tour à 4,89 au quatre-centième, alors que la frontière est en place depuis longtemps et qu'aucune décision ne change plus. Sur les données non séparables, les prédictions incorrectes imposent un minimum fini et le critère de stagnation termine la boucle. Sur des données séparables, la norme croît sans limite ; le plafond d'itérations devient alors la seule condition d'arrêt effective.

Agrandir les coefficients raidit la sigmoïde autour de la frontière, sans déplacer celle-ci. Les probabilités s'écartent donc de 0,5, ce qui produit deux effets opposés : les 1 564 prédictions correctes voient la leur tendre vers 1 et leur coût vers 0 ; les 36 autres voient la leur tendre vers 0 et leur coût vers l'infini.




FIGURE H.1: Perte de deux prédictions quand la norme est multipliée par 1, 2 puis 3, à frontière fixe. La perte tend vers zéro pour l'observation correctement classée et croît sans borne pour l'autre.




FIGURE H.2: Coût à frontière fixe selon la norme. La part des prédictions correctes décroît; celle des 36 autres croît. Minimum en  $\|w\| = 5,38$ .

| $\ w\ $ | 1 564 correctes | 36 incorrectes | total |                        |
|---------|-----------------|----------------|-------|------------------------|
| 0,49    | 0,445           | 0,019          | 0,464 | transition très étalée |
| 4,89    | 0,041           | 0,067          | 0,108 | modèle de ce chapitre  |
| 5,38    | 0,034           | 0,073          | 0,107 | minimum                |
| 14,68   | 0,005           | 0,189          | 0,194 | transition abrupte     |

TABLE H.1: Entre la première ligne et la dernière, la part des prédictions correctes est divisée par quatre-vingt-neuf, celle des incorrectes multipliée par dix.

Le gain est borné par zéro, la perte ne l'est pas. Au-delà de  $\|w\| = 5,38$ , agrandir les coefficients coûte donc plus qu'il ne rapporte, et la descente cesse de le faire. La descente l'atteint en suivant le gradient. Le modèle de ce chapitre s'arrête un peu avant, à 4,89, parce que le compteur est coupé au quatre centième tour.

Ce mécanisme disparaît lorsqu'un hyperplan sépare parfaitement les deux classes — les données sont alors dites *linéairement séparables*. La part des prédictions incorrectes est vide, la courbe orange de la figure H.2 est identiquement nulle, et il ne reste que la courbe bleue, décroissante : la perte diminue indéfiniment sans jamais atteindre son infimum, et  $\|w\|$  diverge (annexe G).

Sur des données séparables, deux mécanismes distincts peuvent alors terminer la descente. Le premier est le plafond d'itérations. Le second est le critère de stagnation, qui compare la *baisse* de la perte à un seuil relatif : cette baisse tend vers zéro même quand  $\|w\|$  diverge, la perte décroissant de plus en plus lentement vers son infimum, de sorte que le critère se déclenche alors qu'aucun minimum fini n'existe et que les coefficients continuent de croître. Un critère fondé sur la norme du gradient se comporte de même, le gradient tendant lui aussi vers zéro. Diagnostiquer la séparabilité demande donc de surveiller  $\|w\|$  elle-même plutôt que la vitesse de convergence.

### Reconnaître et traiter la divergence

Ce cas se reconnaît à trois signes conjoints : la descente consomme son plafond d'itérations, ou s'arrête sur une stagnation avec une norme anormalement grande ; les coefficients croissent régulièrement sans se stabiliser ; et les probabilités produites valent exactement 0 ou 1 après arrondi.

Ces trois signes n'établissent pas à eux seuls que la cause est dans les données. Un pas trop long, un signe inversé dans la correction, un gradient mal calculé ou une perte instable produisent des symptômes voisins. L'ordre de diagnostic est donc : contrôler le gradient par différences finies (ch. 11), vérifier la perte en  $z = \pm 1000$  (annexe J), réduire  $\alpha$ , et seulement ensuite conclure à la séparabilité — qui se vérifie directement, en cherchant si un hyperplan sépare les deux classes sans erreur.

Une fois la séparabilité établie, deux traitements existent. Le plus simple est d'arrêter sur un nombre de tours fixé, ce que fait le plafond : la frontière obtenue est correcte, seule sa raideur est arbitraire, et les probabilités produites sont alors sans valeur informative. Le second, la *régularisation*, ajoute à la perte un terme  $\frac{\mu}{2} \|\mathbf{w}\|^2$  qui croît avec la norme. La courbe bleue de la figure H.2, relevée par une parabole, laisse réapparaître un minimum fini et unique, même sur des données séparables ; le paramètre  $\mu$  fixe où il tombe. La bibliothèque `scikit-learn` l'applique par défaut, ce qui explique qu'elle converge sur des données où une implémentation directe diverge.

### Interprétation de la norme finale

La norme finale traduit le degré de séparation que les données justifient. Un recouvrement des deux populations la maintient basse et laisse une transition étalée ; une séparation nette la porte haut. La forcer davantage ferait annoncer une certitude que les données ne soutiennent pas, et une probabilité de 0,99 sur un cas limite est une information fausse.



# Annexe I

## Surface de perte et longueur du pas

**OBJECTIFS** lire une descente sur la surface de perte et sur ses lignes de niveau ; relier la longueur du pas à la courbure de la perte ; énoncer la condition suffisante de décroissance

**PRÉREQUIS** dérivée partielle et gradient (annexe B) ; chapitre 7 ; annexe G

**PARCOURS** approfondissement

**Résultat employé dans le fil principal.** Le réglage  $\alpha = 1$  retenu au chapitre 7 fait décroître la perte à chaque tour. Cette annexe donne la condition qui l'assure, la borne qui la quantifie, et la lecture géométrique de la trajectoire.

### I.1 Surface du coût

Chaque couple de coefficients produit un coût, calculable sur les 1 600 observations. Porter ce coût en altitude au-dessus du couple qui le produit définit une surface au-dessus du plan  $(w_1, w_2)$ , dont chaque point représente un modèle possible. Le coût dépendant de trois coefficients, sa représentation demanderait quatre dimensions ; fixer le biais à sa valeur finale ramène à deux.

Cette surface est convexe (annexe G), donc sans minimum local parasite, et sa pente décroît à l'approche du minimum, ce qui raccourcit les pas successifs.

La descente se lit sur la surface : partant d'un point, elle suit la direction opposée au gradient et progresse par pas de longueur proportionnelle à  $\alpha$ . Le gradient étant orthogonal aux lignes de niveau, la trajectoire les coupe perpendiculairement.

Les deux figures suivantes tracent une descente à *deux* coefficients, le biais restant figé à  $w_0 = -4,745$  tandis que  $w_1$  et  $w_2$  se déplacent. Elle est réellement exécutée sur la surface affichée, ce qui rend cette lecture exacte, et se distingue sur deux points de la descente à trois coefficients du chapitre 7. Son point de départ  $(0 ; 0)$  vaut  $J = 0,98$  plutôt que  $\log 2 = 0,693$ , le biais n'y étant pas nul ; et le minimum qu'elle atteint,  $(-3,489 ; +3,512)$ , est le meilleur couple *sous la contrainte* d'un biais figé, légèrement distinct de  $M_{400}$ .




FIGURE I.1: Longueur du gradient en échelle logarithmique, de 0,42 à 0,0026 en 400 itérations. Cette décroissance fournit le critère d'arrêt.




FIGURE I.2: Surface de perte au-dessus du plan  $(w_1, w_2)$ , biais fixé à  $w_0 = -4,745$ . La courbe rouge est une descente à deux coefficients exécutée sur cette surface, de  $J = 0,98$  à  $J = 0,11$ .




FIGURE I.3: La même surface vue de dessus. Chaque courbe relie les couples de perte égale ; la trajectoire les coupe perpendiculairement. Les points marquent une itération sur vingt-cinq.

## I.2 Longueur du pas

À chaque tour, le gradient fournit une direction : son opposé  $-\nabla J$  est celle dans laquelle la perte décroît le plus vite depuis le point courant. La distance à parcourir dans cette direction est fixée par  $\alpha$ . Direction et longueur sont deux décisions séparées : la première se calcule, la seconde se règle.

Un pas court consomme la correction disponible par fractions, et il en faut d'autant plus de tours pour parcourir la même distance. Chaque tour demandant un passage complet sur les 1 600 lignes, ce choix se paie en temps de calcul pour aboutir à la même frontière.

Un pas long expose au dépassement. La pente que donne le gradient décrit fidèlement le terrain au seul voisinage du point où elle est calculée. Sortir de ce voisinage fait passer les coefficients de l'autre côté du minimum, sur la pente opposée, et le coût augmente. Les tours suivants ramènent vers le bas, au prix d'un détour.




FIGURE I.4: Quarante itérations à partir de  $M_0$ , quatre réglages du pas. À  $\alpha = 100$ , la trajectoire est heurtée : le déplacement dépasse le minimum le long de plusieurs directions.

PERTE MOYENNE SELON LE PAS

| $\alpha$ | départ   | après un tour | après quarante |                                 |
|----------|----------|---------------|----------------|---------------------------------|
| 0,05     | 0,693147 | 0,684362      | 0,466848       | pas trop court                  |
| 0,3      | 0,693147 | 0,642124      | 0,237761       |                                 |
| 1        | 0,693147 | 0,538507      | 0,153427       | réglage retenu                  |
| 100      | 0,693147 | 0,408290      | 0,111846       | trajectoire heurtée             |
| 1 000    | 0,693147 | 4,049         | —              | premier pas au-delà de la cible |

Les cinq réglages partent de  $\log 2$ , les coefficients nuls donnant 0,5 partout. À  $\alpha = 100$ , le faible gradient initial produit encore une baisse au premier tour malgré l'amplitude du déplacement ; la trajectoire devient ensuite heurtée. À  $\alpha = 1\,000$ , le premier tour porte la perte de 0,69 à 4,05. Le seuil se lit sur la courbe, non à l'œil.

$\alpha$  se règle par essais, en lisant la courbe de perte : un bon réglage la fait décroître à chaque tour, vite d'abord puis de moins en moins. Une remontée, même isolée, indique un pas trop long. Le cours retient  $\alpha = 1$ .

### I.3 Condition de décroissance

La longueur du déplacement,  $\alpha \|\nabla J\|$ , croît sans borne avec  $\alpha$ , et un pas suffisamment grand fait diverger la descente. Le seuil au-delà duquel cela se produit est fixé par la courbure de  $J$  par rapport aux *coefficients*, c'est-à-dire par la hessienne  $\frac{1}{m} \mathbf{X}^\top S \mathbf{X}$ , qui fait intervenir l'échelle et les corrélations des colonnes de  $\mathbf{X}$  (annexe G). La borne  $p(1-p) \leq \frac{1}{4}$  porte sur le seul facteur  $s_i$  et laisse ce seuil indéterminé.

L'énoncé exact est conditionnel. Si le gradient de  $J$  est  $L$ -lipschitzien — ce qui est le cas ici, avec  $L \leq \frac{1}{4m} \|\mathbf{X}\|^2$  — alors tout pas  $\alpha < 2/L$  fait décroître  $J$  à chaque tour, et  $\alpha \leq 1/L$  garantit une

convergence en  $O(1/t)$  [7, 8]. Ce seuil dépend des données, d'où le réglage par essais plutôt que par formule.

La standardisation des colonnes (ch. 3) intervient directement : en rapprochant les échelles des colonnes, elle réduit l'écart entre les courbures dans les différentes directions et rend un même  $\alpha$  acceptable pour tous les coefficients.




FIGURE I.5: Quadratique d'une variable, courbure  $c$ , minimum en 2. À gauche  $\alpha < 2/c$  : convergence. À droite  $\alpha = 2/c$  : oscillation entre deux valeurs; tout  $\alpha > 2/c$  diverge.

#### Exercice I.1 – Pas critique d'une quadratique

Soit  $f(\theta) = \frac{c}{2}(\theta - 2)^2$  avec  $c = 4$ . Écrire l'itération de descente de gradient, en déduire la relation entre  $\theta_{t+1} - 2$  et  $\theta_t - 2$ , puis la valeur de  $\alpha$  à partir de laquelle la suite cesse de converger. Vérifier sur la figure I.5.

**Retour au fil principal.** Le critère d'arrêt et les régimes successifs de la descente sont au chapitre 7, section 5.

# Annexe J

## Réécritures pour la stabilité numérique

**OBJECTIFS** réécrire la perte à partir du score seul ; écrire des formes protégées de softplus et de  $\sigma$  ; contrôler une implémentation en  $z = \pm 1000$   
**PRÉREQUIS** logarithme (annexe B) ; annexe E  
**PARCOURS** approfondissement ; la recette employée par le programme figure au chapitre 10, c'est sa démonstration qui est ici

### J.1 Coût exprimé à partir du score

En double précision,  $\sigma(z)$  vaut exactement 1 dès que  $z$  dépasse environ 37 :  $e^{-37}$  est de l'ordre de  $10^{-17}$ , en dessous de ce qu'un flottant distingue de 1 lorsqu'on l'y ajoute. Le coût demande alors  $\log(1 - 1)$ , qui n'existe pas. Un élève d'une autre maison auquel le modèle attribue une forte probabilité d'être [Gryffindor](#) suffit donc à interrompre le programme, alors que c'est exactement le cas que le coût doit signaler.

#### Logarithme d'un quotient, logarithme d'une exponentielle

$$\log(a/b) = \log a - \log b, \text{ et } \log(e^b) = b.$$

Reprenons la perte d'une prédiction et remplaçons  $p$  par  $\sigma(z)$  :

$$\begin{aligned}
\ell &= -[y \log \sigma(z) + (1 - y) \log(1 - \sigma(z))] \\
\log \sigma(z) &= \log \frac{1}{1 + e^{-z}} = \log 1 - \log(1 + e^{-z}) \\
&= -\log(1 + e^{-z}) && \text{car } \log 1 = 0 \\
\log(1 - \sigma(z)) &= \log \frac{e^{-z}}{1 + e^{-z}} = \log e^{-z} - \log(1 + e^{-z}) \\
&= -z - \log(1 + e^{-z}) && \text{car } \log e^{-z} = -z \\
\ell &= -\left[ y(-\log(1 + e^{-z})) \right. \\
&\quad \left. + (1 - y)(-z - \log(1 + e^{-z})) \right] \\
&= y \log(1 + e^{-z}) + (1 - y)z + (1 - y) \log(1 + e^{-z}) && \text{on distribue} \\
&= \log(1 + e^{-z}) + (1 - y)z && \text{les logs se regroupent} \\
&= \underbrace{\log(1 + e^{-z}) + z}_{= \log(1 + e^z)} - yz \\
&= \log(1 + e^z) - yz
\end{aligned} \tag{J.1}$$

Le regroupement souligné s'établit ainsi :

$$\log(1 + e^{-z}) + z = \log(1 + e^{-z}) + \log e^z = \log(e^z(1 + e^{-z})) = \log(e^z + 1),$$

en remontant  $z$  sous forme de  $\log e^z$ , en regroupant les deux logarithmes en celui d'un produit, puis en développant :  $e^z \cdot e^{-z} = e^0 = 1$ .

#### Forme employée par le programme

$$\ell(y, z) = \text{softplus}(z) - yz, \quad \text{softplus}(z) = \log(1 + e^z).$$

Cette forme se calcule directement à partir du score et exclut l'opération  $\log 0$  qui met en défaut l'écriture fondée sur  $\sigma(z)$ .

Pour  $z$  très négatif, la précision finie de  $\text{softplus}(z)$  affecte une valeur de l'ordre de  $e^z$ , négligeable dans la moyenne. Cette forme est employée par `step3_single_cost.py`, puis par tout le programme de la partie II.

Pour  $y = 1$  et  $z = 6$ , la forme directe donne  $-\log(0,997527) = 0,002476$  et celle-ci  $\text{softplus}(6) - 6 = 6,002476 - 6 = 0,002476$ .

## J.2 Formes protégées de softplus et de la sigmoïde

`softplus` contient encore  $e^z$ , qui déborde pour  $z$  grand. On l'écrit donc

$$\text{softplus}(z) = \max(z, 0) + \log(1 + e^{-|z|}),$$

dont l'exposant est toujours négatif ou nul. La vérification porte sur deux cas. Pour  $z \geq 0$ ,  $\max(z, 0) = z$  et l'expression vaut  $z + \log(1 + e^{-z}) = \log(e^z + 1)$ , par le même regroupement que ci-dessus. Pour  $z < 0$ ,  $\max(z, 0) = 0$  et  $|z| = -z$ , il reste  $\log(1 + e^z)$ , qui est la définition.

La sigmoïde reçoit le même traitement, avec ses deux écritures (annexe C) :

$$\sigma(z) = \begin{cases} 1/(1 + e^{-z}), & z \geq 0, \\ e^z/(1 + e^z), & z < 0. \end{cases}$$

Dans les deux branches, l'exponentielle porte sur un nombre négatif ou nul. Un exposant très négatif s'arrondit à zéro sans dommage ; un exposant très positif dépasse en revanche la capacité du format et provoque une erreur.




FIGURE J.1: Trois régimes du calcul en double précision. L'écriture directe tient dans la zone centrale ; les formes protégées restent finies sur tout l'axe.

| $y$ | $z$  | écriture directe                   | écriture protégée |
|-----|------|------------------------------------|-------------------|
| 0   | -800 | $-\log(1 - \sigma(-800)) = \log 0$ | 0,0               |
| 1   | -800 | $-\log(\sigma(-800)) = \log 0$     | 800,0             |
| 0   | +40  | $-\log(1 - \sigma(40)) = \log 0$   | 40,0              |
| 1   | +40  | $-\log(\sigma(40))$                | 0,0               |

TABLE J.1: Pertes aux scores extrêmes. Dès  $|z| \approx 37$ , l'écriture directe échoue sur trois lignes ;  $\text{softplus}(z) - yz$  reste définie sur les quatre.

### Contrôles numériques

La première perte vaut  $\log 2 = 0,693147$  quand les coefficients partent de zéro. Toute autre valeur signale une erreur dans le score ou l'initialisation.

Le gradient calculé par la formule, comparé à  $(J(\mathbf{w} + h\mathbf{e}_j) - J(\mathbf{w} - h\mathbf{e}_j))/2h$  sur un cas de petite taille, doit coïncider à  $10^{-6}$  près. Ce test détecte un signe inversé, un facteur  $1/m$  oublié, un indice décalé.

La sigmoïde et la perte, évaluées en  $z = \pm 1000$  pour  $y = 0$  puis  $y = 1$ , doivent rendre des nombres finis dans les quatre cas. C'est le test que `step3_single_cost.py` exécute.



# Annexe K

## Géométrie en dimension quelconque

**OBJECTIFS** écrire l'équation d'une frontière pour  $n$  variables et en donner la dimension ; décrire la région attribuée à une classe par la règle du maximum et énoncer ses propriétés exactes

**PRÉREQUIS** produit scalaire et norme (annexe B) ; chapitres 4 et 9

**PARCOURS** approfondissement ; se saute sans rompre la lecture du fil principal

### K.1 Frontière pour un nombre quelconque de matières

Avec  $n$  notes, une observation est un point de  $\mathbb{R}^n$  et l'équation de la frontière devient

$$w_0 + w_1x_1 + \cdots + w_nx_n = 0,$$

soit une équation linéaire à  $n$  inconnues, non triviale dès que  $(w_1, \dots, w_n) \neq 0$ . Son ensemble de solutions est un sous-espace affine de dimension  $n - 1$  : une contrainte non dégénérée retire un degré de liberté. Cet objet porte le nom d'*hyperplan affine* de  $\mathbb{R}^n$  — droite pour  $n = 2$ , plan pour  $n = 3$ , sans représentation graphique au-delà.

| matières | espace des observations | frontière    | sa dimension | coefficients |
|----------|-------------------------|--------------|--------------|--------------|
| 1        | $\mathbb{R}$            | un point     | 0            | 2            |
| 2        | $\mathbb{R}^2$          | une droite   | 1            | 3            |
| 3        | $\mathbb{R}^3$          | un plan      | 2            | 4            |
| $n$      | $\mathbb{R}^n$          | un hyperplan | $n - 1$      | $n + 1$      |
| 10       | $\mathbb{R}^{10}$       | un hyperplan | 9            | 11           |

TABLE K.1: La frontière occupe une dimension de moins que l'espace des observations et le sépare en deux demi-espaces. Le nombre de coefficients croît d'une unité par matière ajoutée.




FIGURE K.1: Frontière pour une, deux et trois matières. Disque : classe traitée ; croix : autres classes. Le vecteur normal,  $|z|/\|w\|$  et le signe de  $z$  conservent leur rôle.

Les formules du fil principal s'écrivent avec un nombre quelconque de notes, et les démonstrations des annexes suivantes valent pour  $n$  quelconque. Deux matières servent en partie I parce qu'elles se dessinent ; le modèle complet du projet en retient dix.

## K.2 Rôle de chaque coefficient

Les trois coefficients agissent séparément :  $(w_1, w_2)$  fixe la direction de la frontière et  $w_0$  sa position. La norme  $\|w\|$  laisse la frontière en place et fixe la vitesse à laquelle  $z$  croît lorsqu'on s'en éloigne (ch. 7).




FIGURE K.2: Frontière  $-0,4 - 0,6x_1 + x_2 = 0$  et son vecteur normal  $(-0,6 ; 1)$ , tracé à l'échelle depuis le pied de la perpendiculaire issue de l'origine. Le segment  $d_O$  mesure  $-w_0/\|w\| = 0,343$ .

Les deux panneaux suivants font varier un coefficient à la fois à partir de  $w = (0 ; 0,8 ; 1)$ . Ils couvrent tous les cas : la frontière ne dépend que de la direction de  $(w_1, w_2)$ , et faire varier  $w_1$  à  $w_2$  fixé parcourt cette direction tout entière.




FIGURE K.3: Trait plein commun aux deux panneaux :  $w = (0 ; 0,8 ; 1)$ . À gauche,  $w_0$  translate la droite ; à droite,  $w_1$  la fait pivoter autour de l'origine, que  $w_0 = 0$  laisse sur la frontière.

### K.3 Forme des régions du classifieur

La règle du score maximal (ch. 9) attribue une classe à chaque point du plan. Quelle forme prend l'ensemble des points attribués à une classe donnée ?

Prenons **Gryffindor**. Son modèle l'emporte en un point lorsque son score y dépasse les trois autres, ce qui fait trois conditions. La première s'écrit

$$z_G \geq z_H \iff (w_{G0} - w_{H0}) + (w_{G1} - w_{H1})x_1 + (w_{G2} - w_{H2})x_2 \geq 0,$$

et les deux autres s'obtiennent en remplaçant  $H$  par  $R$  puis par  $S$ . Le membre de gauche est une fonction affine des deux notes ; l'inégalité définit donc un demi-plan, bordé par la droite où les deux scores s'égalisent.




FIGURE K.4: Les trois demi-plans où **Gryffindor** l'emporte sur chacun de ses rivaux, puis leur intersection. Le dernier panneau porte les observations de cette classe, qui s'y trouvent presque toutes. État du modèle :  $M_4$ .

La région de **Gryffindor** est l'intersection de ces trois demi-plans : un ensemble convexe, intersection finie de demi-plans, donc un polyèdre convexe du plan. Il peut être vide, borné ou non borné. Trois propriétés en découlent, énoncées avec leurs conditions.

1. **Convexité.** Deux points d'une même région ont tout le segment qui les joint dans cette région. Une classe ne peut donc pas occuper deux zones séparées.
2. **Bords.** Les bords sont portés par les droites d'égalité  $z_G = z_R$ , distinctes des quatre frontières binaires  $z_k = 0$ . Un bord s'interrompt là où un troisième modèle prend le dessus. Si la région est bornée, ses arêtes sont de longueur finie ; si elle ne l'est pas — ce qui arrive dès que la région contient une demi-droite — au moins une arête est infinie. Sur les quatre modèles employés ici, les quatre régions sont non bornées.
3. **Départage.** En cas d'égalité exacte entre deux scores maximaux,  $\arg \max$  ne désigne pas une classe : il faut une convention. Le code de la partie II retient le premier maximum rencontré dans l'ordre de la liste des classes. Cet événement est de probabilité nulle sur des données continues, mais se produit sur des valeurs arrondies.




FIGURE K.5: Frontières binaires de **Gryffindor** (trait plein) et de **Ravenclaw** (tireté), et limite entre leurs deux régions (trait épais). Cette limite a pour vecteur normal  $w_G - w_R$  et passe par l'intersection des deux premières.

Quatre classes forment six paires, donc six droites d'égalité, dont chacune ne borde une région que sur la portion où le score commun aux deux classes dépasse aussi les deux autres.

Cette construction se vérifie le long d'un trajet : chaque score y devient une fonction affine du chemin parcouru, donc une droite, et le maximum des quatre une ligne brisée dont les points anguleux marquent les changements de région.



FIGURE K.6: Trajet de **Gryffindor** vers **Hufflepuff**, à gauche ; quatre scores et leur maximum, à droite. Les angles de la ligne épaisse marquent les changements de région.

# Annexe L

## Corrigés

**OBJECTIFS** comparer une tentative au code de référence et aux réponses attendues

**PRÉREQUIS** la tâche correspondante a été tentée

**PARCOURS** à consulter après avoir écrit puis exécuté sa propre version

Cette annexe porte le code des douze tâches du cahier pratique et les réponses aux exercices du fil principal. Chaque section porte le nom du fichier ou le numéro de l'exercice qu'elle corrige.

## L.1 Cahier pratique

### step0\_prepare.py — préparation des données

```
def load():
    data = Data(TRAIN)
    return [data.courses[course] for course in COURSES], data.houses

def fit_stats(columns, rows):
    stats = []
    for col in columns:
        known = sorted(col[i] for i in rows if col[i] is not None)
        lo, hi = known[(len(known) - 1) // 2], known[len(known) // 2]
        median = (lo + hi) / 2
        filled = [col[i] if col[i] is not None else median for i in rows]
        mean = sum(filled) / len(filled)
        sd = (sum((v - mean) ** 2 for v in filled) / len(filled)) ** 0.5
        stats.append((median, mean, sd))
    return stats

def design(columns, stats, rows):
    X = []
    for row in rows:
        line = [1.0]
        for col, (median, mean, sd) in zip(columns, stats):
            value = col[row] if col[row] is not None else median
            line.append((value - mean) / sd)
        X.append(line)
    return X
```

**Transfert.** Avec 40 % de valeurs absentes, la médiane reste une statistique correcte de la colonne observée, mais l'écart-type calculé après imputation s'effondre : 40 % des lignes reçoivent exactement la même valeur. Le nuage montrerait une barre verticale dense à l'abscisse de la médiane, et le coefficient de cette variable serait tiré par un groupe artificiel.

### step1\_score.py — le score

```
def score_of(weights, x):
    total = 0.0
    for column in range(len(weights)):
        total += weights[column] * x[column]
    return total
```

**Transfert.** Sans colonne de 1, le gradient (ch. 11) devrait traiter  $\partial J / \partial w_0$  à part, avec  $x_{i0}$  implicitement égal à 1 ; `one_step` et `descend` hériteraient du même cas particulier, et l’extension à dix matières multiplierait les branches.

## step2\_sigmoid.py — la sigmoïde protégée

```
def sigmoid(z):
    if z >= 0:
        return 1 / (1 + exp(-z))
    return exp(z) / (1 + exp(z)) # exponent stays negative
```

**Transfert.** À  $z = -800$ , la sigmoïde protégée rend exactement 0,0. Pour une étiquette valant 1, la perte directe demanderait  $\log 0$  ; la forme stable de l’étape suivante rend 800, valeur finie qui laisse la descente continuer.

## step3\_single\_cost.py — la perte d’une prédiction

```
from math import exp, log, log1p

def softplus(z):
    return max(z, 0.0) + log1p(exp(-abs(z)))

def student_cost(score, expected):
    return softplus(score) - expected * score
```

**Transfert.** Pour  $z \rightarrow -\infty$  et  $y = 1$ ,  $\text{softplus}(z) - z \rightarrow -z = |z|$  : la perte croît linéairement. Une croissance quadratique donnerait un gradient non borné ; une croissance bornée rendrait la correction insensible aux prédictions les plus fausses. La dérivée  $p - y$  reste ici comprise entre  $-1$  et  $1$  (annexe F).

## step4\_total\_cost.py — la perte moyenne

```
def total_cost(weights, X, target):
    total = 0.0
    for x, expected in zip(X, target):
        total += student_cost(score_of(weights, x), expected)
    return total / len(X)
```

**Transfert.** Un fichier deux fois plus long, de même composition, double la somme et laisse la moyenne inchangée. Seule la moyenne compare les deux fichiers. Le pas  $\alpha$  multiplie le gradient :



avec une somme, la longueur du déplacement croîtrait avec l'effectif, et un  $\alpha$  réglé sur 1 600 lignes ferait diverger la descente sur 3 200.

### step5\_gradient.py — gradient et contrôle numérique

```
def gradient(weights, X, target):
    slope = [0.0] * len(weights)
    for x, expected in zip(X, target):
        error = sigmoid(score_of(weights, x)) - expected
        for column in range(len(weights)):
            slope[column] += error * x[column]
    return [s / len(X) for s in slope]

def measured_slope(weights, X, target, column, h=1e-5):
    below, above = list(weights), list(weights)
    below[column] -= h
    above[column] += h
    rise = total_cost(above, X, target) - total_cost(below, X, target)
    return rise / (2 * h)
```

**Transfert.** En  $(0, 0, 0)$ , tous les scores valent zéro et  $p_i - y_i = \pm 0,5$ ; un facteur  $1/m$  omis multiplie les trois composantes par  $m$ , ce qu'une comparaison à la mesure détecte — mais la mesure elle-même emploie `total_cost`, affecté du même facteur, et les deux erreurs se compensent. Un point d'évaluation à composantes distinctes, comme  $(0,3; -0,7; 0,4)$ , sépare les trois colonnes et révèle un indice décalé, que  $(0, 0, 0)$  laisse invisible puisque les colonnes  $y$  jouent des rôles symétriques.

### step6\_one\_step.py — un pas

```
ALPHA = 1.0

def one_step(weights, X, target):
    slope = gradient(weights, X, target)
    return [w - ALPHA * g for w, g in zip(weights, slope)]
```

**Transfert.** Les *Gryffindor* occupent la région  $x_1 < 0, x_2 > 0$  (figure 4.2). Au premier tour,  $p_i - y_i$  vaut  $-0,5$  sur eux et  $+0,5$  ailleurs; la composante  $\partial J / \partial w_1$  est donc dominée par des produits  $(-0,5) \times (x_1 \text{ négatif})$ , positifs, d'où une pente positive et un  $w_1$  qui diminue. Le raisonnement symétrique donne  $w_2$  croissant. La trace du tableau 7.1 confirme :  $-0,2289$  et  $+0,1924$ .

## step7\_loop.py — la boucle et ses deux arrêts

```

EPSILON, MAX_ITER = 1e-6, 6000

def descend(X, target):
    weights = [0.0] * len(X[0])
    cost = total_cost(weights, X, target)
    for iteration in range(1, MAX_ITER + 1):
        weights = one_step(weights, X, target)
        previous, cost = cost, total_cost(weights, X, target)
        if previous - cost < EPSILON * abs(previous):
            return weights, cost, iteration
    return weights, cost, MAX_ITER

```

**Transfert.** Un critère portant sur les décisions comparerait le vecteur des prédictions à celui du tour précédent et s'arrêterait après  $k$  tours sans changement. Il coûte un passage supplémentaire sur les lignes pour former les prédictions, plus le stockage du vecteur précédent. Sur ces données il se déclencherait quelques centaines de tours avant le critère de perte, au prix d'une frontière moins nette : les probabilités resteraient plus proches de 0,5.

## step8\_four\_houses.py — quatre descentes et l'argmax

```

def train(X, houses):
    model = {}
    for house in HOUSES:
        target = [1.0 if h == house else 0.0 for h in houses]
        model[house], cost, iterations = descend(X, target)
        print(f" {house:<12} cost {cost:.4f} {iterations:>4} iterations")
    return model

def predict(model, x):
    return max(HOUSES, key=lambda house: score_of(model[house], x))

```

**Transfert.** Cinq classes demandent cinq descentes et  $5 \times (n + 1)$  coefficients, soit 55 pour dix matières. Les statistiques de préparation restent au nombre de  $3n$ . Aucune ligne de `train` ni de `predict` ne change : la première itère sur `HOUSES`, la seconde prend le maximum de la liste des scores.

## step9\_holdout.py — découpage stratifié

```
def split(houses, part=0.8, seed=0):
    state, learn, test = seed, [], []
    for house in HOUSES:
        rows = [i for i, h in enumerate(houses) if h == house]
        for k in range(len(rows) - 1, 0, -1):
            state = (state * 1103515245 + 12345) % (1 << 31)
            j = state % (k + 1)
            rows[k], rows[j] = rows[j], rows[k]
        cut = round(part * len(rows))
        learn += rows[:cut]
        test += rows[cut:]
    return learn, test

columns, houses = load()
learn, test = split(houses)
stats = fit_stats(columns, learn)
X_learn = design(columns, stats, learn)
X_test = design(columns, stats, test)
print(f"{len(learn)} students to learn from, {len(test)} set aside")
print("median, mean and sd fitted on the learning rows only\n")
model = train(X_learn, [houses[i] for i in learn])
seen = accuracy(model, X_learn, houses, learn)
unseen = accuracy(model, X_test, houses, test)
```

**Transfert.** [Slytherin](#), la plus petite classe avec 60 lignes de test sur 300 attendues, subit la variation relative la plus large : un tirage global laisse son effectif de test fluctuer d'environ  $\pm 7$  lignes d'une graine à l'autre. L'intervalle de Wilson global change peu — il dépend de  $n = 320$ , non de la composition — mais les rappels par classe deviennent instables, celui de [Slytherin](#) pouvant varier de plusieurs points sans que le modèle ait changé.

## step10\_evaluation.py — matrice et incertitude

```
def wilson(right, total, z=Z):
    if total == 0:
        return 0.0, 1.0
    p, n = right / total, total
    half = z * sqrt(p * (1 - p) / n + z * z / (4 * n * n))
    centre, spread = p + z * z / (2 * n), 1 + z * z / n
    return (centre - half) / spread, (centre + half) / spread

def confusion(model, X, observed):
    table = {a: {b: 0 for b in HOUSES} for a in HOUSES}
    for x, house in zip(X, observed):
        table[house][predict(model, x)] += 1
    return table
```

**Transfert.** Rappel 0,55 pour précision 0,98 : le modèle ne désigne cette classe qu'à coup sûr et en manque près de la moitié. La ligne de la classe dans la matrice le révèle — ses effectifs sont dispersés sur les autres colonnes — alors que sa colonne reste presque vide hors diagonale. En binaire, abaisser le seuil rééquilibrerait les deux mesures ; sous la règle du maximum, il faudrait agir sur le biais du modèle concerné, ce qui déplace la limite avec les trois autres régions à la fois.

## transfert\_micro.py — douze pièces

```
def fit_stats(columns):
    stats = []
    for col in columns:
        mean = sum(col) / len(col)
        sd = (sum((v - mean) ** 2 for v in col) / len(col)) ** 0.5
        stats.append((mean, sd))
    return stats

def design(columns, stats):
    rows = len(columns[0])
    return [[1.0] + [(col[i] - mean) / sd
                     for col, (mean, sd) in zip(columns, stats)]
            for i in range(rows)]

def total_cost(weights, X, target):
    return sum(student_cost(score_of(weights, x), y)
               for x, y in zip(X, target)) / len(X)

def descend(X, target):
    weights = [0.0] * len(X[0])
    previous = total_cost(weights, X, target)
    for turn in range(1, MAX_TURNS + 1):
        slopes = gradient(weights, X, target)
        weights = [w - ALPHA * g for w, g in zip(weights, slopes)]
        cost = total_cost(weights, X, target)
        if previous - cost < EPSILON * abs(previous):
            return weights, cost, turn, "stagnation"
        previous = cost
    return weights, previous, MAX_TURNS, "plafond"
```

**Transfert.** Les douze pièces étant séparables, il existe un  $w$  qui classe tout correctement; multiplier ce  $w$  par  $\lambda > 1$  laisse la frontière en place et rapproche chaque probabilité de son étiquette, donc fait décroître la perte. Aucun minimum fini n'existe, la norme croît sans borne (annexe H) et la baisse relative reste au-dessus de  $10^{-6}$  : seul le plafond arrête la boucle. Un plafond dix fois plus grand laisserait la frontière à la même position et ne ferait que resserrer la transition, comme au chapitre 7. La pièce de 10,20 mm et 133 HV donne  $z = +2,775 > 0$  : rebut.

## L.2 Exercices du fil principal

### Exercice 4.1 — vecteur normal et distance

$$\begin{aligned}\|w\| &= \sqrt{3,454^2 + 3,469^2} = 4,895, \\ -\frac{w_0}{\|w\|} &= \frac{4,745}{4,895} = 0,969.\end{aligned}$$

La distance signée de l'origine à la frontière vaut donc 0,969 écart-type. Le score de  $x = (0; 0)$  vaut  $w_0 = -4,745$  : l'observation moyenne appartient au demi-plan des trois autres classes. Les [Gryffindor](#) occupent le quadrant  $x_1 < 0, x_2 > 0$ , éloigné du centre.

### Exercice 5.1 — probabilité de bout en bout

$x_1 = (4,12 - 1,189)/5,175 = +0,566$ . La note d'[Ancient Runes](#) étant absente, elle reçoit la médiane 463,918, d'où  $x_2 = (463,918 - 495,052)/105,186 = -0,296$ . Alors

$$z = -4,745 + (-3,454)(0,566) + 3,469(-0,296) = -7,724, \quad p = 0,00044.$$

Le score est négatif : l'observation appartient au demi-plan des autres classes, loin de la frontière. L'écart avec l'élève 3 ( $z = +1,34$ ) vient d'[Herbology](#) : le terme passe de +5,13 à -1,96, soit sept unités, quand celui d'[Ancient Runes](#) n'en change que d'une seule.

### Exercice 7.1 — signe d'une composante du gradient

Voir le transfert de `step6_one_step.py` ci-dessus :  $\partial J / \partial w_1$  est positive et  $\partial J / \partial w_2$  négative, d'où un  $w_1$  décroissant et un  $w_2$  croissant dès le premier tour.

### Exercice 8.1 — lecture d'un coefficient

Un modèle ajusté sur les notes brutes vérifie  $w_2^{\text{brut}} v = w_2^{\text{std}} (v - \mu) / \sigma$  à un terme constant près, absorbé par le biais :  $w_2^{\text{brut}} = w_2^{\text{std}} / \sigma = 3,469 / 105,186 = 0,033$ . Les deux décrivent la même frontière. Seul  $w_2^{\text{std}}$  se compare à celui d'[Herbology](#), les deux étant exprimés par écart-type. Un écart-type de plus en [Ancient Runes](#) multiplie la cote par  $e^{3,469} = 32$  dans les deux paramétrages : l'exposant est le produit coefficient  $\times$  variation, invariant par changement d'échelle.

### Exercice 9.1 — portée des quatre sorties

0,952 répond à « cette observation appartient-elle à [Gryffindor](#), oui ou non ? » et 0,899 à « appartient-elle à [Ravenclaw](#) ? ». Les deux questions sont séparées et leurs réponses ne se

partagent aucun budget : leur somme, 1,851 pour cet élève, dépasse 1. Seule la seconde phrase est autorisée. La première supposerait une distribution sur les quatre classes, c'est-à-dire une somme égale à 1, que la construction un-contre-tous n'impose pas.

### Exercice I.1 — pas critique d'une quadratique

Pour  $f(\theta) = \frac{c}{2}(\theta - 2)^2$ ,  $f'(\theta) = c(\theta - 2)$  et l'itération  $\theta_{t+1} = \theta_t - \alpha c(\theta_t - 2)$  donne

$$\theta_{t+1} - 2 = (1 - \alpha c) (\theta_t - 2).$$

La suite converge si  $|1 - \alpha c| < 1$ , soit  $0 < \alpha < 2/c$ ; elle oscille sans converger en  $\alpha = 2/c$  et diverge au-delà. Avec  $c = 4$ , le pas critique vaut 0,5. La figure I.5 montre les deux régimes.

# Références

- [1] Roderick J. A. LITTLE et Donald B. RUBIN. *Statistical Analysis with Missing Data*. 3<sup>e</sup> éd. Wiley, 2019.
- [2] Peter McCULLAGH et John A. NELDER. *Generalized Linear Models*. 2<sup>e</sup> éd. Chapman et Hall, 1989.
- [3] Ryan RIFKIN et Aldebaro KLAUTAU. « In Defense of One-Vs-All Classification ». In : *Journal of Machine Learning Research* 5 (2004), p. 101-141.
- [4] Edwin B. WILSON. « Probable Inference, the Law of Succession, and Statistical Inference ». In : *Journal of the American Statistical Association* 22.158 (1927), p. 209-212.
- [5] A. ALBERT et J. A. ANDERSON. « On the Existence of Maximum Likelihood Estimates in Logistic Regression Models ». In : *Biometrika* 71.1 (1984), p. 1-10.
- [6] David GOLDBERG. *What Every Computer Scientist Should Know About Floating-Point Arithmetic*. ACM Computing Surveys 23(1), 5–48, 1991.
- [7] Jorge NOCEDAL et Stephen J. WRIGHT. *Numerical Optimization*. 2<sup>e</sup> éd. Springer, 2006.
- [8] Stephen BOYD et Lieven VANDENBERGHE. *Convex Optimization*. Cambridge University Press, 2004.