

Régression logistique binaire

Du score linéaire à la décision probabiliste

Sylvain Maitre

Étude de cas : Gryffondor et Serpentard

Observations disponibles

Pour chaque élève :

- une note de Potions sur 20;
 - une note de Vol sur 100.
-


Maison observée

Deux maisons sont représentées :


- Gryffondor;
 - Serpentard.
-

Construire une règle qui associe les deux notes à une maison.

DISTRIBUTION DES NOTES DE POTIONS ET DE VOL



CHAÎNE DE CONSTRUCTION DU CLASSIFIEUR



Définir les données et le protocole

SÉPARATION ENTRE ESTIMATION ET ÉVALUATION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Le groupe d'estimation constitue le *jeu d'apprentissage* : lui seul fixe les nombres du modèle.
Le groupe d'évaluation les reçoit sans les modifier.

GROUPE D'ESTIMATION : DOUZE ÉLÈVES

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
---------	----------------	----------	------------------	----------	-------------	----------	------------

ID	Élève	Maison	Potions	Vol
E01	Harry Potter	Gryffondor	3	47
E02	Drago Malefoy	Serpentard	9	29
E03	Hermione Granger	Gryffondor	5	53
E04	Pansy Parkinson	Serpentard	11	35
E05	Ron Weasley	Gryffondor	6	56
E06	Blaise Zabini	Serpentard	12	38
E07	Neville Londubat	Gryffondor	14	44
E08	Vincent Crabbe	Serpentard	8	62
E09	Ginny Weasley	Gryffondor	9	65
E10	Gregory Goyle	Serpentard	15	47
E11	Dean Thomas	Gryffondor	11	71
E12	Théodore Nott	Serpentard	17	53

GROUPE D'ÉVALUATION : HUIT ÉLÈVES

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
---------	----------------	----------	------------------	----------	-------------	----------	------------

ID	Élève	Maison	Potions	Vol
E13	Seamus Finnigan	Gryffondor	—	60
E14	Daphné Greengrass	Serpentard	16	—
E15	Parvati Patil	Gryffondor	7	50
E16	Millicent Bulstrode	Serpentard	7	35
E17	Lavande Brown	Gryffondor	13	65
E18	Marcus Flint	Serpentard	10	55
E19	Colin Crivey	Gryffondor	4	41
E20	Adrian Pucey	Serpentard	13	55

Deux notes sont manquantes

Potions manque pour Seamus; Vol manque pour Daphné. Une case vide ne peut pas être standardisée : elle doit d'abord recevoir une valeur numérique.

COMPLÉTER, PUIS STANDARDISER UNE NOTE MANQUANTE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

Valeurs de remplacement

$$\tilde{P} = 10, \quad \tilde{V} = 50.$$

Ces médianes sont calculées sur les douze élèves du groupe d'estimation.

Deux substitutions

$$P_{\text{Seamus}} \leftarrow 10 \implies x_{\text{pot}} = 0,$$

$$V_{\text{Daphné}} \leftarrow 50 \implies x_{\text{vol}} = 0.$$

Ici, médiane et moyenne coïncident dans chaque matière.

note manquante

médiane
de la matière

valeur
numérique v

$x = (v - \mu)/s$
note standardisée

DEUX MATIÈRES, DEUX ÉCHELLES DE MESURE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Un point représente 5% de l'échelle en Potions, contre 1% en Vol.

Les paramètres de standardisation sont calculés sur le groupe d'estimation, puis conservés :

Potions

$$\mu_{\text{pot}} = 10, \quad s_{\text{pot}} = 4,$$

$$x_{\text{pot}} = \frac{P - 10}{4}.$$

Vol

$$\mu_{\text{vol}} = 50, \quad s_{\text{vol}} = 12,$$

$$x_{\text{vol}} = \frac{V - 50}{12}.$$

Pour Harry : $x_{\text{pot}} = -1,75$ et $x_{\text{vol}} = -0,25$. Les deux coordonnées sont désormais sans unité.

EFFET GÉOMÉTRIQUE DE LA STANDARDISATION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE



PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Le centrage-réduction change les unités, pas l'identité des élèves ni leur maison.

Construire le score linéaire

DÉFINITION DU SCORE LINÉAIRE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

$$z_i = w_0 + w_{\text{pot}}x_{i,\text{pot}} + w_{\text{vol}}x_{i,\text{vol}}$$

Coefficients

Le signe indique le sens de l'association; la valeur absolue en mesure l'intensité sur l'échelle standardisée.

État du modèle

Les coefficients sont encore inconnus. Leur estimation viendra après la définition de la perte et du gradient.

CONTRIBUTIONS DES DEUX MATIÈRES AU SCORE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

Prenons provisoirement $w^{\text{essai}} = (0, -1, +1)$, donc $z = x_{\text{vol}} - x_{\text{pot}}$.

élève	x_{pot}	x_{vol}	$-x_{\text{pot}}$	$+x_{\text{vol}}$	z
Harry	-1,75	-0,25	+1,75	-0,25	+1,50
Drago	-0,25	-1,75	+0,25	-1,75	-1,50
Neville	+1,00	-0,50	-1,00	-0,50	-1,50

Le score agrège les contributions; il ne constitue encore ni une probabilité ni une classe prédite.

LE NIVEAU DE SCORE NUL DÉFINIT UNE DROITE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Pour les douze observations du groupe d'estimation :

$$X = \begin{pmatrix} 1 & x_{1,\text{pot}} & x_{1,\text{vol}} \\ \vdots & \vdots & \vdots \\ 1 & x_{12,\text{pot}} & x_{12,\text{vol}} \end{pmatrix}, \quad w = \begin{pmatrix} w_0 \\ w_{\text{pot}} \\ w_{\text{vol}} \end{pmatrix}.$$

$$z = Xw$$

Une même multiplication produit les douze scores; chaque ligne de X correspond à un élève.

Transformer le score en probabilité

LA SIGMOÏDE ASSOCIE UNE PROBABILITÉ À TOUT SCORE RÉEL

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



$$p_i = \sigma(z_i) = \frac{1}{1 + e^{-z_i}}$$

PROPRIÉTÉS DE LA FONCTION LOGISTIQUE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

Monotonie

$$z_1 < z_2 \Rightarrow \sigma(z_1) < \sigma(z_2).$$

Point central

$$\sigma(0) = \frac{1}{2}.$$

Symétrie

$$\sigma(-z) = 1 - \sigma(z).$$

La sigmoïde conserve l'ordre des scores et les transforme en valeurs strictement comprises entre 0 et 1.

LE LOGIT EST L'INVERSE DE LA SIGMOÏDE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

Du score à la probabilité

$$\frac{p}{1-p} = e^z, \quad p = \frac{e^z}{1+e^z}.$$

De la probabilité au score

$$\text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = z.$$

z	$-\ln 5$	-1	0	1	$+\ln 5$
p	$1/6$	$0,269$	$1/2$	$0,731$	$5/6$

PROBABILITÉS ASSOCIÉES À TROIS SCORES

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
---------	----------------	----------	------------------	----------	-------------	----------	------------

élève	z d'essai	$p = \sigma(z)$	maison favorisée
Harry	+1,50	0,818	Gryffondor
Drago	-1,50	0,182	Serpentard
Neville	-1,50	0,182	Serpentard

La sigmoïde étant strictement croissante, deux observations de même score reçoivent la même probabilité selon le modèle.

Définir la perte logistique

$$y_i = \begin{cases} 1 & \text{si l'élève appartient à Gryffondor,} \\ 0 & \text{si l'élève appartient à Serpentard.} \end{cases}$$

Ce codage n'était nécessaire ni pour calculer le score z_i , ni pour le transformer en probabilité p_i . Il devient nécessaire pour comparer la sortie du modèle à la maison observée.

$$\ell(z, y) = -y \ln p - (1 - y) \ln(1 - p)$$

Maison observée : Gryffondor

$$y = 1, \quad \ell = -\ln p = \ln(1 + e^{-z}).$$

La perte décroît lorsque le score augmente.

Maison observée : Serpentard

$$y = 0, \quad \ell = -\ln(1 - p) = \ln(1 + e^z).$$

La perte décroît lorsque le score diminue.

COMPORTEMENT DE LA PERTE SELON LA MAISON OBSERVÉE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



$$\ell(z, y) = \text{softplus}(z) - yz.$$

Avec les coefficients d'essai, le signe du score concorde avec la maison observée pour dix élèves et s'y oppose pour deux :

$$J = \frac{10 \times 0,201 + 2 \times 1,701}{12} = 0,451.$$

Signe concordant

Perte : 0,201.

Signe discordant

Perte : 1,701, soit environ 8,4 fois plus.

Ces deux observations empêchent une séparation parfaite des maisons.

Calculer le gradient

$$\frac{\partial \ell_i}{\partial z_i} = p_i - y_i.$$

Comme $z_i = w_0 + w_{\text{pot}}x_{i,\text{pot}} + w_{\text{vol}}x_{i,\text{vol}}$,

$$\nabla J(w) = \frac{1}{n} \sum_{i=1}^n (p_i - y_i) \begin{pmatrix} 1 \\ x_{i,\text{pot}} \\ x_{i,\text{vol}} \end{pmatrix} = \frac{1}{n} X^\top (p - y).$$

GRADIENT AU POINT D'INITIALISATION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

$$w^{(0)} = (0, 0, 0) \implies z_i = 0, \quad p_i = \frac{1}{2}.$$

Les douze observations donnent exactement

$$\sum_i (p_i - y_i) = 0, \quad \sum_i (p_i - y_i)x_{i,\text{pot}} = 3, \quad \sum_i (p_i - y_i)x_{i,\text{vol}} = -3.$$

Donc

$$\nabla J(w^{(0)}) = (0, 0,25, -0,25).$$

CONTRIBUTION DE QUATRE OBSERVATIONS AU GRADIENT

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
élève	y	$p - y$ à $w = 0$	x_{pot}	$(p - y)x_{\text{pot}}$	$(p - y)x_{\text{vol}}$		
Harry	1	-0,5	-1,75	+0,875	+0,125		
Drago	0	+0,5	-0,25	-0,125	-0,875		
Neville	1	-0,5	+1,00	-0,500	+0,250		
Vincent	0	+0,5	-0,50	-0,250	+0,500		

Les contributions sont additionnées avant la division par $n = 12$.

$$z = Xw,$$

$$p = \sigma(z),$$

$$r = p - y,$$

$$\nabla J(w) = \frac{1}{12} X^\top r.$$

Dimensions

$$X \in \mathbb{R}^{12 \times 3}, w \in \mathbb{R}^3, p, y, r \in \mathbb{R}^{12} \text{ et } \nabla J(w) \in \mathbb{R}^3.$$

VÉRIFICATION DU GRADIENT PAR DIFFÉRENCE FINIE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

$$\frac{\partial J}{\partial w_j} \approx \frac{J(w + he_j) - J(w - he_j)}{2h}, \quad h = 10^{-5}.$$

composante j	gradient analytique	différence finie	écart
0	+0,046541807	+0,046541807	0,00000000000
1	+0,144621051	+0,144621051	0,00000000000
2	-0,164881324	-0,164881324	0,00000000001

Écart maximal : 0,00000000001.

Estimer les coefficients

$$w^{(t+1)} = w^{(t)} - \alpha \nabla J(w^{(t)}), \quad \alpha = 1.$$

À partir de $w^{(0)} = (0, 0, 0)$:

$$w^{(1)} = (0, 0, 0) - (0, 0, 25, -0, 25) = \boxed{(0, -0, 25, +0, 25)}.$$

Pour Harry, $x_{\text{vol}} - x_{\text{pot}} = 1,5$:

$$z^{(1)} = 0,375, \quad p^{(1)} = 0,593.$$

La perte moyenne passe de 0,693147 à 0,585623.

CONVERGENCE DE LA DESCENTE DE GRADIENT

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
---------	----------------	----------	------------------	----------	-------------	----------	------------

itération	J	w_0	w_{pot}	w_{vol}	$\ \nabla J\ $
0	0,693147	+0,000000	+0,000000	+0,000000	0,353553
1	0,585623	+0,000000	−0,250000	+0,250000	0,255266
2	0,529140	+0,000000	−0,430500	+0,430500	0,188035
5	0,469709	+0,000000	−0,741135	+0,741135	0,085794
10	0,453187	+0,000000	−0,946007	+0,946007	0,029858
20	0,450636	+0,000000	−1,051109	+1,051109	0,004881
50	0,450561	+0,000000	−1,072827	+1,072827	$2,915 \times 10^{-5}$
100	0,450561	+0,000000	−1,072959	+1,072959	$5,961 \times 10^{-9}$
152	0,450561	+0,000000	−1,072959	+1,072959	$8,678 \times 10^{-13}$

Le critère $\|\nabla J\| \leq 10^{-12}$ est atteint à l'itération 152.

Les six observations vérifiant $V > 3P + 20$ comprennent cinq Gryffondor et un Serpentard. Une probabilité commune q y maximise la vraisemblance pour

$$q = \frac{5}{6}.$$

Leur différence standardisée vaut $x_{\text{vol}} - x_{\text{pot}} = 18/12 = 3/2$. En posant $w_{\text{pot}} = -a$ et $w_{\text{vol}} = a$,

$$\sigma\left(\frac{3}{2}a\right) = \frac{5}{6} \implies \frac{3}{2}a = \text{logit}\left(\frac{5}{6}\right) = \ln 5.$$

$$a = \frac{2 \ln 5}{3} = 1,072959.$$

PARAMÈTRES STANDARDISÉS ET PARAMÈTRES BRUTS

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

Variables standardisées

$$(w_0, w_{\text{pot}}, w_{\text{vol}}) = \left(0; -\frac{2 \ln 5}{3}; +\frac{2 \ln 5}{3}\right)$$

$$z = \frac{2 \ln 5}{3}(x_{\text{vol}} - x_{\text{pot}}).$$

Notes brutes

$$b = -\frac{10 \ln 5}{9}, \quad \beta_{\text{pot}} = -\frac{\ln 5}{6},$$

$$\beta_{\text{vol}} = +\frac{\ln 5}{18}.$$

$$z = \frac{\ln 5}{18}(V - 3P - 20).$$

$$J(w^*) = 0,450561.$$

LE RECOUVREMENT REND L'OPTIMUM FINI

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Sans Neville et Vincent, les maisons seraient parfaitement séparées : la perte décroîtrait vers zéro lorsque a augmente, sans optimum fini.

FRONTIÈRE DU MODÈLE AJUSTÉ

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Définir la règle de décision

$$\hat{y}_i = \mathbf{1}[p_i \geq \tau].$$

$$p_i < \tau$$

Maison prédite : Serpentard.

$$p_i \geq \tau$$

Maison prédite : Gryffondor.

Le seuil agit après l'estimation : le modifier ne recalcule ni la standardisation, ni les coefficients.

$$V - 3P - 20 = +18 \Rightarrow z = +\ln 5 \Rightarrow p = \frac{5}{6},$$

$$V - 3P - 20 = -18 \Rightarrow z = -\ln 5 \Rightarrow p = \frac{1}{6}.$$

Dix observations correctement classées

$$\ell = -\ln(5/6) = 0,182322.$$

Neville et Vincent

$$\ell = -\ln(1/6) = 1,791759.$$

RÉSULTATS SUR LE GROUPE D'ESTIMATION

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
---------	----------------	----------	------------------	----------	-------------	----------	------------

ID	élève	maison obs.	score	prob.	préd. 0,50	préd. 0,65
E01	Harry	Gryff.	+1,609438	0,833333	Gryff.	Gryff.
E02	Drago	Serp.	−1,609438	0,166667	Serp.	Serp.
E03	Hermione	Gryff.	+1,609438	0,833333	Gryff.	Gryff.
E04	Pansy	Serp.	−1,609438	0,166667	Serp.	Serp.
E05	Ron	Gryff.	+1,609438	0,833333	Gryff.	Gryff.
E06	Blaise	Serp.	−1,609438	0,166667	Serp.	Serp.
E07	Neville	Gryff.	−1,609438	0,166667	Serp.	Serp.
E08	Vincent	Serp.	+1,609438	0,833333	Gryff.	Gryff.
E09	Ginny	Gryff.	+1,609438	0,833333	Gryff.	Gryff.
E10	Gregory	Serp.	−1,609438	0,166667	Serp.	Serp.
E11	Dean	Gryff.	+1,609438	0,833333	Gryff.	Gryff.
E12	Théodore	Serp.	−1,609438	0,166667	Serp.	Serp.

MATRICE DE CONFUSION SUR LE GROUPE D'ESTIMATION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

Gryffondor prédit
Serpentard obs.

Serpentard prédit Gryffondor prédit

VN = 5

FP = 1

FN = 1

VP = 5

$$\text{exactitude} = \frac{5 + 5}{12} = 83,3\%.$$

LE SEUIL DÉPLACE LA FRONTIÈRE SANS RÉESTIMER LE MODÈLE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE


GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

$$p \geq \tau \iff V \geq 3P + 20 + \frac{18}{\ln 5} \operatorname{logit}(\tau).$$



Évaluer le modèle hors échantillon

LES PARAMÈTRES SONT FIGÉS AVANT L'ÉVALUATION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Aucune statistique et aucun coefficient ne sont réestimés avec les huit élèves.

PRÉDICTIONS SUR LE GROUPE D'ÉVALUATION

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
---------	----------------	----------	------------------	----------	-------------	----------	------------

ID	élève	maison obs.	score	prob.	préd. 0,50	préd. 0,65
E13	Seamus	Gryff.	+0,894132	0,709742	Gryff.	Gryff.
E14	Daphné	Serp.	−1,609438	0,166667	Serp.	Serp.
E15	Parvati	Gryff.	+0,804719	0,690983	Gryff.	Gryff.
E16	Millicent	Serp.	−0,536479	0,369007	Serp.	Serp.
E17	Lavande	Gryff.	+0,536479	0,630993	Gryff.	Serp.
E18	Marcus	Serp.	+0,447066	0,609941	Gryff.	Serp.
E19	Colin	Gryff.	+0,804719	0,690983	Gryff.	Gryff.
E20	Adrian	Serp.	−0,357653	0,411528	Serp.	Serp.

Perte moyenne : $J_{\text{eval}} = 0,457133$.

ANALYSE LOCALE AUTOUR DU SEUIL DE DÉCISION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



EFFET DU SEUIL SUR LA MATRICE DE CONFUSION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

$$\tau = 0,50$$

	Serp. prédit	Gryff. prédit
Serp. obs.	3	1
Gryff. obs.	0	4

Marcus est classé à tort.

$$\tau = 0,65$$

	Serp. prédit	Gryff. prédit
Serp. obs.	4	0
Gryff. obs.	1	3

Lavande est alors classée à tort.

L'exactitude reste 7/8; la nature de l'erreur change.

COMPARAISON DES MÉTRIQUES SELON LE SEUIL

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
seuil	exactitude	précision	rappel	spécificité	F1		
0,50	0,8750	0,8000	1,0000	0,7500	0,8889		
0,65	0,8750	1,0000	0,7500	1,0000	0,8571		

À $\tau = 0,50$: précision = 0,8000, rappel = 1,0000, spécificité = 0,7500, $F_1 = 0,8889$.

$$\widehat{\text{acc}} = \frac{7}{8} = 87,5\%.$$

L'intervalle de Wilson à 95% vaut

$$\boxed{[0,529112; 0,977583]} \approx [52,9\%; 97,8\%].$$

Portée de l'étude de cas

Les vingt observations sont synthétiques, équilibrées et choisies pour rendre chaque transformation vérifiable. Elles illustrent une méthode; elles ne mesurent pas la performance attendue sur une population réelle.
