

Régression logistique binaire

Du score linéaire à la décision probabiliste

Sylvain Maitre

Observations disponibles

Pour chaque élève :

- une note de **Potions** sur 20;
 - une note de **Vol** sur 100.
-

Maison observée


Deux maisons sont représentées :

- **Gryffondor**;
 - **Serpentard**.
-


Construire une règle qui associe les deux notes à une maison.

DISTRIBUTION DES NOTES DE POTIONS ET DE VOL

élève	maison	Potions	Vol
Harry	Gryffondor	8	60
Drago	Serpentard	15	29
Hermione	Gryffondor	14	28
Pansy	Serpentard	12	24
Ron	Gryffondor	—	57
Gregory	Serpentard	14	9
Neville	Gryffondor	7	52
Ginny	Gryffondor	6	80
Vincent	Serpentard	12	30
Seamus	Gryffondor	12	60
Dean	Gryffondor	5	67
Marcus	Serpentard	6	65
Colin	Gryffondor	13	30
Angelina	Gryffondor	5	84
Lavande	Gryffondor	4	71
Katie	Gryffondor	9	57
Blaise	Serpentard	17	32
Théodore	Serpentard	16	44
Millicent	Serpentard	10	64
Parvati	Gryffondor	5	57
Fred	Gryffondor	8	85
Olivier	Gryffondor	11	54
George	Gryffondor	6	—
Alicia	Gryffondor	14	45
Daphné	Serpentard	10	41
Adrian	Serpentard	14	40
Graham	Serpentard	16	13
Terence	Serpentard	17	24



CHAÎNE DE CONSTRUCTION DU CLASSIFIEUR



Définir les données et le protocole

SÉPARATION ENTRE ESTIMATION ET ÉVALUATION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Le groupe d'estimation constitue le *jeu d'apprentissage* : lui seul fixe les nombres du modèle.
Le groupe d'évaluation les reçoit sans les modifier.

GROUPE D'ESTIMATION : 20 ÉLÈVES

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
---------	----------------	----------	------------------	----------	-------------	----------	------------

ID	Élève	Maison	Potions	Vol
E01	Harry Potter	Gryffondor	8	60
E02	Drago Malefoy	Serpentard	15	29
E03	Hermione Granger	Gryffondor	14	28
E04	Pansy Parkinson	Serpentard	12	24
E05	Ron Weasley	Gryffondor	—	57
E06	Gregory Goyle	Serpentard	14	9
E07	Neville Londubat	Gryffondor	7	52
E08	GINNY Weasley	Gryffondor	6	80
E09	Vincent Crabbe	Serpentard	12	30
E10	Seamus Finnigan	Gryffondor	12	60
E11	Dean Thomas	Gryffondor	5	67
E12	Marcus Flint	Serpentard	6	65
E13	Colin Crivey	Gryffondor	13	30
E14	Angelina Johnson	Gryffondor	5	84
E15	Lavande Brown	Gryffondor	4	71
E16	Katie Bell	Gryffondor	9	57
E17	Blaise Zabini	Serpentard	17	32
E18	Théodore Nott	Serpentard	16	44
E19	Millicent Bulstrode	Serpentard	10	64
E20	Parvati Patil	Gryffondor	5	57

Une note manque ici même

La note de **Potions** de Ron est absente. Le trou se trouve donc là où sont calculées les statistiques : sa valeur de remplacement participera aux médianes, aux moyennes et aux coefficients.

GROUPE D'ÉVALUATION : HUIT ÉLÈVES

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
---------	----------------	----------	------------------	----------	-------------	----------	------------

ID	Élève	Maison	Potions	Vol
E21	Fred Weasley	Gryffondor	8	85
E22	Olivier Dubois	Gryffondor	11	54
E23	George Weasley	Gryffondor	6	—
E24	Alicia Spinnet	Gryffondor	14	45
E25	Daphné Greengrass	Serpentard	10	41
E26	Adrian Pucey	Serpentard	14	40
E27	Graham Montague	Serpentard	16	13
E28	Terence Higgs	Serpentard	17	24

Une note manque aussi à l'évaluation

La note de **Vol** de George est absente. Une case vide ne peut pas être standardisée : elle doit d'abord recevoir une valeur numérique, et cette valeur vient du groupe d'estimation.

COMPLÉTER, PUIS STANDARDISER UNE NOTE MANQUANTE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

Valeurs de remplacement

$$\tilde{P} = 10, \quad \tilde{V} = 57.$$

Ces médianes ne sont lues que sur les notes *observées* du groupe d'estimation, jamais sur le groupe d'évaluation.

Deux substitutions

$$P_{\text{Ron}} \leftarrow 10 \implies x_{\text{pot}} = 0,$$

$$V_{\text{George}} \leftarrow 57 \implies x_{\text{vol}} = 0,35.$$

En **Potions** la médiane égale la moyenne; en **Vol** elle vaut 57 contre une moyenne de 50.

note manquante

médiane
de la matière

valeur
numérique v

$x = (v - \mu)/s$
note standardisée

DEUX MATIÈRES, DEUX ÉCHELLES DE MESURE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Un point représente 5% de l'échelle en **Potions**, contre 1% en **Vol**.

Les paramètres de standardisation sont calculés sur le groupe d'estimation, puis conservés :

Potions

$$\mu_{\text{pot}} = 10, \quad s_{\text{pot}} = 4,$$

$$x_{\text{pot}} = \frac{P - 10}{4}.$$

Vol

$$\mu_{\text{vol}} = 50, \quad s_{\text{vol}} = 20,$$

$$x_{\text{vol}} = \frac{V - 50}{20}.$$

Pour Harry : $x_{\text{pot}} = -0,50$ et $x_{\text{vol}} = +0,50$. Les deux coordonnées sont désormais sans unité.

La covariance d'estimation vaut -64 , soit une corrélation de $-\frac{4}{5}$: les deux notes varient en sens opposé.

EFFET GÉOMÉTRIQUE DE LA STANDARDISATION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE



PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Le centrage-réduction change les unités, pas l'identité des élèves ni leur maison.

Construire le score linéaire

DÉFINITION DU SCORE LINÉAIRE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

$$z_i = w_0 + w_{\text{pot}}x_{i,\text{pot}} + w_{\text{vol}}x_{i,\text{vol}}$$

Coefficients

Le signe indique le sens de l'association; la valeur absolue en mesure l'intensité sur l'échelle standardisée.

État du modèle

Les coefficients sont encore inconnus. Leur estimation viendra après la définition de la perte et du gradient.

CONTRIBUTIONS DES DEUX MATIÈRES AU SCORE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

Prenons provisoirement $w^{\text{essai}} = (0, -2, +1)$, donc $z = x_{\text{vol}} - 2x_{\text{pot}}$.

élève	x_{pot}	x_{vol}	$-2x_{\text{pot}}$	$+x_{\text{vol}}$	z	p	ℓ
Harry	-0,50	+0,50	+1,00	+0,50	+1,50	0,818	0,201
Drago	+1,25	-1,05	-2,50	-1,05	-3,55	0,028	0,028
Hermione	+1,00	-1,10	-2,00	-1,10	-3,10	0,043	3,144
Marcus	-1,00	+0,75	+2,00	+0,75	+2,75	0,940	2,812
Neville	-0,75	+0,10	+1,50	+0,10	+1,60	0,832	0,184

Le score agrège les contributions; il ne constitue encore ni une probabilité ni une classe prédite.

LE NIVEAU DE SCORE NUL DÉFINIT UNE DROITE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Une droite, deux demi-plans

L'ensemble $z = 0$ est une droite du plan des notes; elle le partage en deux demi-plans où le score est de signe constant.

Après estimation des coefficients, son équation sera

$$V = 10,0120 P - 73,6071.$$

Pour les 20 observations du groupe d'estimation :

$$X = \begin{pmatrix} 1 & x_{1,\text{pot}} & x_{1,\text{vol}} \\ \vdots & \vdots & \vdots \\ 1 & x_{20,\text{pot}} & x_{20,\text{vol}} \end{pmatrix}, \quad w = \begin{pmatrix} w_0 \\ w_{\text{pot}} \\ w_{\text{vol}} \end{pmatrix}.$$

$$z = Xw$$

Une même multiplication produit les 20 scores; chaque ligne de X correspond à un élève.

Transformer le score en probabilité

LA SIGMOÏDE ASSOCIE UNE PROBABILITÉ À TOUT SCORE RÉEL

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



$$p_i = \sigma(z_i) = \frac{1}{1 + e^{-z_i}}$$

PROPRIÉTÉS DE LA FONCTION LOGISTIQUE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

Monotonie

$$z_1 < z_2 \Rightarrow \sigma(z_1) < \sigma(z_2).$$

Point central

$$\sigma(0) = \frac{1}{2}.$$

Symétrie

$$\sigma(-z) = 1 - \sigma(z).$$

La sigmoïde conserve l'ordre des scores et les transforme en valeurs strictement comprises entre 0 et 1.

LE LOGIT EST L'INVERSE DE LA SIGMOÏDE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

Du score à la probabilité

$$\frac{p}{1-p} = e^z, \quad p = \frac{e^z}{1+e^z}.$$

De la probabilité au score

$$\text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = z.$$

z	−2	−1	0	1	2
p	0,119	0,269	1/2	0,731	0,881

PROBABILITÉS ASSOCIÉES AUX SCORES D'ESSAI

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
élève	maison observée	z d'essai	$p = \sigma(z)$	maison favorisée			
Harry	Gryffondor	+1,50	0,818	Gryffondor			
Drago	Serpentard	-3,55	0,028	Serpentard			
Hermione	Gryffondor	-3,10	0,043	Serpentard ●			
Marcus	Serpentard	+2,75	0,940	Gryffondor ●			
Neville	Gryffondor	+1,60	0,832	Gryffondor			

La sigmoïde étant strictement croissante, deux observations de même score reçoivent la même probabilité selon le modèle. Les lignes marquées ● sont celles pour lesquelles la maison favorisée contredit la maison observée.

Définir la perte logistique

$$y_i = \begin{cases} 1 & \text{si l'élève appartient à Gryffondor,} \\ 0 & \text{si l'élève appartient à Serpentard.} \end{cases}$$

Ce codage n'était nécessaire ni pour calculer le score z_i , ni pour le transformer en probabilité p_i . Il devient nécessaire pour comparer la sortie du modèle à la maison observée.

$$\ell(z, y) = -y \ln p - (1 - y) \ln(1 - p)$$

Maison observée : Gryffondor

$$y = 1, \quad \ell = -\ln p = \ln(1 + e^{-z}).$$

La perte décroît lorsque le score augmente.

Maison observée : Serpentard

$$y = 0, \quad \ell = -\ln(1 - p) = \ln(1 + e^z).$$

La perte décroît lorsque le score diminue.

COMPORTEMENT DE LA PERTE SELON LA MAISON OBSERVÉE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



$$\ell(z, y) = \text{softplus}(z) - yz.$$

Avec les coefficients d'essai, le signe du score concorde avec la maison observée pour 15 élèves et s'y oppose pour 5 :

$$J = \frac{1}{20} \sum_{i=1}^{20} \ell(z_i, y_i) = 0,617793.$$

Signe concordant

Harry : $z = +1,50$, $y = 1$, perte 0,201.

Signe discordant

Hermione : $z = -3,10$, $y = 1$, perte 3,144, soit un rapport de 16.

Les observations situées dans l'agrégat de la maison opposée interdisent toute séparation linéaire parfaite et concentrent l'essentiel de la perte.

Calculer le gradient

$$\frac{\partial \ell_i}{\partial z_i} = p_i - y_i.$$

Comme $z_i = w_0 + w_{\text{pot}}x_{i,\text{pot}} + w_{\text{vol}}x_{i,\text{vol}}$,

$$\nabla J(w) = \frac{1}{n} \sum_{i=1}^n (p_i - y_i) \begin{pmatrix} 1 \\ x_{i,\text{pot}} \\ x_{i,\text{vol}} \end{pmatrix} = \frac{1}{n} X^\top (p - y).$$

GRADIENT AU POINT D'INITIALISATION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

$$w^{(0)} = (0, 0, 0) \implies z_i = 0, \quad p_i = \frac{1}{2}.$$

Les 20 observations donnent exactement

$$\sum_i (p_i - y_i) = -2,0000, \quad \sum_i (p_i - y_i) x_{i,\text{pot}} = +5,5000, \quad \sum_i (p_i - y_i) x_{i,\text{vol}} = -5,1500.$$

Donc

$$\nabla J(w^{(0)}) = (-0,100000; +0,275000; -0,257500).$$

La première composante est non nulle : les maisons ne sont pas également représentées, l'ordonnée à l'origine bouge dès le premier pas.

CONTRIBUTION DE CINQ OBSERVATIONS AU GRADIENT

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
---------	----------------	----------	------------------	----------	-------------	----------	------------

élève	y	$p - y$ à $w = 0$	x_{pot}	$(p - y)x_{\text{pot}}$	$(p - y)x_{\text{vol}}$
Harry	1	-0,5	-0,50	+0,250	-0,250
Drago	0	+0,5	+1,25	+0,625	-0,525
Hermione	1	-0,5	+1,00	-0,500	+0,550
Marcus	0	+0,5	-1,00	-0,500	+0,375
Neville	1	-0,5	-0,75	+0,375	-0,050

Les contributions sont additionnées avant la division par $n = 20$.

$$z = Xw,$$

$$p = \sigma(z),$$

$$r = p - y,$$

$$\nabla J(w) = \frac{1}{20} X^\top r.$$

Dimensions

$$X \in \mathbb{R}^{20 \times 3}, w \in \mathbb{R}^3, p, y, r \in \mathbb{R}^{20} \text{ et } \nabla J(w) \in \mathbb{R}^3.$$

VÉRIFICATION DU GRADIENT PAR DIFFÉRENCE FINIE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

$$\frac{\partial J}{\partial w_j} \approx \frac{J(w + he_j) - J(w - he_j)}{2h}, \quad h = 10^{-5}.$$

composante j	gradient analytique	différence finie	écart
0	-0,054724771	-0,054724771	0,00000000000
1	+0,124493338	+0,124493338	0,00000000000
2	-0,111803507	-0,111803507	0,00000000000

Écart maximal : 0,00000000000.

Estimer les coefficients

$$w^{(t+1)} = w^{(t)} - \alpha \nabla J(w^{(t)}), \quad \alpha = 1.$$

À partir de $w^{(0)} = (0, 0, 0)$:

$$\begin{aligned} w^{(1)} &= (0, 0, 0) - (-0,100000; +0,275000; -0,257500) \\ &= \boxed{(+0,100000; -0,275000; +0,257500)}. \end{aligned}$$

La perte moyenne passe de 0,693147 à 0,573791 : une itération réduit le coût sans encore fixer de règle de décision.

CONVERGENCE DE LA DESCENTE DE GRADIENT

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
---------	----------------	----------	------------------	----------	-------------	----------	------------

itération	J	w_0	w_{pot}	w_{vol}	$\ \nabla J\ $
0	0,693147	+0,000000	+0,000000	+0,000000	0,389784
1	0,573791	+0,100000	-0,275000	+0,257500	0,226364
2	0,531952	+0,176332	-0,433705	+0,399721	0,145894
5	0,499775	+0,331248	-0,655142	+0,577057	0,058724
10	0,491770	+0,469108	-0,785845	+0,643876	0,022873
20	0,489764	+0,567160	-0,880651	+0,634754	0,007756
50	0,489160	+0,600309	-0,978382	+0,561283	0,002314
100	0,489082	+0,603157	-1,019962	+0,522817	$4,268 \times 10^{-4}$
200	0,489080	+0,603719	-1,029091	+0,514394	$1,468 \times 10^{-5}$
400	0,489080	+0,603740	-1,029417	+0,514094	$1,742 \times 10^{-8}$
690	0,489080	+0,603740	-1,029417	+0,514094	$9,967 \times 10^{-13}$

Le critère $\|\nabla J\| \leq 10^{-12}$ est atteint à l'itération 690.

L'optimum n'admet pas de forme close : il est caractérisé par l'annulation du gradient. Les résidus $p_i - y_i$ y sont de somme nulle et orthogonaux aux deux notes.

colonne de X	condition	valeur atteinte
1	$\sum_i (p_i - y_i) 1$	$2,776 \times 10^{-17}$
x_{pot}	$\sum_i (p_i - y_i) x_{\text{pot}}$	$7,494 \times 10^{-16}$
x_{vol}	$\sum_i (p_i - y_i) x_{\text{vol}}$	$5,516 \times 10^{-16}$

Unicité de l'optimum

Newton–Raphson converge en une dizaine d'itérations, la descente de gradient à pas constant en 690. Les deux méthodes atteignent le même vecteur : la perte logistique est strictement convexe sous recouvrement des deux maisons.

PARAMÈTRES STANDARDISÉS ET PARAMÈTRES BRUTS

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

Variables standardisées

$$(w_0, w_{\text{pot}}, w_{\text{vol}}) = (+0,603740; -1,029417; +0,514094)$$

Le coefficient de **Potions** vaut deux fois celui de **Vol** : un écart-type de **Potions** déplace le score deux fois plus qu'un écart-type de **Vol**.

Notes brutes

$$(b, \beta_{\text{pot}}, \beta_{\text{vol}}) = (+1,892048; -0,257354; +0,025705)$$

Le rapport s'inverse sur les notes brutes : un point de **Potions** équivaut à dix points de **Vol**, les deux échelles n'étant pas commensurables.

$$z = +1,892048 - 0,257354 P + 0,025705 V$$

L'ordonnée à l'origine n'est pas nulle et les deux poids n'ont pas la même intensité : la frontière ne passe ni par le barycentre ni le long d'une bissectrice. $J(w^*) = 0,489080$.

LE RECOUVREMENT REND L'OPTIMUM FINI

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Hermione, Marcus, Colin, Millicent se situent du côté opposé à leur maison. En l'absence de ces 4 observations les deux agrégats seraient linéairement séparables : la perte décroîtrait vers zéro lorsque t croît, les coefficients divergeraient et l'optimum ne serait pas atteint.

FRONTIÈRE DU MODÈLE AJUSTÉ

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Observations mal classées

Hermione, Marcus, Colin, Millicent.

$$V = 10,0120 P - 73,6071$$

Le modèle ajusté affecte ces 4 observations à la maison opposée.

Définir la règle de décision

$$\hat{y}_i = \mathbf{1}[p_i \geq \tau].$$

$$p_i < \tau$$

Maison prédite : **Serpentard**.

$$p_i \geq \tau$$

Maison prédite : **Gryffondor**.

Le seuil agit après l'estimation : le modifier ne recalcule ni la standardisation, ni les coefficients.

DISTRIBUTION DE LA PERTE SUR LE GROUPE D'ESTIMATION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

$$\ell_i = -\ln p_i \text{ si Gryffondor,} \quad \ell_i = -\ln(1 - p_i) \text{ si Serpentard.}$$

Au centre de son agrégat

Angelina : $p = 0,9407$, perte 0,0611.

Au voisinage de la frontière

Seamus : $p = 0,5857$, perte 0,5350.

Dans l'agrégat opposé

Marcus : $p = 0,8827$, perte 2,1434.

La perte moyenne $J(w^*) = 0,489080$ est concentrée sur un petit nombre d'observations : elle mesure le coût du recouvrement.

RÉSULTATS SUR LE GROUPE D'ESTIMATION

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
ID	élève	maison obs.	score	prob.	préd. 0,50	préd. 0,65	
E01	Harry	Gryff.	+1,375495	0,798267	Gryff.	Gryff.	
E02	Drago	Serp.	−1,222830	0,227439	Serp.	Serp.	
E03	Hermione	Gryff.	−0,991181	0,270679	Serp.	Serp.	
E04	Pansy	Serp.	−0,579291	0,359096	Serp.	Serp.	
E05	Ron	Gryff.	+0,783672	0,686471	Gryff.	Gryff.	
E06	Gregory	Serp.	−1,479570	0,185492	Serp.	Serp.	
E07	Neville	Gryff.	+1,427212	0,806467	Gryff.	Gryff.	
E08	Ginny	Gryff.	+2,404297	0,917154	Gryff.	Gryff.	
E09	Vincent	Serp.	−0,425063	0,395306	Serp.	Serp.	
E10	Seamus	Gryff.	+0,346078	0,585666	Gryff.	Serp.	
E11	Dean	Gryff.	+2,327491	0,911128	Gryff.	Gryff.	
E12	Marcus	Serp.	+2,018727	0,882749	Gryff.	Gryff.	
E13	Colin	Gryff.	−0,682417	0,335722	Serp.	Serp.	
E14	Angelina	Gryff.	+2,764470	0,940725	Gryff.	Gryff.	
E15	Lavande	Gryff.	+2,687664	0,936295	Gryff.	Gryff.	
E16	Katie	Gryff.	+1,041027	0,739048	Gryff.	Gryff.	
E17	Blaise	Serp.	−1,660425	0,159705	Serp.	Serp.	
E18	Théodore	Serp.	−1,094614	0,250750	Serp.	Serp.	
E19	Millicent	Serp.	+0,963605	0,723843	Gryff.	Gryff.	
E20	Parvati	Gryff.	+2,070444	0,887997	Gryff.	Gryff.	

MATRICE DE CONFUSION SUR LE GROUPE D'ESTIMATION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

	Serpentard prédit	Gryffondor prédit
Serpentard observé	VN = 6	FP = 2
Gryffondor observé	FN = 2	VP = 10

$$\text{exactitude} = \frac{10 + 6}{20} = 0,8000,$$

$$\text{prédire toujours Gryffondor} = \frac{12}{20} = 0,6000.$$

LE SEUIL DÉPLACE LA FRONTIÈRE SANS RÉESTIMER LE MODÈLE

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Translation, pas rotation

$$b + \beta_{\text{pot}}P + \beta_{\text{vol}}V \geq \text{logit}(\tau)$$

Pente inchangée, ordonnée à l'origine relevée de 24,083 points de **Vol** : relever le seuil à 0,65 revient à exiger un **Vol** supérieur à niveau de **Potions** constant.

Évaluer le modèle hors échantillon

LES PARAMÈTRES SONT FIGÉS AVANT L'ÉVALUATION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Aucune statistique et aucun coefficient ne sont réestimés avec les huit élèves.

PRÉDICTIONS SUR LE GROUPE D'ÉVALUATION

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
---------	----------------	----------	------------------	----------	-------------	----------	------------

ID	élève	maison obs.	score	prob.	préd. 0,50	préd. 0,65
E21	Fred	Gryff.	+2,018112	0,882686	Gryff.	Gryff.
E22	Olivier	Gryff.	+0,449204	0,610450	Gryff.	Serp.
E23	George	Gryff.	+1,813090	0,859735	Gryff.	Gryff.
E24	Alicia	Gryff.	−0,554201	0,364890	Serp.	Serp.
E25	Daphné	Serp.	+0,372397	0,592038	Gryff.	Serp.
E26	Adrian	Serp.	−0,682724	0,335654	Serp.	Serp.
E27	Graham	Serp.	−1,891459	0,131078	Serp.	Serp.
E28	Terence	Serp.	−1,866062	0,133998	Serp.	Serp.

Perte moyenne : $J_{\text{eval}} = 0,420942$.

ANALYSE LOCALE AUTOUR DU SEUIL DE DÉCISION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE


PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION



Entre les deux droites

Olivier : $p = 0,610450$.

Daphné : $p = 0,592038$.

Seules ces deux observations changent de classe prédite lors du passage de $\tau = 0,50$ à $\tau = 0,65$.

EFFET DU SEUIL SUR LA MATRICE DE CONFUSION

DONNÉES

SCORE LINÉAIRE

SIGMOÏDE

PERTE LOGISTIQUE

GRADIENT

MISE À JOUR

DÉCISION

ÉVALUATION

$$\tau = 0,50$$

	Serp. prédit	Gryff. prédit
Serp. obs.	3	1
Gryff. obs.	1	3

Daphné est un faux positif, Alicia un faux négatif.

$$\tau = 0,65$$

	Serp. prédit	Gryff. prédit
Serp. obs.	4	0
Gryff. obs.	2	2

Plus aucun faux positif; Olivier devient un faux négatif.

L'exactitude reste 6/8; la nature de l'erreur change. Le seuil élevé achète de la précision (1,0000) au prix du rappel (0,5000).

COMPARAISON DES MÉTRIQUES SELON LE SEUIL

DONNÉES	SCORE LINÉAIRE	SIGMOÏDE	PERTE LOGISTIQUE	GRADIENT	MISE À JOUR	DÉCISION	ÉVALUATION
seuil	exactitude	précision	rappel	spécificité	F1		
0,50	0,7500	0,7500	0,7500	0,7500	0,7500	0,7500	
0,65	0,7500	1,0000	0,5000	1,0000	0,6667		

À $\tau = 0,50$: précision = 0,7500, rappel = 0,7500, spécificité = 0,7500, $F_1 = 0,7500$.

$$\widehat{\text{acc}} = \frac{6}{8} = 0,7500.$$

L'intervalle de Wilson à 95% vaut

$$[0,409275 ; 0,928521].$$

Portée de l'étude de cas

Les 28 observations sont synthétiques et choisies pour rendre chaque transformation vérifiable à la main. Elles illustrent une méthode; elles ne mesurent pas la performance attendue sur une population réelle.
