Statistiques descriptives

1. Cadres de travail

On distingue deux présentations usuelles d'une série statistique quantitative.

1.1 Données simples

Chaque observation est écrite individuellement.

Observation	Valeur
1	8
2	10
3	12
4	15

1.2 Données avec effectifs

Plutôt que de répéter chaque observation, on regroupe les valeurs identiques : chaque valeur distincte est listée une seule fois avec son nombre d'occurrences, appelé **effectif**.

Valeur	Effectif
8	2
10	3
12	4
15	1

Ce tableau est équivalent à la série : 8, 8, 10, 10, 10, 12, 12, 12, 12, 15 (10 observations au total).

---

2. Effectif et notations

Notations utilisées dans tout le document

Symbole	Signification
n	nombre total d'observations (données simples)
k	nombre de **valeurs distinctes** (données avec effectifs)
x_i	la i-ème valeur distincte, i allant de 1 à k (valeurs triées par ordre croissant)
n_i	effectif de x_i : combien de fois x_i apparaît dans la série
N	effectif total (données avec effectifs) : $N = \sum_{i=1}^{k} n_i$
C_i	effectif **cumulé** jusqu'à x_i : $C_i = \sum_{j=1}^{i} n_j$ (combien d'observations ont une valeur $\leq x_i$)

Effectif total

- **Données simples** : l'effectif est directement n, le nombre de valeurs dans la liste.
- **Données avec effectifs** : $N = n_1 + n_2 + \cdots + n_k$ (somme de tous les effectifs par valeur).

Exemple avec le tableau de la section 1.2 ($k = 4$ valeurs distinctes) :

$$N = n_1 + n_2 + n_3 + n_4 = 2 + 3 + 4 + 1 = 10$$

i	x_i (valeur)	n_i (effectif)	C_i (cumulé)
1	8	2	2
2	10	3	5
3	12	4	9
4	15	1	10

---

3. Minimum et maximum

Après classement dans l'ordre croissant :

- le **minimum** est la plus petite valeur observée ;
- le **maximum** est la plus grande valeur observée.

3.1 Données simples

On trie la série puis on lit directement les extrêmes.

Exemple — série brute : 10, 5, 15, 8, 12 ($n = 5$)

Série triée :

Rang	Valeur
1	**5** ← minimum
2	8
3	10
4	12
5	**15** ← maximum

$$\min = 5 \qquad \max = 15$$

3.2 Données avec effectifs

Le minimum est la première valeur du tableau (ligne $i = 1$, celle avec le plus petit x_i) et le maximum est la dernière ($i = k$), à condition que leur effectif soit non nul — ce qui est toujours le cas si le tableau est propre.

Exemple — tableau standard ($k = 5$, $N = 12$)

i	Valeur x_i	Effectif n_i
1	**5** ← minimum	1
2	8	2
3	10	3
4	12	4
5	**15** ← maximum	2

$$\min = 5 \qquad \max = 15$$

---

4. Médiane

La médiane est une valeur centrale de la série ordonnée.

4.1 Données simples

Soit une série ordonnée

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}$$

- si n est impair, la médiane est la valeur de rang $\dfrac{n+1}{2}$
- si n est pair, la médiane est la moyenne des deux valeurs centrales

$$\text{médiane} = \frac{x_{(n/2)} + x_{(n/2+1)}}{2}$$

Exemple — cas impair : série ordonnée 5, 8, 10, 12, 15 ($n = 5$)

Rang central : $\dfrac{5+1}{2} = 3$

Rang	Valeur	Note
1	5	
2	8	
3	10	← **rang central 3**
4	12	
5	15	

$$\text{médiane} = 10$$

Exemple — cas pair : série ordonnée 5, 8, 10, 12 ($n = 4$)

Rangs centraux : $\dfrac{4}{2} = 2$ et $\dfrac{4}{2} + 1 = 3$

Rang	Valeur	Note
1	5	
2	8	← **rang central 1**
3	10	← **rang central 2**
4	12	

$$\text{médiane} = \frac{8+10}{2} = 9$$

4.2 Données avec effectifs

Principe : le cumulé C_i indique combien d'observations ont une valeur $\leq x_i$. La valeur x_i "occupe" donc les rangs de $C_{i-1} + 1$ à C_i dans la série complète reconstituée. On cherche quelle(s) valeur(s) se trouvent aux rangs centraux.

Rangs centraux à trouver :

- N impair → un seul rang central : $\dfrac{N+1}{2}$
- N pair → deux rangs centraux : $\dfrac{N}{2}$ et $\dfrac{N}{2} + 1$

Si les deux rangs tombent sur la **même** valeur → c'est la médiane. Sinon → moyenne des deux valeurs.

Exemple — $N = 12$ (pair), rangs centraux : 6 et 7

Tableau compact (une ligne par valeur distincte) :

i	Valeur x_i	Effectif n_i	Cumulé C_i	Plage de rangs occupés
1	5	1	1	rang 1

i	Valeur x_i	Effectif n_i	Cumulé C_i	Plage de rangs occupés
2	8	2	3	rangs 2 – 3
3	10	3	6	rangs 4 – 6
4	12	4	10	rangs 7 – 10
5	15	2	12	rangs 11 – 12

Tableau déroulé (une ligne par observation, série complète reconstituée) :

Rang	Valeur	Note
1	5	
2	8	
3	8	
4	10	
5	10	
6	10	← **rang central 1** ($N/2 = 6$) → valeur **10**
7	12	← **rang central 2** ($N/2 + 1 = 7$) → valeur **12**
8	12	
9	12	
10	12	
11	15	
12	15	

Deux valeurs distinctes aux rangs centraux :

$$\text{médiane} = \frac{10 + 12}{2} = 11$$

---

5. Quartiles

Les quartiles sont définis sur la série ordonnée.

- Q_1 est une valeur telle qu'au moins 25 % des observations lui sont inférieures ou égales.
- Q_3 est une valeur telle qu'au moins 75 % des observations lui sont inférieures ou égales.

5.1 Données simples

On adopte la convention usuelle suivante :

$$Q_1 = x_{(\lceil n/4 \rceil)} \qquad \text{et} \qquad Q_3 = x_{(\lceil 3n/4 \rceil)}$$

où $\lceil \cdot \rceil$ désigne l'arrondi à l'entier supérieur.

Ainsi, lorsque $n/4$ ou $3n/4$ n'est pas entier, on retient le premier rang entier supérieur.

Exemple — série ordonnée : 3, 7, 8, 12, 14, 18, 21, 25 ($n = 8$)

Rangs-seuils : $Q_1 \to \lceil 8/4 \rceil = \mathbf{2}$ et $Q_3 \to \lceil 3 \times 8/4 \rceil = 6$

Rang	Valeur	Note
1	3	
2	7	← **rang-seuil** $Q_1 = 2$ → $Q_1 = \mathbf{7}$
3	8	
4	12	
5	14	
6	18	← **rang-seuil** $Q_3 = 6$ → $Q_3 = \mathbf{18}$
7	21	
8	25	

5.2 Données avec effectifs

Même principe qu'en 4.2 : on reconstitue la série complète via les plages de rangs, puis on lit la valeur au rang-seuil.

Rangs-seuils à trouver :

- Q_1 → rang-seuil $= \lceil N/4 \rceil$
- Q_3 → rang-seuil $= \lceil 3N/4 \rceil$

La valeur cherchée est celle dont la plage de rangs **contient** le rang-seuil.

Exemple — même série, $N = 12$

Rangs-seuils : $Q_1 \to \lceil 12/4 \rceil = \mathbf{3}$ et $Q_3 \to \lceil 3 \times 12/4 \rceil = 9$

Tableau compact :

i	Valeur x_i	Effectif n_i	Cumulé C_i	Plage de rangs occupés
1	5	1	1	rang 1
2	8	2	3	rangs 2 – 3
3	10	3	6	rangs 4 – 6
4	12	4	10	rangs 7 – 10
5	15	2	12	rangs 11 – 12

Tableau déroulé :

Rang	Valeur	Note
1	5	
2	8	
3	8	← **rang-seuil** $Q_1 = 3$ → $Q_1 = \mathbf{8}$
4	10	
5	10	
6	10	
7	12	
8	12	
9	12	← **rang-seuil** $Q_3 = 9$ → $Q_3 = \mathbf{12}$
10	12	
11	15	
12	15	

5.3 Cas de faible effectif

Lorsque la série contient très peu de valeurs, les quartiles existent encore dès lors que la série n'est pas vide, mais leur interprétation est naturellement limitée.

---

6. Moyenne

6.1 Données simples

$\bar{x}$ désigne la moyenne, x_i la i-ème valeur de la série, n le nombre total de valeurs.

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

Exemple — série 5, 8, 10, 12, 15 ($n = 5$)

$$\bar{x} = \frac{5 + 8 + 10 + 12 + 15}{5} = \frac{50}{5} = 10$$

6.2 Données avec effectifs

Chaque valeur x_i est **pondérée** par son effectif n_i : une valeur qui apparaît 3 fois contribue 3 fois dans la somme.

$$\bar{x} = \frac{1}{N}\sum_{i=1}^{k} n_i x_i = \frac{n_1x_1 + n_2x_2 + \cdots + n_kx_k}{N}$$

Exemple — tableau standard ($N = 12$)

i	x_i	n_i	$n_i \times x_i$
1	5	1	5
2	8	2	16
3	10	3	30
4	12	4	48
5	15	2	30
Total		**12**	**129**

$$\bar{x} = \frac{129}{12} = 10{,}75$$

---

7. Écart type

L'écart type mesure la dispersion des valeurs autour de la moyenne.

7.1 Population complète

Données simples

σ est l'écart type, $\bar{x}$ la moyenne, $(x_i - \bar{x})^2$ le carré de l'écart de chaque valeur à la moyenne.

$$\sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Exemple — série 5, 8, 10, 12, 15 ($n = 5$, $\bar{x} = 10$)

i	x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
1	5	−5	25
2	8	−2	4
3	10	0	0
4	12	+2	4
5	15	+5	25
Somme			**58**

$$\sigma = \sqrt{\frac{58}{5}} = \sqrt{11{,}6} \approx 3{,}41$$

Données avec effectifs

Chaque carré d'écart est pondéré par l'effectif n_i de la valeur correspondante.

$$\sigma = \sqrt{\frac{1}{N}\sum_{i=1}^{k} n_i (x_i - \bar{x})^2}$$

Exemple — tableau standard ($N = 12$, $\bar{x} = 10{,}75$)

i	x_i	n_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$n_i(x_i - \bar{x})^2$
1	5	1	−5,75	33,0625	33,0625
2	8	2	−2,75	7,5625	15,1250
3	10	3	−0,75	0,5625	1,6875
4	12	4	+1,25	1,5625	6,2500
5	15	2	+4,25	18,0625	36,1250
Total		**12**			**92,25**

$$\sigma = \sqrt{\frac{92{,}25}{12}} = \sqrt{7{,}6875} \approx 2{,}77$$

7.2 Échantillon

Lorsqu'on travaille sur un échantillon et non sur une population complète, on emploie la correction de Bessel.

Données simples

Seule différence avec σ : on divise par $n - 1$ au lieu de n (correction de Bessel). Les carrés d'écarts sont les mêmes.

$$s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n} (x_i - \bar{x})^2}$$

Exemple — mêmes valeurs que 7.1 (somme des carrés $= 58$, $n = 5$)

$$s = \sqrt{\frac{58}{5-1}} = \sqrt{\frac{58}{4}} = \sqrt{14{,}5} \approx 3{,}81$$

Données avec effectifs

Même principe : diviseur $N - 1$ au lieu de N.

$$s = \sqrt{\frac{1}{N-1}\sum_{i=1}^{k} n_i (x_i - \bar{x})^2}$$

Exemple — mêmes valeurs que 7.1 (somme pondérée $= 92{,}25$, $N = 12$)

$$s = \sqrt{\frac{92{,}25}{12-1}} = \sqrt{\frac{92{,}25}{11}} = \sqrt{8{,}386} \approx 2{,}90$$

---

8. Récapitulatif

Indicateur	Données simples	Données avec effectifs
Effectif	nombre de valeurs	somme des effectifs
Minimum	plus petite valeur	plus petite valeur d'effectif non nul
Maximum	plus grande valeur	plus grande valeur d'effectif non nul
Médiane	valeur centrale ou moyenne des deux valeurs centrales	lecture à partir des effectifs cumulés
Premier quartile	rang $\lceil n/4 \rceil$	premier cumulé $\geq N/4$
Troisième quartile	rang $\lceil 3n/4 \rceil$	premier cumulé $\geq 3N/4$
Moyenne	moyenne arithmétique	moyenne pondérée
Écart type	formule usuelle	formule pondérée